

Regressione

Algoritmi per l'intelligenza artificiale

Vincenzo Bonnici

Corso di Laurea Magistrale in Scienze Informatiche

Dipartimento di Scienze Matematiche, Fisiche e Informatiche

Università degli Studi di Parma

2026-2027

Nei problemi di **classificazione** supervisionata ad ogni pattern x_i del training set é associata un'etichetta y_i (classe di appartenenza) Obiettivo del training é l'apprendimento di un **mapping** dallo spazio dei pattern a quello (**discreto**) delle etichette.

Nella **regressione** i valori y_i sono numerici e **continui** (in $\mathbb{R}$) e l'obiettivo del training è l'**apprendimento di una funzione** $f(x) \mapsto y$.

- f è controllata da un insieme di **parametri**. Se la dipendenza dai parametri è lineare (es assenza di elevazioni a potenza dei parametri nella definizione di f) la regressione si definisce **lineare**
- Nella regressione x è detta variabile **indipendente** e y variabile **dipendente**.
- Si assume che la variabile **indipendente** sia **esatta** mentre la variabile **dipendente** sia affetta da **errore** (es imprecisione di misura)

Se la variabile indipendente è uno scalare x (i.e. una sola variabile indipendente), parliamo di **simple linear regression** (retta di regressione).

Dato un training set TS contenente n dati $(x_1, y_1) \dots (x_n, y_n)$ e la seguente dipendenza tra variabile indipendente e dipendente

$$y_i = \alpha + \beta \cdot x_i + \varepsilon_i$$

dove:

- ε_i è l'errore di misura (incognito) del punto x_i
- α, β sono parametri da determinare


Regressione lineare semplice

La soluzione ai **minimi quadrati** (**Least Square**) del problema consiste nel determinare l'equazione della retta

$$f(x) = y = \alpha + \beta \cdot x$$

che minimizza la somma dei quadrati dei residui

$$\alpha^*, \beta^* = \operatorname{argmin}_{\alpha, \beta} \sum_{i=1 \dots n} (f(x_i) - y_i)^2 = \operatorname{argmin}_{\alpha, \beta} \sum_{i=1 \dots n} \varepsilon_i^2$$



Il precedente problema di minimizzazione può essere facilmente risolto uguagliando a zero le derivate parziali della funzione obiettivo rispetto ai parametri α, β ottenendo le cosiddette equazioni normali.

Risolvendo il sistema (due equazioni in due incognite) si ottiene:


$$\beta^* = \frac{\sum_{i=1\dots n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1\dots n}(x_i - \bar{x})^2}$$

$$\alpha^* = \bar{y} - \beta^* \bar{x}$$

dove $\bar{x}$ e $\bar{y}$ sono la media degli x_i e y_i rispettivamente.

Necessari almeno due punti x_i altrimenti il denominatore si annulla.


Regressione lineare semplice



Peso	Altezza
72	173
54	159
65	172
58	170
62	165
72	176
60	173
64	179
55	166
46	158
52	158
47	160
55	167
54	166
55	164
49	157
51	165
51	162

Regressione lineare multipla

Se la variabile indipendente è un vettore $\mathbf{x}$ (i.e. più variabili indipendenti), parliamo di **multiple linear regression** (esempio iperpiano di regressione).



Regressione lineare multipla

Generalizziamo a iperpiani ($\mathbf{x} \in \mathbb{R}^d$).

Per semplicità di trattazione sia X la matrice rettangolare ($n \times (d + 1)$) ottenuta inserendo sulle righe gli n punti del TS, e avendo cura di inserire a destra una colonna con tutti valori 1

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1d} & 1 \\ x_{21} & \cdots & x_{2d} & 1 \\ \vdots & \ddots & \vdots & \vdots \\ x_{n1} & \cdots & x_{nd} & 1 \end{bmatrix}$$

e siano

$$\begin{array}{c} \text{uno scalare per} \\ \text{ogni pattern} \end{array} \rightarrow \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \text{e} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_{d+1} \end{bmatrix} \leftarrow \begin{array}{c} \text{termine noto} \end{array}$$

i vettori costruiti a partire dai valori della variabile indipendente (uno per ogni pattern) e dai $d + 1$ parametri da determinare.

Regressione lineare multipla

Le relazioni tra variabili indipendenti e dipendente possono essere scritte attraverso le equazioni

$$y_i = \sum_{j=1 \dots d+1} x_{ij} \cdot \beta_j \quad \text{per } i = 1 \dots n$$

.....



indici i, j riferiti alla matrice $\mathbf{X}$

o in forma matriciale come

$$\mathbf{y} = \mathbf{X}\beta$$

per $n > (d + 1)$, $\mathbf{X}$ è rettangolare, quindi ho un sistema di equazioni sovradeterminato.

In formato matriciale la funzione obiettivo da minimizzare Least Square può essere scritta come

$$\|\mathbf{y} - \mathbf{X}\beta\|^2$$

Regressione lineare multipla: equazioni normali

Uguagliando a zero il gradiente rispetto a β


$$\nabla_{\beta} ||\mathbf{y} - \mathbf{X}\beta||^2 = -2\mathbf{X}^T(\mathbf{y} - \mathbf{X}\beta) = \mathbf{0} \Rightarrow \mathbf{X}^T\mathbf{X}\beta = \mathbf{X}^T\mathbf{y}$$

(**equazioni normali**). Se le colonne di $\mathbf{X}$ sono linearmente indipendenti, $\mathbf{X}^T\mathbf{X}$ è invertibile e

$$\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

- valori predetti: $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta} = \mathbf{H}\mathbf{y}$, con $\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$ (**hat matrix**): proiezione ortogonale di $\mathbf{y}$ sullo spazio generato dalle colonne di $\mathbf{X}$
- residui: $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H})\mathbf{y}$, ortogonali alle colonne di $\mathbf{X}$ ($\mathbf{X}^T\mathbf{e} = \mathbf{0}$)
- in pratica l'inversa non si calcola mai: si usa la fattorizzazione **QR** ($\mathbf{X} = \mathbf{QR} \Rightarrow \mathbf{R}\hat{\beta} = \mathbf{Q}^T\mathbf{y}$) o la **SVD** (pseudo-inversa), numericamente più stabili quando $\mathbf{X}^T\mathbf{X}$ è mal condizionata. Costo $O(nd^2)$.

Regressione vs fitting geometrico



La regressione lineare least square minimizza le distanze **verticali** dall'iperpiano e non le distanze **euclidee** (cosa semplicemente ottenibile attraverso PCA). Ciò è conseguenza del fatto che le variabili indipendente e dipendente non hanno ruolo simmetrico (la variabile indipendente si considera esatta, mentre quella dipendente affetta da errore). Nota: scambiando le due variabili il risultato cambia. Nel caso di **nuvole di punti geometrici** le coordinate hanno lo stesso ruolo e PCA fitting è preferibile.

RMSE (Root Mean Square Error) è un indicatore di accuratezza di predizione. esso è la radice quadrata del criterio **MSE (Mean Square Error)** $= \frac{1}{N} \sum_{i=1 \dots N} (\hat{y}_i - y_i)^2$ implicito nell'ottimizzazione least square del modello lineare, dove y_i è il valore osservato e $\hat{y}_i$ è il valore predetto. Quindi $\hat{y}_i - y_i$ è l'errore (lo scostamento tra la curva fittata e i valori di input) punto per punto.

Altri modi di valutare l'accuratezza di predizione (non direttamente utilizzabili come loss per modello lineare) sono:

- **MAE** (Mean Absolute Error) = $\frac{1}{N} \sum_{i=1 \dots N} |\hat{y}_i - y_i|$
 - è più robusta di MSE rispetto a outliers (dati non affidabili con ampi scostamenti)
 - mantiene l'unità di misura (es scostamento in metri)
- **MAPE** (Mean Absolute Percentage Error) = $\frac{1}{N} \sum_{i=1 \dots N} \left| \frac{\hat{y}_i - y_i}{y_i} \right|$. E' una variante del MAE dove la penalizzazione dipende dallo scostamento percentuale rispetto alla grandezza dei dati.
- **R^2** (coefficiente di determinazione) = $1 - \frac{\sum_{i=1 \dots N} (y_i - \hat{y}_i)^2}{\sum_{i=1 \dots N} (y_i - \bar{y})^2}$. Indicatore statistico (con valori tra 0 e 1) che indica quanto il modello lineare fitta i dati (ovvero spiega la varianza della variabile dipendente). **Non valido per modelli non lineari.**

Con un semplice accorgimento è possibile continuare ad utilizzare la regressione lineare per approssimare i dati con **curve** e superfici.


Nella teoria introdotta infatti l'importante è che la funzione di regressione sia lineare rispetto ai parametri e non rispetto alla variabile indipendente, i cui elementi possono comparire elevati a potenza, combinati tra loro, come argomento di funzioni trascendenti, ecc.

Regressione polinomiale

Esempio, per $d = 1$ e modello **quadratico** $y = \beta_1 x^2 + \beta_2 x + \beta_3$ scriviamo X come

$$X = \begin{bmatrix} x_1^2 & x_1 & 1 \\ x_2^2 & x_2 & 1 \\ \vdots & \vdots & \vdots \\ x_n^2 & x_n & 1 \end{bmatrix}$$

ottenendo ($d = 2$ a destra)



Inferenza statistica e selezione del modello

Il modello stimato è affidabile? Quali variabili servono davvero?
Quale modello scegliere tra più candidati?

Finora $\hat{\beta}$ è stata una **stima puntuale**. Ma il training set è un **campione**: ripetendo l'esperimento (nuovi errori ε_i) otterremmo un $\hat{\beta}$ diverso.

⇒ $\hat{\beta}$ è una **variabile aleatoria** e possiamo chiederci:

- il coefficiente β_j è davvero diverso da 0? (la variabile x_j serve?) → **test t**
- il modello nel suo complesso spiega qualcosa? → **test F / ANOVA**
- tra due modelli annidati, quello più complesso è significativamente migliore? → **F parziale, likelihood ratio test (χ^2)**
- tra modelli qualsiasi, quale scegliere? → **AIC, BIC**, cross-validation
- i dati rispettano le ipotesi del modello? → **diagnostica dei residui**, test χ^2 di adattamento

Ipotesi del modello lineare classico

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon, \quad \mathbf{X} \in \mathbb{R}^{n \times p}, \quad p = d + 1$$

- ❶ **linearità** nei parametri
- ❷ errori a **media nulla**: $E[\varepsilon_i] = 0$
- ❸ **omoschedasticità**: $\text{Var}(\varepsilon_i) = \sigma^2$ costante
- ❹ errori **incorrelati**: $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ per $i \neq j$
- ❺ $\mathbf{X}$ a **rango pieno** (p colonne linearmente indipendenti)
- ❻ (per l'inferenza) **normalità**: $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$

Teorema di Gauss-Markov

Sotto le ipotesi 1–5 lo stimatore least square è **BLUE** (Best Linear Unbiased Estimator): tra gli stimatori lineari e non distorti è quello a varianza minima.

Aggiungendo la 6: $\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}^T \mathbf{X})^{-1})$ e least square coincide con la stima di **massima verosimiglianza**.

Richiami: test d'ipotesi

- **ipotesi nulla** H_0 (es. $\beta_j = 0$) e **ipotesi alternativa** H_1 (es. $\beta_j \neq 0$)
- **statistica test** T : funzione dei dati la cui distribuzione sotto H_0 è nota
- **p-value**: probabilità, assumendo H_0 vera, di osservare un valore di T estremo almeno quanto quello osservato
- **livello di significatività** α (tipicamente 0.05): si rifiuta H_0 se p-value $< \alpha$
- **errore di I tipo**: rifiutare H_0 vera (probabilità α);
errore di II tipo: non rifiutare H_0 falsa; **potenza** = $1 - P(\text{errore II tipo})$

Attenzione

- non rifiutare H_0 non significa dimostrarla
- il p-value **non** è la probabilità che H_0 sia vera
- eseguendo m test, la probabilità di almeno un falso positivo cresce: correzione di **Bonferroni** (si usa α/m)

Tre distribuzioni fondamentali

Siano $Z, Z_1, \dots, Z_k$ indipendenti
 $\sim N(0, 1)$

- **chi quadro** con k gradi di libertà:

$$\chi_k^2 = \sum_{i=1}^k Z_i^2$$
$$E[\chi_k^2] = k, \quad \text{Var}[\chi_k^2] = 2k$$


- **t di Student**: $t_k = \frac{Z}{\sqrt{\chi_k^2/k}}$

- **F di Fisher-Snedecor**:

$$F_{k_1, k_2} = \frac{\chi_{k_1}^2/k_1}{\chi_{k_2}^2/k_2}$$

con numeratore e denominatore indipendenti.

Nota: $t_k^2 = F_{1, k}$



Densità della χ_k^2

Stima della varianza dell'errore

σ^2 è incognita. Uno stimatore non distorto è

$$s^2 = \frac{RSS}{n - p}, \quad RSS = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- $n - p$ sono i **gradi di libertà residui**: p gradi di libertà sono “consumati” per stimare β
- s è detto **errore standard dei residui** (stessa unità di misura di y). Differisce dal RMSE ($\sqrt{RSS/n}$) solo per il denominatore
- sotto ipotesi di normalità

$$\frac{(n - p) s^2}{\sigma^2} \sim \chi_{n-p}^2$$

indipendente da $\hat{\beta}$: è ciò che permette di costruire i test t ed F

Test t sui singoli coefficienti

Errore standard del coefficiente j -esimo: $SE(\hat{\beta}_j) = s \sqrt{[(\mathbf{X}^T \mathbf{X})^{-1}]_{jj}}$

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0$$

$$t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t_{n-p} \text{ sotto } H_0, \quad \text{p-value} = 2 P(t_{n-p} > |t_j|)$$

Intervallo di confidenza di livello $1 - \alpha$:

$$\hat{\beta}_j \pm t_{1-\alpha/2, n-p} \cdot SE(\hat{\beta}_j)$$

H_0 è rifiutata al livello $\alpha \Leftrightarrow$ lo 0 non appartiene all'intervallo.

- nella regressione semplice: $SE(\hat{\beta}) = \frac{s}{\sqrt{\sum_i (x_i - \bar{x})^2}}$,


$$SE(\hat{\alpha}) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_i (x_i - \bar{x})^2}}$$

- il test valuta il contributo di x_j **a parità delle altre variabili** presenti nel modello

Esempio: regressione semplice

x	1	2	3	4	5	6	7	8
y	2.3	2.9	4.8	4.1	6.5	6.0	8.2	7.4

- $n = 8$, $\bar{x} = 4.5$, $\bar{y} = 5.275$
- $\sum (x_i - \bar{x})^2 = 42$,
 $\sum (x_i - \bar{x})(y_i - \bar{y}) = 34.1$
- $\hat{\beta} = 34.1/42 = 0.812$
- $\hat{\alpha} = 5.275 - 0.812 \cdot 4.5 = 1.621$
- $RSS = 3.509$,
 $s^2 = 3.509/6 = 0.585$, $s = 0.765$



Esempio: test t

- $SE(\hat{\beta}) = 0.765/\sqrt{42} = 0.118$, $t = 0.812/0.118 = 6.88$
- con 6 gradi di libertà $t_{0.975,6} = 2.447$: p-value $\approx 0.0005 \Rightarrow$ la pendenza è significativa
- $SE(\hat{\alpha}) = 0.596$, $t = 2.72$, p-value $\approx 0.035 \Rightarrow$ intercetta significativa al 5% (ma non all'1%)

Tipico output di una libreria statistica (es. `statsmodels`, `summary()` in R):

	coef	std err	t	$P > t $	[0.025	0.975]
intercetta	1.621	0.596	2.72	0.035	0.163	3.080
x	0.812	0.118	6.88	0.000	0.523	1.101

Intervalli di confidenza e di predizione

Dato un nuovo punto $\mathbf{x}_0$, la predizione è $\hat{y}_0 = \mathbf{x}_0^T \hat{\beta}$. Due domande diverse:

- dove si trova la **media** $E[y | \mathbf{x}_0]$? → **intervallo di confidenza**

$$\hat{y}_0 \pm t_{1-\alpha/2, n-p} s \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

- dove cadrà una **nuova osservazione** y_0 ? → **intervallo di predizione**

$$\hat{y}_0 \pm t_{1-\alpha/2, n-p} s \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

L'intervallo di predizione è sempre più ampio: include anche il rumore ε_0 della nuova osservazione, che non si riduce aumentando n . Entrambi si allargano allontanandosi da $\bar{\mathbf{x}}$ (**estrapolare è rischioso**).

Decomposizione della varianza

- $TSS = \sum_i (y_i - \bar{y})^2$ variabilità **totale**
- $ESS = \sum_i (\hat{y}_i - \bar{y})^2$ variabilità **spiegata** dal modello
- $RSS = \sum_i (y_i - \hat{y}_i)^2$ variabilità **residua**

Se il modello contiene l'intercetta, i vettori $\hat{\mathbf{y}} - \bar{y}\mathbf{1}$ e $\mathbf{e}$ sono ortogonali, quindi (Pitagora)

$$TSS = ESS + RSS \quad \Rightarrow \quad R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

- questo spiega perché R^2 non è valido per modelli non lineari (o senza intercetta): la decomposizione non vale più
- nell'esempio: $31.195 = 27.686 + 3.509$, $R^2 = 0.888$

R^2 **non diminuisce mai** aggiungendo variabili al modello (anche se sono puro rumore!): non può essere usato per confrontare modelli con un numero diverso di parametri.

L' R^2 **aggiustato** confronta le varianze stimate invece delle somme dei quadrati:

$$R_{adj}^2 = 1 - \frac{RSS/(n-p)}{TSS/(n-1)} = 1 - (1 - R^2) \frac{n-1}{n-p}$$

- penalizza il numero di parametri p
- aumenta solo se la nuova variabile riduce RSS più di quanto ci si aspetterebbe per caso
- può essere negativo
- nell'esempio: $R_{adj}^2 = 1 - 0.112 \cdot 7/6 = 0.869$

ANOVA per la regressione: test F globale

$H_0 : \beta_1 = \dots = \beta_d = 0$ (nessuna variabile spiega y , basta la media)

H_1 : almeno un $\beta_j \neq 0$

Tabella ANOVA (ANalysis Of VAriance):


Sorgente	SS	gdl	MS	F
Regressione	ESS	$p - 1$	$MSR = ESS/(p - 1)$	MSR/MSE
Residuo	RSS	$n - p$	$MSE = RSS/(n - p)$	
Totale	TSS	$n - 1$		

(SS = somma dei quadrati, gdl = gradi di libertà, MS = media dei quadrati)

Sotto H_0 : $F = \frac{MSR}{MSE} \sim F_{p-1, n-p}$. Si rifiuta H_0 per valori grandi di F .

Intuizione: se H_0 è vera sia MSR che MSE stimano σ^2 e $F \approx 1$; se il modello spiega davvero parte della variabilità, MSR è molto più grande di MSE .

Test F : regione di rifiuto



Densità della $F_{2,20}$ (es. $d = 2$ variabili, $n = 23$ punti). Il test è a **una coda**: si rifiuta H_0 se il valore osservato cade nella zona ombreggiata.

Esempio: tabella ANOVA

Per i dati dell'esempio precedente ($n = 8$, $p = 2$):

Sorgente	SS	gdl	MS	F
Regressione	27.686	1	27.686	47.34
Residuo	3.509	6	0.585	
Totale	31.195	7		

- $F_{0.95}(1, 6) = 5.99$, $p\text{-value} \approx 0.0005 \Rightarrow$ si rifiuta H_0
- con una sola variabile indipendente il test F globale coincide con il test t sulla pendenza: $F = t^2 = 6.88^2 = 47.34$, stesso $p\text{-value}$
- con più variabili i due test rispondono a domande diverse: può accadere che F sia significativo ma nessun t_j lo sia (tipico sintomo di **multicollinearità**)

Confronto tra modelli annidati: test F parziale

Modello **ridotto** M_0 con p_0 parametri, contenuto nel modello **completo** M_1 con $p_1 > p_0$ parametri (es. polinomio di grado 3 vs grado 4).

H_0 : i $p_1 - p_0$ parametri aggiuntivi sono tutti nulli

$$F = \frac{(RSS_0 - RSS_1)/(p_1 - p_0)}{RSS_1/(n - p_1)} \sim F_{p_1 - p_0, n - p_1}$$

- misura se la riduzione dei residui ottenuta con i parametri aggiuntivi è maggiore di quella attesa per caso
- il test F globale è il caso particolare con $M_0 =$ sola intercetta
- il test t su un coefficiente è il caso $p_1 - p_0 = 1$ (e $F = t^2$)
- usi tipici: scegliere il **grado** di un polinomio, verificare se un **gruppo** di variabili (es. le dummy di una variabile categorica) è utile
- vale solo per modelli **annidati**

Nata (Fisher, anni '20) per confrontare le **medie di k gruppi**. Sia y_{ij} la j -esima osservazione del gruppo i , n_i osservazioni nel gruppo i , $N = \sum_i n_i$, $\bar{y}_i$ media del gruppo, $\bar{y}$ media globale.

$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$ vs H_1 : almeno una media è diversa

$$\underbrace{\sum_{i,j} (y_{ij} - \bar{y})^2}_{SS_T} = \underbrace{\sum_i n_i (\bar{y}_i - \bar{y})^2}_{SS_B \text{ (tra gruppi)}} + \underbrace{\sum_{i,j} (y_{ij} - \bar{y}_i)^2}_{SS_W \text{ (entro i gruppi)}}$$

$$F = \frac{SS_B / (k - 1)}{SS_W / (N - k)} \sim F_{k-1, N-k}$$

Ipotesi: osservazioni indipendenti, normalità entro i gruppi, **varianze uguali** tra i gruppi (verificabile con i test di Levene o Bartlett).

ANOVA come caso particolare della regressione

Una variabile categorica con k livelli si codifica con $k - 1$ **variabili dummy** (one-hot encoding eliminando una categoria di **riferimento**; con k dummy e l'intercetta le colonne di $\mathbf{X}$ sarebbero linearmente dipendenti: *dummy variable trap*)

$$y = \beta_0 + \beta_1 D_1 + \cdots + \beta_{k-1} D_{k-1} + \varepsilon$$

- β_0 = media del gruppo di riferimento, $\beta_i = \mu_{i+1} - \mu_1$
- H_0 dell'ANOVA $\Leftrightarrow \beta_1 = \cdots = \beta_{k-1} = 0 \Leftrightarrow$ test F globale della regressione
- $SS_B = ESS$, $SS_W = RSS$

Modello lineare generale

Test t , ANOVA e regressione sono casi particolari dello stesso modello $\mathbf{y} = \mathbf{X}\beta + \varepsilon$. Estensioni: ANOVA a due vie (con **interazioni**), ANCOVA (variabili numeriche e categoriche), MANOVA (y multivariata).

Esempio: confrontare configurazioni di un algoritmo

Tre configurazioni (A, B, C) di un algoritmo genetico, 5 esecuzioni indipendenti (seed diversi) ciascuna. Fitness finale:

	esecuzioni					$\bar{y}_i$
A	12	14	11	15	13	13
B	16	18	15	17	19	17
C	13	15	14	12	16	14

	SS	gdl	MS	F
Tra	43.33	2	21.67	8.67
Entro	30.00	12	2.50	
Totale	73.33	14		

- $\bar{y} = 14.67$, $F_{0.95}(2, 12) = 3.89$, $p\text{-value} \approx 0.005 \Rightarrow$ le configurazioni non sono equivalenti
- **quali** differiscono? servono test **post-hoc** (Tukey HSD, test t a coppie con correzione di Bonferroni)
- se le configurazioni sono valutate sulle **stesse istanze** i dati non sono indipendenti: ANOVA a misure ripetute o il test non parametrico di **Friedman**

Test del chi quadro

Test per variabili **categoriche**: confronta le frequenze **osservate** O_i con quelle **attese** E_i sotto H_0

$$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i} \underset{\sim}{\text{approx}} \chi_{gdl}^2 \quad (\text{Pearson})$$

- ❶ **Bontà di adattamento** (goodness of fit): i dati seguono una distribuzione teorica?
 k categorie, $gdl = k - 1 - m$, con m numero di parametri della distribuzione stimati dai dati
- ❷ **Indipendenza** tra due variabili categoriche (tabella di contingenza $r \times c$):

$$E_{ij} = \frac{(\text{totale riga } i) \cdot (\text{totale colonna } j)}{N}, \quad gdl = (r - 1)(c - 1)$$

Si rifiuta H_0 per valori grandi di χ^2 . L'approssimazione è affidabile se $E_i \geq 5$ per tutte le celle (altrimenti si accorpano categorie o si usa il test esatto di Fisher).

Esempio: test di indipendenza

150 utenti di un servizio: il piano sottoscritto dipende dal dispositivo usato?

Frequenze osservate (attese tra parentesi):

	Base	Standard	Premium	Tot
Desktop	30 (33.3)	45 (40.0)	25 (26.7)	100
Mobile	20 (16.7)	15 (20.0)	15 (13.3)	50
Tot	50	60	40	150

es. $E_{11} = 100 \cdot 50 / 150 = 33.3$

$$\chi^2 = \frac{(30 - 33.3)^2}{33.3} + \frac{(45 - 40)^2}{40} + \dots + \frac{(15 - 13.3)^2}{13.3} = 3.19$$

$gdl = (2 - 1)(3 - 1) = 2$, $\chi^2_{0.95,2} = 5.99$, $p\text{-value} \approx 0.20$

$\Rightarrow$ **non** si rifiuta l'ipotesi di indipendenza.

Il chi quadro in regressione e nel machine learning

- **normalità dei residui**: si suddividono i residui standardizzati in classi e si confrontano le frequenze con quelle attese per una $N(0, 1)$ ($gdl = k - 3$ se media e varianza sono stimate). Alternative: Shapiro-Wilk, Q-Q plot
- **varianza dell'errore**: da $(n - p)s^2/\sigma^2 \sim \chi^2_{n-p}$ si ottiene un intervallo di confidenza per σ^2
- **likelihood ratio test** (teorema di Wilks): per modelli annidati stimati a massima verosimiglianza

$$LR = -2(\ell_0 - \ell_1) \stackrel{approx}{\sim} \chi^2_{p_1 - p_0}$$

generalizza il test F parziale a modelli non gaussiani (regressione logistica, GLM, dove -2ℓ è detta **devianza**)

- **feature selection**: in scikit-learn `SelectKBest(chi2)` ordina le feature (non negative, es. conteggi) in base alla statistica χ^2 di dipendenza dalla classe

Verosimiglianza del modello lineare

Con $\varepsilon_i \sim N(0, \sigma^2)$ indipendenti:

$$L(\beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \mathbf{x}_i^T \beta)^2}{2\sigma^2}\right)$$

$$\ell(\beta, \sigma^2) = \log L = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{RSS(\beta)}{2\sigma^2}$$

- massimizzare ℓ rispetto a $\beta \Leftrightarrow$ minimizzare RSS : **MLE = least square**
- $\hat{\sigma}_{ML}^2 = RSS/n$ (distorto, a differenza di s^2)
- sostituendo le stime:

$$\ell_{max} = -\frac{n}{2} \left[\log\left(2\pi \frac{RSS}{n}\right) + 1 \right]$$

la log-verosimiglianza massima dipende solo da RSS : è la base di AIC e BIC

Aggiungere parametri riduce **sempre** RSS sul training set (e aumenta ℓ_{max}) $\Rightarrow$ **overfitting**.

Occorre bilanciare **bontà di adattamento** e **complessità** (principio di parsimonia, rasoio di Occam, trade-off bias-varianza).

Approcci principali:

- **test d'ipotesi** (F parziale, likelihood ratio): solo modelli annidati
- **criteri informativi** (AIC, BIC): penalizzano ℓ_{max} con il numero di parametri; applicabili anche a modelli non annidati (purché stimati sugli stessi dati e con la stessa y)
- **validazione** (hold-out, k -fold cross-validation): stima diretta dell'errore di generalizzazione, computazionalmente più costosa
- **regolarizzazione** (Ridge, Lasso): la complessità è controllata in modo continuo

Sia k il numero di parametri stimati (nella regressione: p coefficienti $+$ σ^2 , quindi $k = p + 1$)

$$AIC = 2k - 2\ell_{\max} \quad (\text{Akaike, 1974}) \quad BIC = k \ln n - 2\ell_{\max} \quad (\text{Schwarz, 1978})$$

Per il modello lineare gaussiano, a meno di costanti comuni a tutti i modelli:

$$AIC = n \ln \frac{RSS}{n} + 2k \quad BIC = n \ln \frac{RSS}{n} + k \ln n$$

- si sceglie il modello con il valore **minimo**; contano solo le **differenze** tra modelli
- la penalità del BIC supera quella dell'AIC quando $\ln n > 2$ ($n \geq 8$): **BIC è più parsimonioso**
- **AIC** stima la distanza di Kullback-Leibler dal modello vero: orientato alla **predizione** (asintoticamente equivalente alla leave-one-out cross-validation)
- **BIC** è **consistente**: se il modello vero è tra i candidati, viene selezionato con probabilità $\rightarrow 1$ per $n \rightarrow \infty$

BIC: interpretazione bayesiana

Dato un insieme di modelli candidati, per il teorema di Bayes

$$P(M | D) \propto P(D | M) P(M), \quad P(D | M) = \int P(D | \theta, M) P(\theta | M) d\theta$$

Approssimando l'integrale (metodo di Laplace) per n grande:


$$\ln P(D | M) \approx \ell_{\max} - \frac{k}{2} \ln n \quad \Rightarrow \quad BIC \approx -2 \ln P(D | M)$$

- minimizzare il $BIC \approx$ scegliere il modello con la massima **evidenza** (con prior uniforme sui modelli)
- fattore di Bayes tra due modelli: $B_{10} = \frac{P(D|M_1)}{P(D|M_0)} \approx \exp(-\Delta BIC/2)$, con $\Delta BIC = BIC_1 - BIC_0$
- scala di Kass & Raftery per ΔBIC : 0–2 evidenza debole, 2–6 positiva, 6–10 forte, > 10 molto forte

Esempio: scelta del grado del polinomio

Polinomi di grado 1–6 su $n = 50$ punti ($k = \text{grado} + 2$). $F = \text{test parziale rispetto al grado precedente}$, $F_{0.95}(1, \approx 45) \approx 4.05$

grado	k	RSS	F	AIC	BIC
1	3	412.0	–	111.45	117.19
2	4	198.5	50.55	76.94	84.59
3	5	101.3	44.14	45.30	54.86
4	6	95.8	2.58	44.51	55.98
5	7	94.1	0.79	45.62	59.00
6	8	93.6	0.23	47.35	62.65



Test F e BIC scelgono il grado 3, l'AIC (meno severo) il grado 4. Le differenze tra grado 3 e 4 sono però piccole ($\Delta AIC = 0.79$, $\Delta BIC = 1.12$): i due modelli sono di fatto equivalenti e per parsimonia si preferisce il grado 3.

Regularizzazione: Ridge e Lasso

Invece di scegliere un sottoinsieme discreto di variabili, si **penalizza** la norma dei coefficienti:

- **Ridge** (Tikhonov)

$$\min_{\beta} ||\mathbf{y} - \mathbf{X}\beta||^2 + \lambda ||\beta||_2^2 \quad \Rightarrow \quad \hat{\beta} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

la matrice è sempre invertibile: utile con variabili molto correlate. I coefficienti vengono ridotti ma non annullati

- **Lasso**

$$\min_{\beta} ||\mathbf{y} - \mathbf{X}\beta||^2 + \lambda ||\beta||_1$$

molti coefficienti diventano **esattamente zero**: selezione automatica delle variabili. Non ha forma chiusa (si risolve con **coordinate descent**)

- **Elastic Net**: combinazione delle due penalità

L'intercetta non si penalizza e le variabili vanno **standardizzate**.

L'iperparametro λ si sceglie con cross-validation.

Algoritmo: selezione stepwise forward

Scegliere il miglior sottoinsieme di d variabili richiede di valutare 2^d modelli (**best subset selection**). Alternativa greedy:

Input: dataset $(\mathbf{X}, \mathbf{y})$, variabili candidate $V = \{x_1, \dots, x_d\}$, criterio C (es. BIC)

Output: insieme S di variabili selezionate

- 1: $S \leftarrow \emptyset$
- 2: $best \leftarrow C(\text{modello con sola intercetta})$
- 3: **ripeti**
- 4: **per ogni** $v \in V \setminus S$ **esegui**
- 5: stima il modello con variabili $S \cup \{v\}$ e calcola C_v
- 6: $v^* \leftarrow \arg \min_v C_v$
- 7: **se** $C_{v^*} < best$ **allora**
- 8: $S \leftarrow S \cup \{v^*\}; best \leftarrow C_{v^*}$
- 9: **altrimenti**
- 10: **restituisce** S
- 11: **finché** $S = V$
- 12: **restituisce** S

Selezione stepwise: osservazioni

- è un **hill climbing** nello spazio dei sottoinsiemi di variabili, con funzione obiettivo C : al più $O(d^2)$ modelli stimati invece di 2^d
- come ogni ricerca locale può fermarsi in un **ottimo locale**
- varianti:
 - **backward elimination**: parte dal modello completo e rimuove una variabile alla volta (richiede $n > p$)
 - **bidirezionale**: a ogni passo valuta sia inserimenti che rimozioni
 - criterio basato sul p-value del test F parziale (soglie α_{in} , α_{out}) invece che su AIC/BIC
- **attenzione**: i p-value del modello finale sono ottimistici, perché le variabili sono state scelte guardando gli stessi dati. Il modello va validato su un **test set** indipendente
- con variabili molto correlate la selezione è instabile: piccole variazioni dei dati cambiano le variabili scelte (in questi casi il Lasso è spesso preferibile)

L'inferenza è valida solo se le ipotesi del modello sono (approssimativamente) rispettate. Strumenti grafici e test:

- **residui vs valori predetti**: un andamento curvo indica **non linearità**; una dispersione “a ventaglio” indica **eteroschedasticità** (test di Breusch-Pagan)
- **Q-Q plot** dei residui standardizzati: verifica della **normalità** (Shapiro-Wilk, χ^2 di adattamento)
- **residui vs ordine/tempo**: **autocorrelazione** (test di Durbin-Watson)
- **punti influenti**:
 - **leverage** h_{ii} (diagonale della hat matrix): punto sospetto se $h_{ii} > 2p/n$
 - **distanza di Cook**: $D_i = \frac{e_i^2}{p s^2} \cdot \frac{h_{ii}}{(1-h_{ii})^2}$, punto sospetto se $D_i > 4/n$

Rimedi: trasformazioni di y (logaritmo, Box-Cox), termini polinomiali, minimi quadrati pesati, regressione robusta.

Multicollinearità

Se alcune variabili indipendenti sono fortemente correlate tra loro, $\mathbf{X}^T \mathbf{X}$ è quasi singolare:

- errori standard $SE(\hat{\beta}_j)$ molto grandi e coefficienti instabili (anche con segno controintuitivo)
- test F globale significativo ma nessun test t significativo
- le predizioni possono restare buone: il problema riguarda soprattutto l'**interpretazione** dei coefficienti

Variance Inflation Factor:

$$VIF_j = \frac{1}{1 - R_j^2}$$

dove R_j^2 è l' R^2 della regressione di x_j su tutte le altre variabili indipendenti. $SE(\hat{\beta}_j)$ cresce di un fattore $\sqrt{VIF_j}$. Valori oltre 5–10 indicano un problema.

Rimedi: rimuovere o aggregare variabili, regressione sulle componenti principali (PCA), Ridge.

Riepilogando: inferenza e selezione

- sotto ipotesi di errori gaussiani omoschedastici, least square = massima verosimiglianza, e $\hat{\beta}$, s^2 hanno distribuzioni note (N , χ^2)
- test t : il singolo coefficiente è significativo? $\rightarrow$ intervalli di confidenza
- ANOVA / test F : il modello (o un gruppo di variabili) spiega una parte significativa della varianza? ANOVA sui gruppi = regressione su variabili dummy
- test χ^2 : variabili categoriche (adattamento, indipendenza), likelihood ratio test per modelli annidati
- R^2_{adj} , AIC, BIC, cross-validation: confronto tra modelli di diversa complessità. BIC penalizza di più e tende a scegliere modelli più semplici
- selezione stepwise (ricerca greedy) o regolarizzazione (Lasso) quando le variabili candidate sono molte
- sempre verificare le ipotesi con la diagnostica dei residui

Nel caso di dipendenza non lineare del modello dai parametri non esiste soluzione least square in forma-chiusa.

Esempio dalla biologia (enzyme-mediated reaction)

$$y = \frac{\beta_1 \cdot x}{\beta_2 + x}$$

Se la dipendenza è nota (come nell'esempio sopra), per la risoluzione si possono applicare tecniche iterative di **ottimizzazione numerica**:

- È possibile utilizzare il classico algoritmo di **Gradient Descent** (metodo del primo ordine che esegue passi in direzione contraria al gradiente)
- L'algoritmo più noto e utilizzato è quello di **Gauss-Newton** (metodo del secondo ordine che richiede stima Hessiana)

Gauss-Newton: idea

Modello $y_i = f(\mathbf{x}_i; \beta) + \varepsilon_i$, residui $r_i(\beta) = y_i - f(\mathbf{x}_i; \beta)$, obiettivo

$$S(\beta) = \sum_{i=1}^n r_i(\beta)^2 = \|\mathbf{r}(\beta)\|^2$$

Idea: linearizzare f attorno alla stima corrente β

$$f(\mathbf{x}_i; \beta + \delta) \approx f(\mathbf{x}_i; \beta) + \mathbf{J}_i \delta, \quad J_{ij} = \frac{\partial f(\mathbf{x}_i; \beta)}{\partial \beta_j}$$

dove $\mathbf{J}$ ($n \times p$) è lo **Jacobiano**. Il passo δ risolve allora un problema di regressione **lineare**:

$$\min_{\delta} \|\mathbf{r} - \mathbf{J}\delta\|^2 \quad \Rightarrow \quad (\mathbf{J}^T \mathbf{J}) \delta = \mathbf{J}^T \mathbf{r}$$

(le equazioni normali, con $\mathbf{J}$ al posto di $\mathbf{X}$ e $\mathbf{r}$ al posto di $\mathbf{y}$).

L'Hessiana di S è $2(\mathbf{J}^T \mathbf{J} - \sum_i r_i \nabla^2 f_i)$: Gauss-Newton la approssima con $2\mathbf{J}^T \mathbf{J}$, usando **solo derivate prime**. L'approssimazione è buona quando i residui sono piccoli o f è quasi lineare.

Algoritmo di Gauss-Newton

Input: dati $(\mathbf{x}_i, y_i)$, modello f , stima iniziale $\beta^{(0)}$, tolleranza τ

Output: stima $\hat{\beta}$

- 1: $\beta \leftarrow \beta^{(0)}$
- 2: **ripeti**
- 3: $r_i \leftarrow y_i - f(\mathbf{x}_i; \beta)$ per $i = 1 \dots n$
- 4: $\mathbf{J} \leftarrow$ Jacobiano di f in β
- 5: risolvi $(\mathbf{J}^T \mathbf{J}) \delta = \mathbf{J}^T \mathbf{r}$ (tramite QR di $\mathbf{J}$)
- 6: $\beta \leftarrow \beta + \delta$
- 7: **finché** $\|\delta\| < \tau (\|\beta\| + \tau)$
- 8: **restituisce** β

- ogni iterazione costa quanto una regressione lineare: $O(np^2)$
- vicino alla soluzione la convergenza è rapida: quadratica se i residui all'ottimo sono nulli, lineare (ma veloce) se sono piccoli
- può però **divergere** se $\beta^{(0)}$ è lontano dalla soluzione o se $\mathbf{J}^T \mathbf{J}$ è mal condizionata

Levenberg-Marquardt rende Gauss-Newton robusto introducendo uno smorzamento $\lambda > 0$:

$$(\mathbf{J}^T \mathbf{J} + \lambda \mathbf{I}) \delta = \mathbf{J}^T \mathbf{r}$$

- λ grande: passo corto nella direzione del gradiente (**gradient descent**); λ piccolo: **Gauss-Newton**
- se S diminuisce il passo è accettato e $\lambda \leftarrow \lambda/10$, altrimenti è rifiutato e $\lambda \leftarrow 10\lambda$
- variante di Marquardt: $\lambda \text{diag}(\mathbf{J}^T \mathbf{J})$ al posto di $\lambda \mathbf{I}$, per rendere il passo invariante rispetto alla scala dei parametri
- $\mathbf{J}^T \mathbf{J} + \lambda \mathbf{I}$ è sempre invertibile (stessa idea della regressione Ridge)
- è l'algoritmo usato di default da `scipy.optimize.curve_fit` (senza vincoli)

Esempio: modello di Michaelis-Menten

$$f(x; \beta_1, \beta_2) = \frac{\beta_1 x}{\beta_2 + x} \quad \frac{\partial f}{\partial \beta_1} = \frac{x}{\beta_2 + x}, \quad \frac{\partial f}{\partial \beta_2} = -\frac{\beta_1 x}{(\beta_2 + x)^2}$$

- **stima iniziale:** β_1 è l'asintoto (velocità massima) $\Rightarrow \beta_1^{(0)} \approx \max_i y_i$;
 β_2 è il valore di x per cui $y = \beta_1/2$
- in alternativa si **linearizza** il modello (Lineweaver-Burk):

$$\frac{1}{y} = \frac{1}{\beta_1} + \frac{\beta_2}{\beta_1} \cdot \frac{1}{x}$$

e si usa la regressione lineare di $1/y$ su $1/x$. La trasformazione però distorce gli errori (quelli sui valori piccoli di y vengono amplificati), quindi è adatta solo come punto di partenza per Gauss-Newton

- a convergenza, $s^2(\mathbf{J}^T \mathbf{J})^{-1}$ fornisce (asintoticamente) gli errori standard dei parametri, e si applicano gli stessi test t visti per il caso lineare

Regressione non lineare - dipendenza sconosciuta

Quando la dipendenza tra la variabile indipendente e dipendente non è nota (potrebbe essere lineare o non lineare) il problema può essere approcciato provando e validando sia il modello lineare (baseline) sia modelli non lineari via via più complessi.

Per alcune tecniche di classificazione studiate esiste una variante efficace per problemi di regressione. Casi notevoli (disponibili in scikit learn) sono

- **Random Forest Regressor**
- **Support Vector Regressor** (SVR). L'idea è di invertire la funzione obiettivo invece di richiedere che nella fascia del margine non ricadano sample, vogliamo che in essa ricada il maggior numero di sample del training set
- **Gradient Boosting Regressor**
- anche le **Reti Neurali** addestrate con classico error backpropagation consentono di risolvere efficacemente problemi di regressione

I vantaggi di un modello non lineare sono

- Maggiore **flessibilità** (più gradi di libertà del modello)
- Controllo della **complessità della soluzione** (gradi di libertà del modello, regolarizzazione, ecc)
- Possibilità di utilizzare funzioni loss alternative rispetto a MSE (che è implicita nella risoluzione least square) quali MAE, MAPE, ecc

Regressione ai quantili

Il modello lineare risolto ai minimi quadrati è uno stimatore della media condizionata. Significa che la retta di regressione è determinata per approssimare la media dei dati, e quindi l'entità degli **errori di previsione positivi e negativi** è la stessa.

Nel caso in cui si voglia dare un **peso diverso ai positivi e negativi** (es le conseguenze di una sottostima potrebbero essere più gravi di quelle di una sovrastima) si introduce la **regressione ai quantili** (o **percentili**).

- Con percentile **50%** si passa da media a mediana (la metà dei punti nel training set sono sopra la retta di regressione individuata e la metà sono sotto)
- percentile p la retta è individuata in modo da avere il $p\%$ di punti sotto e $1 - (p)\%$ sopra

Nella formulazione si utilizza una loss MAE con penalità diversa per predizioni in eccesso e difetto.

Per problemi di regressione di **piccole-medie dimensioni**

- Il modello **lineare** (rispetto ai parametri) risolto tramite least square (con fattorizzazione SVD) è l'approccio più semplice che costituisce una sorta di **baseline**
- Un modello **non lineare rispetto alla variabile indipendente** (ma lineare rispetto ai parametri) può essere un'ottima seconda scelta perché coniuga semplicità e flessibilità
- Quando sono necessari modelli più potenti, **Random Forest Regressor** rappresenta una valida alternativa
- Se la dipendenza tra variabile dipendente e indipendente è **nota** (ma **non lineare** rispetto ai parametri) l'ottimizzazione numerica con **Gauss-Newton** è la prima scelta

Per problemi di regressione di **grandi dimensioni** (lineari e non) l'approccio iterativo **Gradient Descent** utilizzato in combinazione con **Reti Neurali** è spesso preferibile per motivi di trattabilità numerica e complessità computazionale.

Nell'ambito del **deep learning**, reti neurali addestrate con gradient descent sono state utilizzate con successo per risolvere problemi di regressione di **enormi dimensioni** come la stima della posizione di un oggetto in un'immagine a partire da milioni di esempi (vedi **Faster R-CNN**)

- la variabile indipendente è un'immagine (pixel)
- La variabile dipendente la bounding box dell'oggetto (trattasi in questo caso di un vettore, quindi multivariate multiple regression)