UNIVERSITÀ DI PARMA · A.A. 2026/2027

Teoria e applicazioni delle reti complesse



Network Science

Michele Bellingeri

Laurea Magistrale in Scienze Informatiche · 1° anno · 6 CFU

Modulo 7

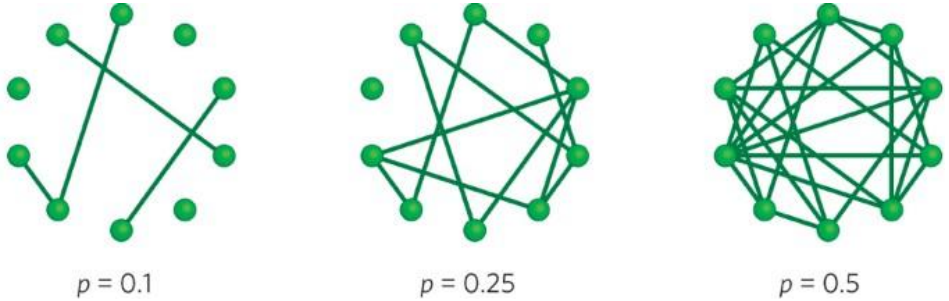
Modelli di Rete

Modelli di Rete (Network Models)

Le reti reali possono presentare strutture molto complesse. Per comprenderne le proprietà, possiamo costruire modelli matematici che generano reti secondo regole semplici.

Un modello di rete permette di:

- Comprendere come semplici regole di formazione dei link producano proprietà globali.



- Studiare la relazione tra struttura e comportamento della rete.
- Confrontare le proprietà delle reti reali con quelle attese da un modello teorico.

Modelli di Rete (Network Models)

Le reti reali possono presentare strutture molto complesse. Per comprenderne le proprietà, possiamo costruire modelli matematici che generano reti secondo regole semplici.

Quale è la componente gigante?

Quale è l'efficienza della rete?

Ci sono comunità?



Robusta all'errore?

Quale è il grado medio?

Quale è la distanza tra nodi?

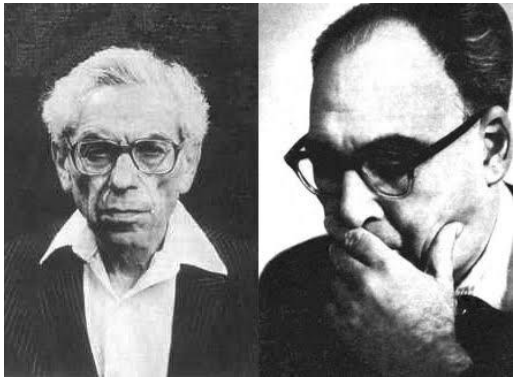
Robusta all'attacco?

Ci sono hub?

Grafo Casuale

Domanda fondamentale:

Quali proprietà emergono se i collegamenti tra i nodi vengono generati completamente a caso?



Paul Erdős – Alfred Rényi

Il modello Erdős–Rényi

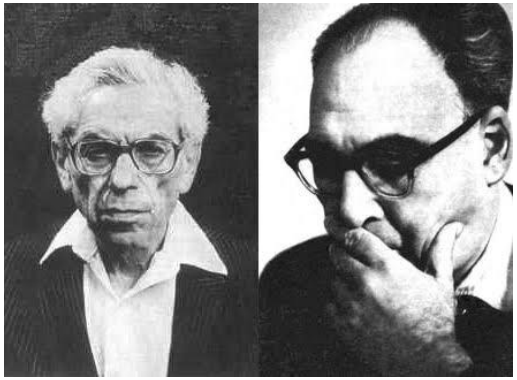
Random Graph — Erdős–Rényi

Pubblicarono due modelli diversi.

Modello $G(n, m)$ fissa il numero esatto di archi m scelti a caso tra tutti i possibili.

Modello $G(n, p)$ — più usato oggi — assegna ogni arco con probabilità p indipendentemente.

Grafo Casuale



Domanda fondamentale:

Quali proprietà emergono se i collegamenti tra i nodi vengono generati completamente a caso?

Il modello Erdős–Rényi

Random Graph

1. La transizione di fase fu una scoperta accidentale

2. Il clustering è bassissimo

3. È ancora il modello nullo di riferimento

Numero di Erdős



Erdős co-firmò oltre 1500 articoli con circa 500 collaboratori diversi

Rete di co-autori matematici: i nodi sono i ricercatori, gli archi collegano chi ha pubblicato almeno un articolo insieme

Numero di Erdős di un ricercatore è la distanza binaria da quel nodo al nodo “Paul Erdős” in questa rete:

$$E(v) = d(v, \text{Erdős})$$

Erdős stesso ha numero 0.

Chi ha pubblicato direttamente con lui ha numero 1.
Chi ha pubblicato con qualcuno di numero 1, e non con Erdos, ha numero 2.
E così via.

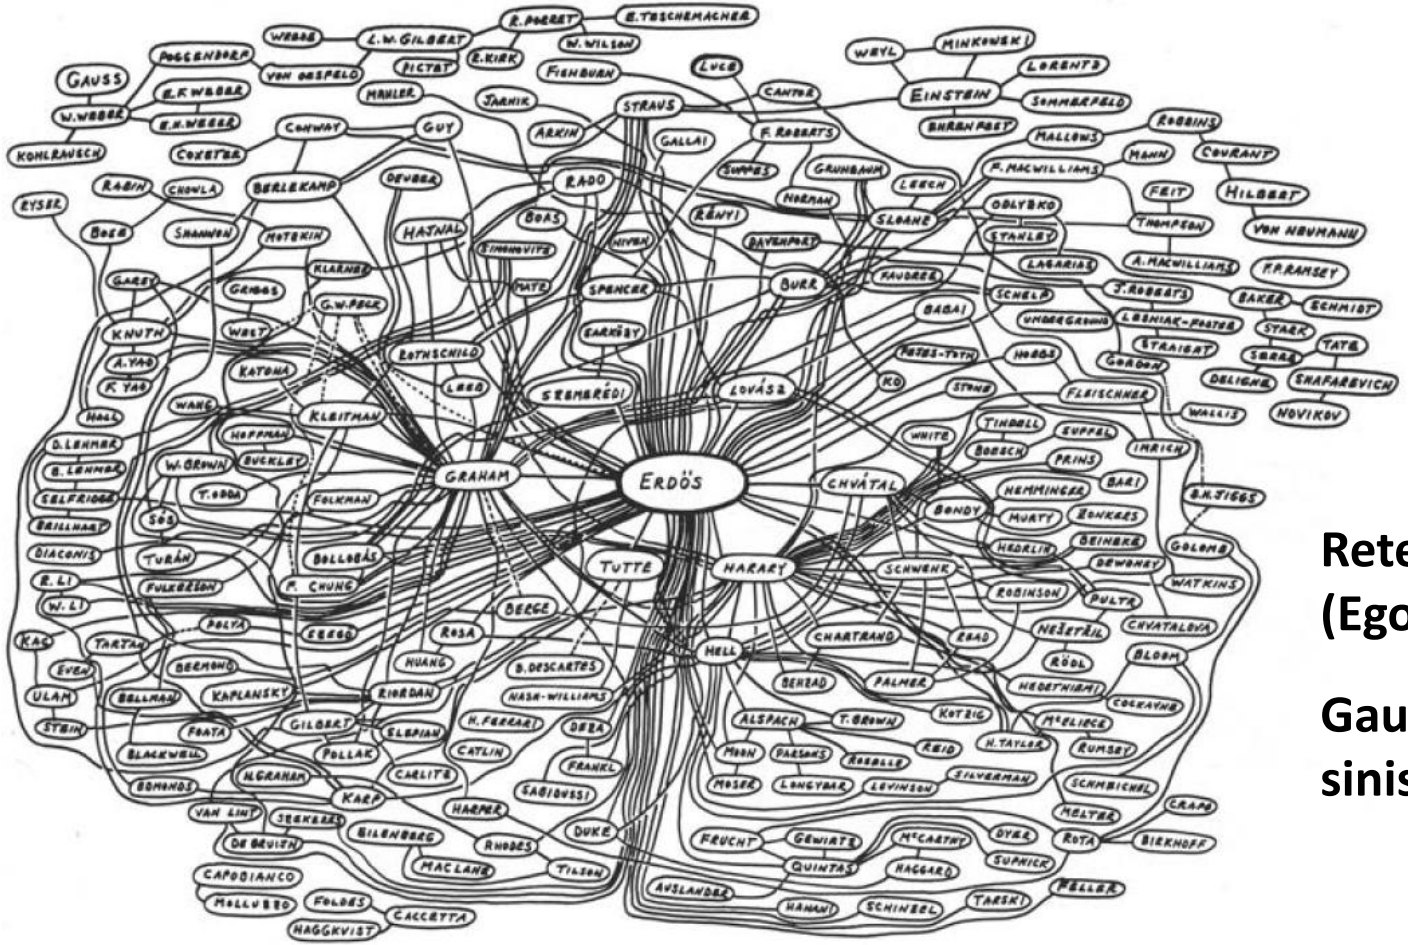
Numero di Erdős



Rete di co-autori matematici: i nodi sono i ricercatori, gli archi collegano chi ha pubblicato almeno un articolo insieme

La rete di co-autori matematici è un tipico esempio di **small-world**:

- **Distanza media** $\langle d \rangle \approx 4 - 5$
- **Clustering alto** — i collaboratori di un matematico tendono a conoscersi
- **Distribuzione dei gradi con coda pesante** — pochi ricercatori molto prolifici, molti con pochi collaboratori





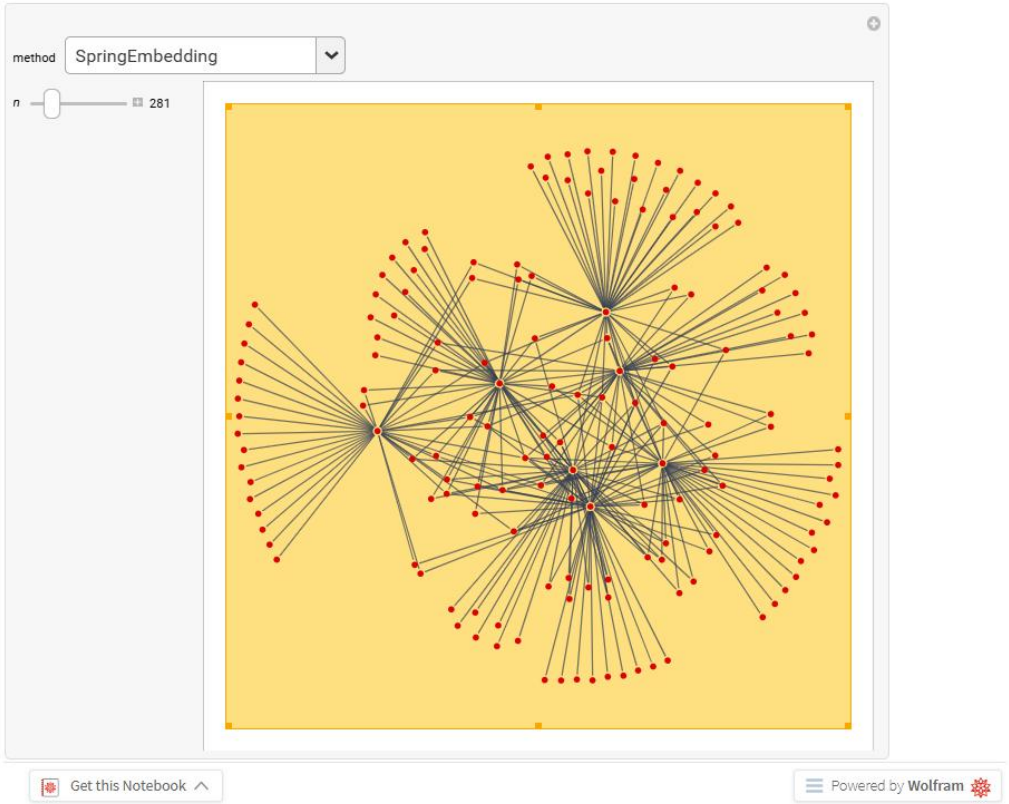
Rete ego-centrata (Ego Network)

Gauss in alto a sinistra

Easley and Kleinberg (2010)

Collaboration Graph for Paul Erdos Coauthors

ResourceData["Demonstration: Collaboration Graph for Paul Erdos Coauthors"]



https://demonstrations.wolfram.com/CollaborationGraphForPaulErdosCoauthors/

Grafo Casuale

Il modello Erdős–Rényi

Modello $G(n, p)$

Consideriamo n nodi.

Ogni coppia di nodi viene collegata con probabilità p, indipendentemente

dalle altre coppie.

Il modello dipende da due parametri:

$G(n, p)$

n: numero di nodi

p: probabilità che esista un arco tra due nodi distinti.

Nel caso di grafi semplici e non orientati:

$$0 \leq p \leq 1$$

Grafo Casuale

Il modello Erdős–Rényi - Modello $G(n, p)$

$G(n, p)$

n: numero di nodi

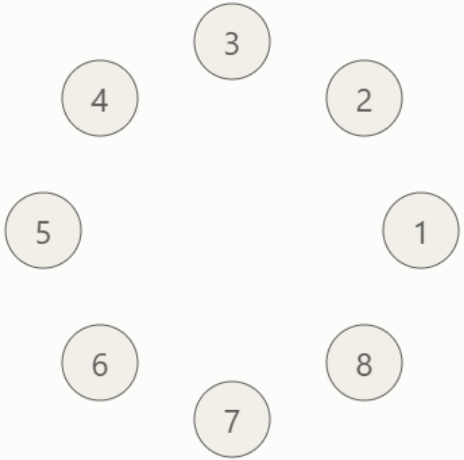
p: probabilità che esista un arco tra due nodi distinti.

Ogni coppia di nodi viene collegata indipendentemente dalle altre con probabilità p

- $(p = 0)$: nessun arco, tutti i nodi sono isolati.
- $(p = 1)$: grafo completo, tutte le coppie di nodi sono collegate.
- $(0 < p < 1)$: rete casuale, numero variabile di archi.

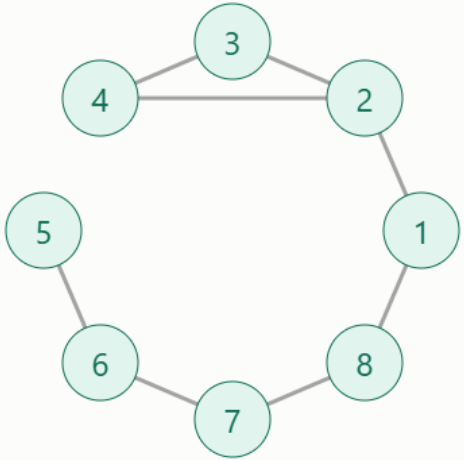
Grafo Casuale

p = 0
nessun arco



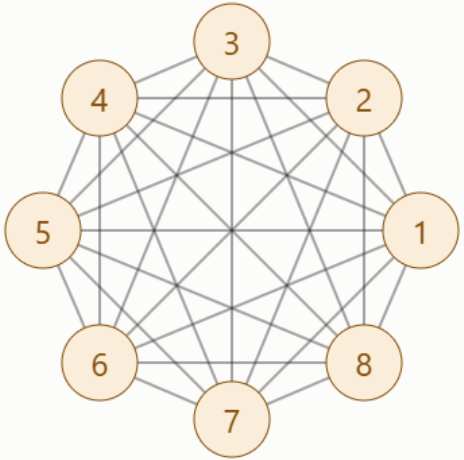
m = 0
⟨k⟩ = 0
C = 0

p = 0.3
alcuni archi



m ≈ 8–9
⟨k⟩ ≈ 2.1
C ≈ 0.3

p = 1
grafo completo



m = 28
⟨k⟩ = 7
C = 1

Grafo Casuale – Numero di Archi

Il modello Erdős–Rényi - Modello $G(n, p)$

In un grafo semplice non orientato con (n) nodi, il **numero massimo di archi** possibili è:

$$M = \frac{n(n-1)}{2}$$

Ogni nodo può collegarsi agli altri $(n-1)$ nodi.

Il prodotto $n(n-1)$ conta ogni possibile arco due volte

quindi dividiamo per 2

Poiché ogni arco viene generato con probabilità p, il numero medio di archi è:

$$\langle m \rangle = p\frac{n(n-1)}{2}$$

Grafo Casuale – Numero di Archi

Il modello Erdős–Rényi - Modello $G(n, p)$

N° massimo di archi: $M = \frac{n(n-1)}{2}$

N° medio di archi: $\langle m \rangle = p\frac{n(n-1)}{2}$

Esempio: con $(n = 100)$ e $(p = 0.1)$:

$$\langle m \rangle = p\frac{n(n-1)}{2} = 0{,}1 \cdot \frac{100(100-1)}{2} = 495$$

numero medio atteso di archi, non necessariamente il numero effettivo in una singola realizzazione.

Grafo Casuale – Grado Medio

Il modello Erdős–Rényi - Modello $G(n, p)$

Ogni nodo può essere collegato agli altri $(n-1)$ nodi, ciascuno con probabilità (p).

$$\langle k \rangle = (n-1)p$$

Per reti grandi:

$$\langle k \rangle \approx np$$

grado medio teorico atteso

Esempio: con $(n = 100)$ e $(p = 0.1)$:

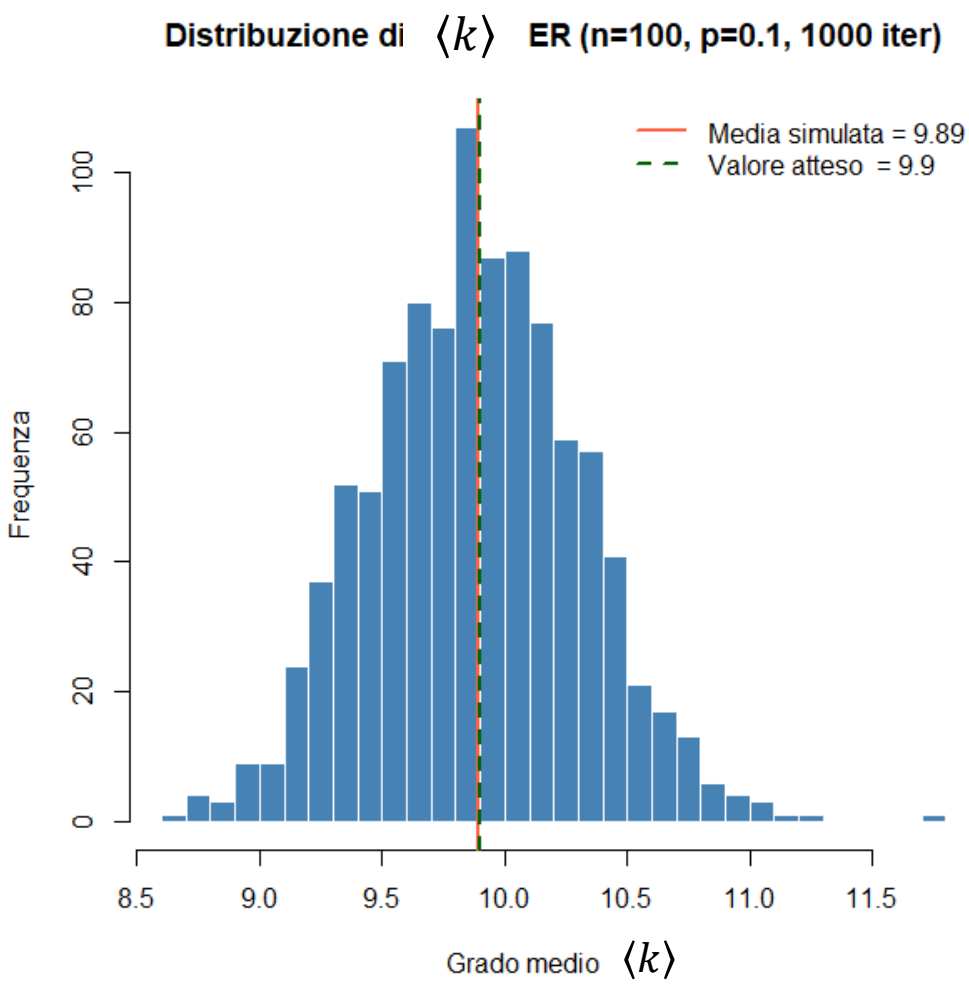
$$\langle k \rangle = (n-1)p$$
$$= (100-1)0.1$$
$$= 9{,}9$$

Graf

Esempio: con $(n = 100)$ e $(p = 0.1)$:

$$\langle k \rangle = (n-1)p$$
$$= (100-1)0.1$$
$$= 9{,}9$$

grado medio teorico atteso



Grafo Casuale – Distribuzione dei Gradi

Il modello Erdős–Rényi - Modello $G(n, p)$

Nel modello, ogni nodo può collegarsi agli altri $(n-1)$ nodi, ciascuno con probabilità (p), indipendentemente dagli altri collegamenti.

Il grado (k) di un nodo è una variabile casuale che segue una distribuzione binomiale:

$$P(k) = \binom{n-1}{k} p^k (1-p)^{n-1-k}$$

- $P(k)$: probabilità che un nodo abbia esattamente grado k.
- $(n-1)$: numero di possibili vicini.
- p: probabilità di collegamento.
- k: numero di collegamenti effettivamente presenti.

Grafo Casuale – Distribuzione dei Gradi

Il modello Erdős–Rényi - Modello $G(n, p)$

Il grado (k) di un nodo è una variabile casuale che segue una distribuzione binomiale:

$$P(k) = \binom{n-1}{k} p^k (1-p)^{n-1-k}$$

- $\binom{n-1}{k}$ Numero di modi in cui possiamo scegliere (k) vicini tra gli $(n-1)$ possibili
- p^k Probabilità che quei k collegamenti siano presenti
- $(1-p)^{n-1-k}$ Probabilità che gli altri $(n-1-k)$ collegamenti siano assenti

Il prodotto fornisce la probabilità che un nodo abbia esattamente k link

Grafo Casuale – Coefficiente Binomiale

$$P(k) = \binom{n-1}{k} p^k (1-p)^{n-1-k}$$

- $\binom{n-1}{k}$ Numero di modi in cui possiamo scegliere (k) vicini tra gli $(n-1)$ possibili

Coefficiente binomiale

$$\boxed{\binom{n-1}{k} = \frac{(n-1)!}{k!(n-1-k)!}}$$

$$4! = 4 \cdot 3 \cdot 2 \cdot 1 = 24$$

Grafo Casuale – Distribuzione dei Gradi

Il modello Erdős–Rényi - Modello $G(n, p)$

Dalla distribuzione binomiale alla distribuzione di Poisson

Per **reti grandi e sparse**, quando: $n \to \infty$, $p \to 0$

La distribuzione binomiale converge alla distribuzione di Poisson:

$$P(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}$$

Nel limite di Poisson

$$\langle k \rangle = \sigma_2^k = \lambda$$

se il grado medio è 4, anche la varianza è 4.

Grafo Casuale – Distribuzione dei Gradi

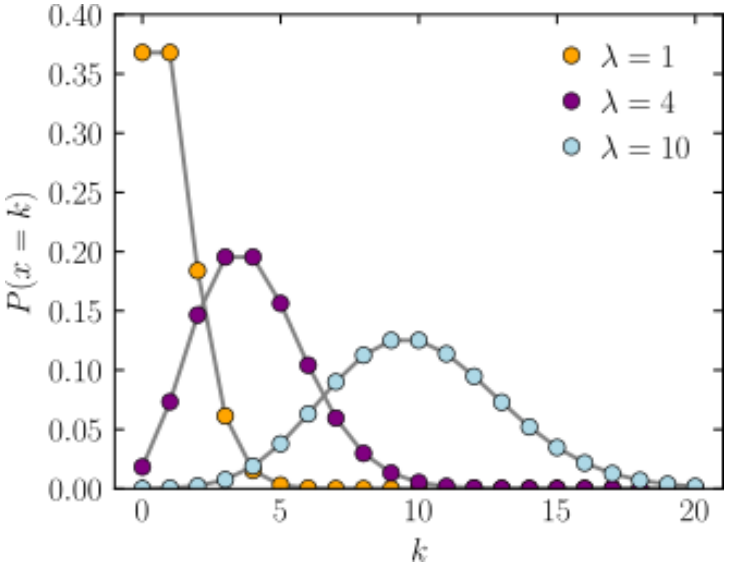


Siméon Denis Poisson (1781–1840)

Nel 1837 Poisson pubblicò il trattato *Recherches sur la probabilité des jugements en matière criminelle et en matière civile*, dedicato alla probabilità applicata alle decisioni giudiziarie. In questo lavoro compare la distribuzione oggi nota come distribuzione di Poisson.

La distribuzione emerge come limite della binomiale quando il numero di prove diventa molto grande e la probabilità di successo molto piccola, mantenendo costante il numero medio di successi.

Grafo Casuale – Distribuzione dei Gradi



Distribuzioni di Poisson teoriche per diversi valori del parametro λ

Il caso dei soldati prussiani

Applicazione empirica famosa fu di **Ladislaus Bortkiewicz** (1898), che usò la distribuzione per modellare il numero di soldati prussiani uccisi ogni anno da calci di cavallo. I dati si adattavano bene alla distribuzione di Poisson con λ= 0.61.

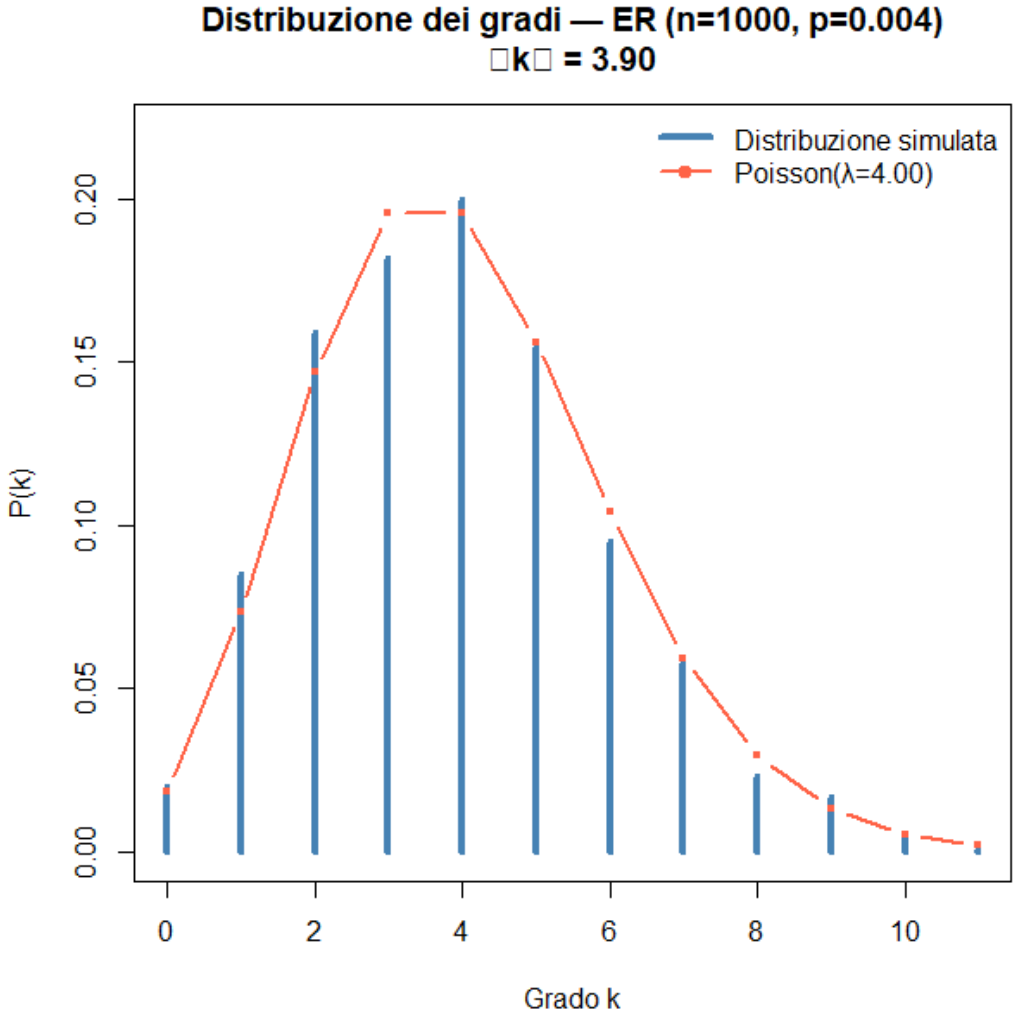
200 osservazioni, 10 corpi d'armata per 20 anni.

122 decessi, con una media di 0,61 per osservazione

Grafo Casuale – D

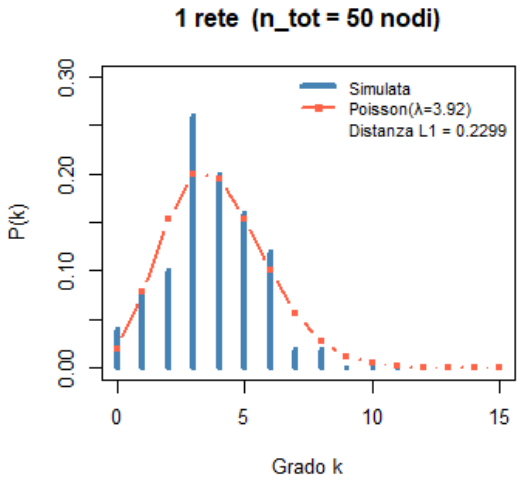
Poisson $P(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}$

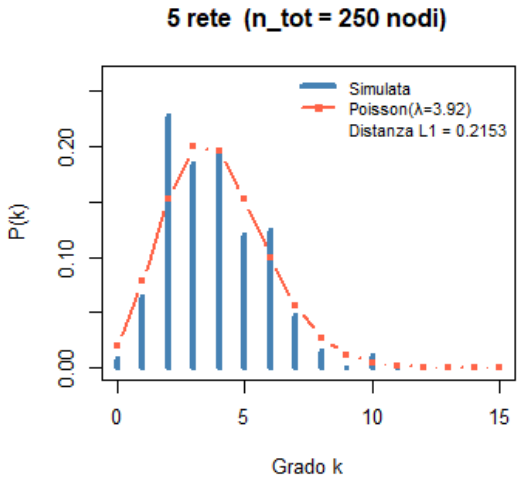
$$\lambda = \langle k \rangle = (n-1)p$$

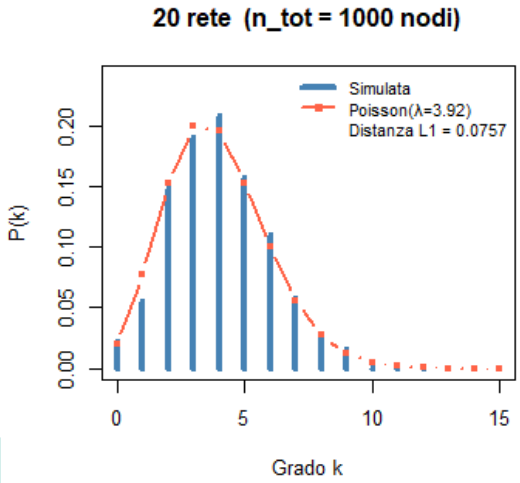


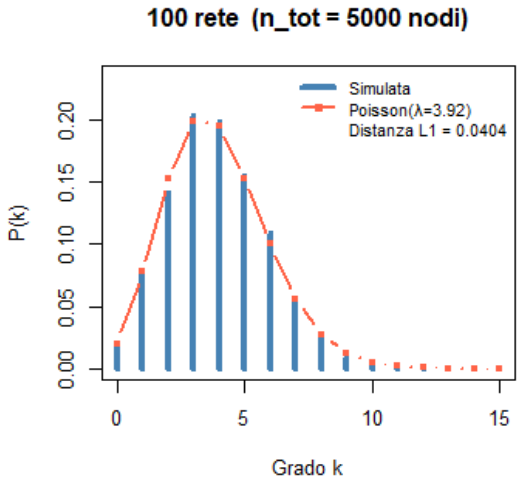
Grafo Casual

Poisson $$P(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}$$



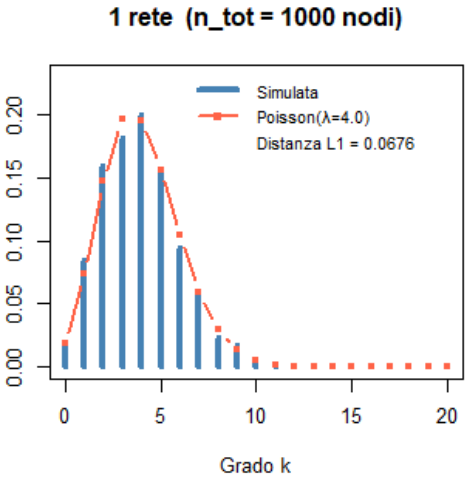


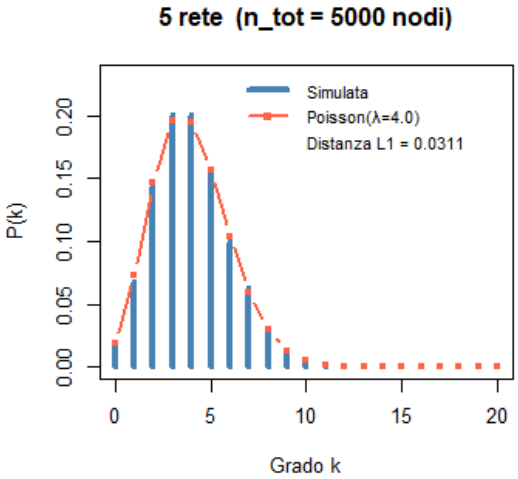


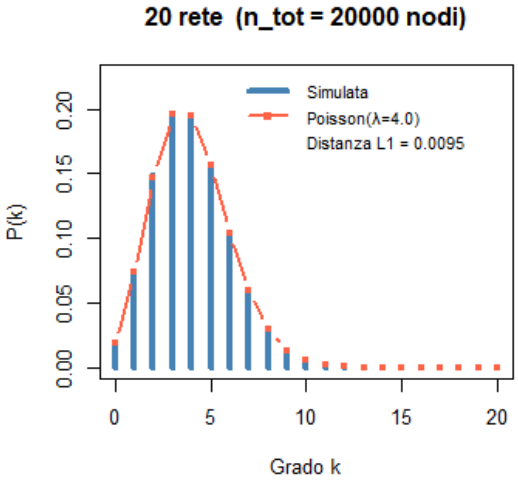


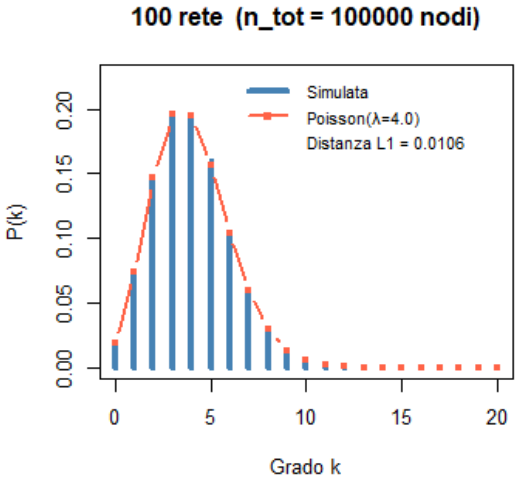
Gra adi

Poisson $P(k) =$



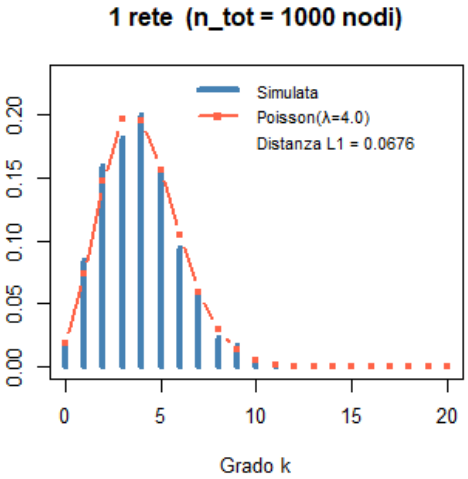


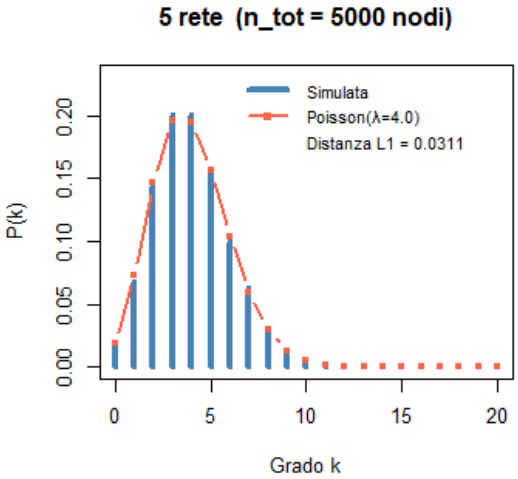


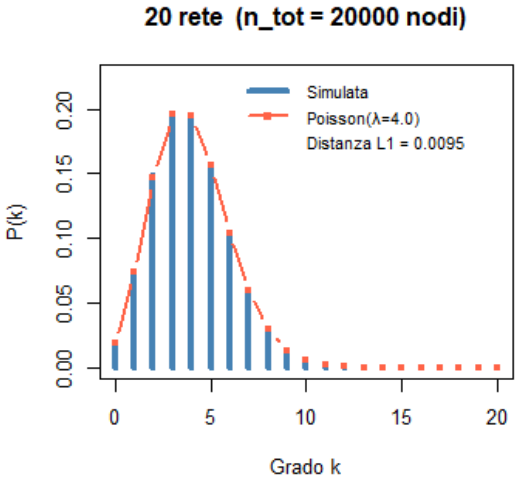


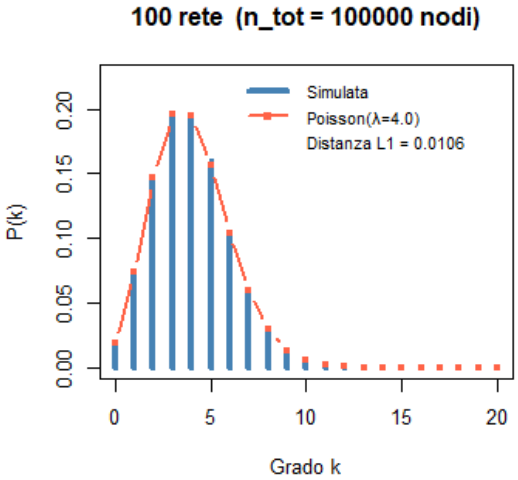
Gra adi

Poisson $P(k) =$









Grafo Casuale – Componente Gigante

In un grafo non orientato, una componente connessa è un insieme massimale di nodi in cui ogni coppia è collegata da almeno un cammino.

La *Largest Connected Component* (LCC) è la componente connessa che contiene il maggior numero di nodi.

Definiamo: $S = \frac{N_{\mathrm{LCC}}}{n}$

Dove N_{LCC} è il numero di nodi della componente più grande e (n) il numero totale di nodi.

La grandezza S rappresenta la frazione di nodi appartenenti alla componente più grande.

Grafo Casuale – Componente Gigante

La Largest Connected Component (LCC) è la componente connessa che contiene il maggior numero di nodi.

$$S = \frac{N_{\mathrm{LCC}}}{n}$$

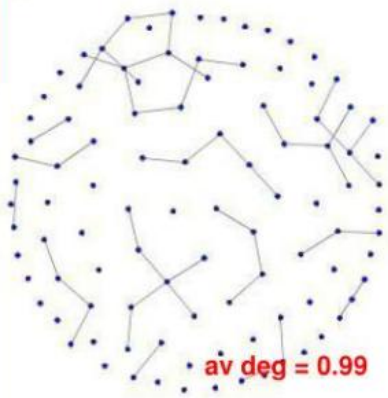
Nota: in una rete finita esiste sempre una componente più grande, ma non necessariamente una componente gigante in senso matematico.

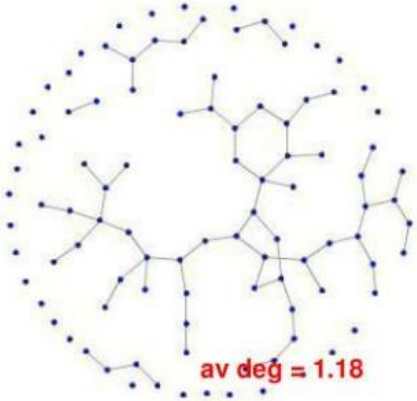
Una **componente è gigante** quando contiene una frazione non nulla dei nodi nel limite $n \to \infty$

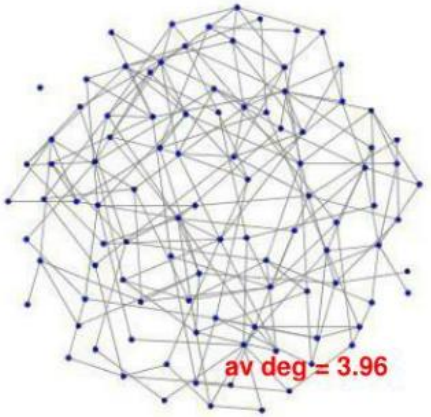
Grafo Casuale – Componente Gigante

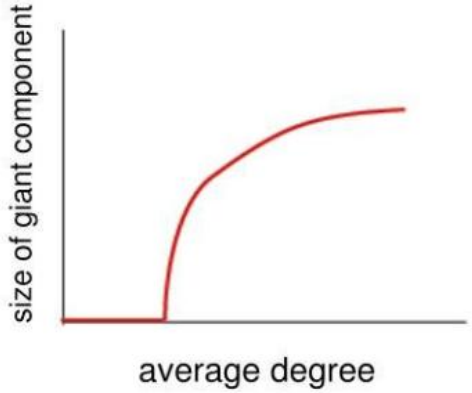
Cosa succede aumentando (p)?

Consideriamo il modello $G(n, p)$, mantenendo fisso il numero di nodi e aumentando progressivamente p.









cambiamento quantitativo

-> cambiamento qualitativo

Grafo Casuale – Componente Gigante

La soglia critica della componente gigante

Risultato fondamentale:

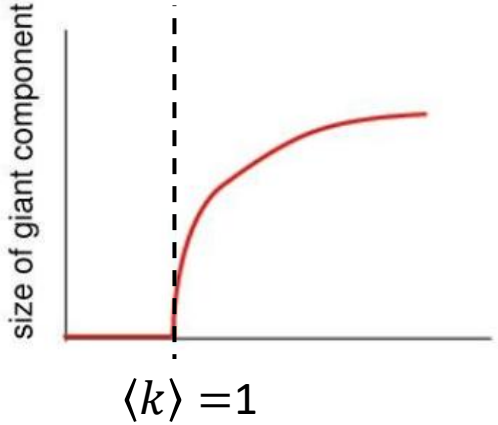
$$\langle k \rangle_c = 1$$

Poiché

$$\langle k \rangle = (n-1)p \quad \Rightarrow \quad p_C \approx \frac{1}{n}$$

Proprietà fondamentale del modello Erdős–Rényi

Una componente è gigante quando contiene una frazione non nulla dei nodi nel limite $n \to \infty$



Grafo Casuale – Componente Gigante

Perché la componente gigante compare proprio quando il grado medio supera 1?

$$\langle k \rangle_c = 1 \qquad p_C \approx \frac{1}{n}$$

Processo di ramificazione

I tre regimi



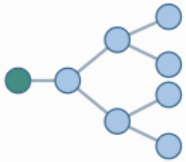
$\langle k \rangle < 1$ — **Regime sottocritico**

Ogni nodo raggiunto genera mediamente meno di un nuovo nodo. L'esplorazione tende a estinguersi e le componenti rimangono piccole.



$\langle k \rangle = 1$ — **Regime critico**

Ogni nodo genera mediamente un nuovo nodo. Siamo al confine tra estinzione e crescita sostenuta dell'esplorazione.

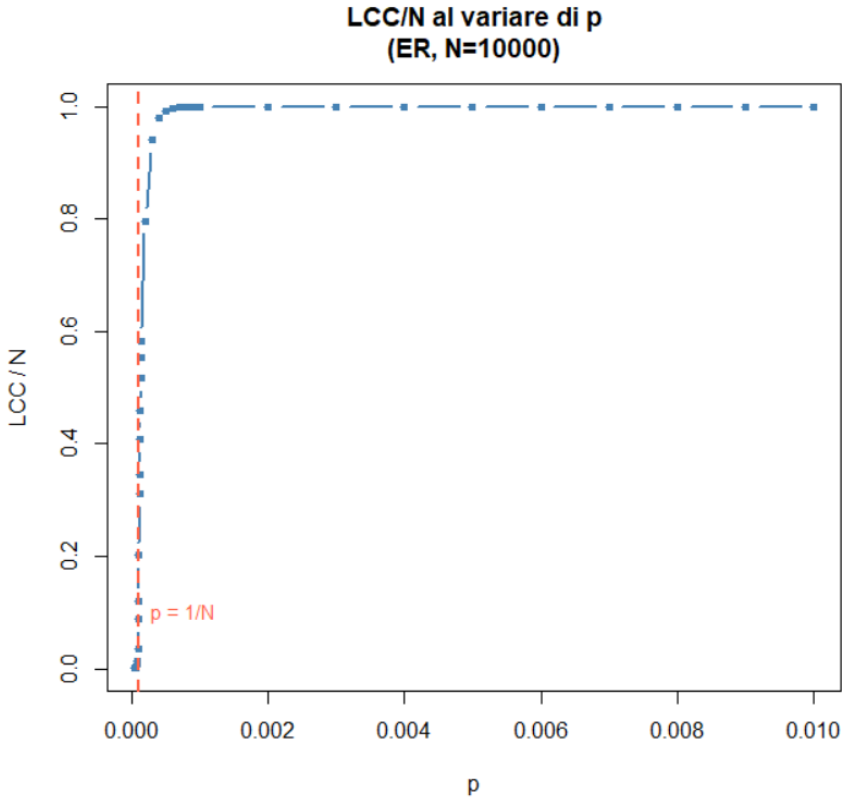


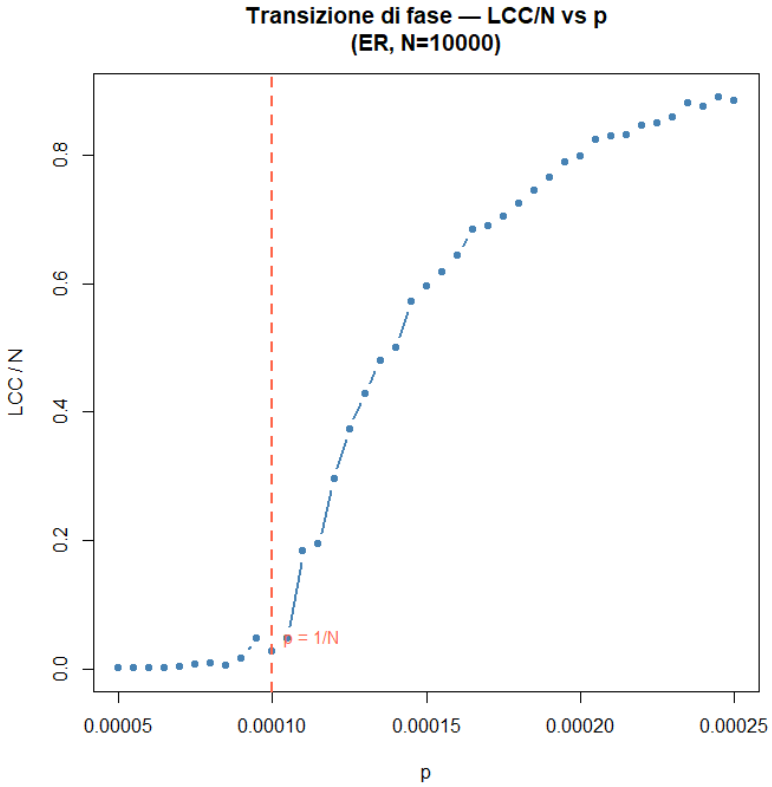
$\langle k \rangle > 1$ — **Regime supercritico**

Ogni nodo genera mediamente più di un nuovo nodo. L'esplorazione può continuare a crescere e raggiungere una frazione macroscopica della rete.

$$p_c \approx \frac{1}{N} = \frac{1}{10\,000} = 0.0001$$

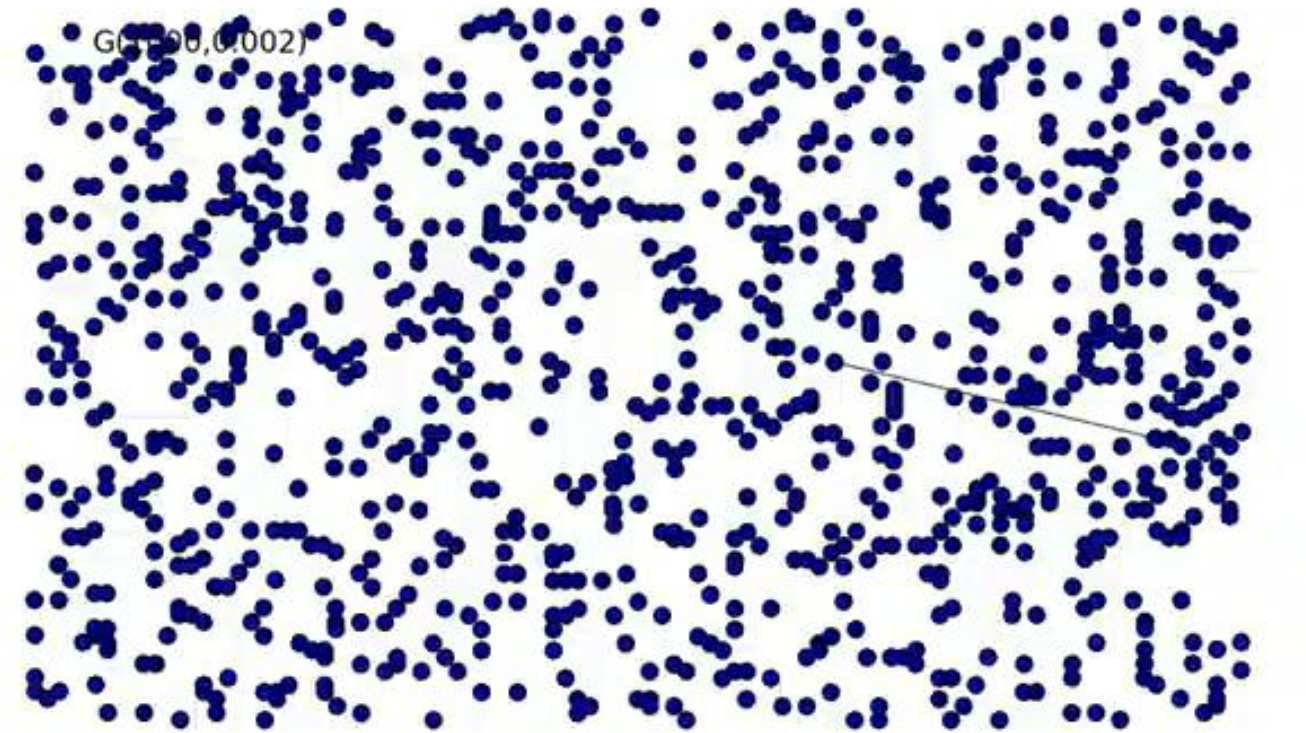
) Casuale – Componente Gigante





$N \to \infty$, sotto la soglia la frazione dei nodi appartenenti alla componente maggiore tende a zero

Grafo Casuale – Componente Gigante



https://www.youtube.com/@EPFLNooC

Grafo Casuale – Connettività della Rete

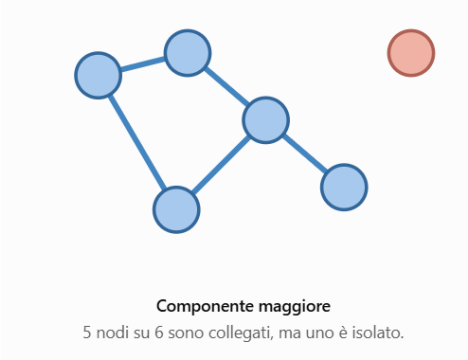
Quando diventa connessa tutta la rete?

$\langle k \rangle_c \sim \log(N)$

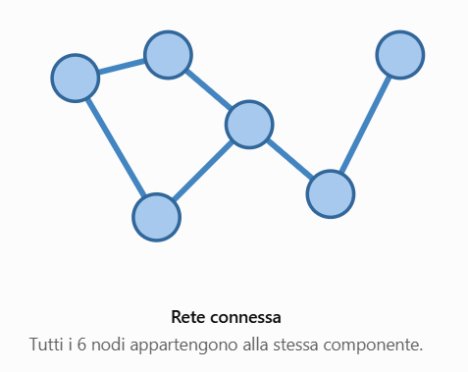
Per **connettività completa** (full connectivity) si intende la condizione in cui tutti i nodi della rete appartengono a un'unica componente connessa.

Ad esempio, per $n = 1000$:

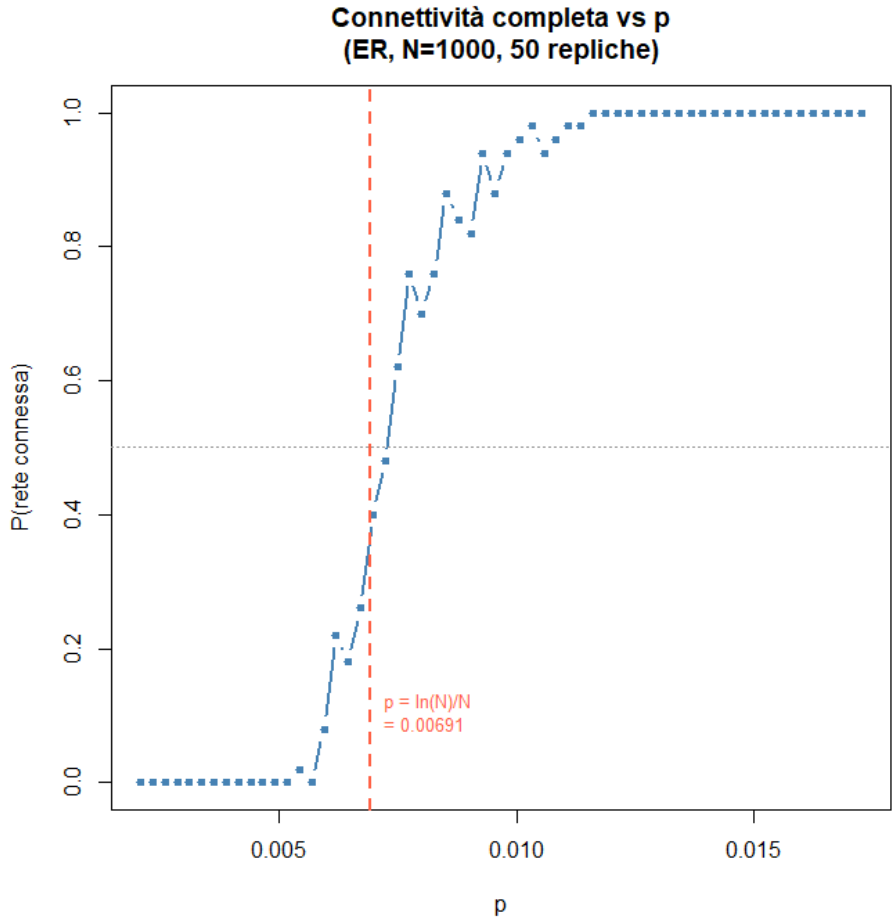
$\ln(1000) \approx 6.91$



Componente maggiore
5 nodi su 6 sono collegati, ma uno è isolato.



Rete connessa
Tutti i 6 nodi appartengono alla stessa componente.



Connettività Completa

La rete diventa connessa con probabilità crescente quando p attraversa la regione critica $\frac{\ln(N)}{N}$, molto dopo la comparsa della componente gigante, che avviene attorno a $p = 1/N$.

$$p_c = \frac{\ln(1000)}{1000} \approx 0.00691$$

Attenzione: non significa che a $p = p_c$ la rete diventi certamente connessa!

Grafo Casuale – Distanza tra nodi

In una rete connessa, la distanza media è la media delle lunghezze dei cammini minimi tra tutte le coppie di nodi distinti.

$$\bar{d} = \frac{1}{n(n-1)} \sum_{i \neq j} d_{ij}$$

Per reti disconnesse, la distanza media può essere calcolata sulla componente connessa maggiore (LCC)

Come cambia la distanza media quando aumentiamo il numero di nodi o la probabilità di collegamento?

Grafo Casuale – Distanza tra nodi

Come cambia la distanza media quando aumentiamo il numero di nodi o la probabilità di collegamento?

$$\bar{d} \sim \frac{\ln n}{\ln \langle k \rangle}$$

Conseguenza: mantenendo costante il grado medio, la distanza media cresce approssimativamente come $\ln n$, non proporzionalmente a n

Grafo Casuale – Distanza tra nodi

La distanza media cresce approssimativamente come $\ln n$, non proporzionalmente a n

$$\bar{d} \sim \frac{\ln n}{\ln \langle k \rangle}$$

Esempio

$\langle k \rangle = 4$

$$\bar{d} = \frac{\ln n}{\ln 4}$$

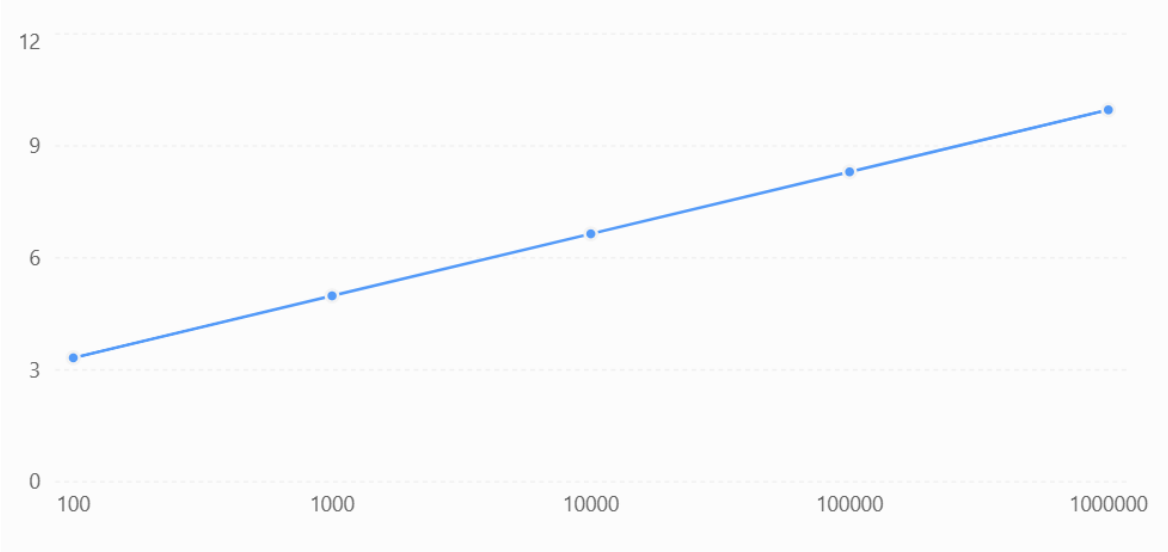
Numero di nodi n	Distanza media stimata
100	3,32
1.000	4,98
10.000	6,64
100.000	8,30
1.000.000	9,97

Grafo Casuale – Distanza tra nodi

La distanza media cresce approssimativamente come $\ln n$, non proporzionalmente a n

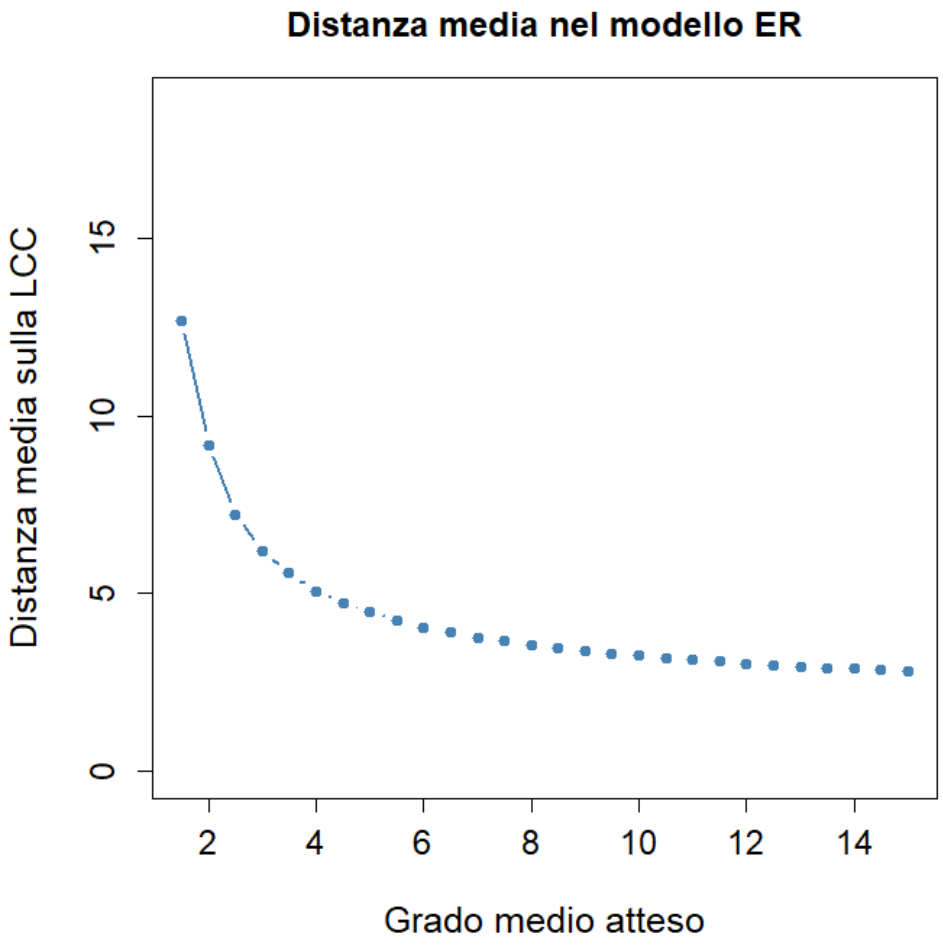
$$\bar{d} = \frac{\ln n}{\ln\langle k \rangle}$$

Comportamento è alla base della proprietà **small-world**



Small-world

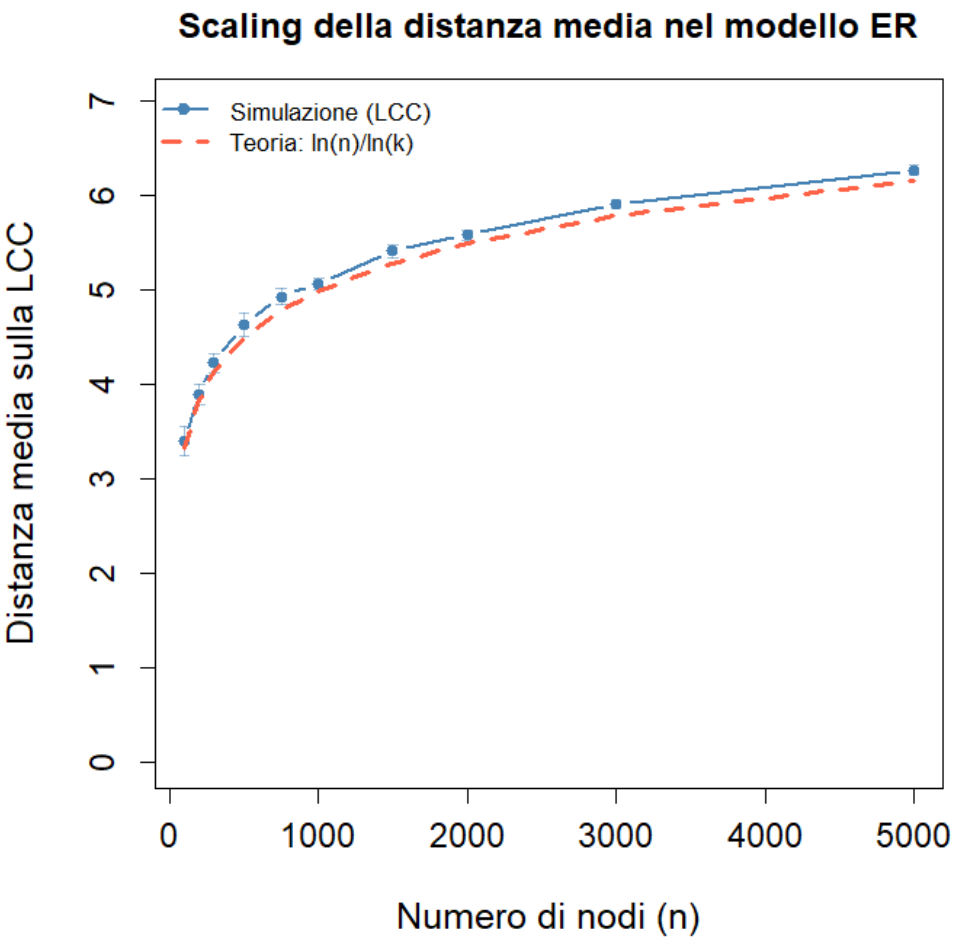
ıza tra Nodi



N=1000, aumentando il grado medio atteso da 1,5 a 15

La distanza media tra i nodi diminuisce all'aumentare del grado medio della rete.

nza tra Nodi



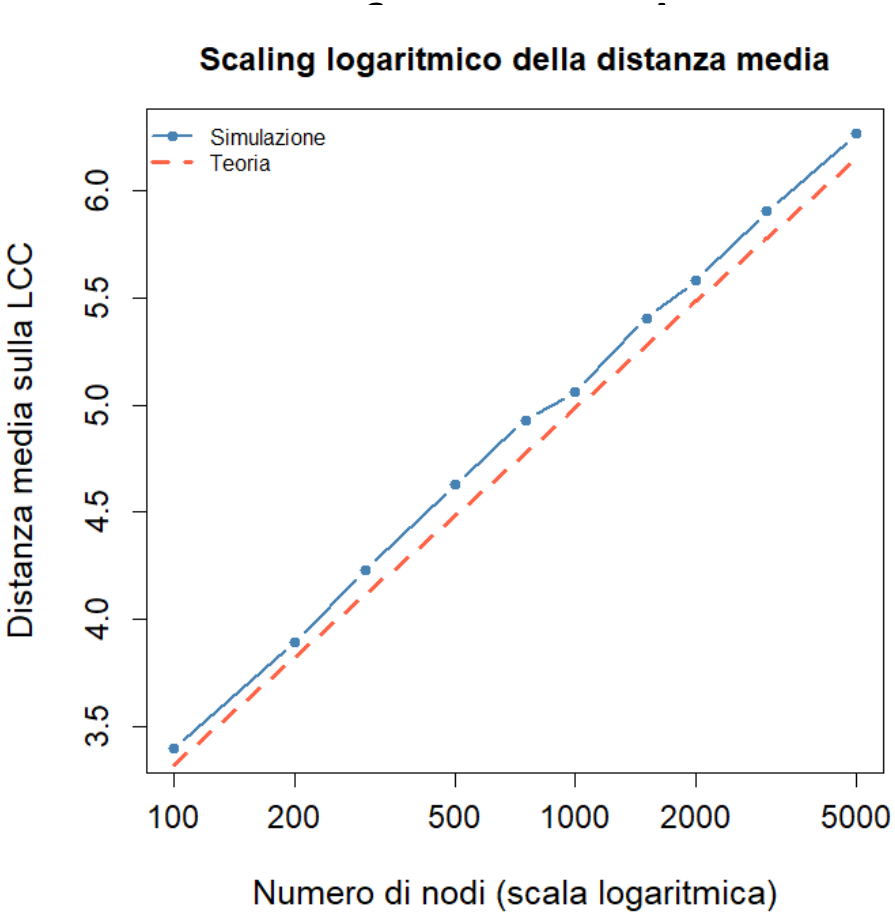
Numero di nodi crescente: da 100 a 5000.

Grado medio atteso costante 4.

La distanza media tra i nodi aumenta lentamente, seguendo approssimativamente una legge logaritmica

Aumentando il numero di nodi, la distanza media cresce soltanto logaritmicamente.

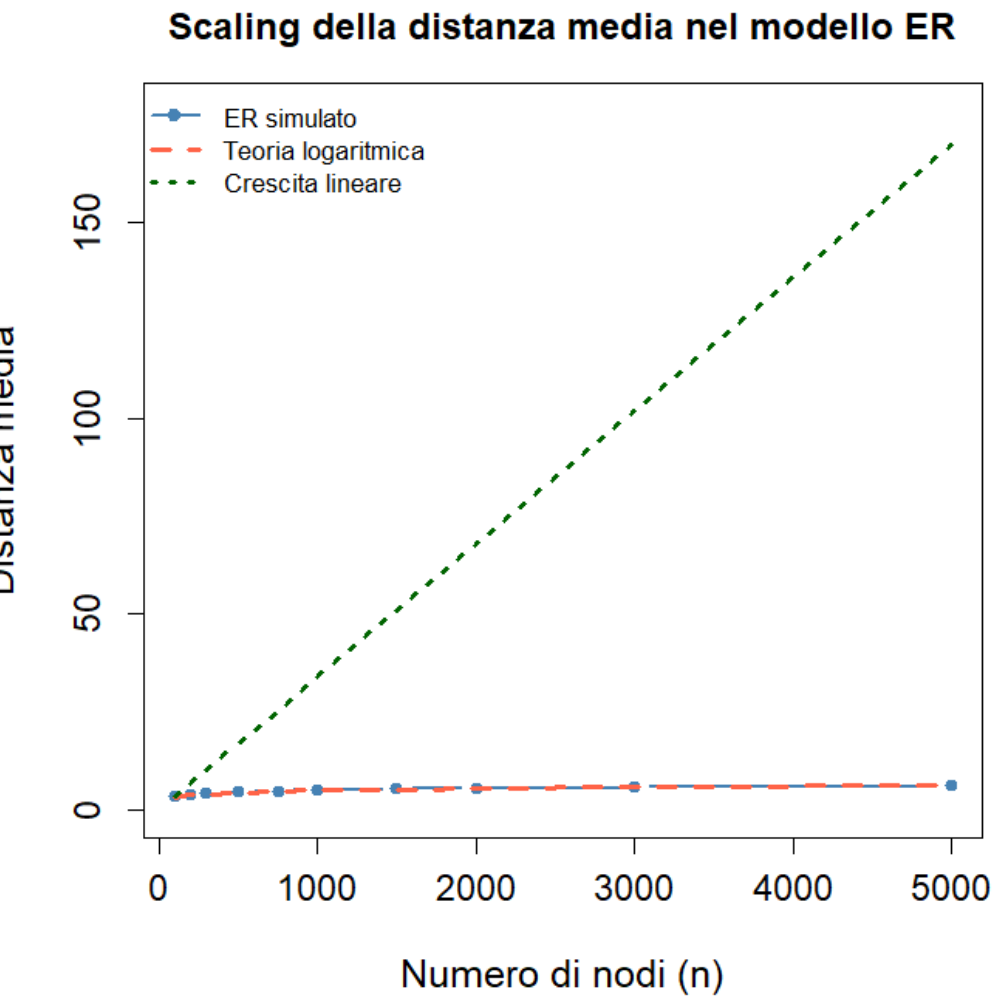
anza tra Nodi



Numero di nodi crescente: da 100 a 5000.

Grado medio 4.

La distanza media tra i nodi aumenta come una legge logaritmica



ıza tra Nodi

Numero di nodi crescente: da 100 a 5000.

Grado medio 4.

La distanza media tra i nodi aumenta come una legge logaritmica

La curva verde rappresenta una crescita lineare di riferimento, analoga a quella osservata in una rete a catena

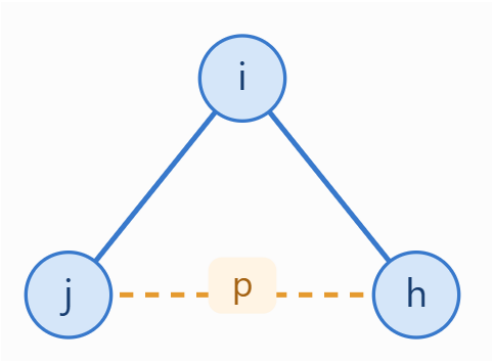
Grafo Casuale – Clustering

Nel modello Erdős–Rényi, ogni coppia di nodi è collegata indipendentemente con probabilità p.

Consideriamo un nodo i e due suoi vicini j e h.

La probabilità che esista anche il collegamento tra j e h è semplicemente p.

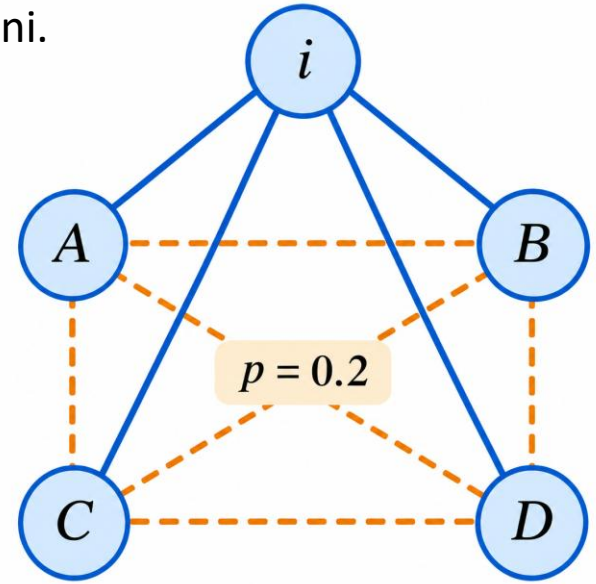
Il clustering locale atteso di un nodo con almeno due vicini è uguale alla probabilità di collegamento p.



Grafo Casuale – Clustering

Il clustering locale atteso di un nodo con almeno due vicini è uguale alla probabilità di collegamento p. Consideriamo un nodo i con quattro vicini.

$$p = 0.2 \qquad \frac{4(4-1)}{2} = 6$$



Quindi il numero atteso di collegamenti tra i vicini è:

$$\mathbb{E}[T_i \mid k_i = 4] = 6 \cdot 0.2 = 1.2$$

Il clustering locale atteso è:

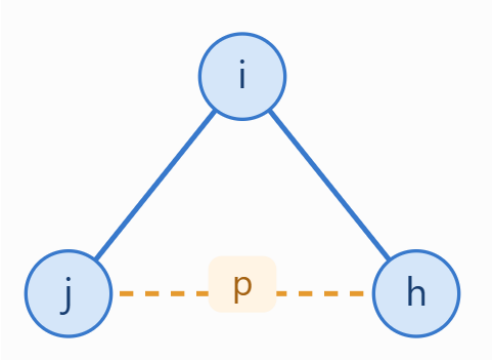
$$\mathbb{E}[C_i \mid k_i = 4] = \frac{1.2}{6} \qquad \mathbb{E}[C_i \mid k_i = 4] = 0.2 = p$$

Grafo Casuale – Clustering

Clustering e dimensione della rete

clustering locale atteso $\mathbb{E}[C_i \mid k_i \geq 2] = p$

Grado atteso $\langle k \rangle = (n-1)p$ ➡ $p = \dfrac{\langle k \rangle}{(n-1)}$



Per reti grandi, $n - 1 \approx n$:

$C \approx \dfrac{\langle k \rangle}{n}$ clustering medio calcolato sui nodi con grado almeno 2

Clustering diminuisce all'aumentare della dimensione della rete!

Grafo Casuale – Clustering

Clustering e dimensione della rete

$$C \approx \frac{\langle k \rangle}{n}$$

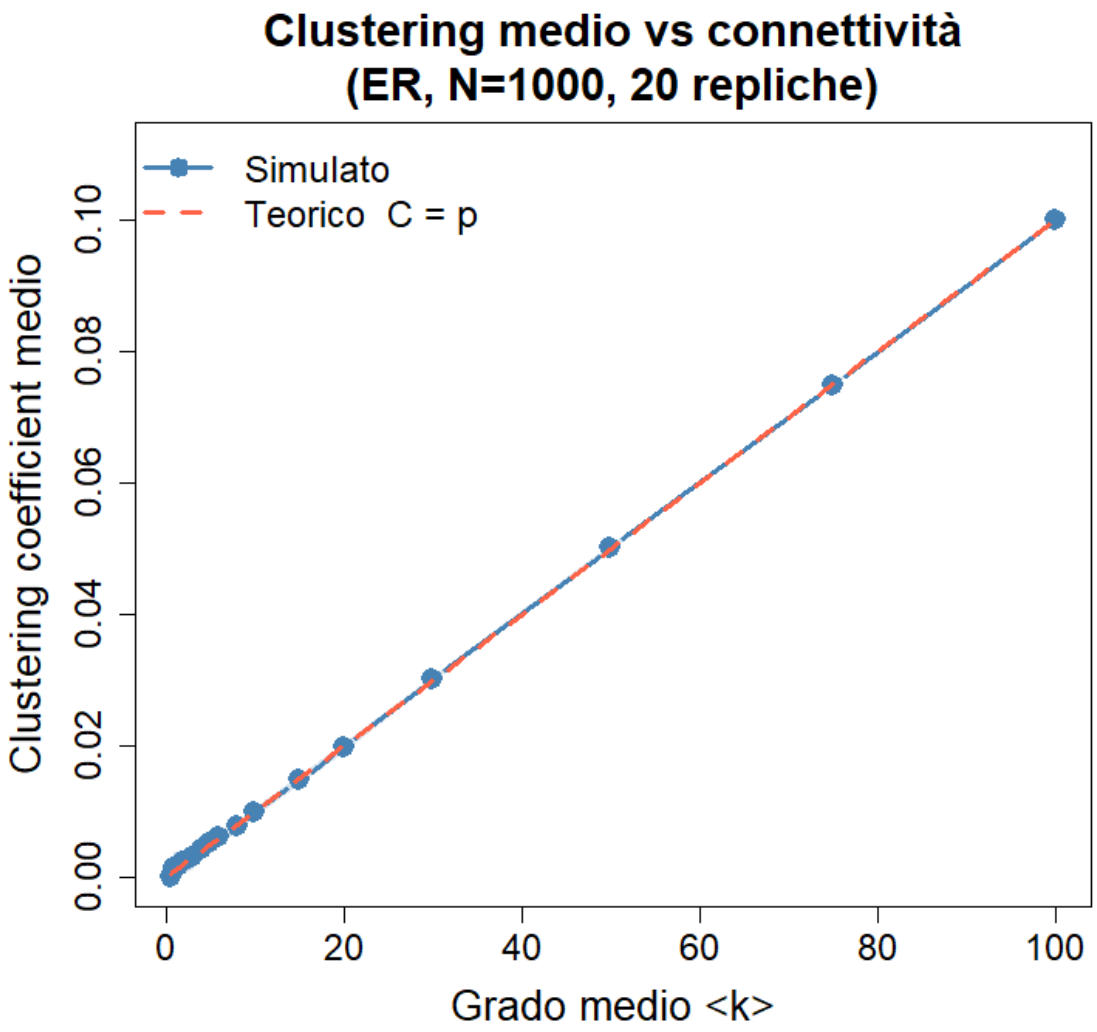
Clustering diminuisce all'aumentare della dimensione della rete!

Ad esempio, mantenendo $\langle k \rangle = 4$:

Numero di nodi	Clustering atteso p
100	0,0404
1.000	0,0040
10.000	0,0004
100.000	0,00004

Grafo Cas

Il clustering locale atteso di un nodo con almeno due vicini è uguale alla probabilità di collegamento p



Grafo Casu

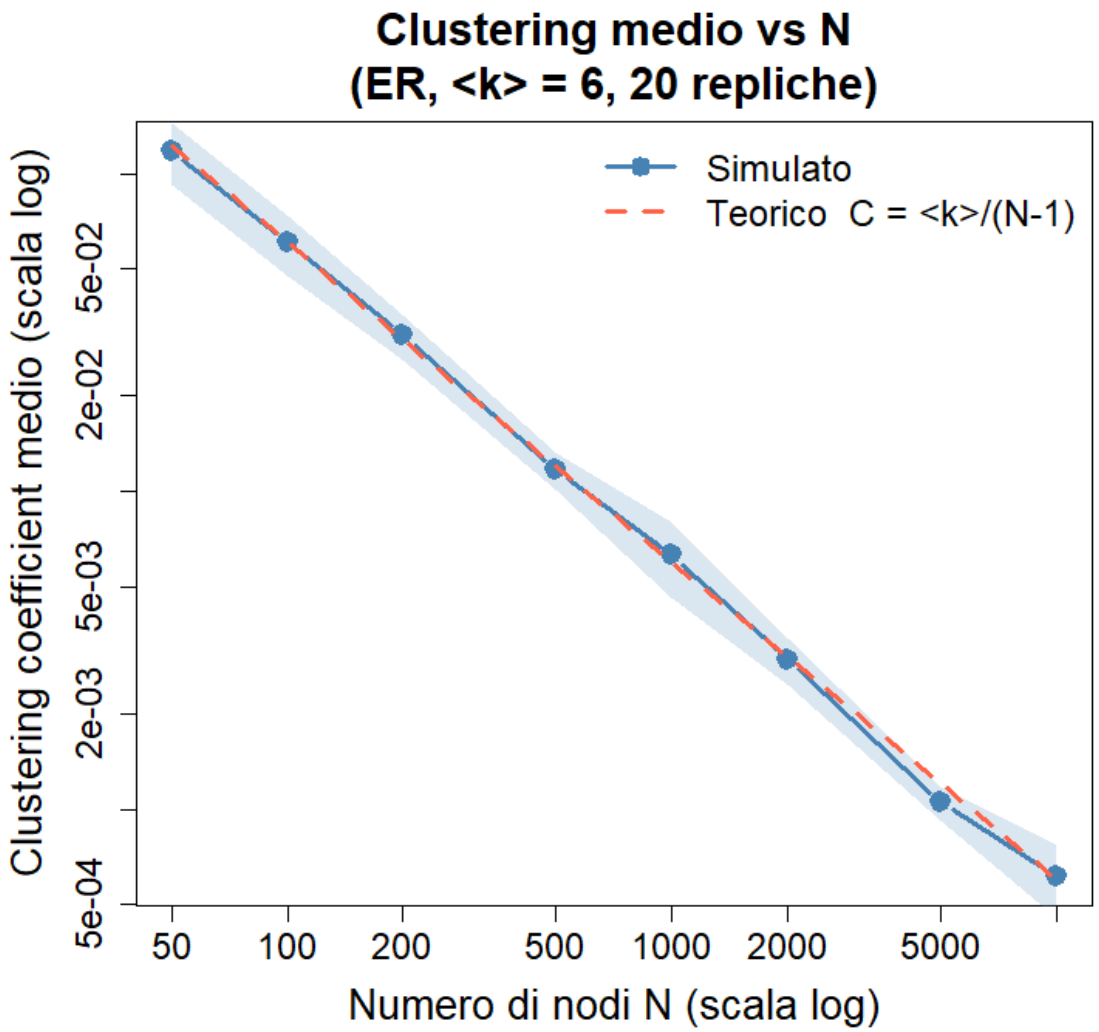
Clustering
Vs dimensione della rete

$$C \approx \frac{\langle k \rangle}{n}$$

Clustering diminuisce

all'aumentare della dimensione

della rete!



Grafo Casuale – Assortatività

Nel modello ER non esiste una preferenza per collegare nodi con gradi simili o differenti

La probabilità di creare un arco non dipende dal grado dei nodi.

Per reti grandi e sparse:

$n \to \infty$ $r \to 0$

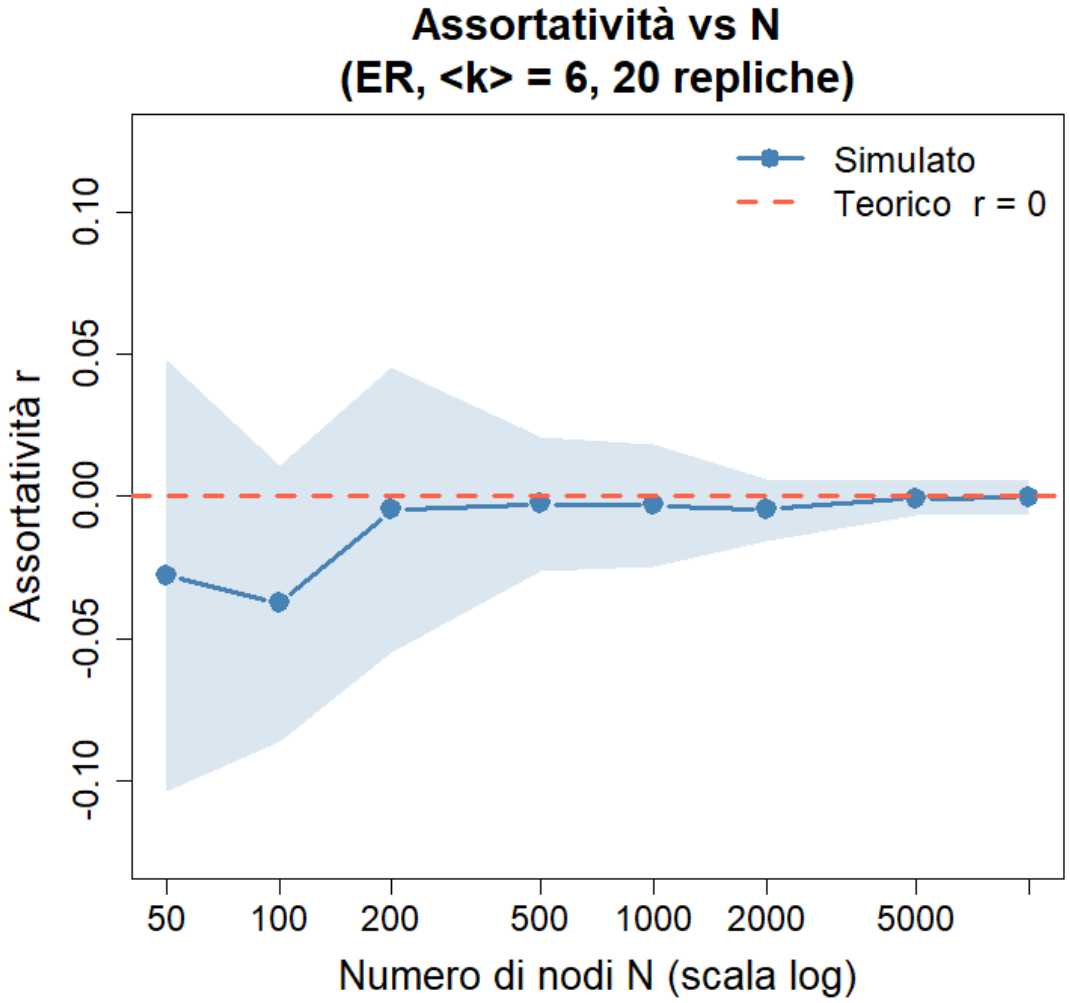
Dove r è il coefficiente di assortatività di grado di Newman.

Interpretazione: il modello ER è asintoticamente non assortativo.

Grafo Casu

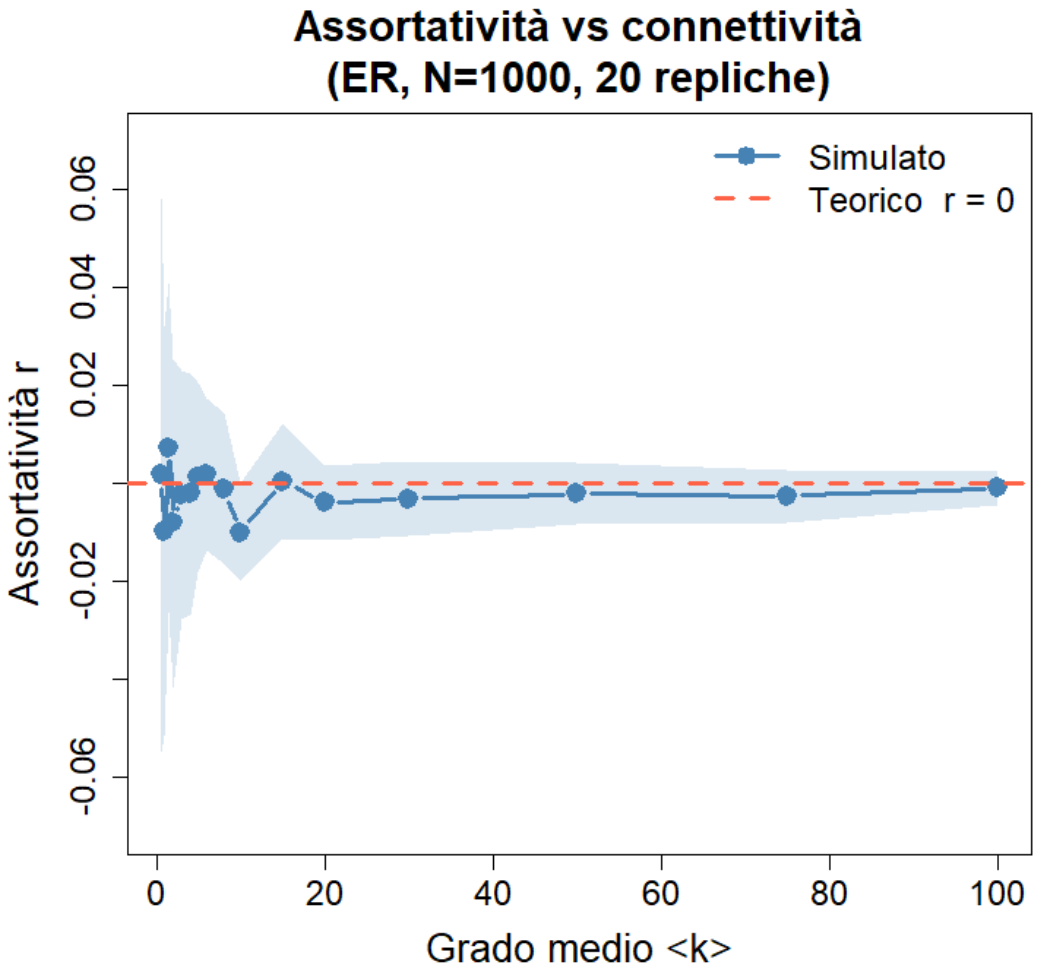
Per reti grandi e sparse:

$n \to \infty$ $r \to 0$



Grafo Casu

Aumentando notevolmente il grado medio, l'assortatività rimane molto vicina a zero

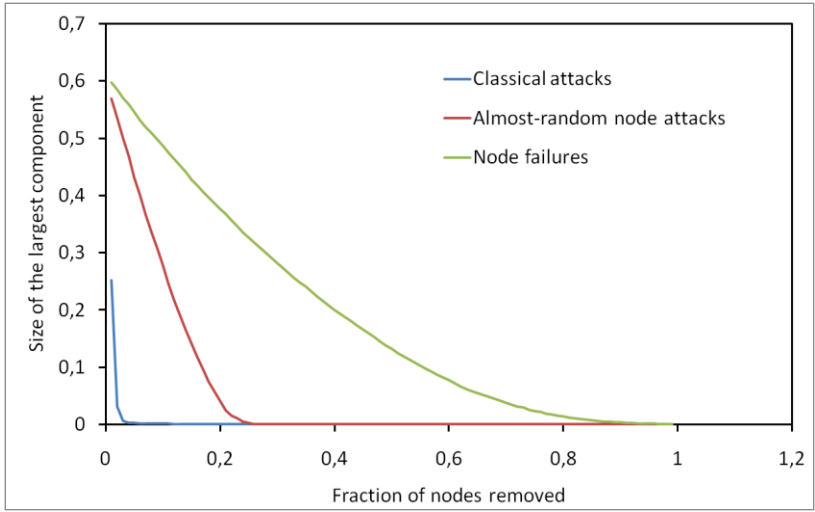


Grafo Casuale – Robustezza

La robustezza misura la capacità di una rete di mantenere la propria connettività quando vengono rimossi nodi o archi.

Nel modello ER consideriamo due strategie di rimozione:

- **Errore casuale**: i nodi vengono rimossi casualmente, indipendentemente dal loro grado.
- **Attacco mirato**: vengono rimossi prioritariamente i nodi con grado più elevato.



Grafo Casuale – Robustezza

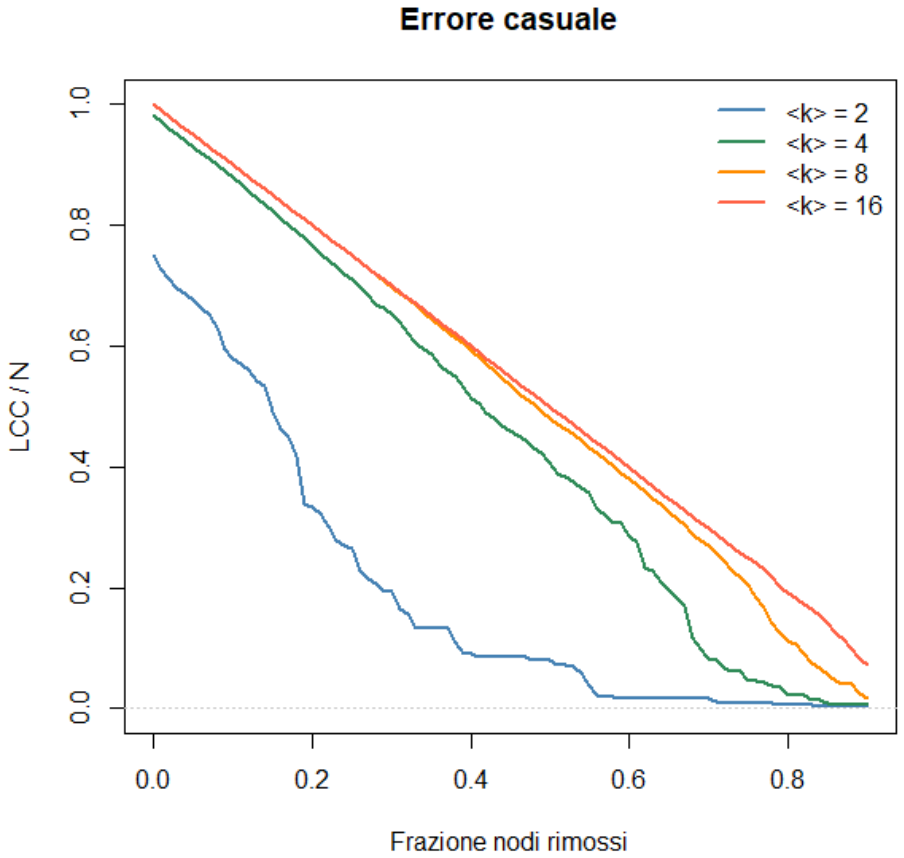
Come misuriamo la robustezza?

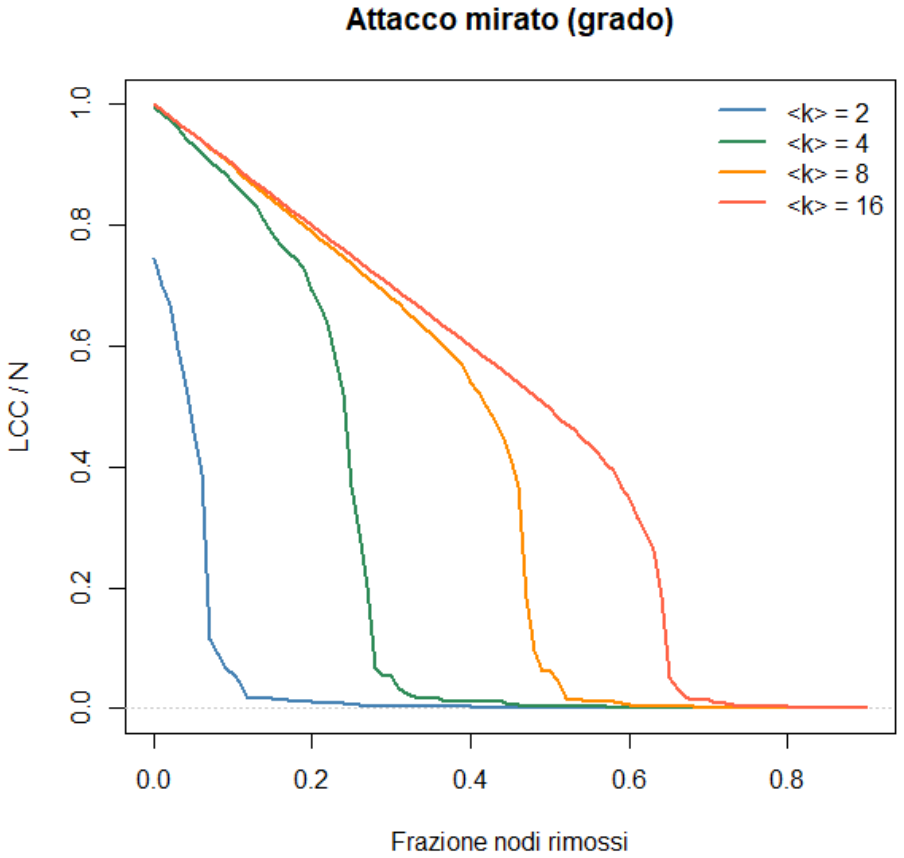
Più usata

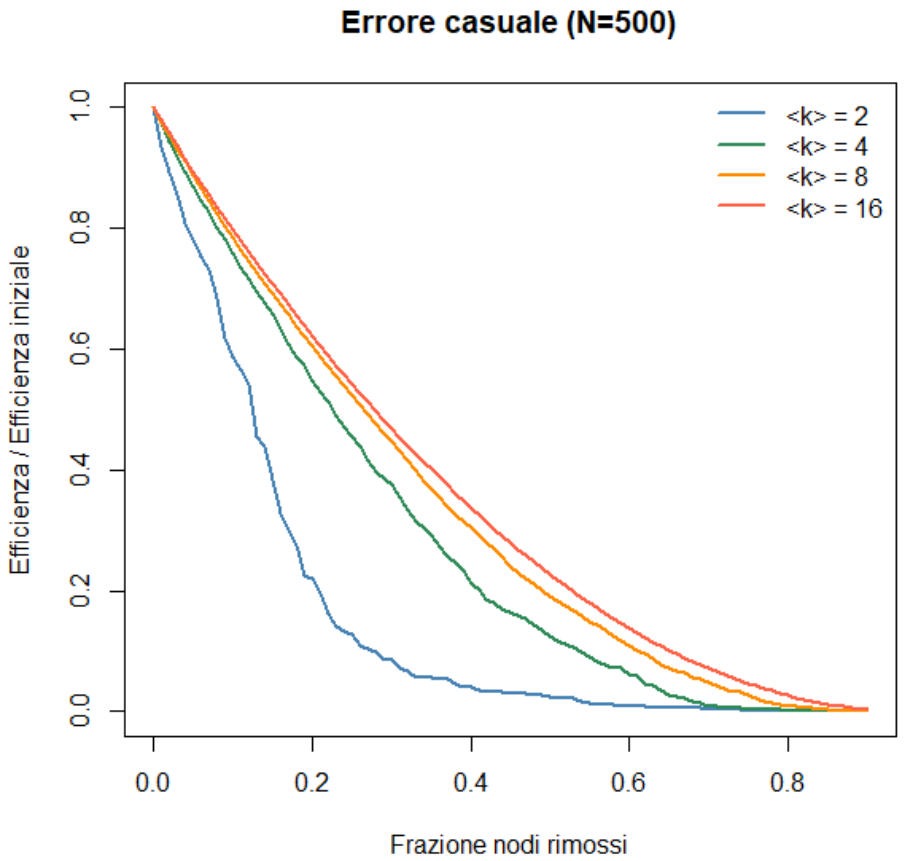
La dimensione relativa della componente connessa maggiore (LCC):

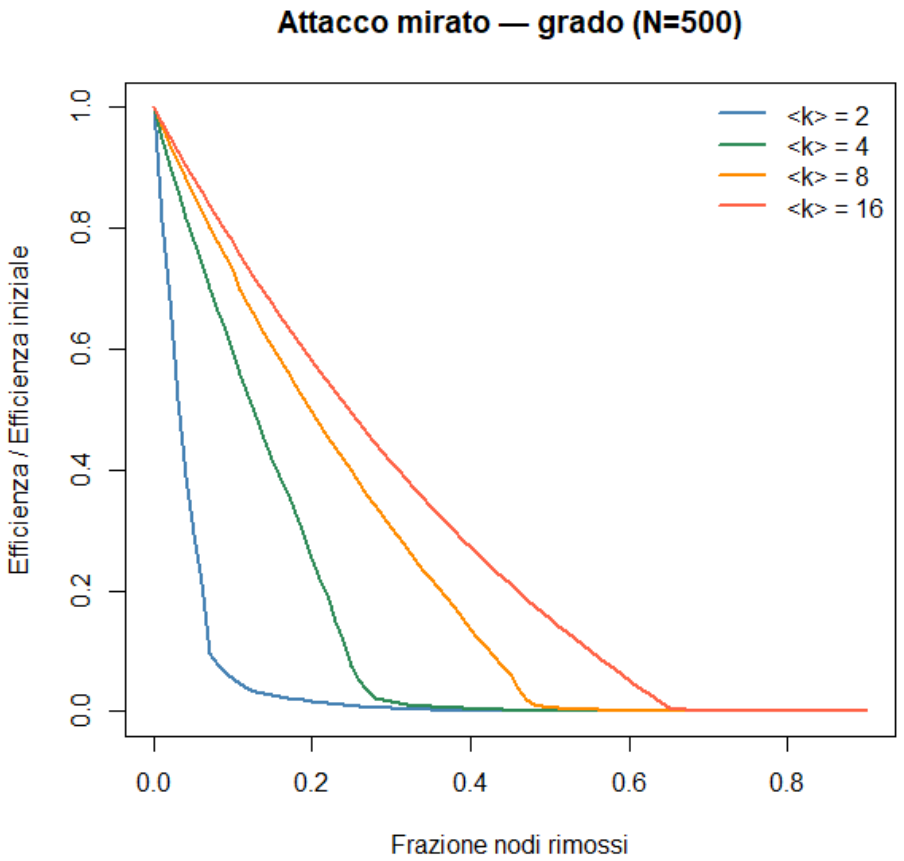
$$S(f) = \frac{N_{LCC}(f)}{N_0}$$

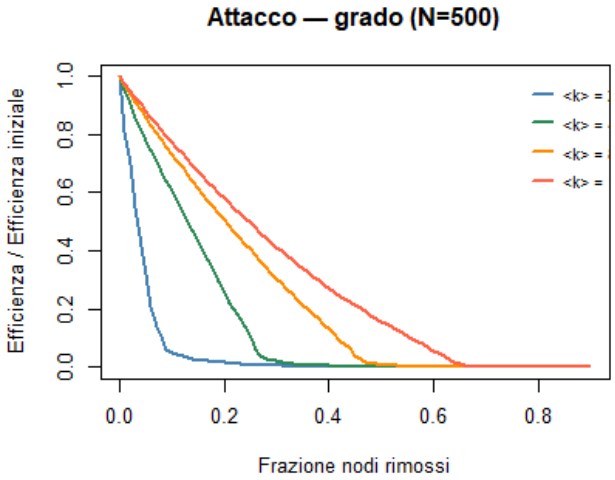
Dove f è la frazione di nodi rimossi e N_0 il numero iniziale di nodi.

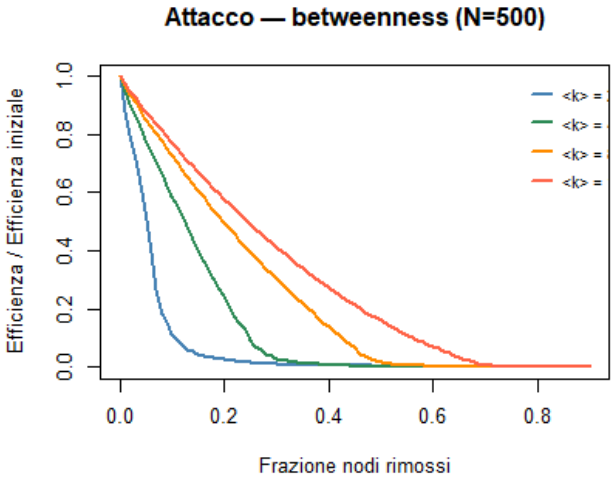

Errore casuale
LCC / N
Frazione nodi rimossi
<k> = 2
<k> = 4
<k> = 8
<k> = 16
0.0
0.2
0.4
0.6
0.8
1.0

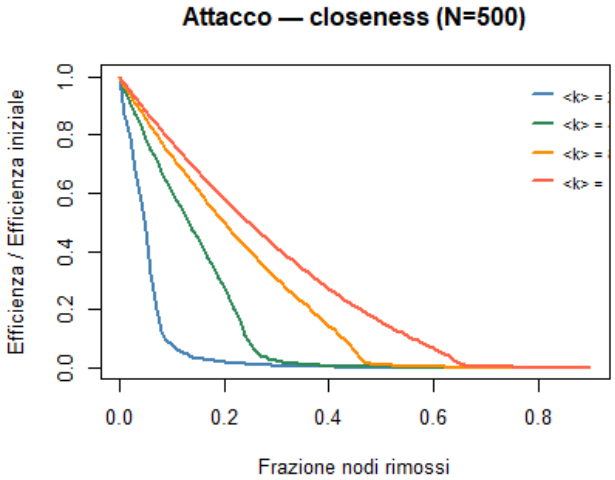

Attacco mirato (grado)
LCC / N
Frazione nodi rimossi
<k> = 2
<k> = 4
<k> = 8
<k> = 16
0.0
0.2
0.4
0.6
0.8
1.0

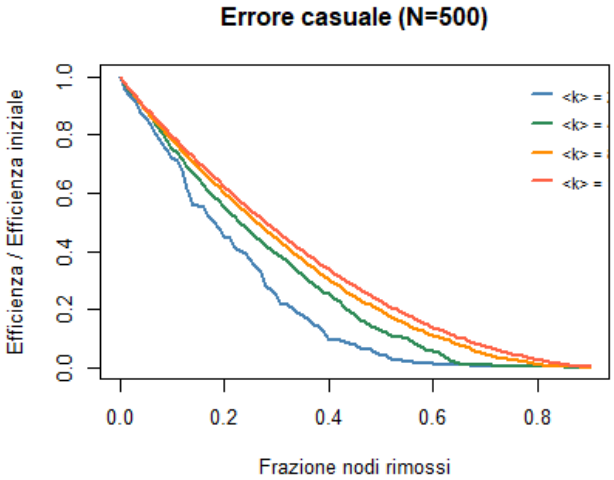

Errore casuale (N=500)
Efficienza / Efficienza iniziale
Frazione nodi rimossi
<k> = 2
<k> = 4
<k> = 8
<k> = 16
0.0
0.2
0.4
0.6
0.8
1.0

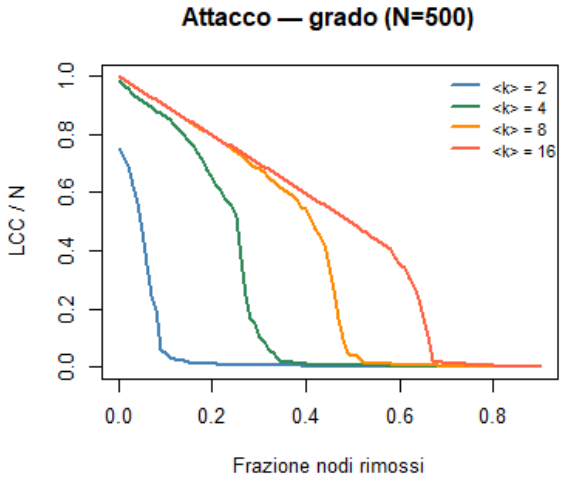

Attacco mirato — grado (N=500)
Efficienza / Efficienza iniziale
Frazione nodi rimossi
<k> = 2
<k> = 4
<k> = 8
<k> = 16
0.0
0.2
0.4
0.6
0.8
1.0

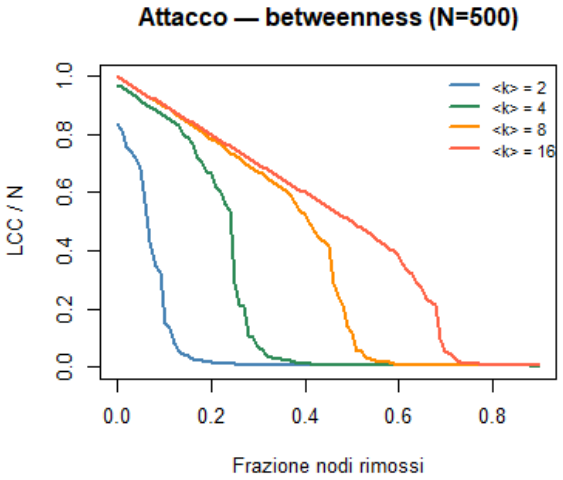

Attacco — grado (N=500)
Efficienza / Efficienza iniziale
Frazione nodi rimossi
<k> =
<k> =
<k> =
<k> =

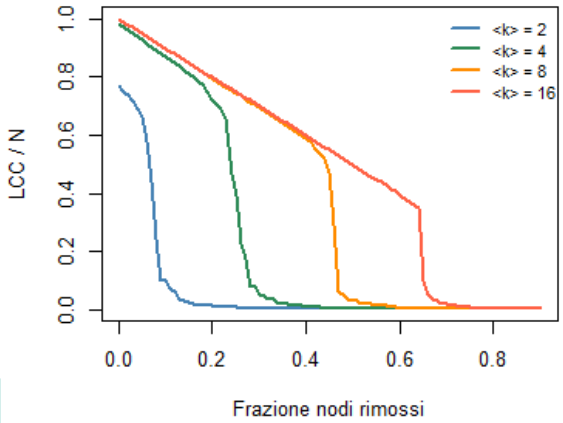

Attacco — betweenness (N=500)
Efficienza / Efficienza iniziale
Frazione nodi rimossi
<k> =
<k> =
<k> =
<k> =

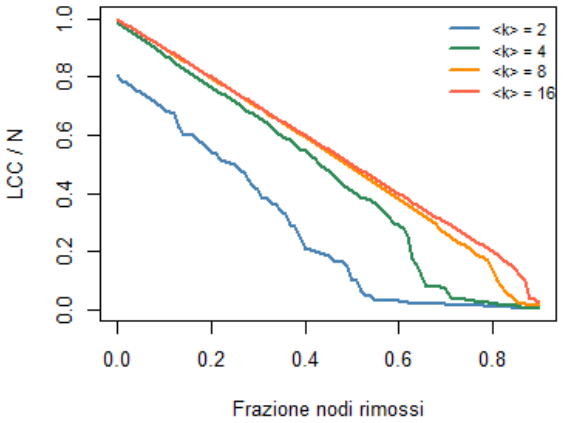

Attacco — closeness (N=500)
Efficienza / Efficienza iniziale
Frazione nodi rimossi
<k> =
<k> =
<k> =
<k> =


Errore casuale (N=500)
Efficienza / Efficienza iniziale
Frazione nodi rimossi
<k> =
<k> =
<k> =
<k> =

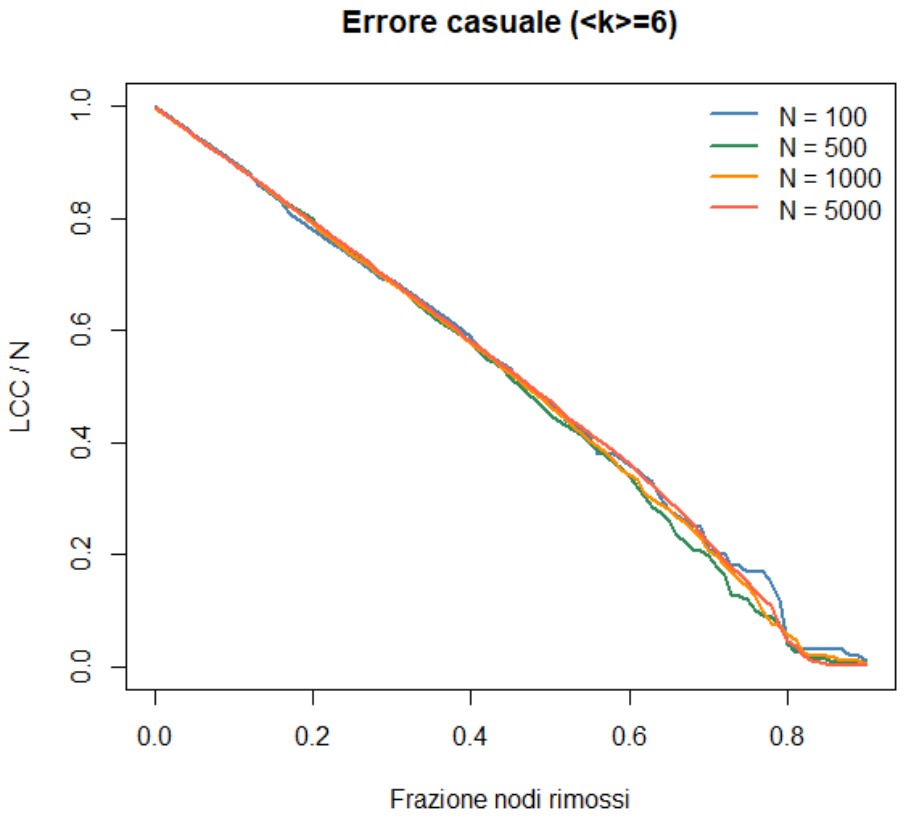

Attacco — grado (N=500)
LCC / N
Frazione nodi rimossi
<k> = 2
<k> = 4
<k> = 8
<k> = 16

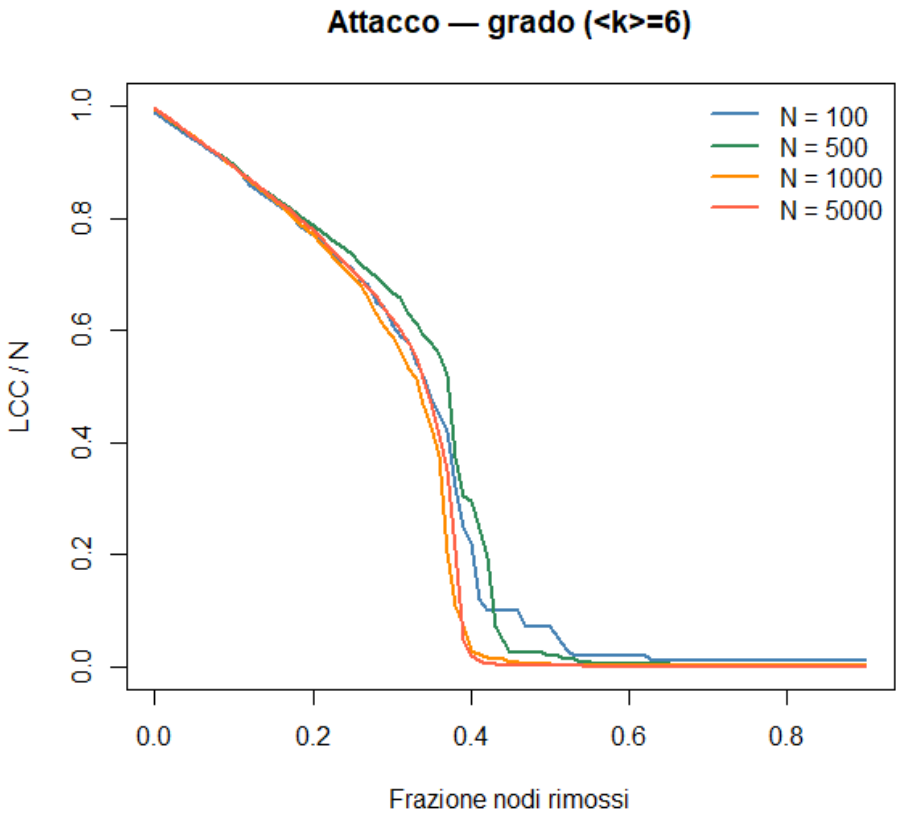

Attacco — betweenness (N=500)
LCC / N
Frazione nodi rimossi
<k> = 2
<k> = 4
<k> = 8
<k> = 16

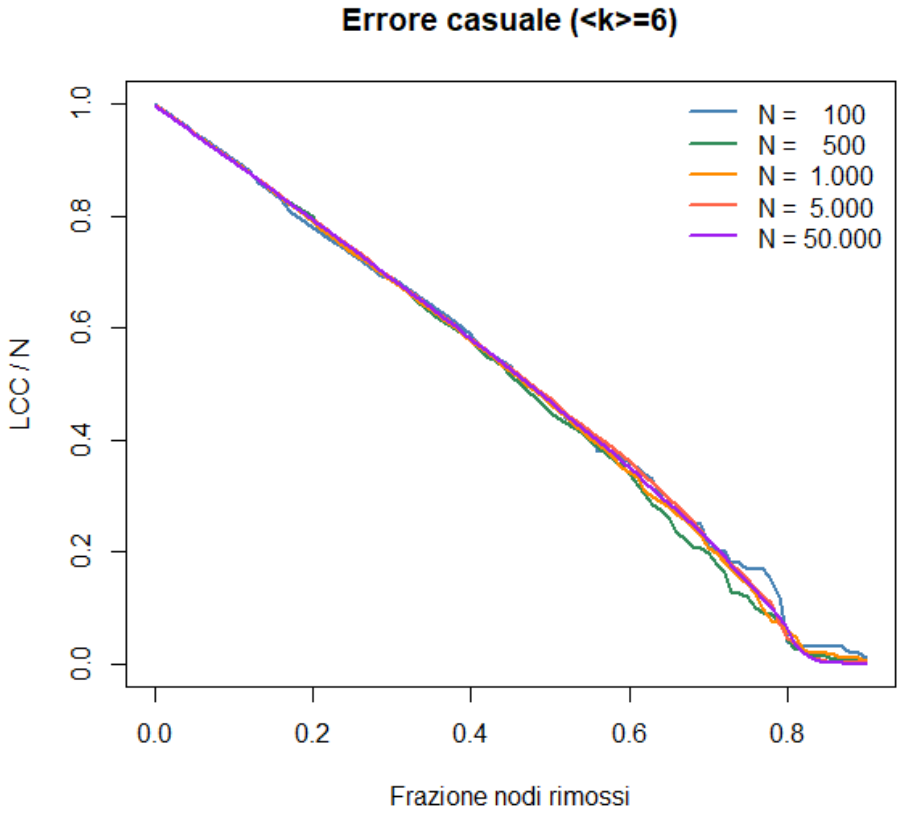

Attacco — closeness (N=500)
LCC / N
Frazione nodi rimossi
<k> = 2
<k> = 4
<k> = 8
<k> = 16

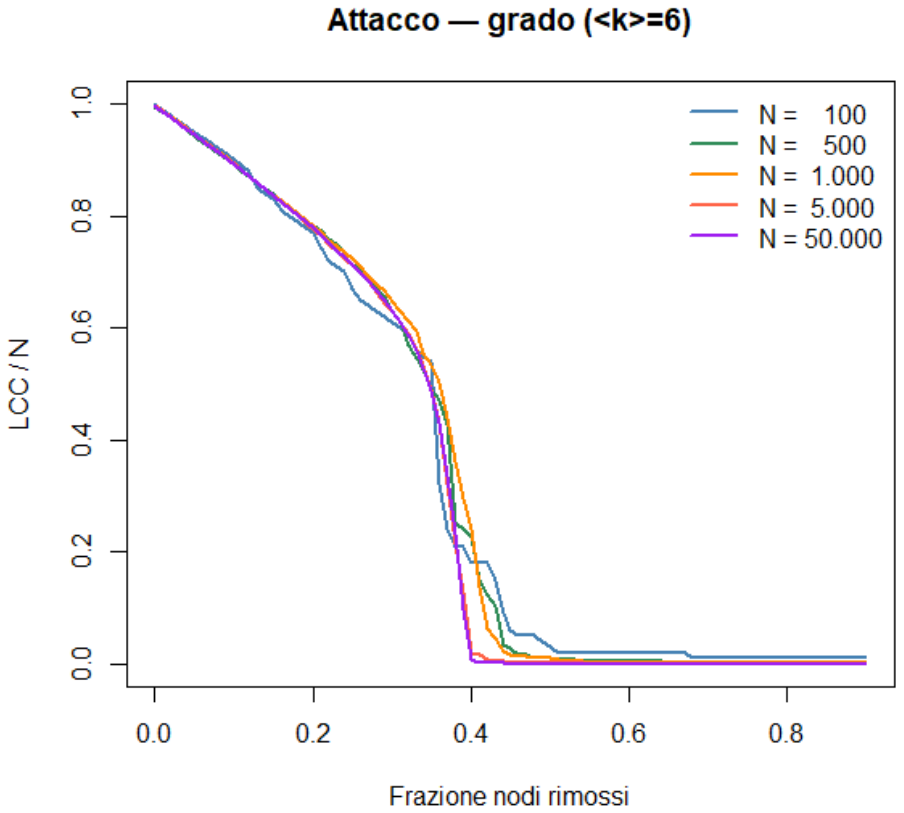

Errore casuale (N=500)
LCC / N
Frazione nodi rimossi
<k> = 2
<k> = 4
<k> = 8
<k> = 16

Grafo Casuale — Attacchi









Nel modello Erdős–Rényi, a grado medio costante, la robustezza relativa alla rimozione dei nodi converge a un comportamento indipendente dalla dimensione della rete.

Modello Watts-Strogatz

Perché nasce il modello Watts–Strogatz?

Modello Erdős–Rényi per reti grandi e sparse a grado medio costante:

$$\bar{d}_{\mathrm{ER}} \sim \frac{\ln n}{\ln\langle k\rangle}$$

Distanze relativamente piccole

$$C_{\mathrm{ER}} \approx \frac{\langle k\rangle}{n}$$

Clustering molto basso

Molte **reti reali**, soprattutto **sociali**, presentano invece:

- Distanze medie piccole tra i nodi.
- Clustering locale elevato.

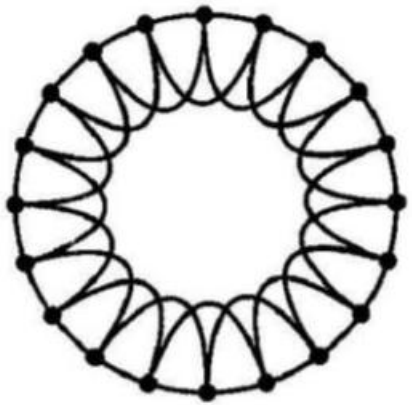
Small-World

Modello Watts-Strogatz

Grafo Small-World – Il modello Watts–Strogatz

Il modello parte da un **reticolo regolare ad anello**, nel quale ogni nodo è collegato ai suoi K vicini più prossimi, con K pari.

K=4



$$\frac{K}{2} \text{ vicini a sinistra e } \frac{K}{2} \text{ vicini a destra}$$

Alto Clustering

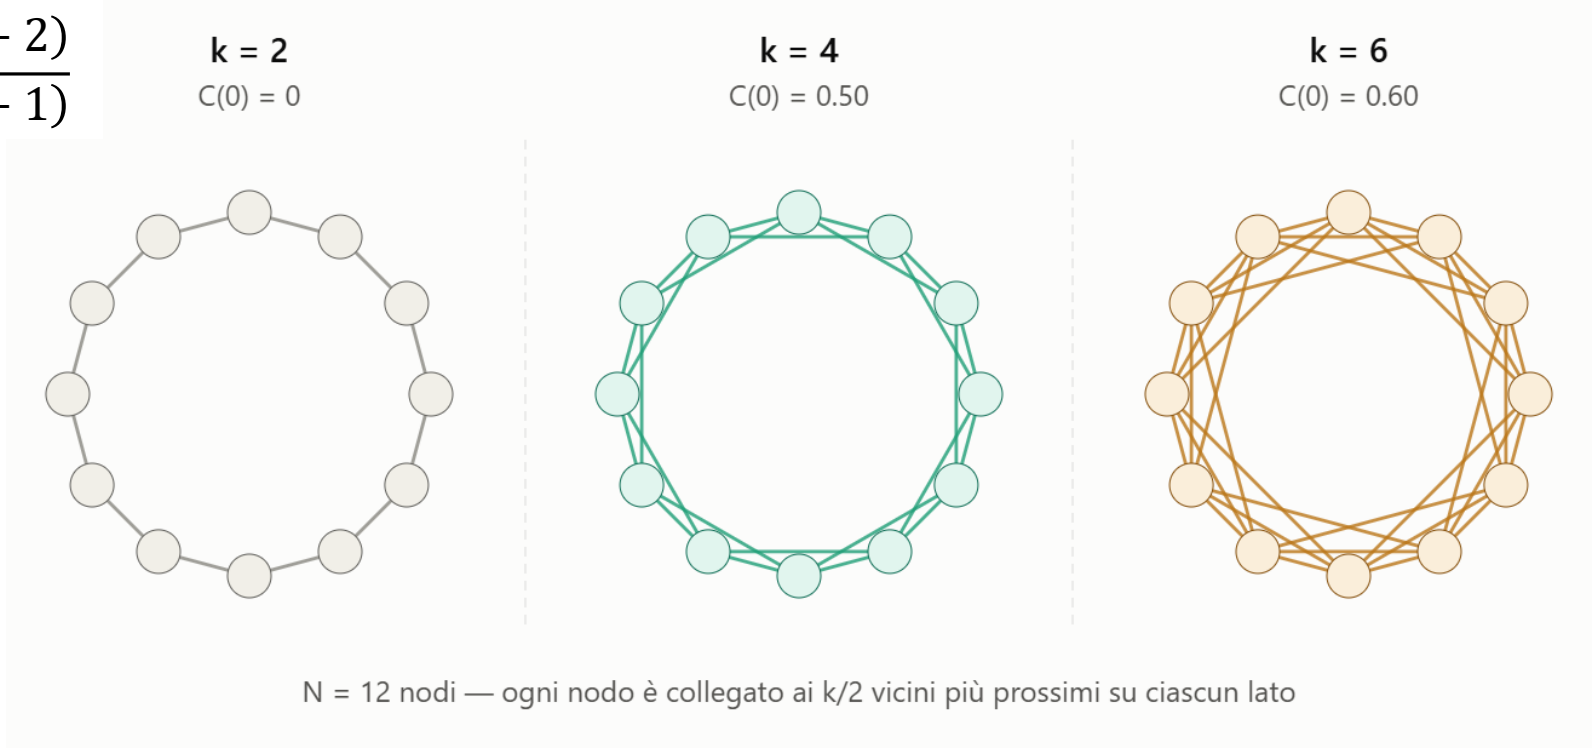
Alta distanza

Proprietà	Reticolo regolare ad anello	Grafo casuale ER
Clustering	$C = \frac{3(K-2)}{4(K-1)}$	$C \approx p$
Distanza media	$\langle d \rangle \sim \frac{n}{2K}$	$\langle d \rangle \sim \frac{\ln n}{\ln \langle k \rangle}$
Struttura	Ordinata e locale	Casuale

Modello Watts-Strogatz

Reticolo regolare ad anello: ogni nodo è collegato ai suoi K vicini più prossimi, con K pari.

$$C(0) = \frac{3(K-2)}{4(K-1)}$$

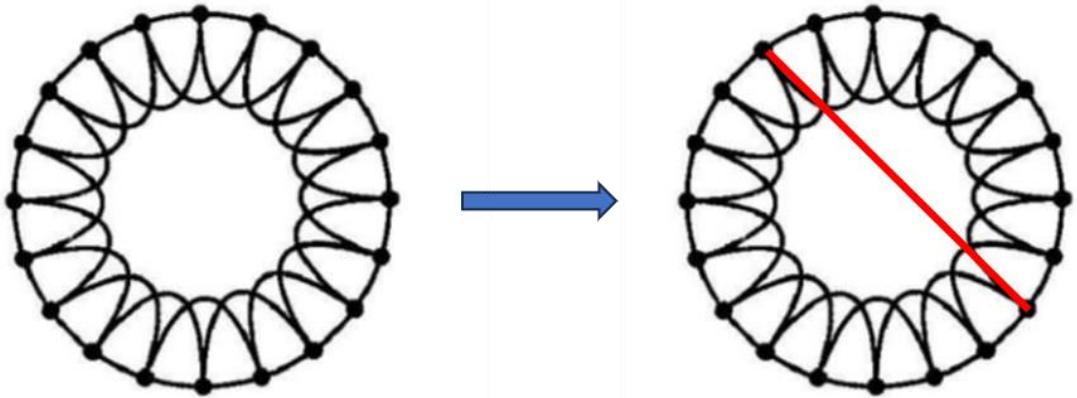


Modello Watts-Strogatz

Grafo Small-World – Il modello Watts–Strogatz

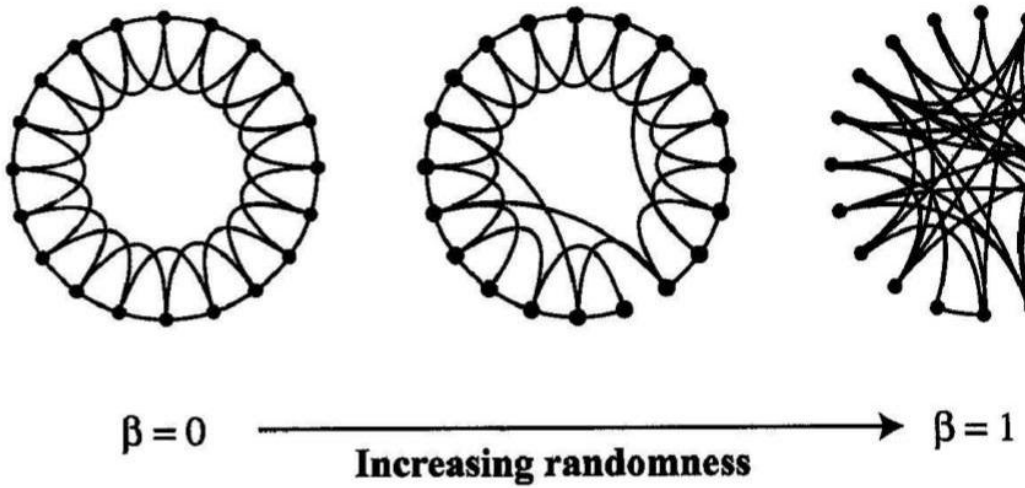
Reticolo regolare ad anello con K pari.

Ogni arco locale viene considerato per il rewiring con probabilità β: uno dei due estremi rimane fisso, mentre l'altro può essere collegato a un nodo scelto a caso



Modello Watts-Strogatz

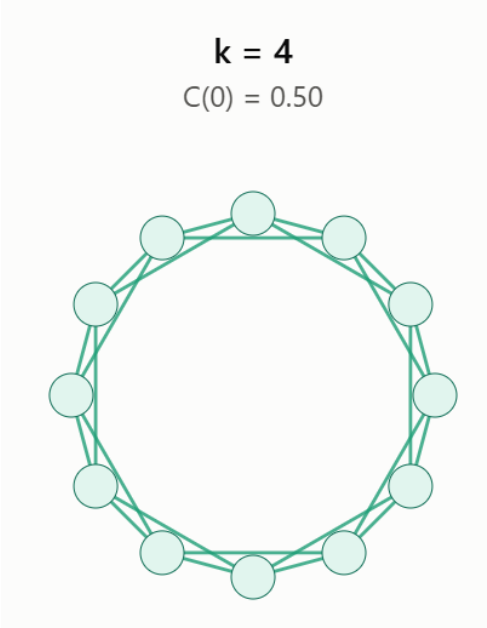
D. J. Watts and Steven Strogatz (June 1998).
"Collective dynamics of 'small-world' networks".
Nature 393 (6684): 440–442.



Il rewiring conserva il numero totale di archi e il grado medio,

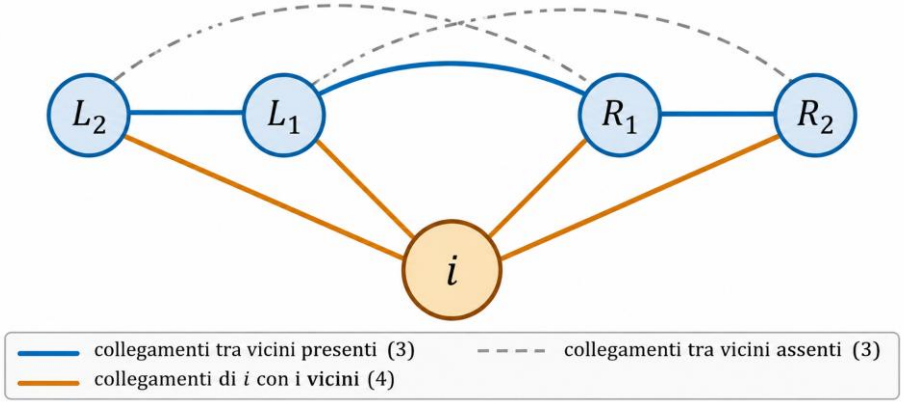
ma introduce collegamenti a lunga distanza.

Modello Watts-Strogatz



$$C(i) = \frac{collegamente\ presenti\ tra\ vicini}{collegamenti\ possibili\ tra\ vicini}$$

esempio con $K = 4$



Triple possibili:

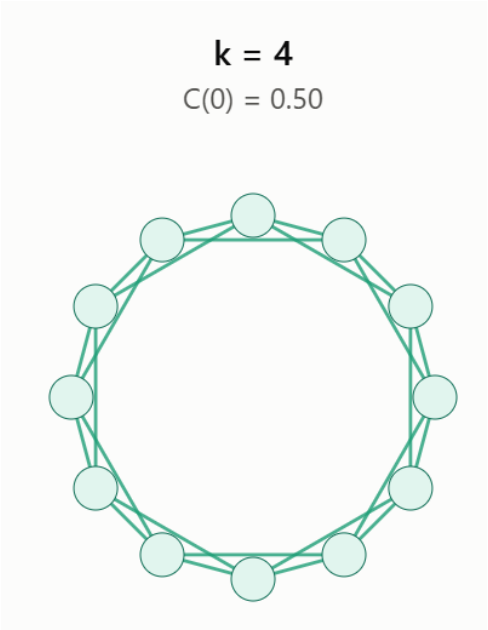
$$M_i = \frac{K(K-1)}{2}$$

$$= \frac{4(4-1)}{2} = \frac{12}{2} = 6$$

Triple realizzate:

$$T_i = 3$$

Modello Watts-Strogatz



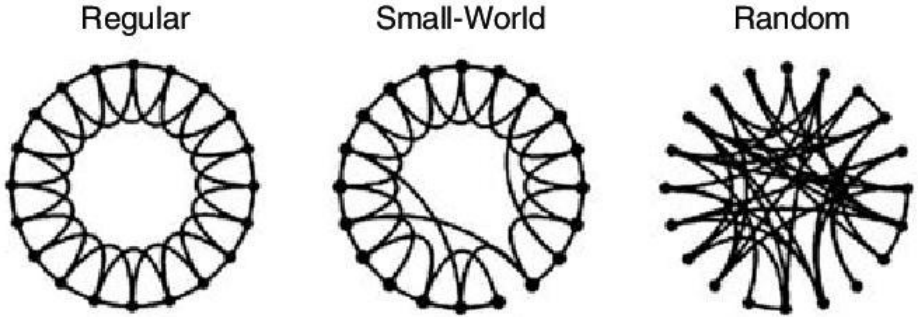
$$C(i) = \frac{collegamente\ presenti\ tra\ vicini}{collegamenti\ possibili\ tra\ vicini}$$

$$C(0) = \frac{3(K-2)}{4(K-1)}$$

esempio con $K = 4$

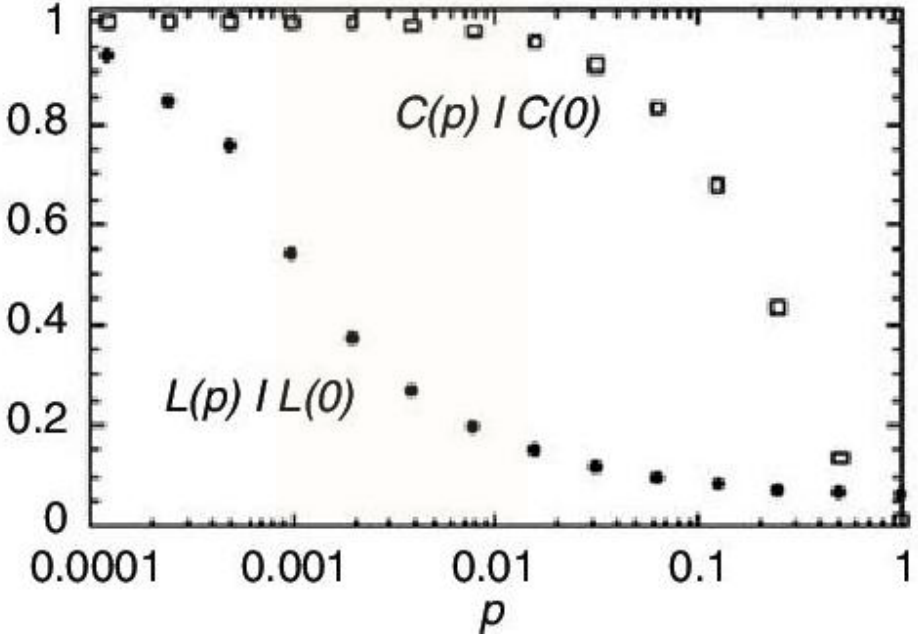
$$C(0) = \frac{3(4-2)}{4(4-1)} = \frac{3(2)}{4(3)} = \frac{6}{12} = 0.5$$

Modello Watts-Strogatz

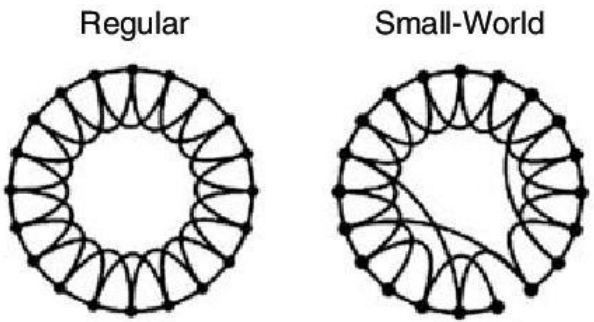


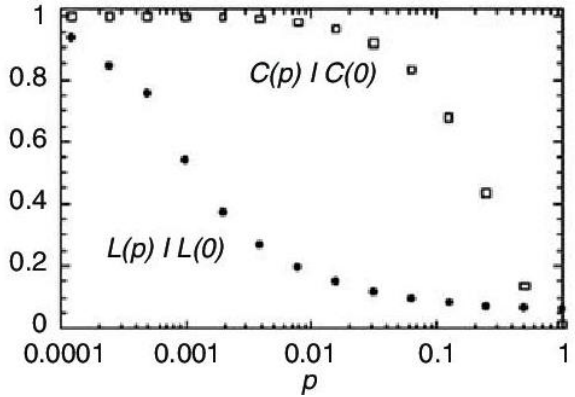
- $L(\beta)$: distanza media per una prob. di rewiring β
- C(β): clustering medio per una prob. di rewiring β
- $C(0)$ e $L(0)$: valori del reticolo regolare iniziale.

$\langle k \rangle$ medio, costante durante il rewiring



Modello Watts-Strogatz





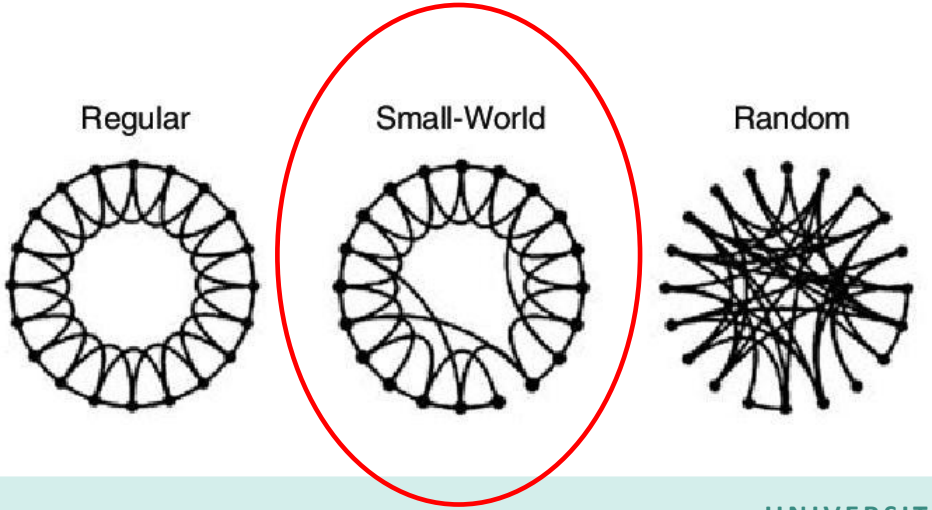
- Un singolo collegamento ricablato può connettere due regioni lontane del reticolo.
- Scorciatoia che può accorciare i cammini minimi tra moltissime coppie di nodi.
- Il clustering, invece, dipende dai collegamenti locali tra i vicini.
- Quando vengono ricablati pochi archi, molti triangoli locali rimangono intatti.

Modello Watts-Strogatz

Regione Small-World

Il modello Watts–Strogatz presenta una regione intermedia nella quale coesistono:

- **Clustering elevato**, simile a quello del reticolo regolare.
- **Distanza media piccola**, simile a quella di una rete randomizzata.

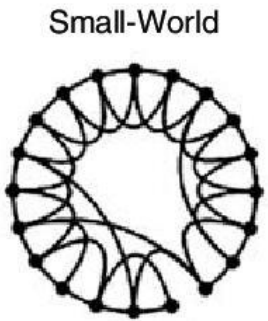


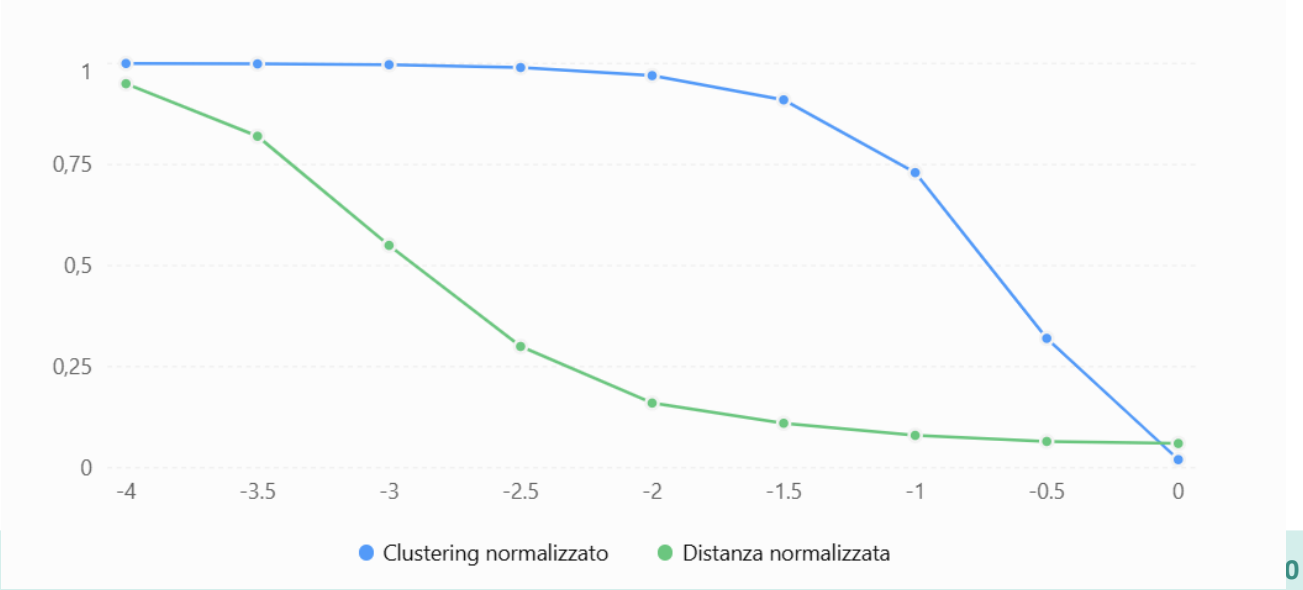
Modello Watts-Strogatz

Regione Small-World

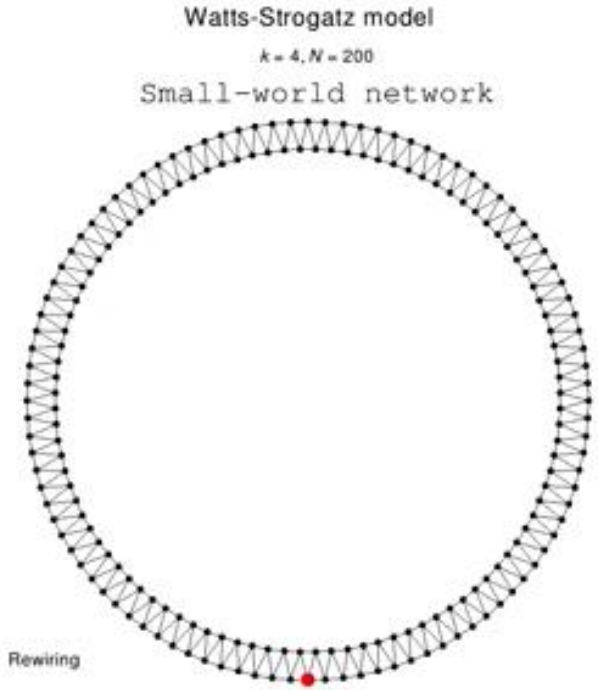
Il modello Watts–Strogatz presenta una regione intermedia nella quale coesistono:

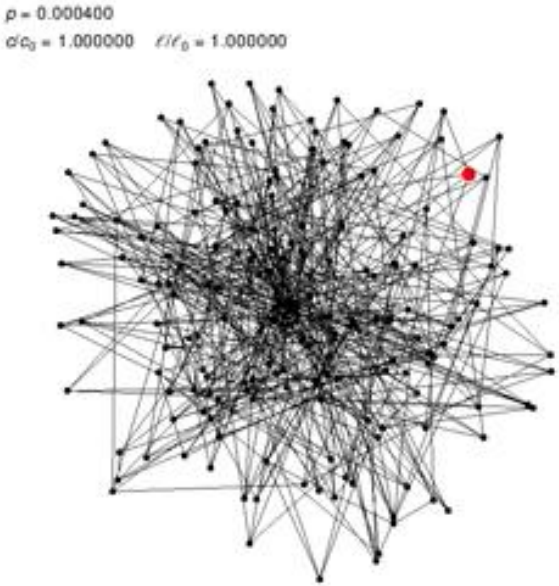
- **Clustering elevato**, simile a quello del reticolo regolare.
- **Distanza media piccola**, simile a quella di una rete randomizzata.





Modello Watts-Strogatz



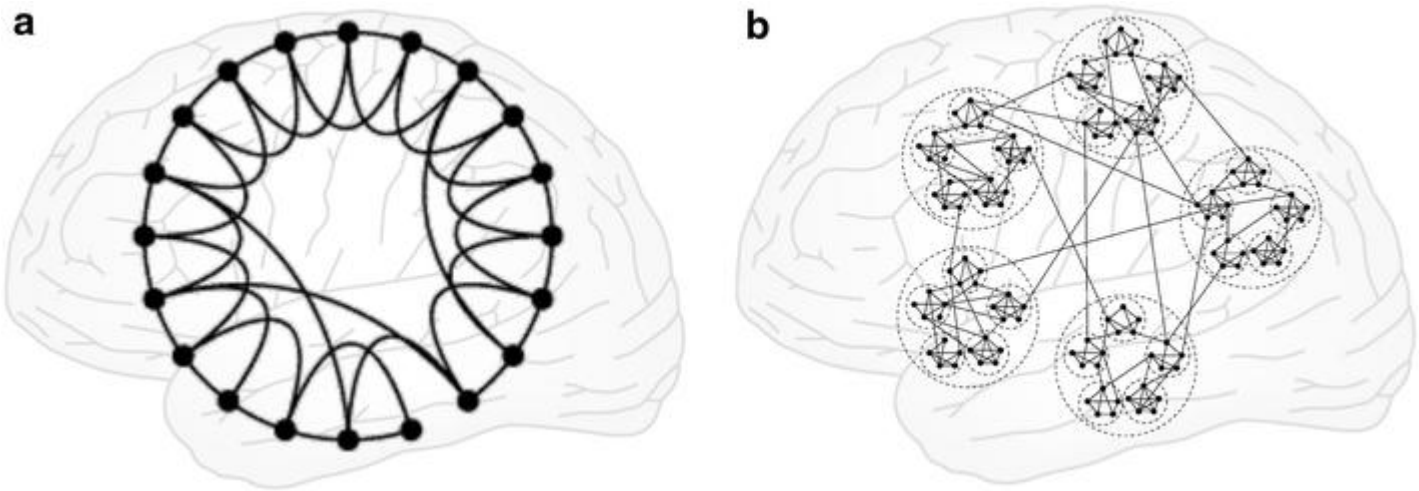


Mo atz



Modello Watts-Strogatz

Is the brain really a small-world network?



https://link.springer.com/article/10.1007/s00429-015-1035-6

Modello Watts-Strogatz - Assortatività

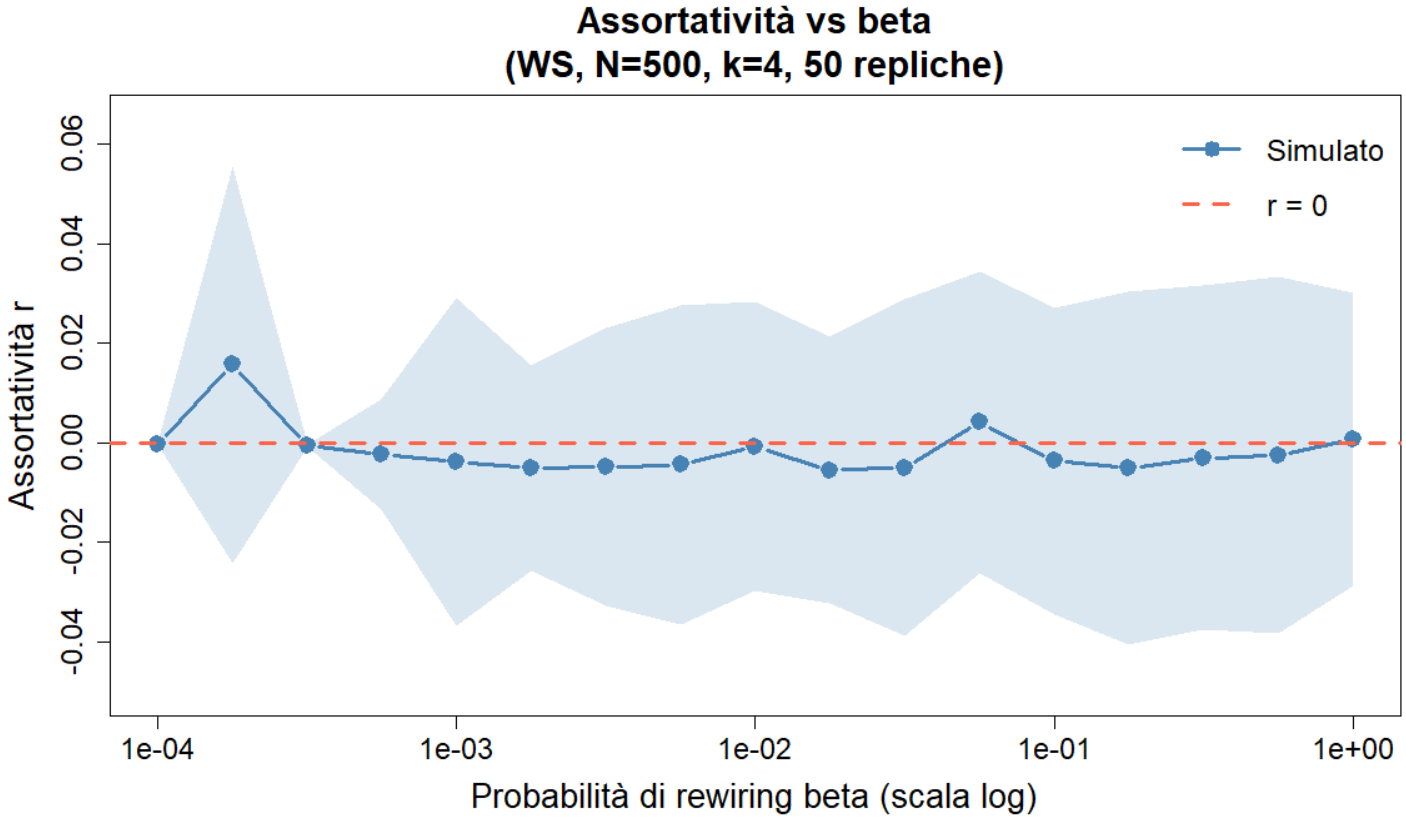
$$r = \frac{Cov(k_i, k_j)}{\sigma_{k_i}\sigma_{k_j}} = \frac{covarianza}{varianza}$$

$\beta = 0$ Tutti i nodi hanno grado K, r non è definito $(\sigma_k^2 = 0)$

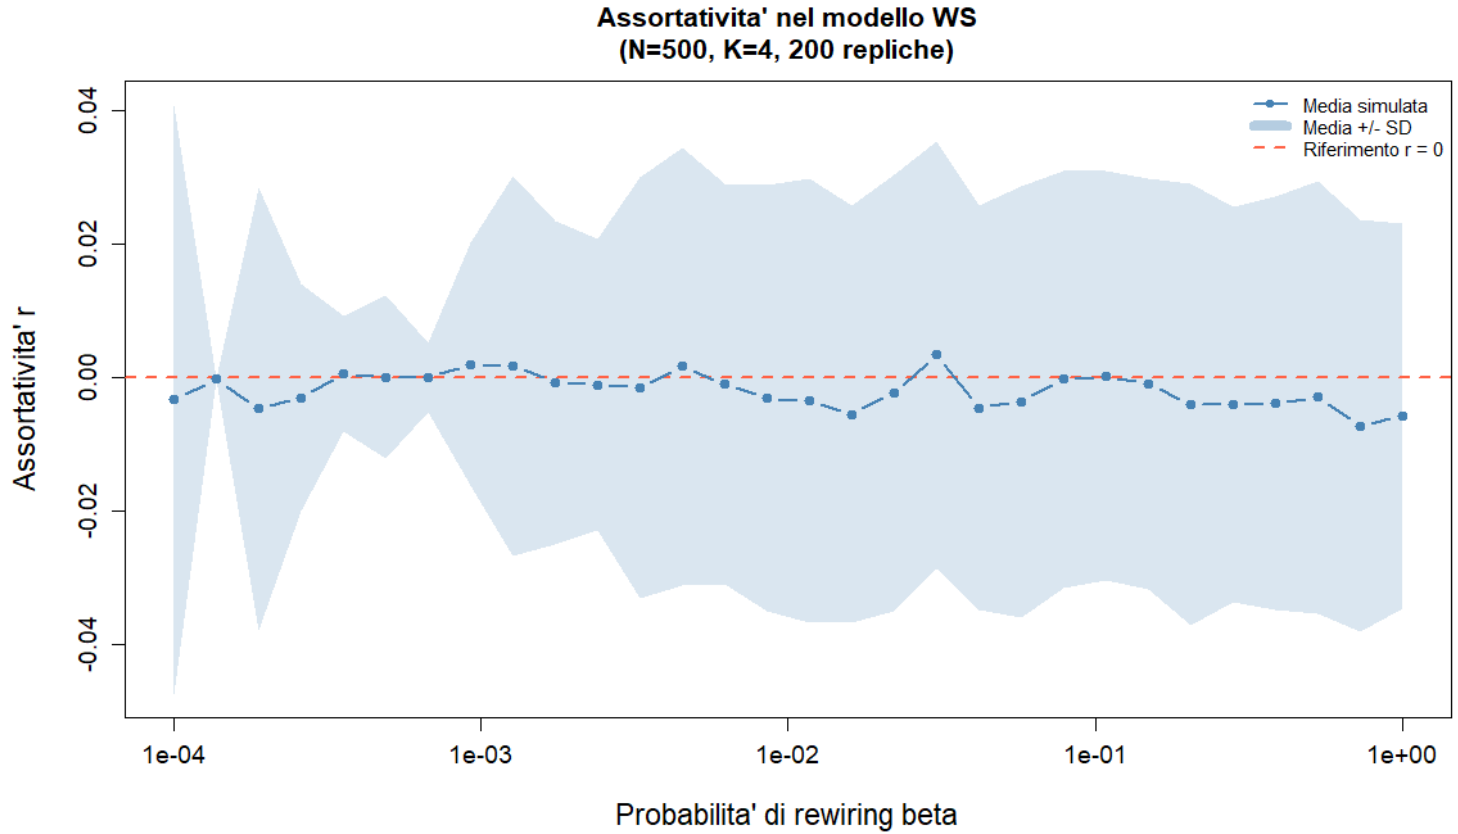
$0 < \beta < 1$ Il rewiring introduce variabilità nei gradi e può generare correlazioni

$\beta \approx 1$ Struttura è fortemente randomizzata; le correlazioni di grado sono deboli

Modello Watts-Strogatz - Assortatività



Modello Watts-Strogatz - Assortatività

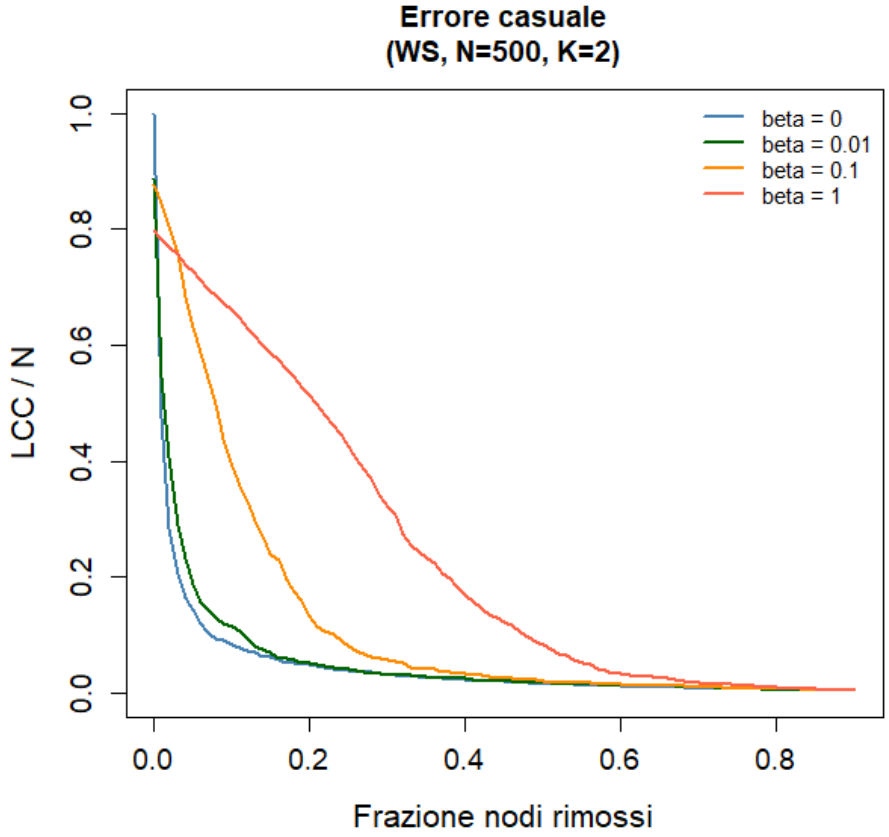


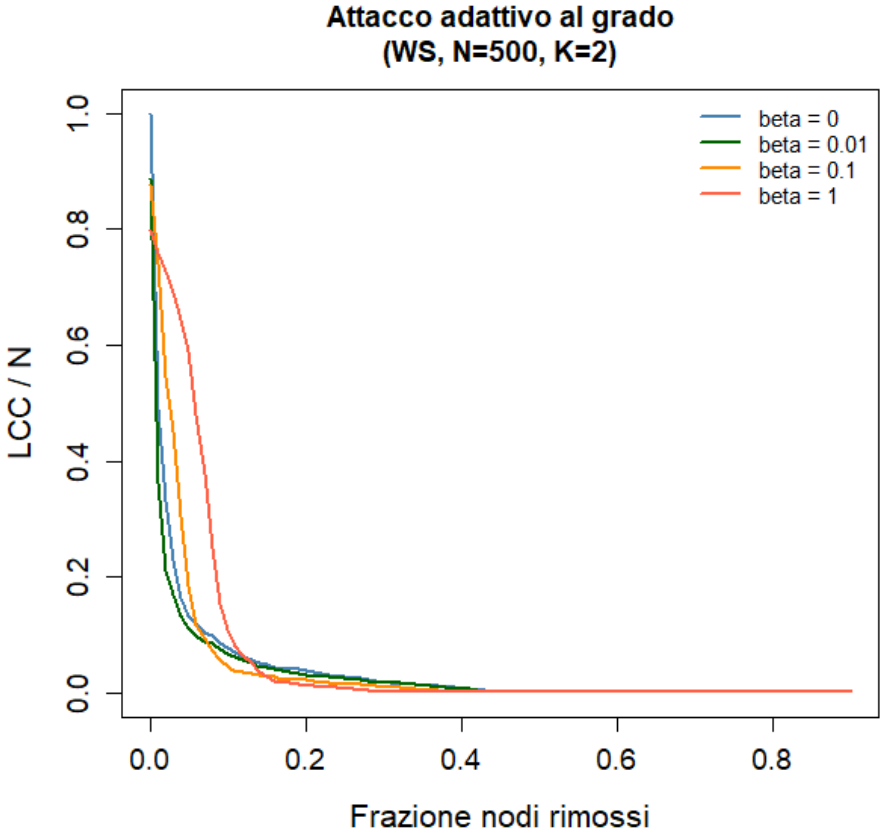
Modello Watts-Strogatz - Robustezza

Reticolo regolare, $\beta = 0$	I collegamenti sono prevalentemente locali; la rimozione di nodi può interrompere la continuità dell'anello
Regione small-world, $0 < \beta < 1$	Le scorciatoie offrono percorsi alternativi tra regioni lontane
Rete fortemente randomizzata, $\beta \approx 1$	La connettività dipende maggiormente dai collegamenti distribuiti casualmente

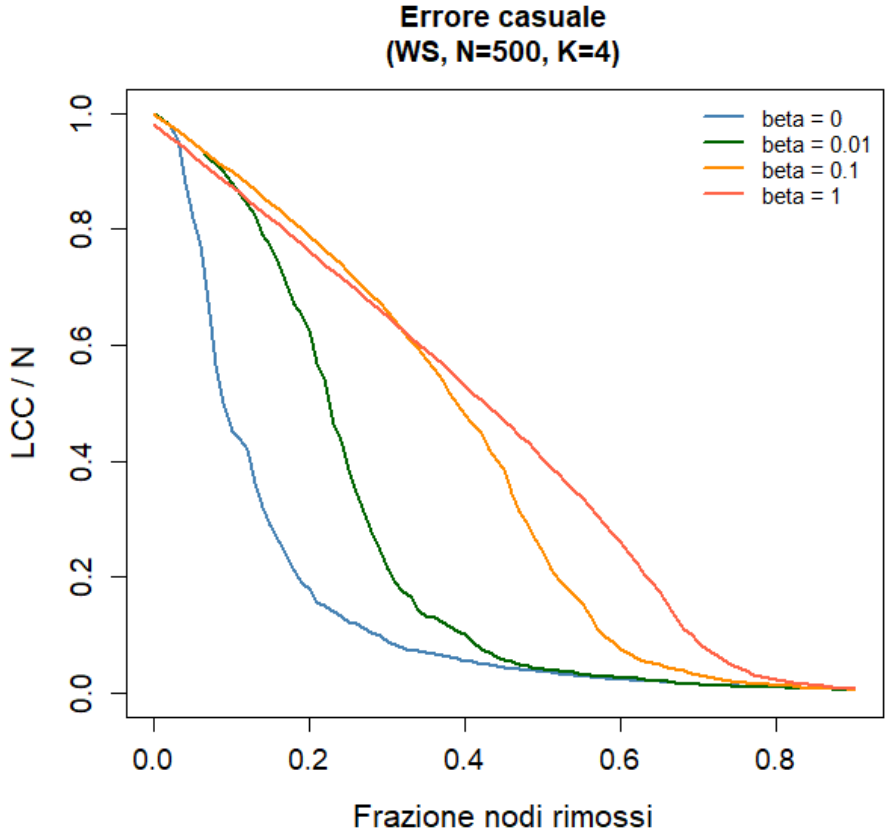
Le scorciatoie possono aumentare la capacità della rete di mantenere collegamenti tra regioni lontane dopo la rimozione di nodi.

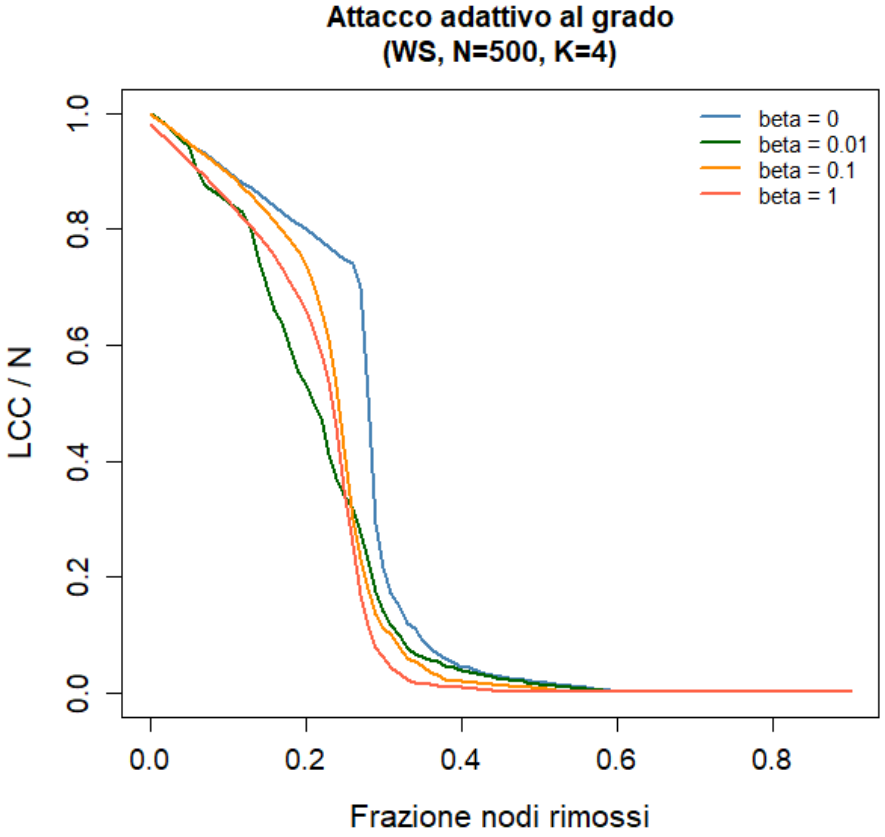
Modello Watts-Strogatz - Robustezza



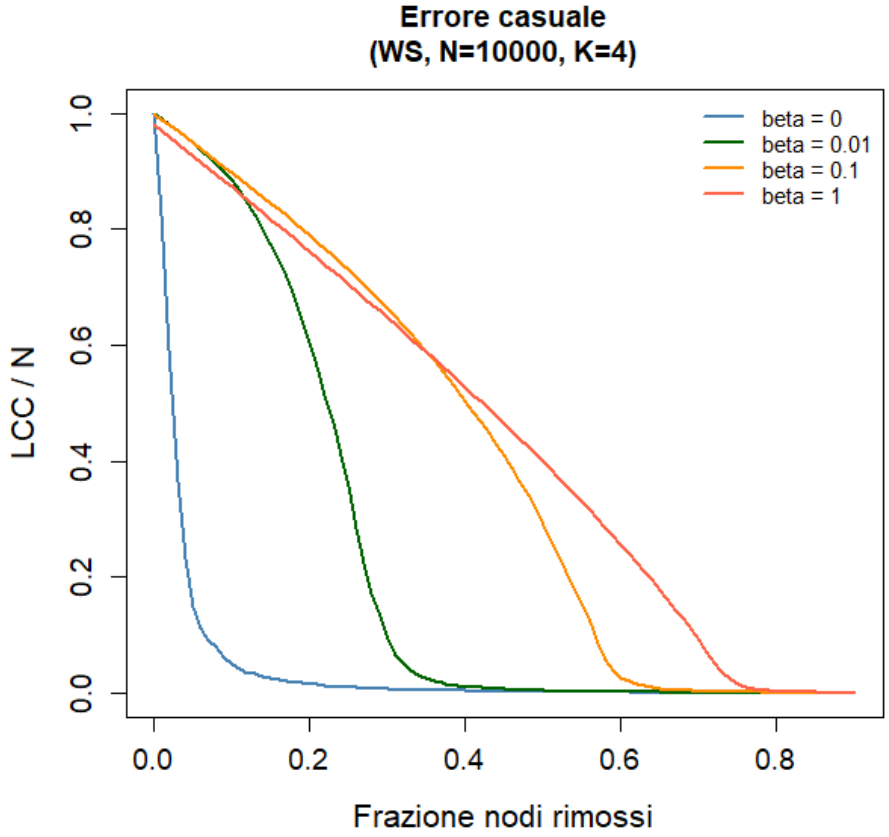


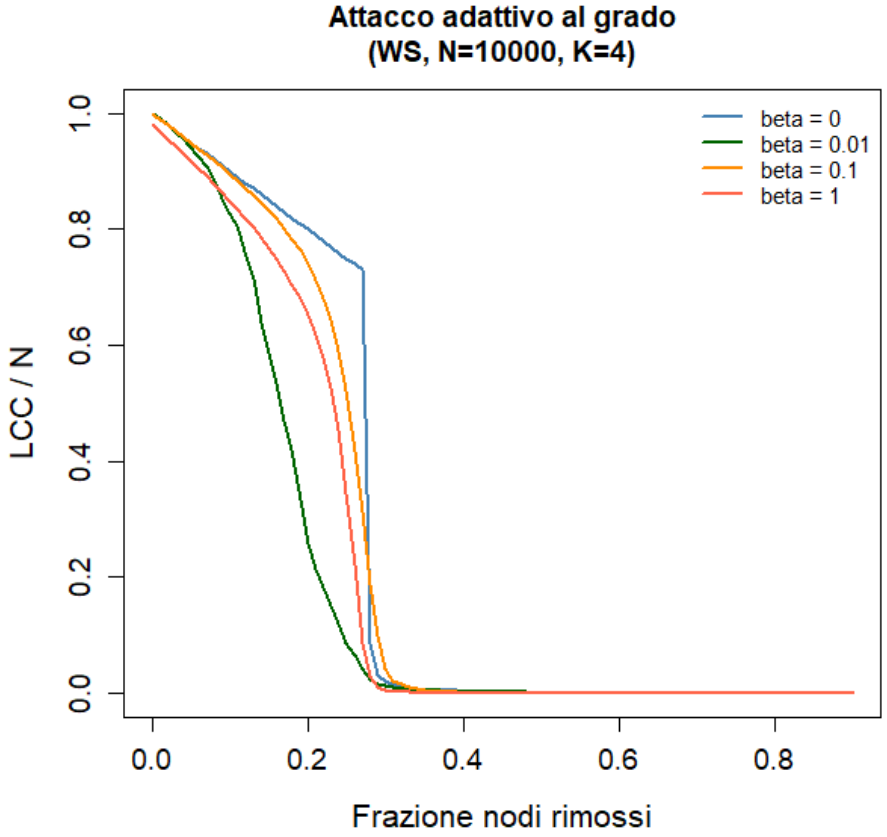
Modello Watts-Strogatz - Robustezza



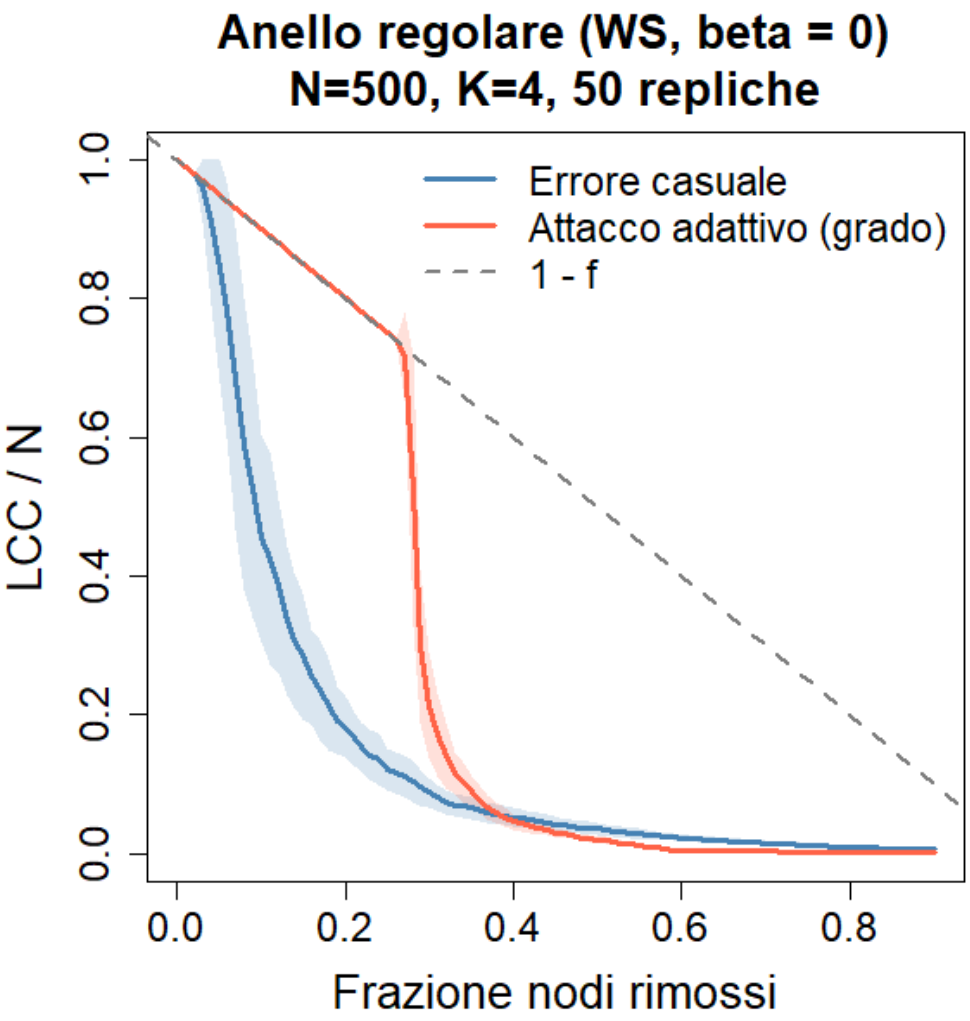


Modello Watts-Strogatz - Robustezza





tz - Robustezza

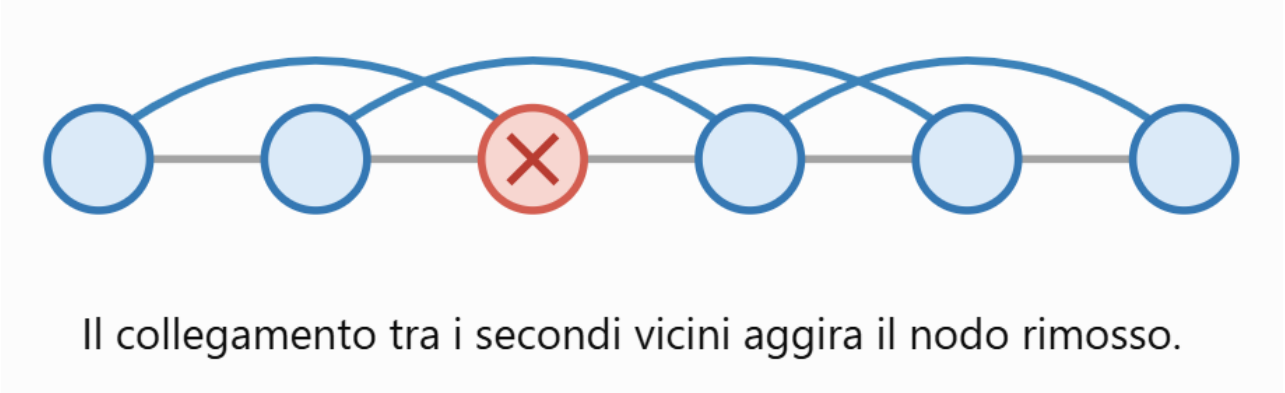


Modello Watts-Strogatz - Robustezza

Qui l'anello ($\beta = 0$, blu) è la rete *più robusta* nella prima fase, e poi crolla di colpo intorno a 0.28. Succede perché nell'anello tutti i nodi hanno grado 4, quindi non ci sono hub da colpire:

1. Dopo aver rimosso un nodo, i suoi vicini entro distanza 2 scendono a grado 3 e non sono più candidati.
2. L'attacco rimuove quindi nodi sempre distanti almeno 3 posizioni l'uno dall'altro.
3. Per spezzare l'anello servono due nodi consecutivi rimossi, cosa che qui non avviene. La rete resta connessa e la LCC segue LCC/N = 1 - f. La curva blu è circa 0.9 a f = 0.1 e 0.8 a f = 0.2.
4. Il crollo arriva quando non restano più nodi di grado 4. A quel punto l'attacco colpisce nodi adiacenti e l'anello si frammenta.

Modello Watts-Strogatz - Robustezza

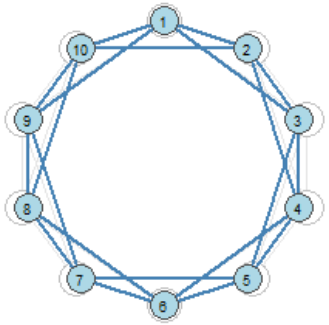


Il collegamento tra i secondi vicini aggira il nodo rimosso.

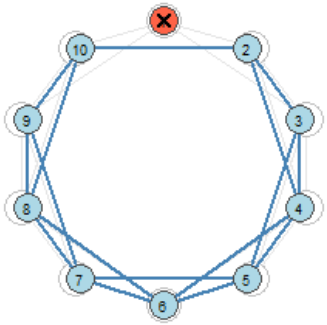
- Tutti i nodi hanno inizialmente grado 4.
- Dopo ogni rimozione, i vicini del nodo eliminato perdono un collegamento.
- L'attacco continua a selezionare nodi di grado 4, mantenendo le rimozioni spazialmente separate.
- La rete rimane inizialmente connessa e la LCC segue 1-f.
- Quando non rimangono nodi di grado 4, l'attacco comincia a colpire nodi più vicini alle posizioni già eliminate.
- Si formano interruzioni multiple e LCC può diminuire rapidamente.

M

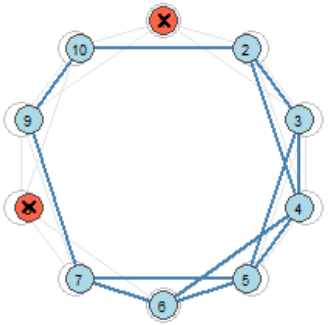
Passo 0 | LCC = 10 | LCC/N = 1



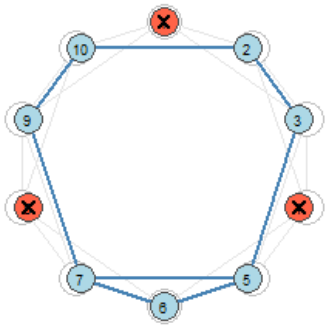
Passo 1 | LCC = 9 | LCC/N = 0.9



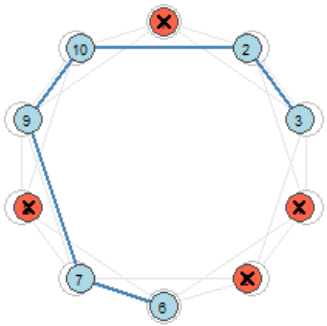
Passo 2 | LCC = 8 | LCC/N = 0.8



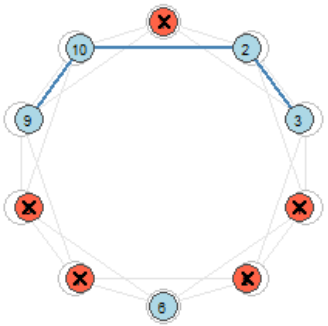
Passo 3 | LCC = 7 | LCC/N = 0.7



Passo 4 | LCC = 6 | LCC/N = 0.6

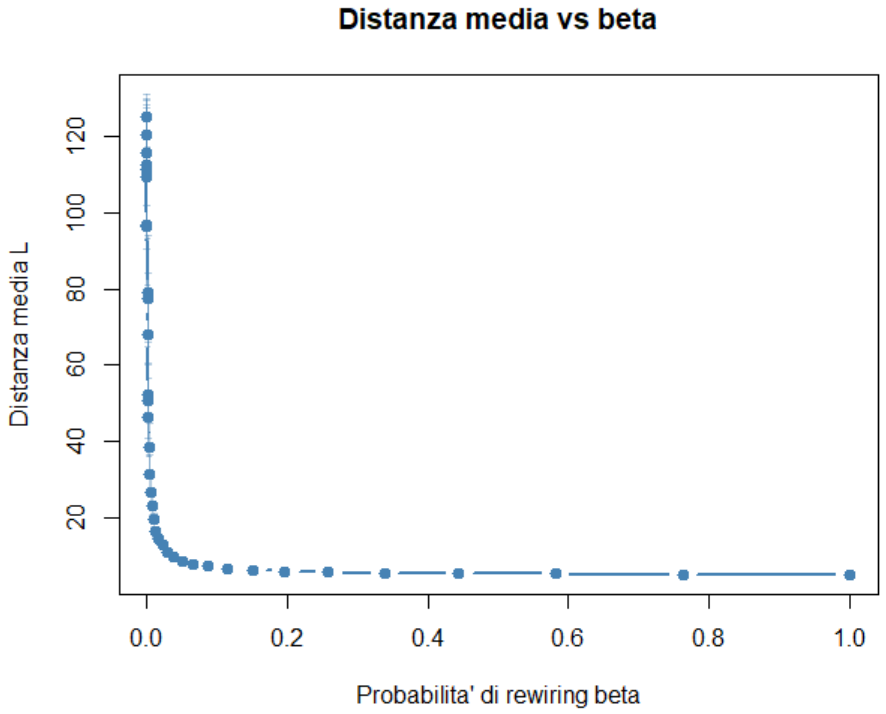


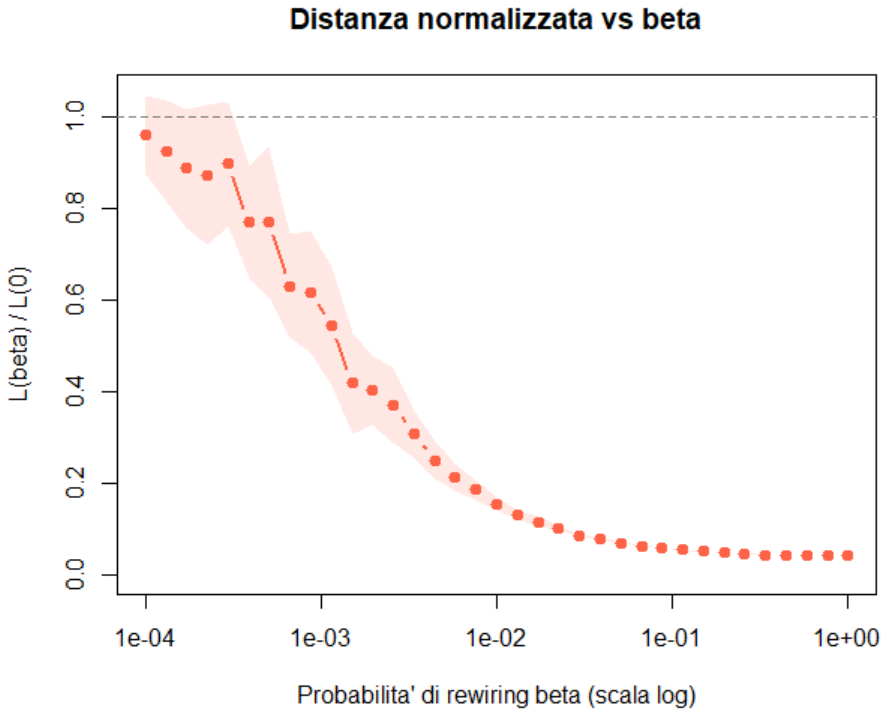
Passo 5 | LCC = 4 | LCC/N = 0.4



Modello WS – Distanza tra Nodi

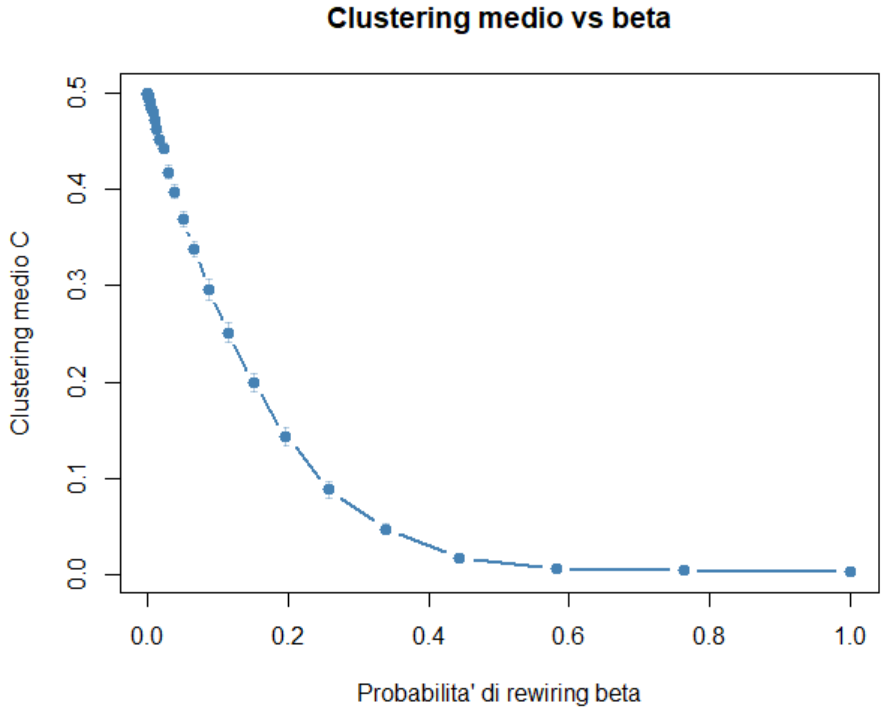
N=1000, K=4, beta 0 a 1, 20 repliche per ogni valore di beta.

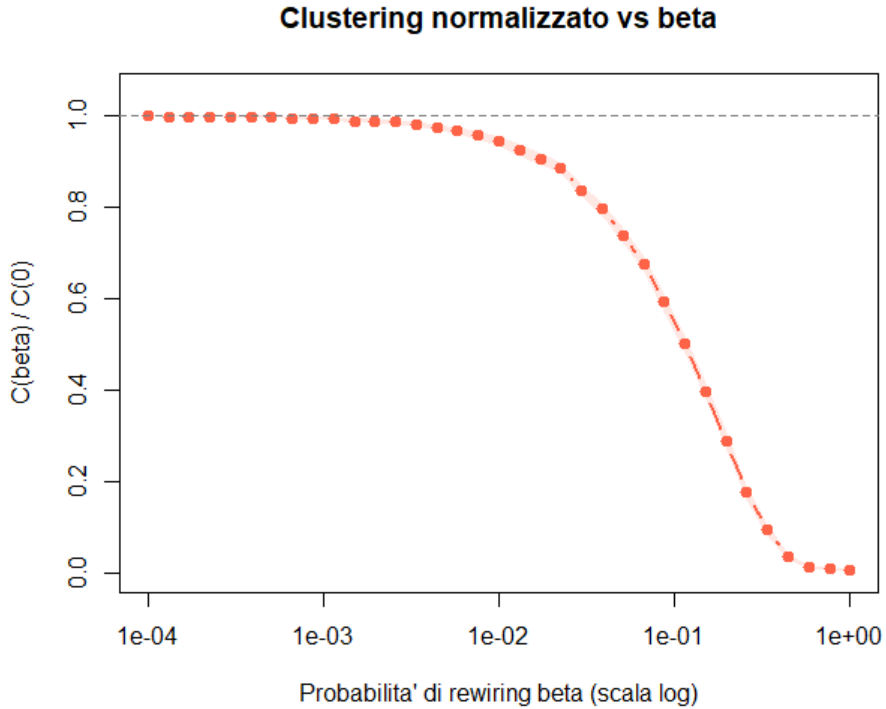




Modello WS – Clustering

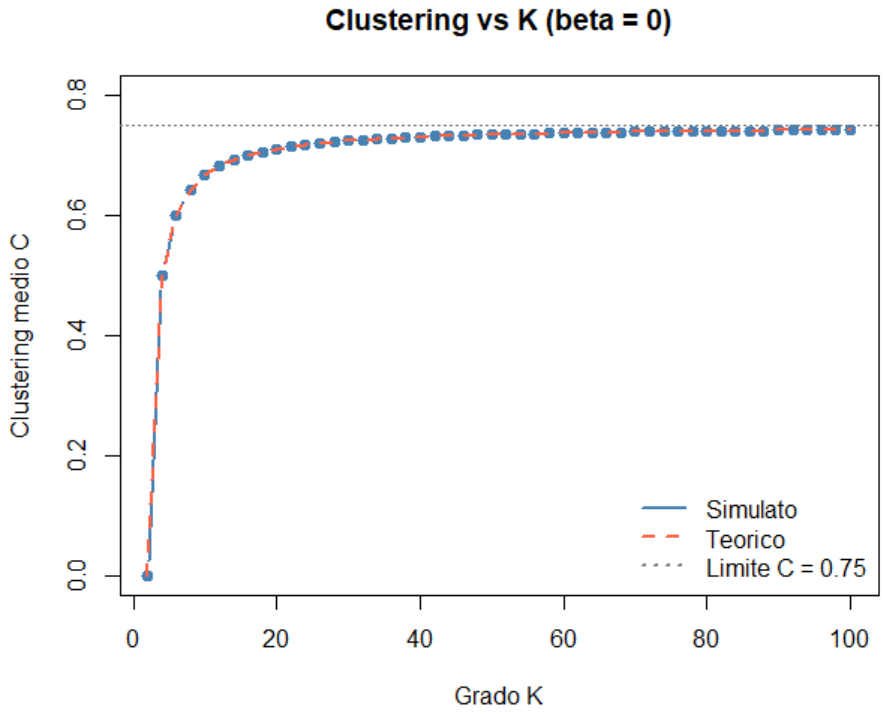
N=1000, K=4, beta 0 a 1, 20 repliche per ogni valore di beta.

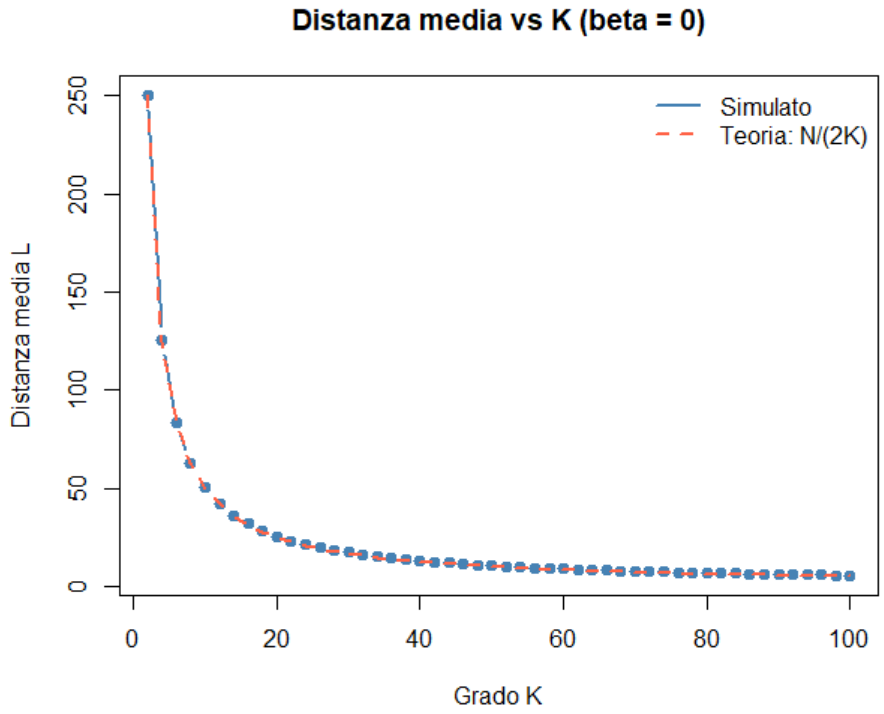


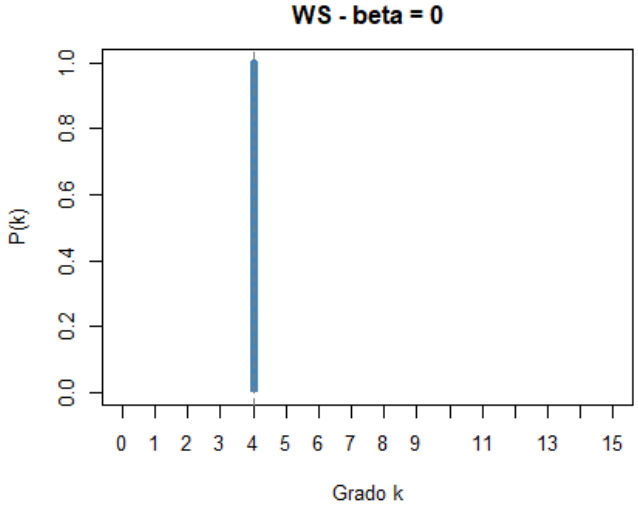


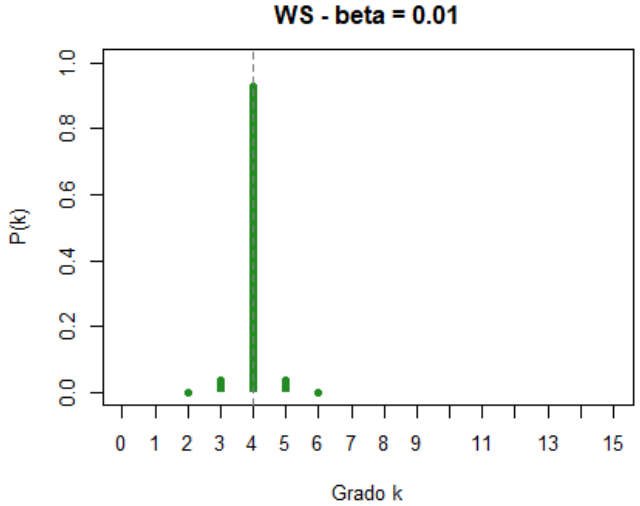
Modello WS – Clustering

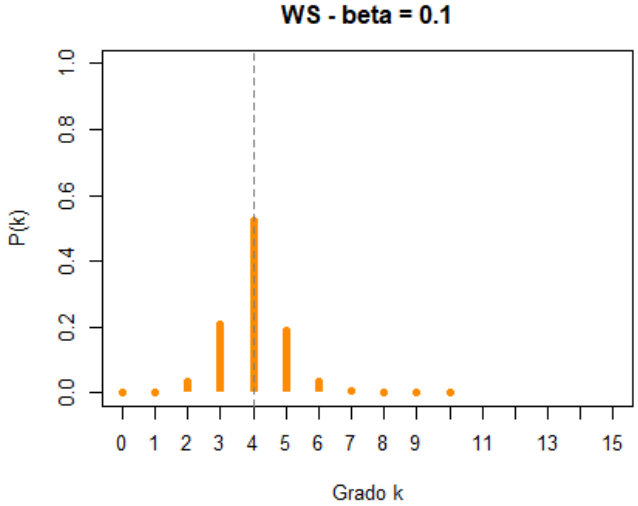
N=1000, beta=0, K crescente da 2 a 100, con soli valori pari.

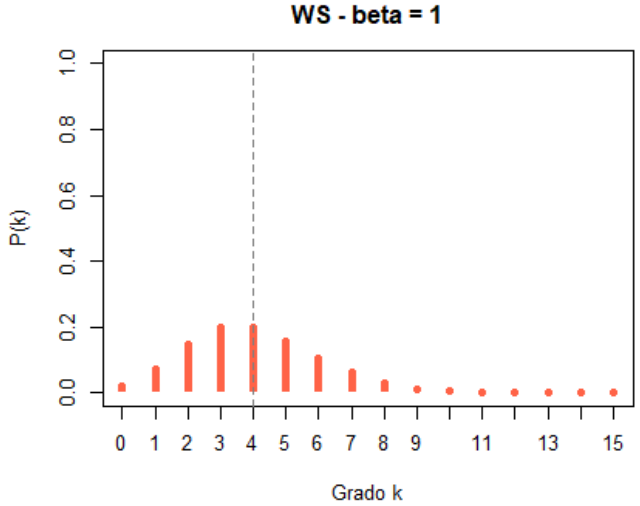












N=1000,
beta crescente,
K=4

Confronto tra Erdős–Rényi e Watts–Strogatz

Proprietà	Erdős–Rényi (ER)	Watts–Strogatz (WS)
Generazione	Archi indipendenti con probabilità p	Reticolo regolare con rewiring β
Grado medio	$(n-1)p$	K, costante
Distribuzione dei gradi	Binomiale, Poisson nel limite sparso	Concentrata intorno a K, dipendente da β
Clustering	Basso nelle reti grandi e sparse $(C \approx p = \langle k \rangle / n)$	Elevato nella regione small-world $(C(0) = 3(K-2)/4(K-1))$
Distanza media	Piccola, crescita logaritmica $(\langle d \rangle \sim \ln n / \ln \langle k \rangle)$	Piccola nella regione small-world $(L(\beta) \ll L(0))$
Assortatività	Asintoticamente nulla $(r \approx 0)$	Dipende dal rewiring; non definita per $\beta = 0$
Componente gigante	Soglia critica $\langle k \rangle = 1$	Dipende da K e dalla struttura; reticolo iniziale connesso
Robustezza	Dipende dal grado medio e dalla strategia di rimozione	Dipende anche dalla presenza di scorciatoie
Limite principale	Clustering basso e gradi poco eterogenei	Non riproduce naturalmente distribuzioni dei gradi a coda pesante

Modello Barabási–Albert

Perché il modello Barabási–Albert*?*

I modelli ER e WS producono reti con distribuzioni dei **gradi relativamente omogenee**.

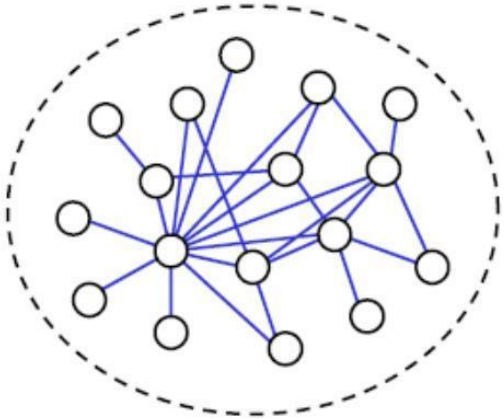
Molte reti reali, invece, presentano una forte eterogeneità:

- La maggior parte dei nodi presenta un grado relativamente basso
- Alcuni nodi, detti hub, possiedono un numero molto elevato di collegamenti.
- La distribuzione dei gradi può presentare una coda pesante, in alcuni casi approssimabile con una legge di potenza.

Barabási, A.-L. & Albert, R. (1999), Emergence of Scaling in Random Networks, Science, 286, 509–512.

Modello Barabási–Albert

Scale-free networks

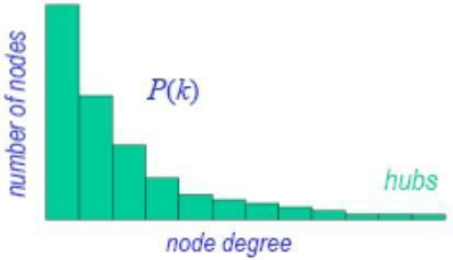


A schematic scale-free network

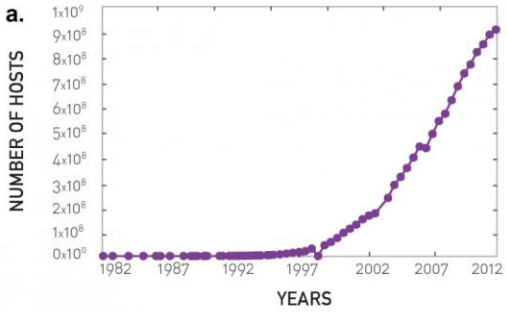
- in a *scale-free network* the degree distribution follows a POWER-LAW:

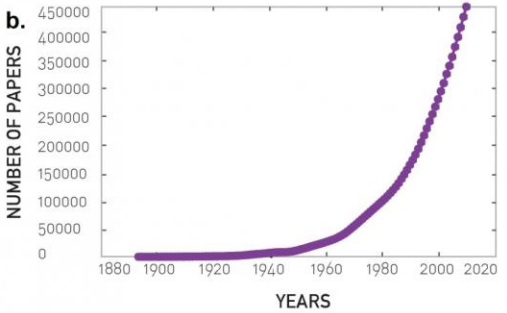
$$P(k) \sim k^{-\gamma}$$

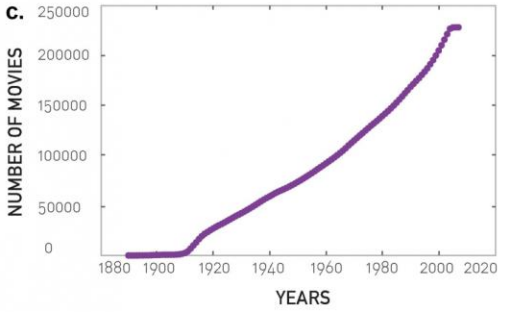
- there exists a small number of highly connected nodes, called *hubs* (tail of the distribution)
- the great majority of nodes have few connections (head of the distribution)



Modello Barabási–Albert







Networks grow over time

a. Numero di host Internet (1982–2012)

b. Numero di articoli scientifici (1880–2015)

c. Numero di film (1880–2015 circa)

Modello Barabási–Albert - Principi

Quale meccanismo può generare nodi con un numero molto elevato di collegamenti?

Modello semplice:

Crescita

(growth)

$$N(t) = m_0 + t$$

Attaccamento preferenziale

(preferential attachment)

$$\Pi_i \propto k_i$$

Modello Barabási–Albert - Principi

Crescita (growth)

La rete parte da un piccolo nucleo iniziale di m_0 nodi.

A ogni passo temporale viene aggiunto un nuovo nodo, che crea m collegamenti verso nodi già presenti, con $m \leq m_0$ nella costruzione standard.

Il numero di nodi cresce quindi nel tempo:

$$\boxed{N(t) = m_0 + t}$$

Modello Barabási–Albert - Principi

Attaccamento preferenziale (preferential attachment)

I nuovi nodi non scelgono casualmente i propri vicini con probabilità uniforme.

I nodi già molto connessi hanno una probabilità maggiore di ricevere nuovi collegamenti.

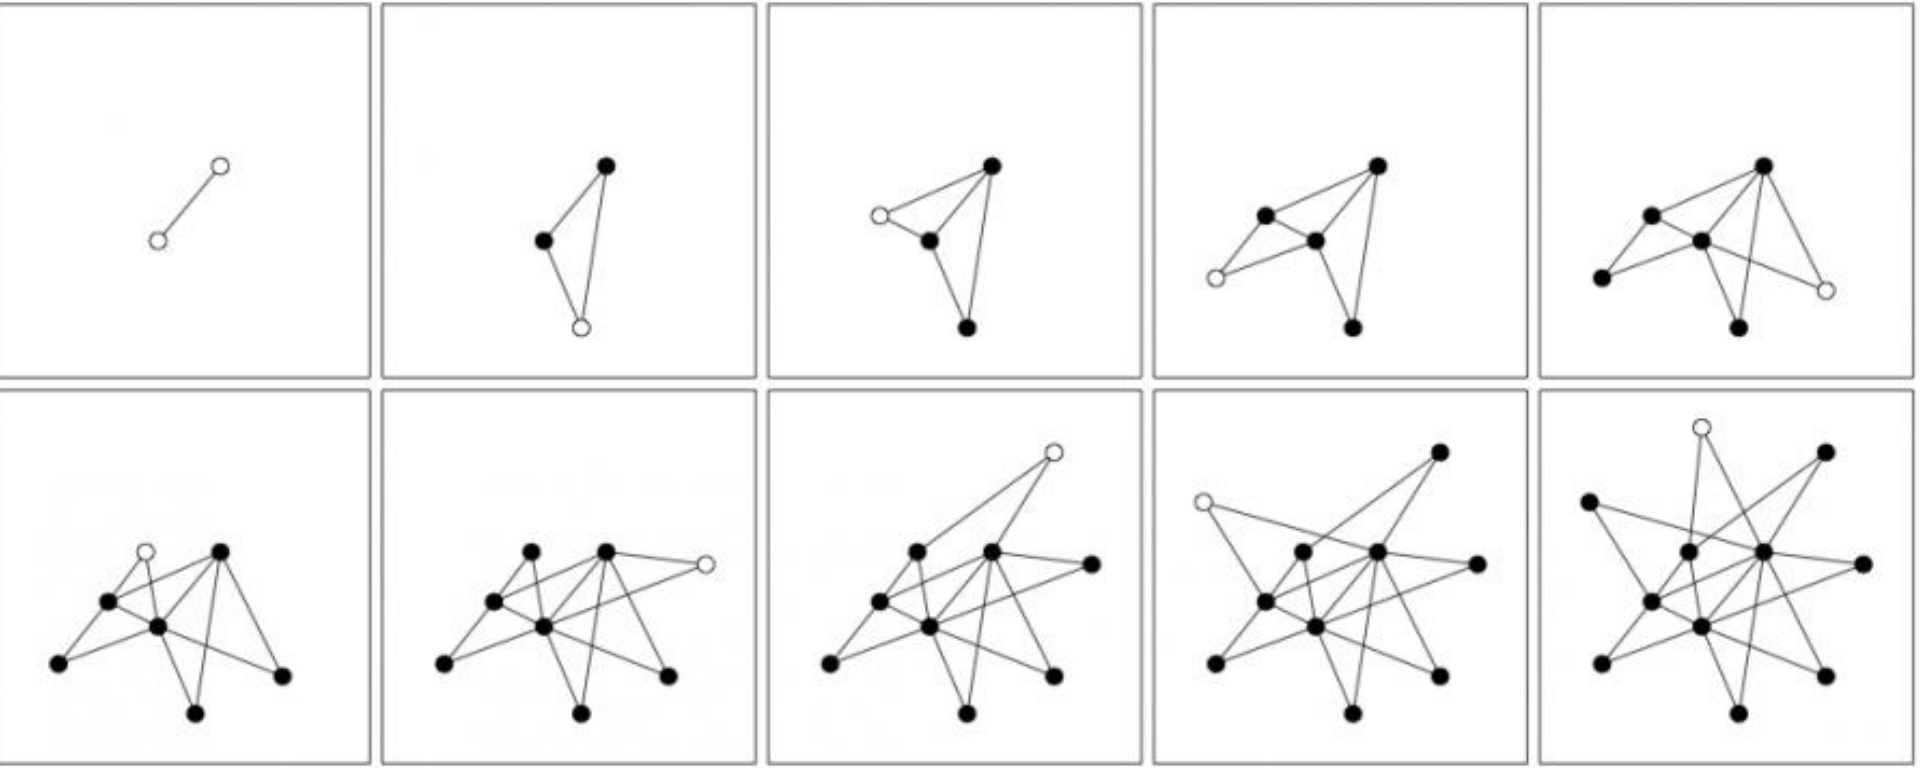
$$\Pi_i = \frac{k_i}{\sum_j k_j}$$

Dove:

- Π_i: probabilità di selezionare il nodo esistente i per un collegamento.
- k_i : grado del nodo i.
- $\sum_j k_j$: somma dei gradi dei nodi esistenti.

Il meccanismo ***rich-get-richer*** :
i nodi che hanno già molti collegamenti tendono ad acquisirne ancora di più.

Modello Barabási–Albert - Principi



Modello Barabási–Albert – Vantaggio Cumulativo

Le origini dell'idea – Preferential Attachment

Yule (1925): processi di crescita cumulativa per spiegare distribuzione specie tra generi biologici.

Simon (1955): generalizzazione matematica dei processi di crescita proporzionale, applicati a diverse distribuzioni statistiche.

de Solla Price (1965, 1976): *cumulative advantage* nelle citazioni scientifiche. Gli articoli già molto citati tendono a ricevere nuove citazioni.

Merton (1968): *effetto Matteo* nella sociologia della scienza. Gli scienziati già prestigiosi tendono a ricevere maggiore riconoscimento.

Barabási e Albert (1999): modello di crescita delle reti con attaccamento preferenziale, che genera distribuzioni dei gradi a legge di potenza.

Rich-Get-Richer

L'analogia con la ricchezza

Immaginiamo due persone:

- Persona A: possiede un patrimonio di un milione di euro.
- Persona B: possiede un patrimonio di 10.000 euro.5

«**Rich-get-richer**:

più collegamenti possiede un nodo, maggiore è la probabilità che ne acquisisca di nuovi.»

	Patrimonio iniziale	Guadagno (5%)
Persona A	1.000.000 €	50.000 €
Persona B	10.000 €	500 €

Effetto Matteo

L'**effetto (San) Matteo** (Matthew Effect) è un concetto introdotto dal sociologo della scienza Robert Merton nel 1968 per descrivere un fenomeno di vantaggio cumulativo: chi possiede già riconoscimento, prestigio o risorse tende ad acquisirne ancora di più.

Scienziati prestigiosi tendono a ricevere maggiore riconoscimento per contributi comparabili a quelli di ricercatori meno conosciuti.

Il nome deriva dal Vangelo secondo Matteo (25,29):

«*A chiunque ha, sarà dato e sarà nell'abbondanza; ma a chi non ha, sarà tolto anche quello che ha*.»



Robert Merton (1968)

Effetto Matteo

Nel 1968 Merton pubblicò sulla rivista Science l'articolo:

The Matthew Effect in Science.



The Matthew Effect in Science

The reward and communication systems of science are considered.

Robert K. Merton

Due ricercatori producono lavori di qualità comparabile.

A è già molto conosciuto, B è poco noto.

Il lavoro di A può ricevere maggiore attenzione perché il suo autore è già riconosciuto. → Questa visibilità può favorire nuove citazioni, collaborazioni, opportunità.

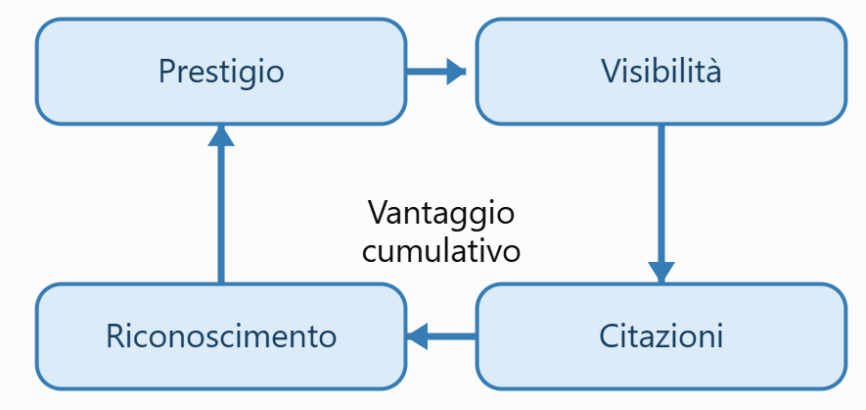
Effetto San Matteo

The Matthew Effect in Science

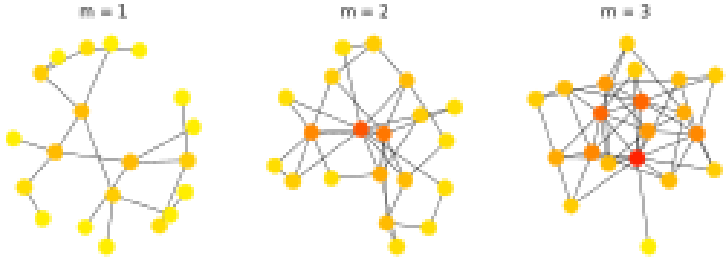


The reward and communication systems of science are considered.

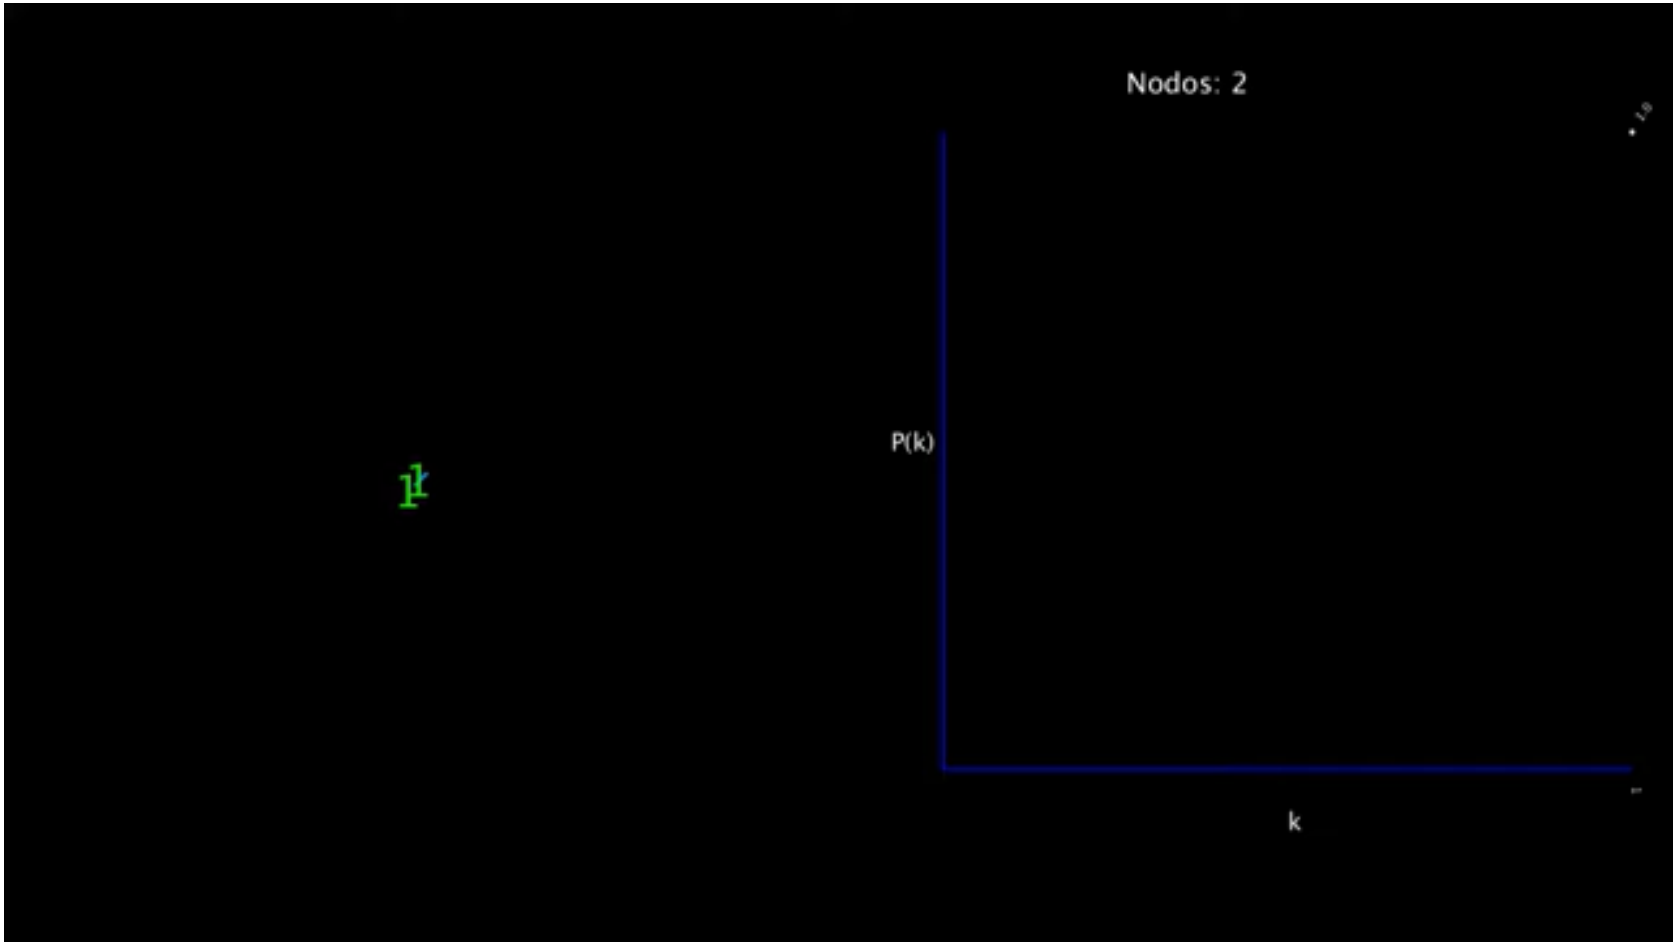
Robert K. Merton

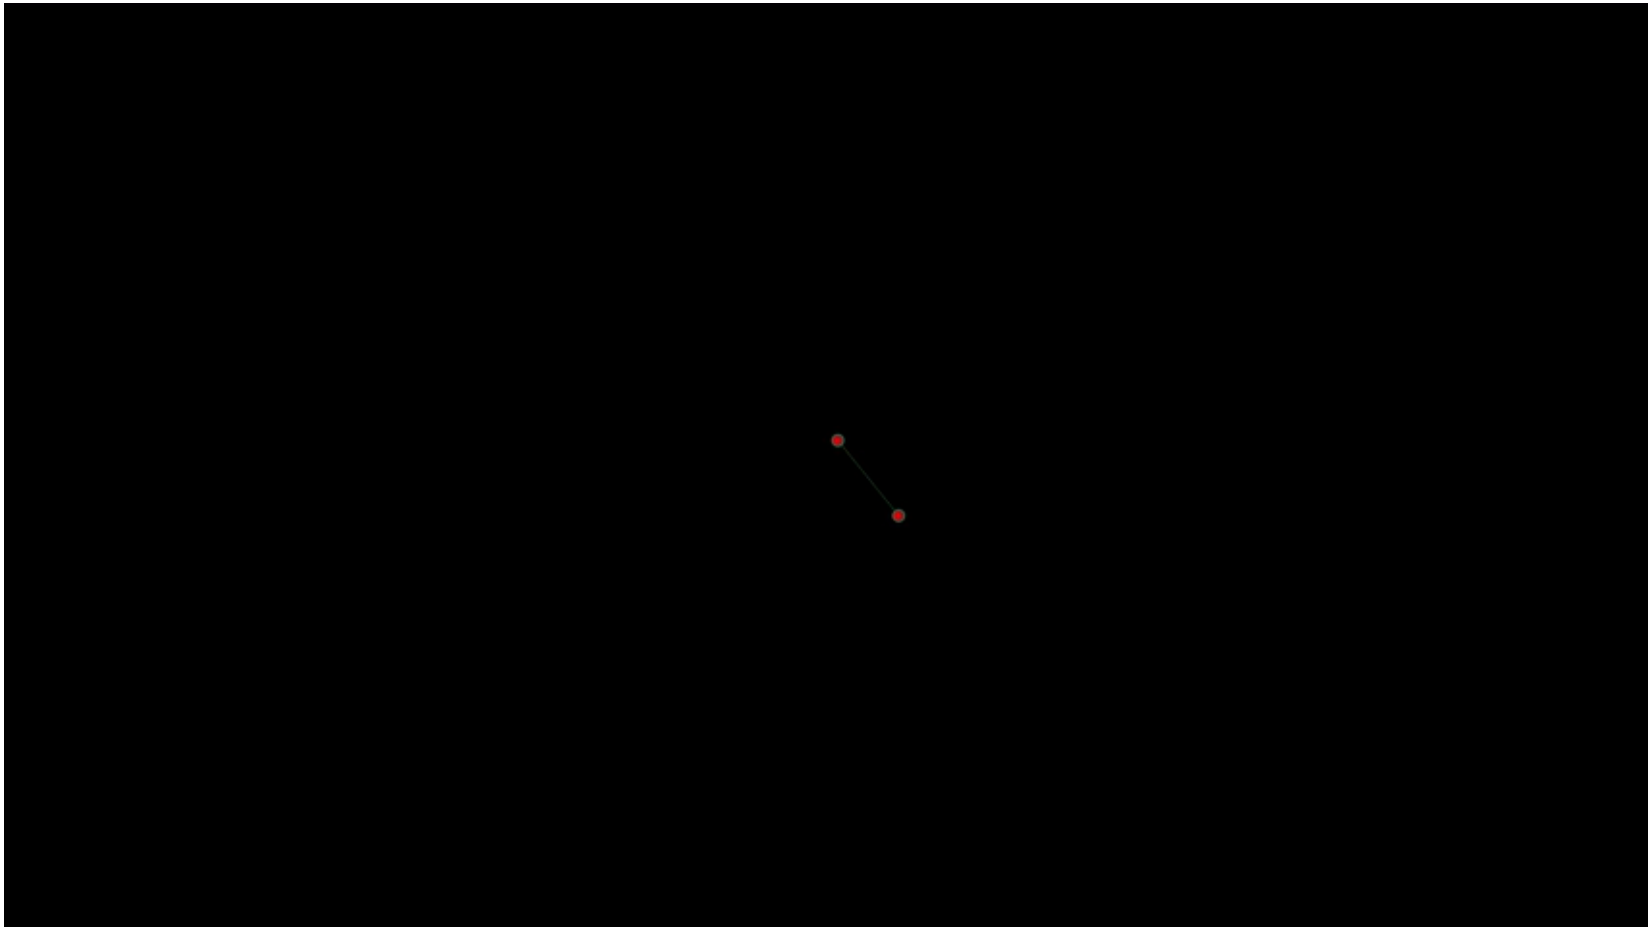


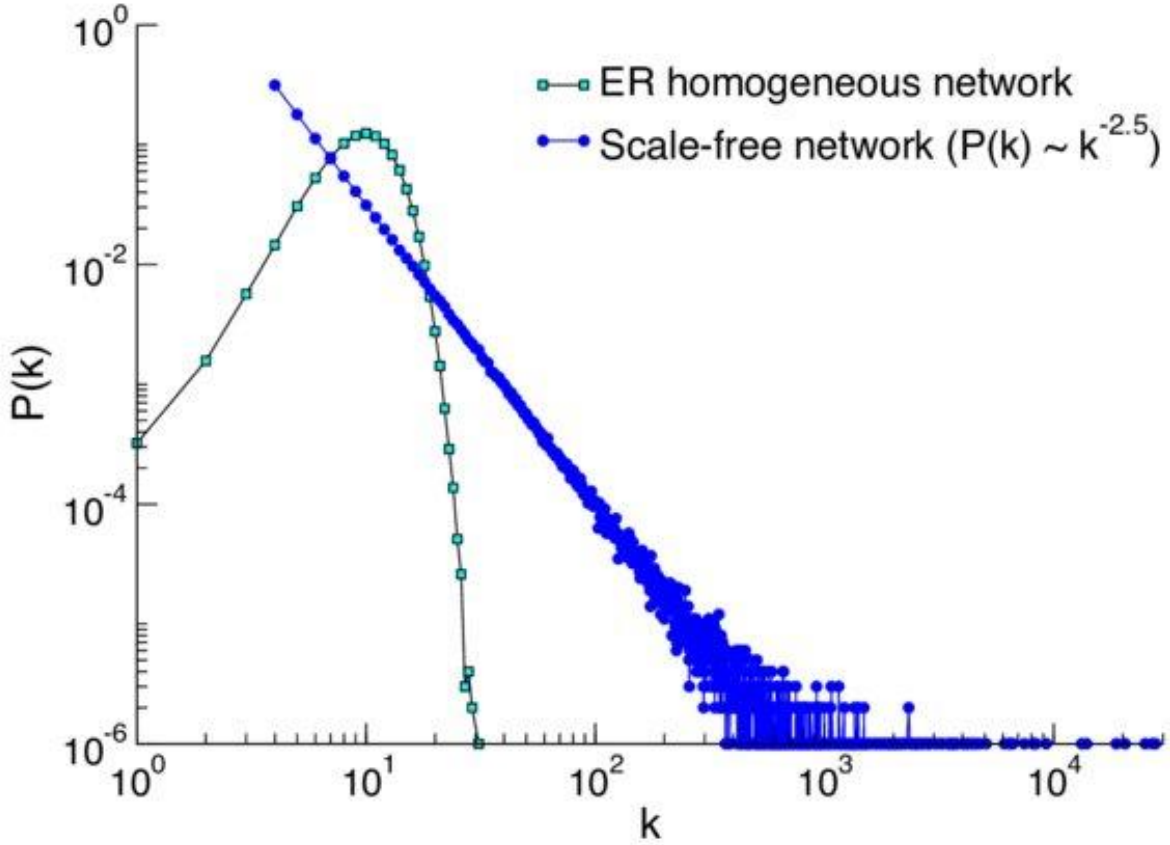
Attaccamento preferenziale (preferential attachment)



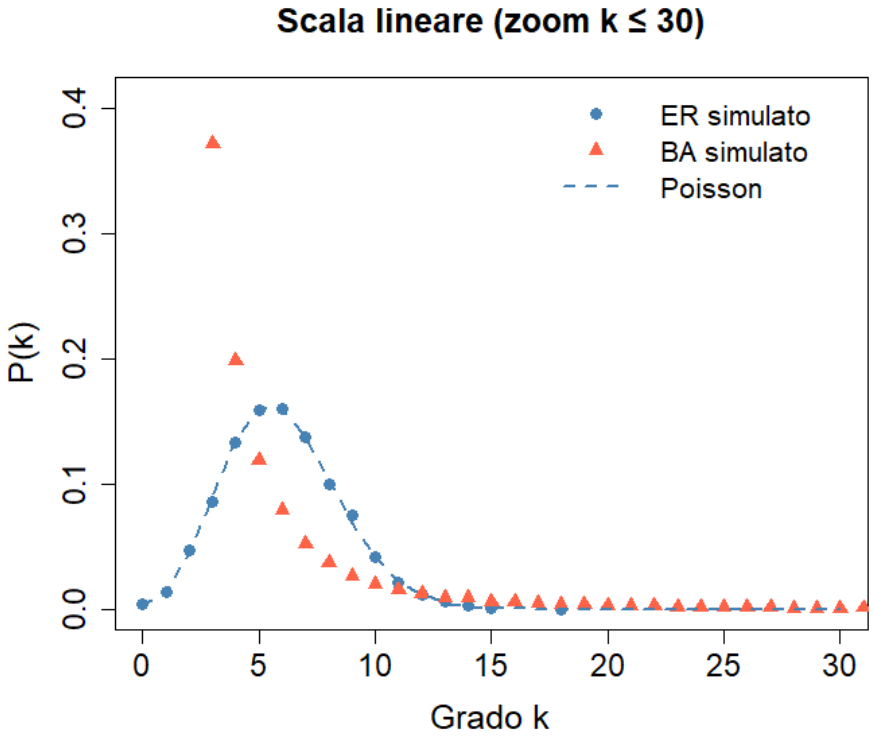
https://en.wikipedia.org/wiki/Barab%C3%A1si%E2%80%93Albert_model

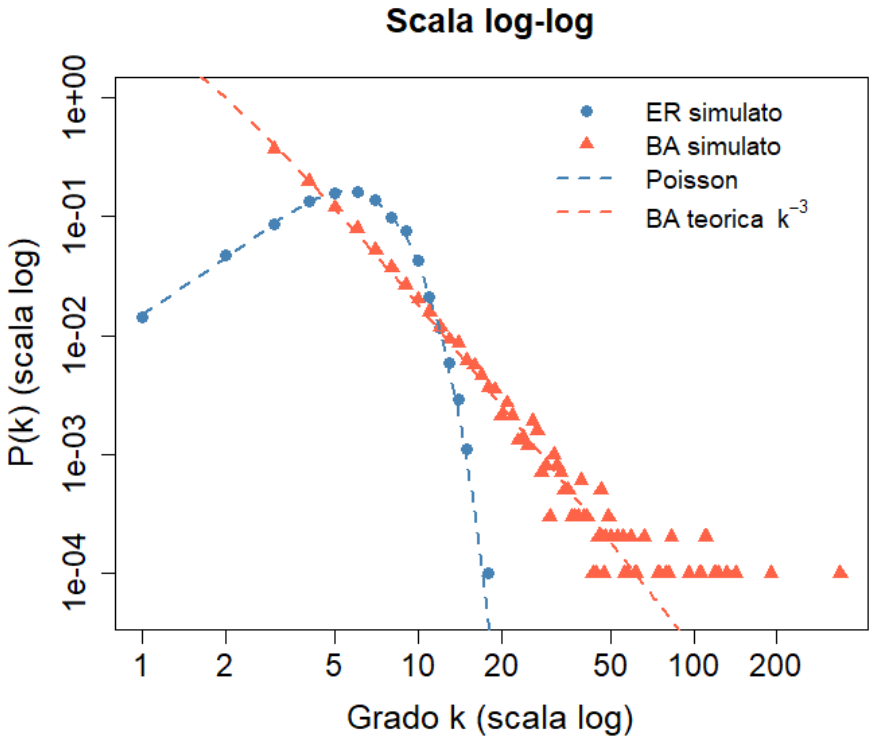

Nodos: 2
P(k)
k




ER homogeneous network
Scale-free network (P(k) ~ k^-2.5)
P(k)
k
10^0
10^-2
10^-4
10^-6
10^0
10^1
10^2
10^3
10^4

Modello BA – Distribuzione dei gradi

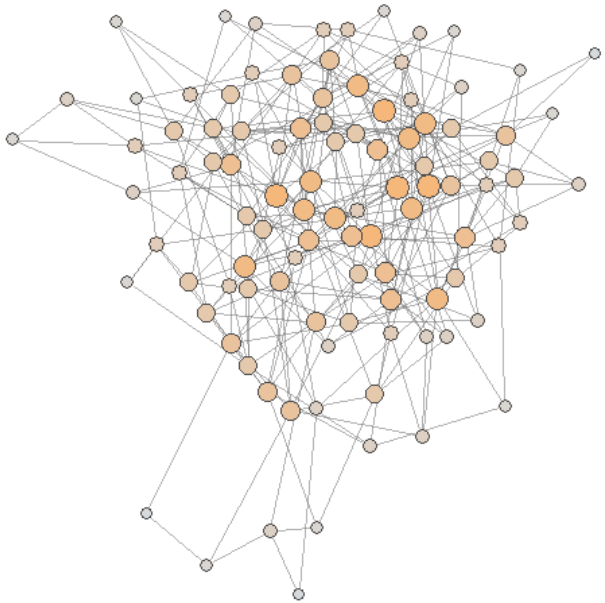




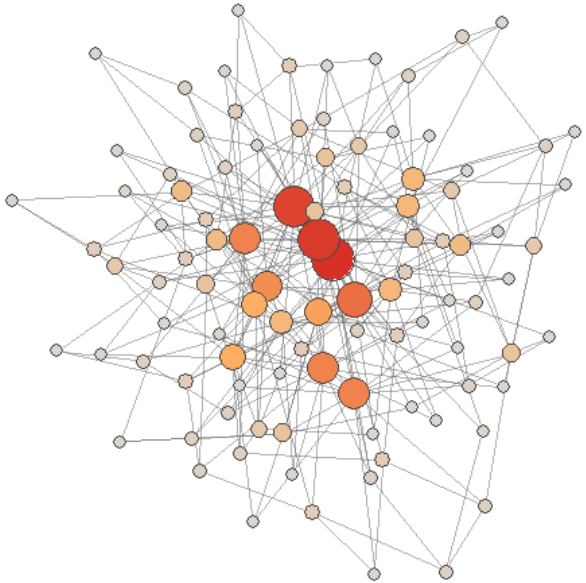
$$\ln P(k) = \ln A - 3 \ln k$$

Modello BA – Distribuzione dei gradi

Erdős-Rényi
N=100, <k>=5.8, k_max=10



Barabási-Albert
N=100, <k>=5.9, k_max=24



Modello BA – Distribuzione dei gradi

Nel modello BA classico, per reti grandi, la distribuzione dei gradi segue asintoticamente una legge di potenza:

$$P(k) \sim k^{-\gamma}$$

con:

$$\gamma = 3$$

Il risultato è molto diverso dal modello ER.

Modello BA – Scale Free

I network Barabási–Albert (BA) vengono chiamati **scale-free** (senza scala caratteristica) perché la loro distribuzione dei gradi segue una legge di potenza.

⟹ anziché essere concentrata attorno a un grado tipico come nel Erdős–Rényi

La distribuzione dei gradi presenta una proprietà matematica detta invarianza di scala.

Questo significa che, osservando la distribuzione a scale differenti del grado, essa mantiene la stessa forma funzionale, a meno di un fattore moltiplicativo.

Modello BA – Scale Free

Invarianza di scala.

Consideriamo una distribuzione di potenza:

$$P(k) = Ak^{-\gamma}$$

Otteniamo:

$$\boxed{P(ak) = a^{-\gamma}P(k)}$$

Cambiando la scala di osservazione, la distribuzione mantiene la stessa forma funzionale

Modello BA – Scale Free

Nel modello BA, per gradi sufficientemente grandi:

$$P(k) \approx Ak^{-3} = \frac{A}{k^3}$$

A è una costante

$$P(10) \approx \frac{A}{10^3} = \frac{A}{1000}$$

$$P(20) \approx \frac{A}{20^3} = \frac{A}{8000}$$

$$\frac{P(20)}{P(10)} = \frac{1000}{8000} = \boxed{\frac{1}{8}}$$

$$P(100) \approx \frac{A}{100^3} = \frac{A}{1000000}$$

$$P(200) \approx \frac{A}{200^3} = \frac{A}{8000000}$$

$$\frac{P(200)}{P(100)} = \frac{1000000}{8000000} = \boxed{\frac{1}{8}}$$

Nelle distribuzioni scale-free, il rapporto tra le probabilità di gradi proporzionali rimane lo stesso, indipendentemente dalla scala considerata.

Modello BA – Grado Medio

Ogni nuovo nodo introduce m archi.

Dopo t passi:

$N(t) = m_0 + t$ Numero nodi

$M(t) = M_0 + mt$ Numero archi

Per il lemma della stretta di mano:

$$\langle k \rangle(\mathrm{t}) = \frac{2M(t)}{N(t)} \Rightarrow \langle k \rangle(\mathrm{t}) = \frac{2(M_0 + mt)}{m_0 + t}$$

$$\lim_{t \to \infty} \langle k \rangle = 2m$$

Lemma Stretta di Mano

La somma dei gradi di tutti i nodi è uguale al doppio del numero totale di archi

$$\sum_{i=1}^{N} k_i = 2M$$

$$\langle k \rangle = \frac{2M}{N}$$

Modello BA – Grado Medio

Ogni nuovo nodo introduce m archi.

Dopo t passi:

$N(t) = m_0 + t$ Numero nodi

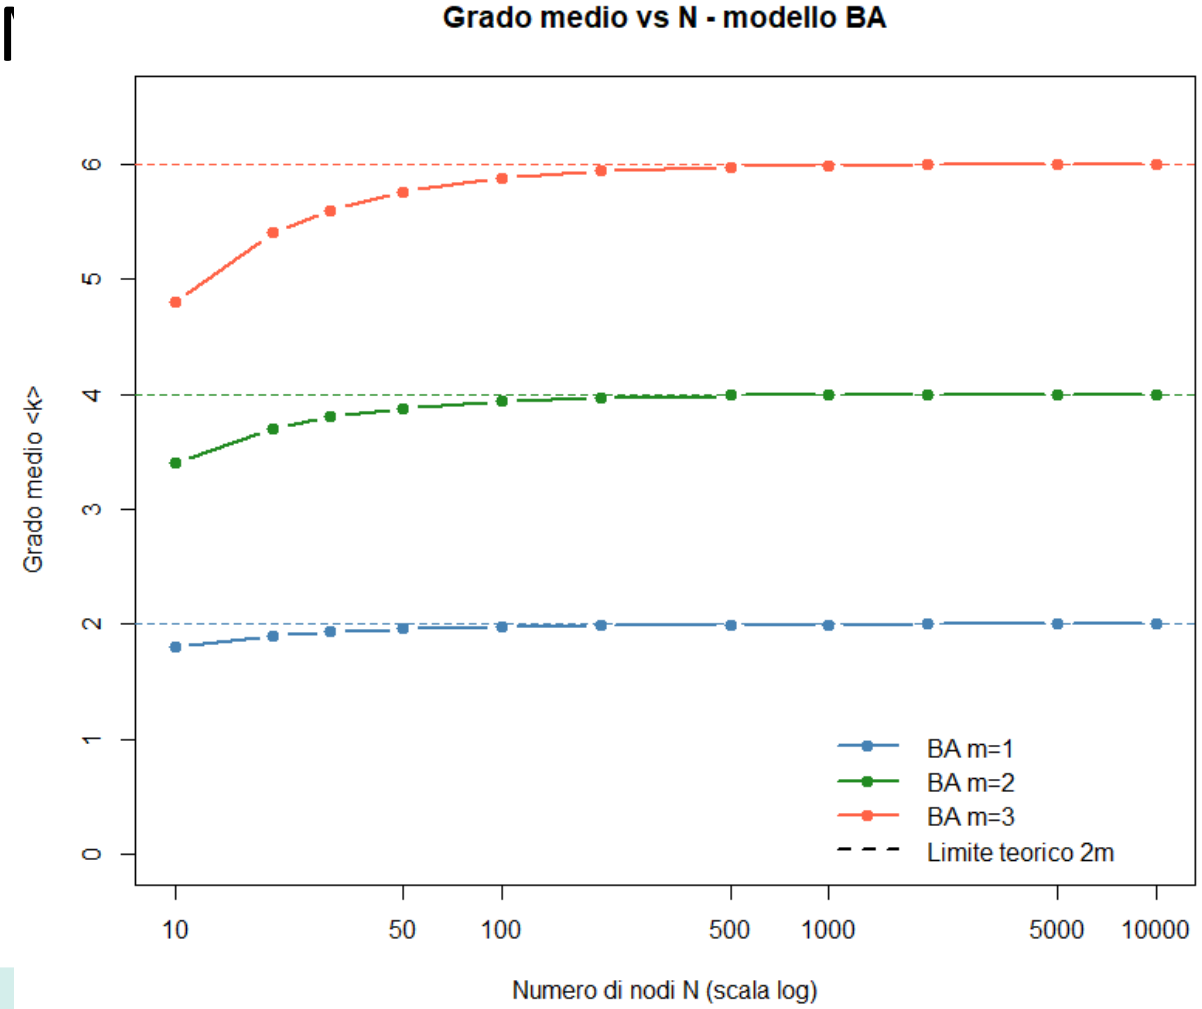
$M(t) = M_0 + mt$ Numero archi

Per il lemma della stretta di mano:

$$\langle k \rangle = \frac{2M(t)}{N(t)} \quad \Rightarrow \quad \boxed{\lim_{t \to \infty} \langle k \rangle = 2m}$$

Esempio

$m = 2 \quad \Rightarrow \quad \langle k \rangle \to 4$


Grado medio vs N - modello BA
Grado medio <k>
0
1
2
3
4
5
6
10
50
100
500
1000
5000
10000
Numero di nodi N (scala log)
BA m=1
BA m=2
BA m=3
Limite teorico 2m

Modello BA – Robustezza

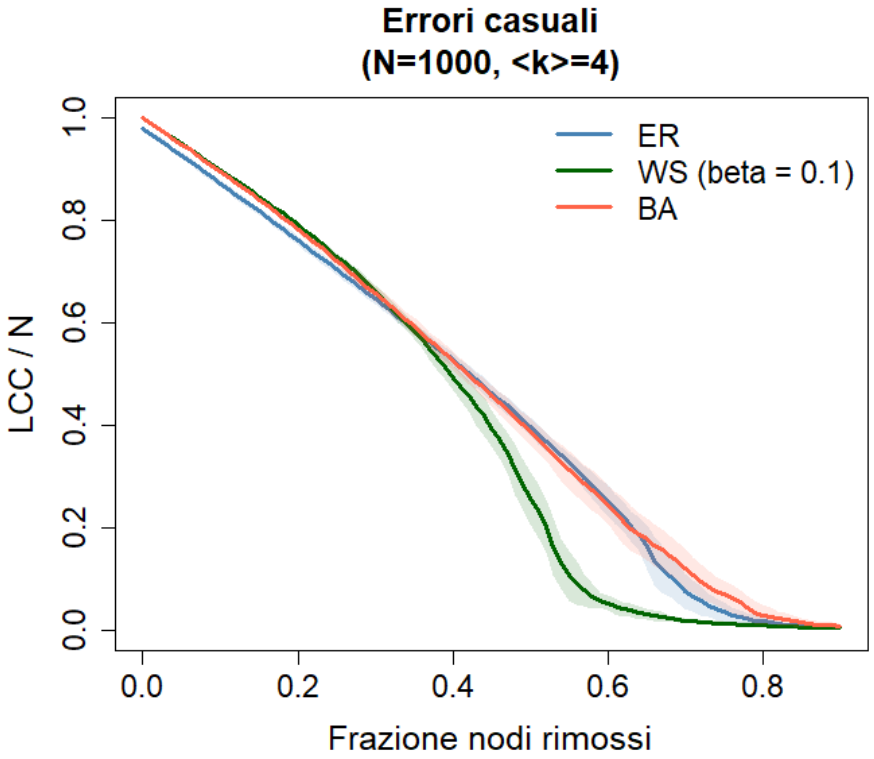


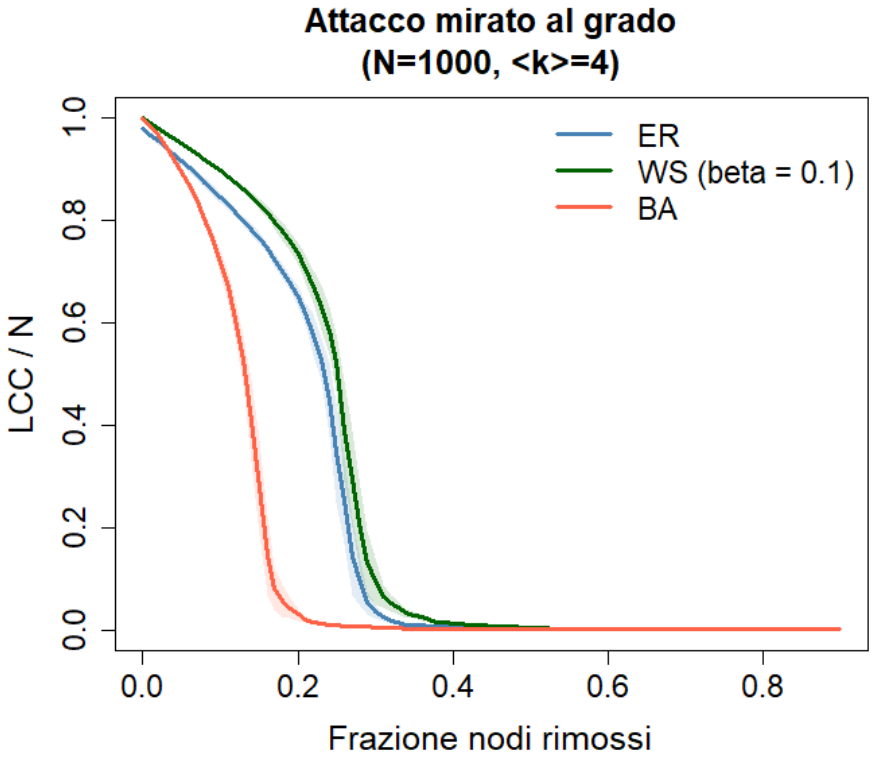
La distribuzione dei gradi a coda pesante ha conseguenze importanti sulla robustezza.

Nel modello BA classico:

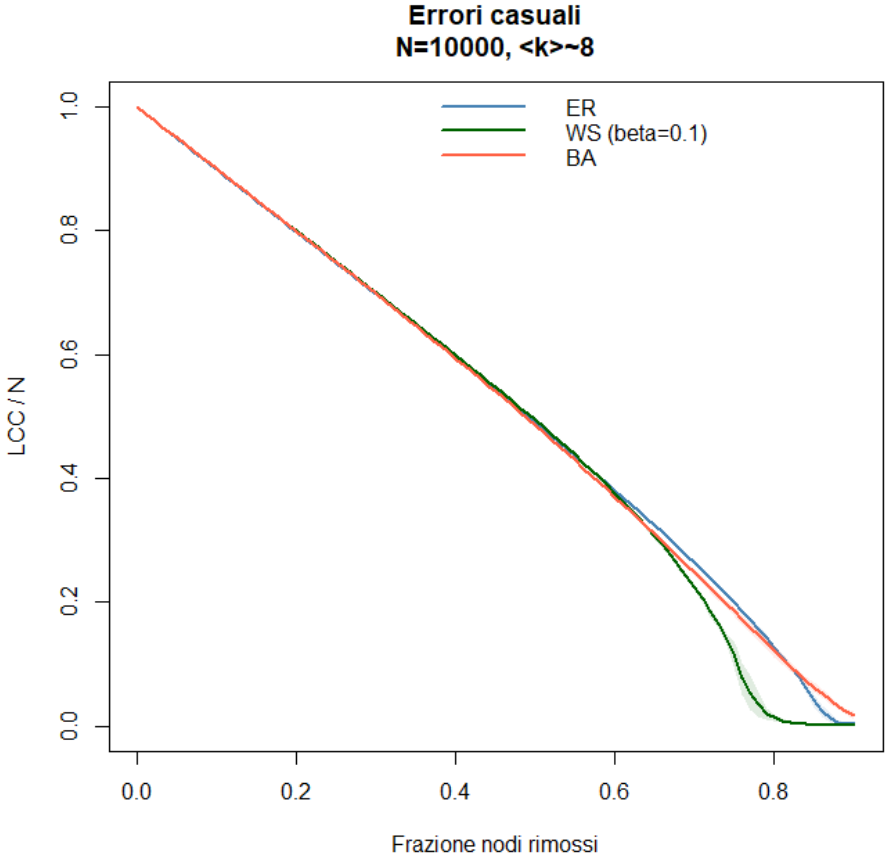
- **Errori casuali**: la rete può conservare una componente gigante anche dopo la rimozione di una frazione elevata dei nodi.
- **Attacchi mirati al grado**: la rimozione degli hub può provocare una frammentazione molto più rapida.

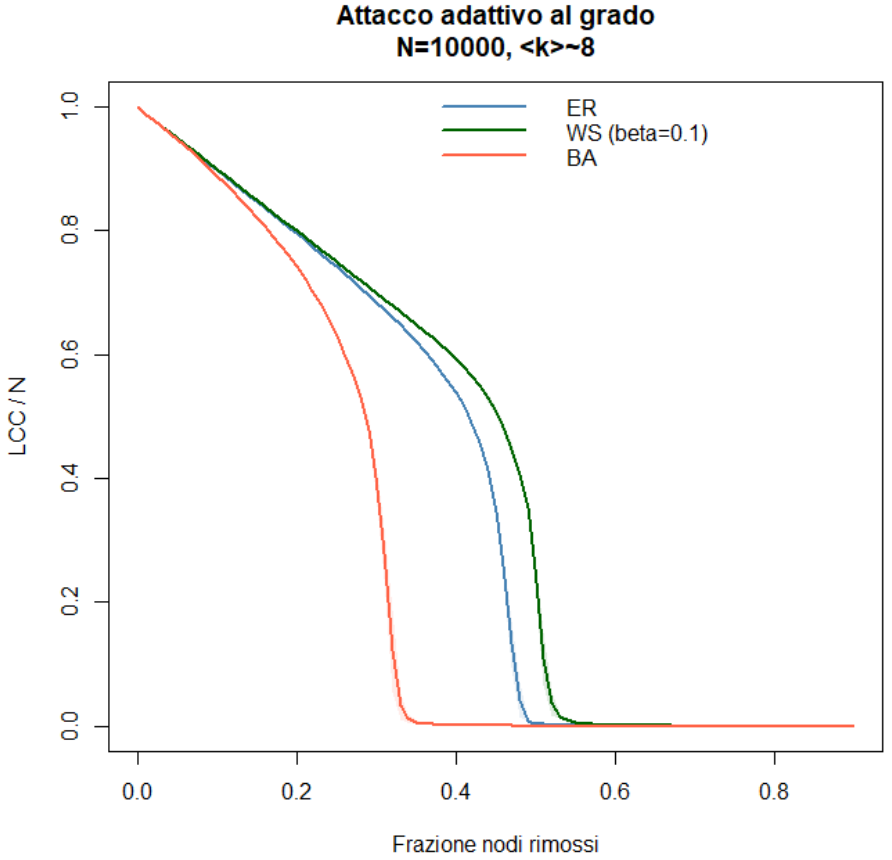
Modello BA – Robustezza



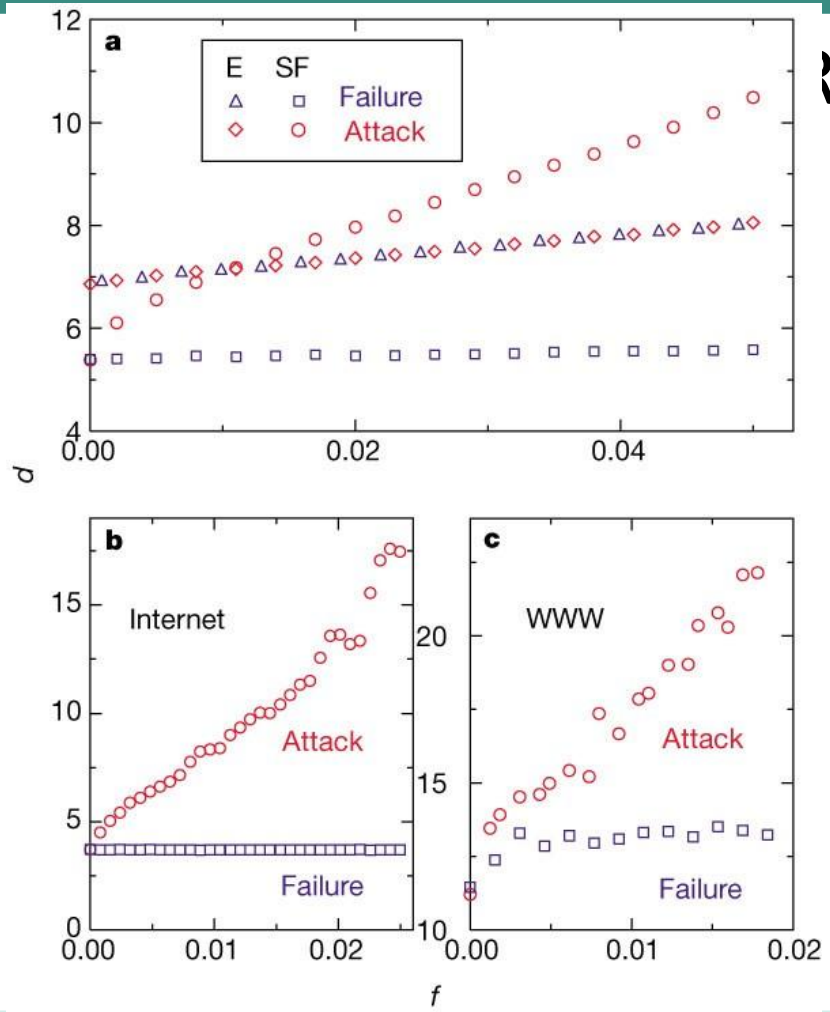


Modello BA – Robustezza





Robustezza



E, il modello ER
SF, una scale-free BA

d “diametro”

Modello BA – Assortatività

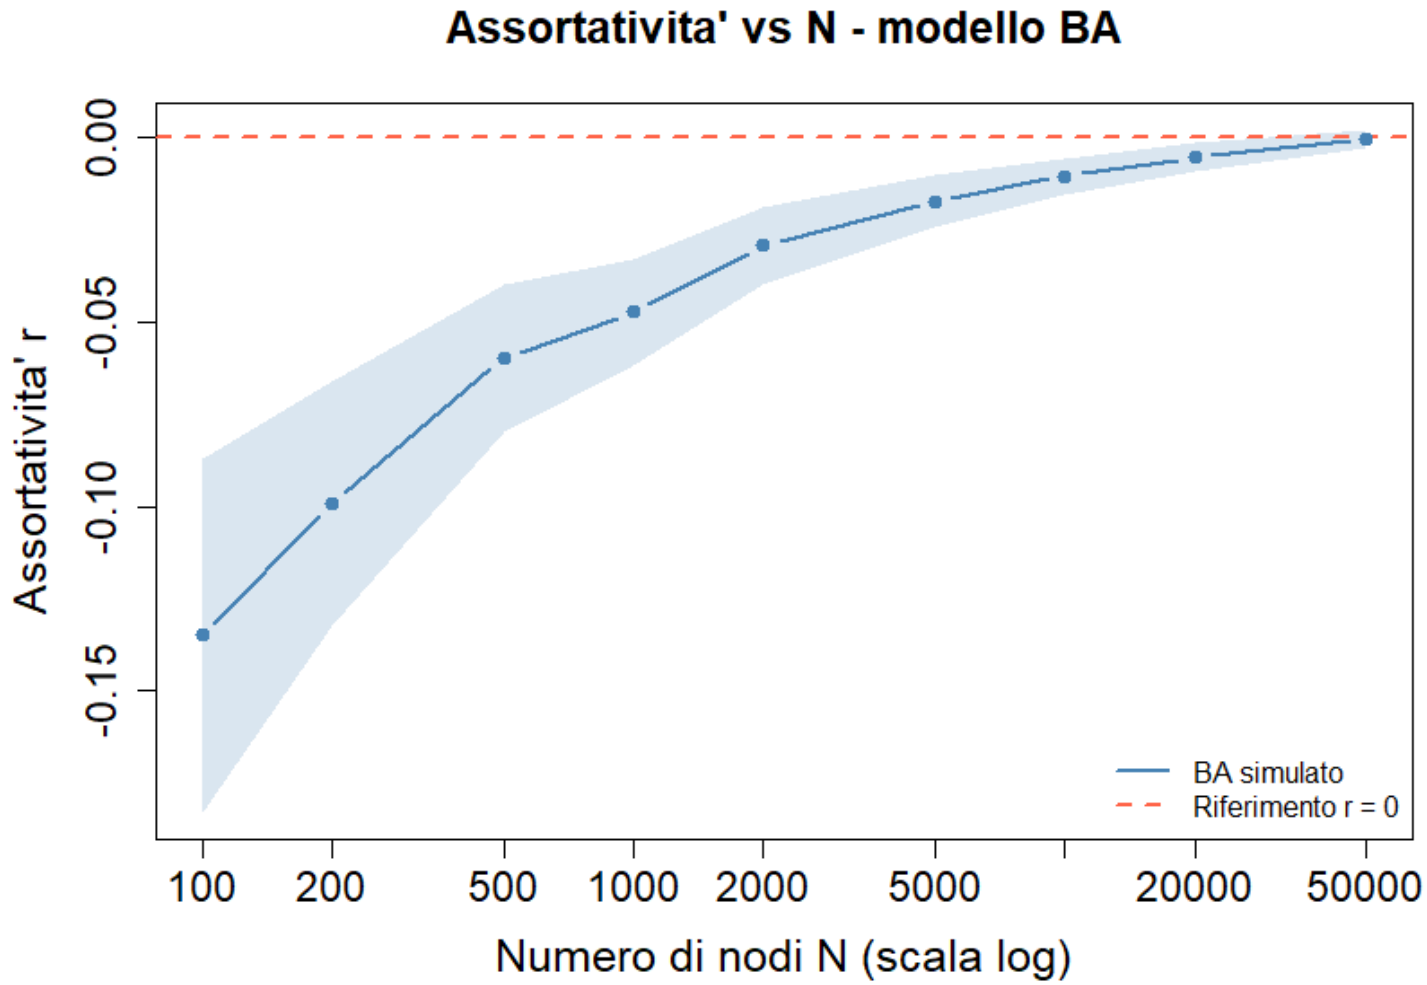
Coefficiente di assortatività misura la correlazione tra i gradi dei nodi collegati:

$$r = \frac{\mathrm{Cov}(k_i, k_j)}{\sigma_{k_i}\sigma_{k_j}}$$

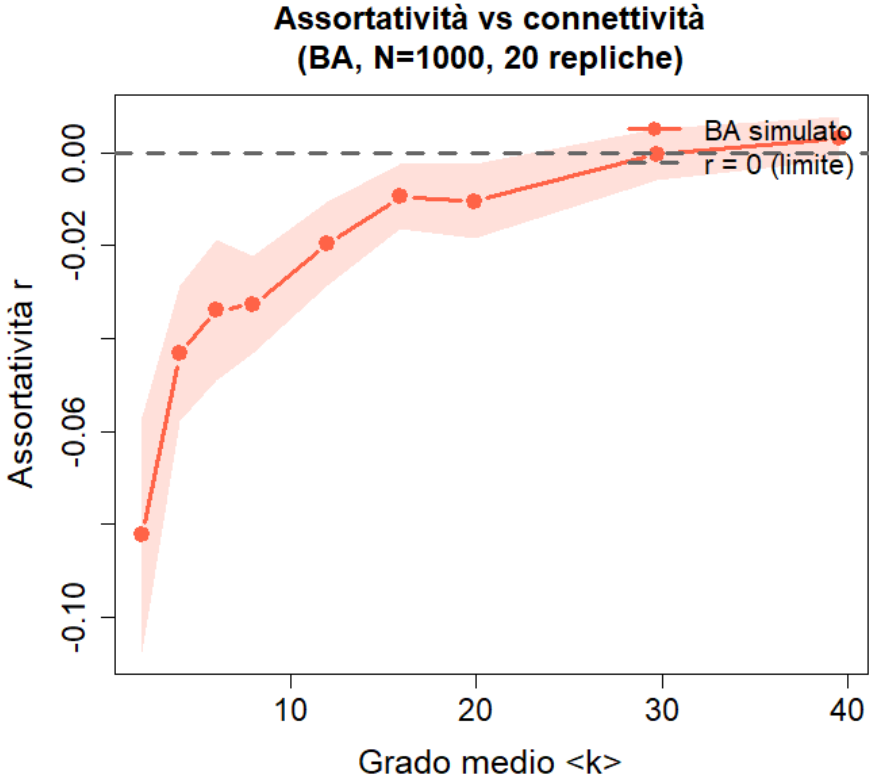
Nel modello BA classico, il coefficiente di assortatività tende asintoticamente a zero:

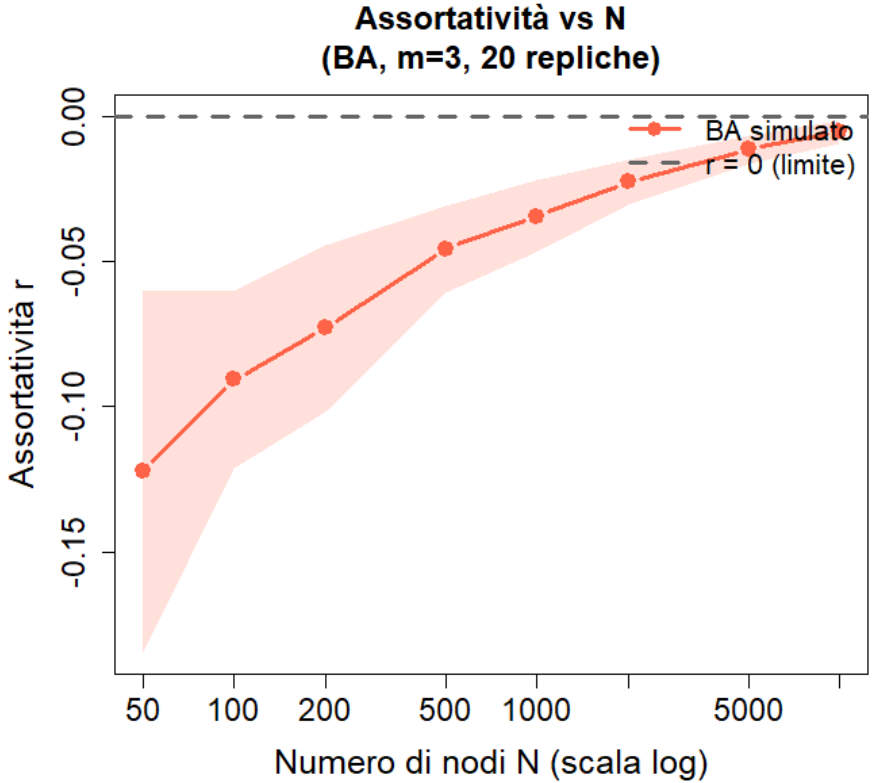
$$\boxed{r_{\mathrm{BA}} \longrightarrow 0 \qquad (N \to \infty)}$$

La presenza di hub non implica necessariamente una forte disassortatività.


Assortativita' vs N - modello BA
Assortativita' r
0.00
-0.05
-0.10
-0.15
100
200
500
1000
2000
5000
20000
50000
Numero di nodi N (scala log)
BA simulato
Riferimento r = 0

Modello BA – Assortatività





«Nel BA, la disassortatività osservata nelle reti finite si attenua all'aumentare della dimensione, mentre la distribuzione dei gradi rimane scale-free.»

Modello BA – Rich Club Effect

Modello BA – Clustering

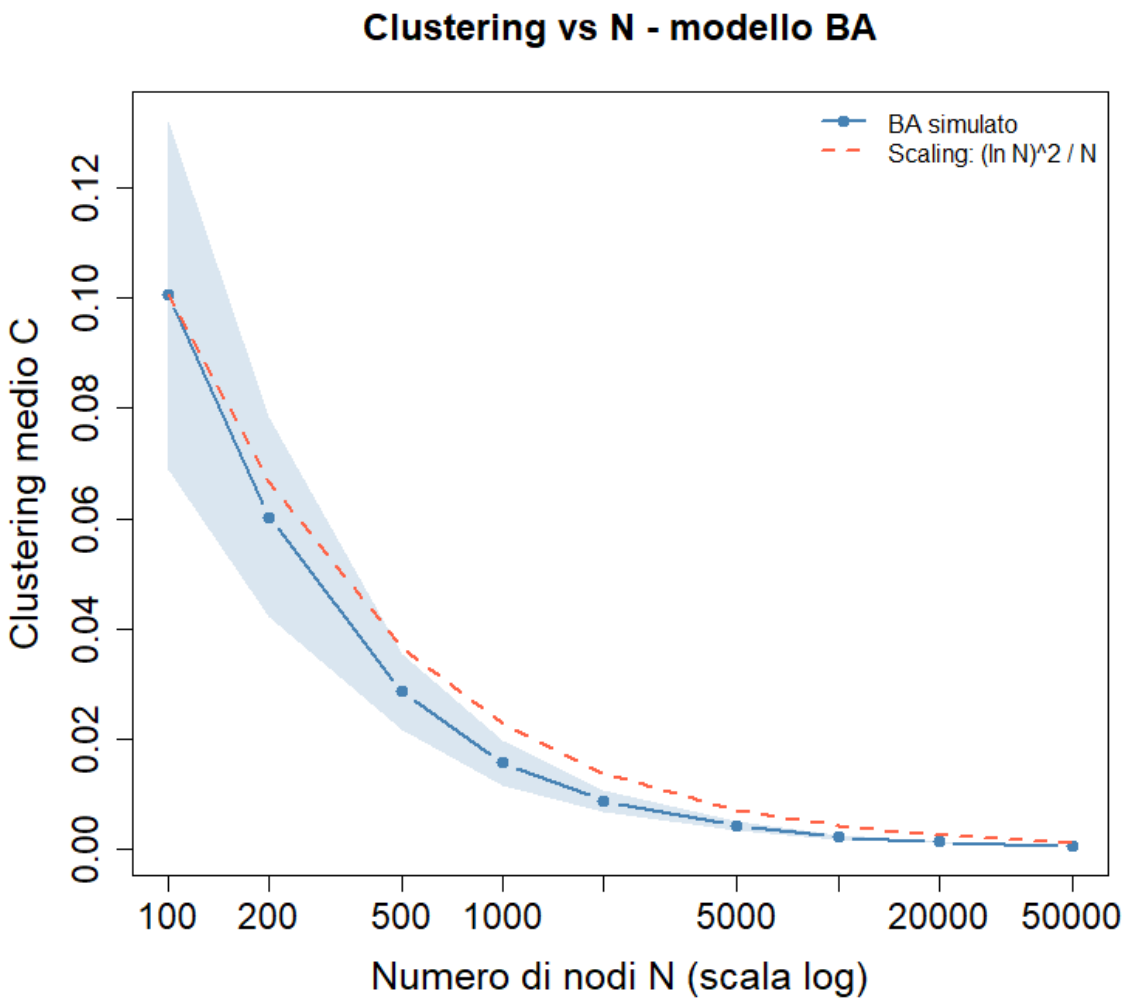
Ricordiamo che il clustering locale misura la frazione di coppie di vicini di un nodo che sono collegate tra loro:

$$C_i = \frac{2T_i}{k_i(k_i - 1)}$$

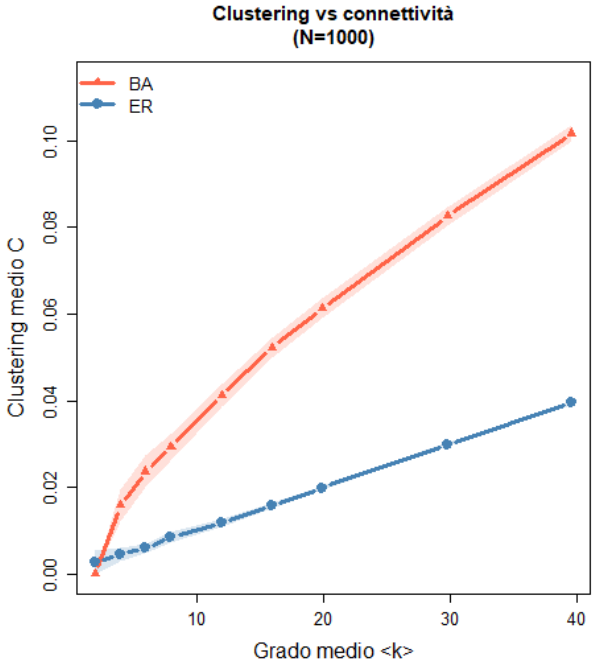
Nel BA, il clustering presenta una proprietà importante: diminuisce all'aumentare della dimensione della rete, nonostante la presenza di hub molto connessi

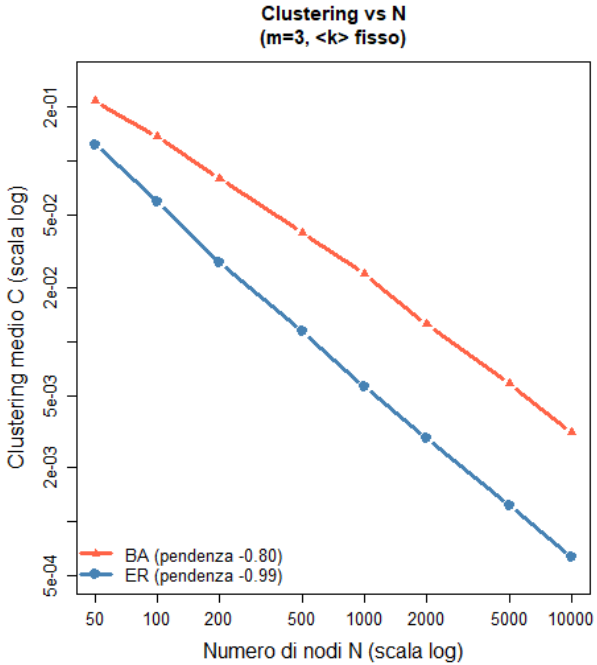
l'attaccamento preferenziale non favorisce direttamente la chiusura dei triangoli.

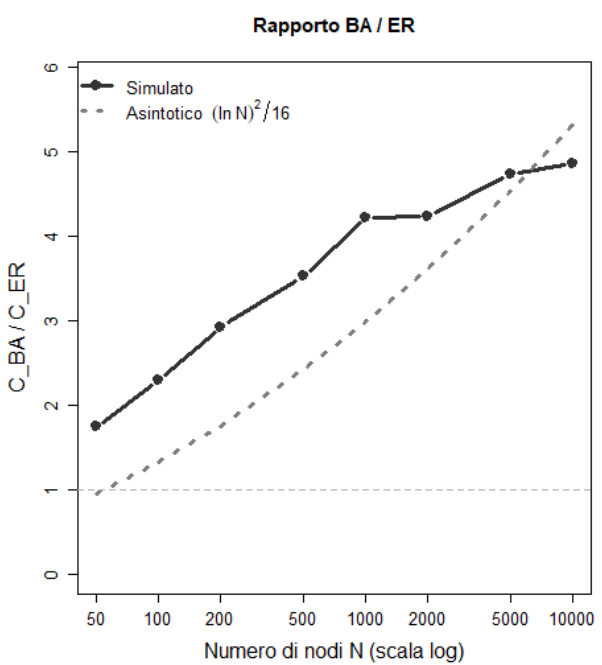
N


Clustering vs N - modello BA
BA simulato
Scaling: (ln N)^2 / N
Clustering medio C
0.00
0.02
0.04
0.06
0.08
0.10
0.12
100
200
500
1000
5000
20000
50000
Numero di nodi N (scala log)

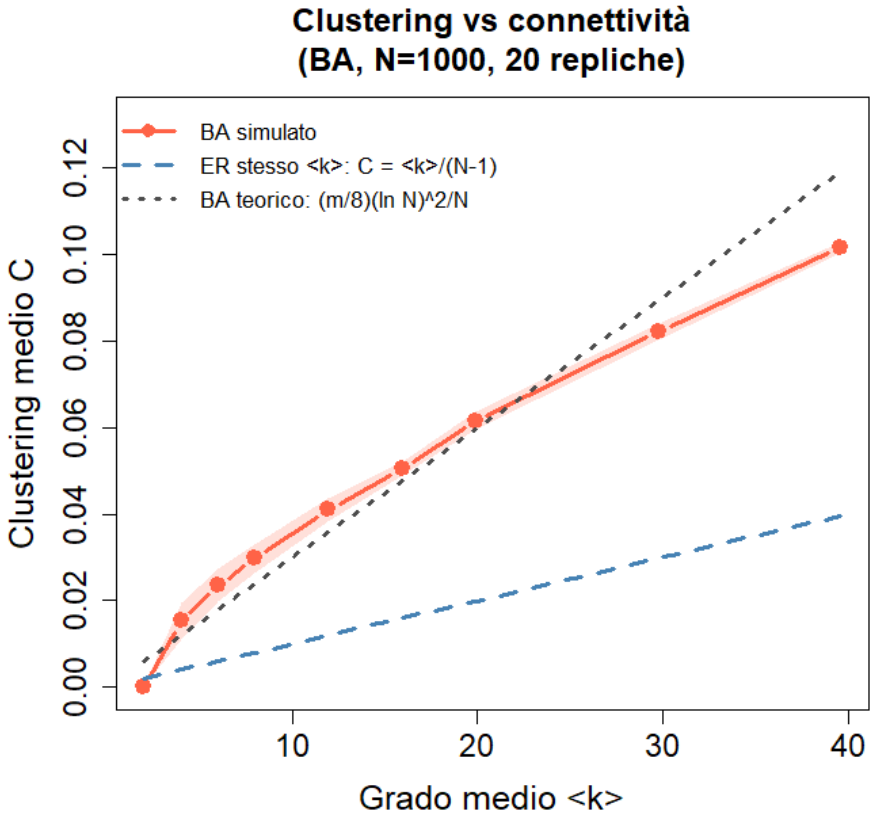
Modello BA – Clustering

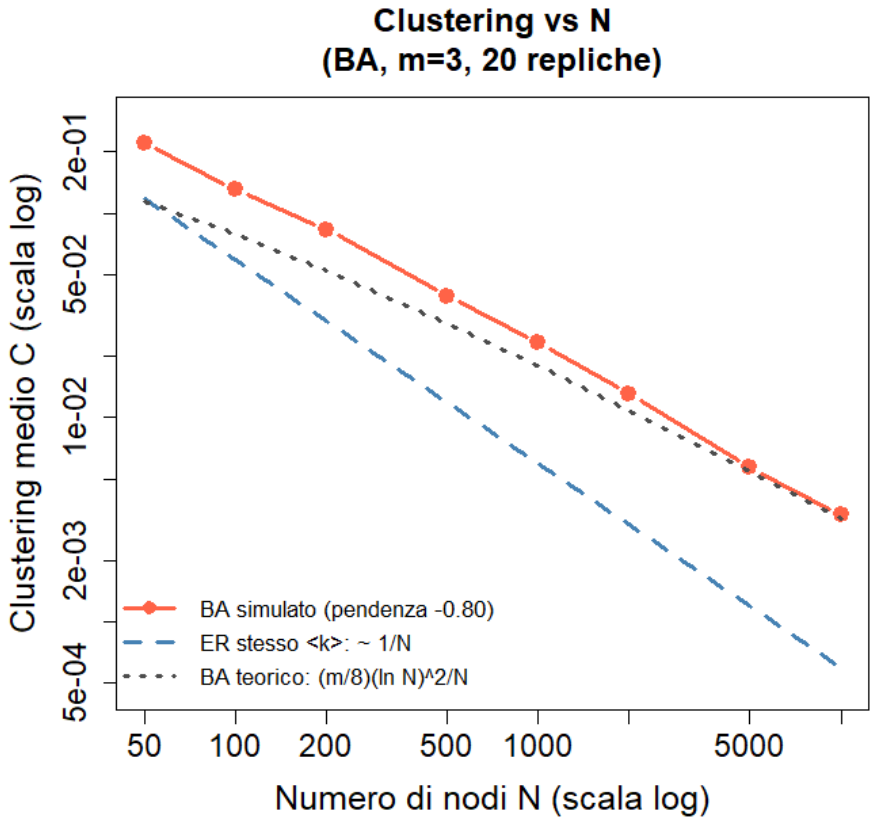






Modello BA – Clustering



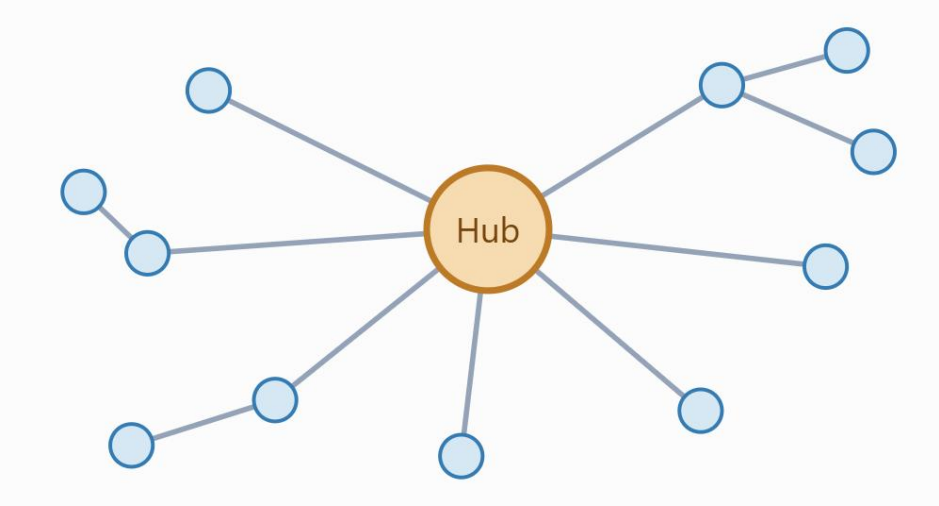


Modello BA – Distanza tra nodi

Nel modello BA, la distribuzione dei gradi segue asintoticamente:

$$P(k) \sim k^{-3}$$

Questo produce una rete con molti nodi poco connessi e pochi hub con un numero elevato di collegamenti.



Gli hub possono funzionare come **scorciatoie strutturali**, riducendo il numero di passaggi necessari per collegare nodi distanti.


Fine