

Regressione

Algoritmi per l'intelligenza artificiale

Vincenzo Bonnici

Corso di Laurea Magistrale in Scienze Informatiche

Dipartimento di Scienze Matematiche, Fisiche e Informatiche

Università degli Studi di Parma

2026-2027

Nei problemi di **classificazione** supervisionata ad ogni pattern x_i del training set é associata un'etichetta y_i (classe di appartenenza) Obiettivo del training é l'apprendimento di un **mapping** dallo spazio dei pattern a quello (**discreto**) delle etichette.

Nella **regressione** i valori y_i sono numerici e **continui** (in $\mathbb{R}$) e l'obiettivo del training è l'**apprendimento di una funzione** $f(x) \mapsto y$.

- f è controllata da un insieme di **parametri**. Se la dipendenza dai parametri è lineare (es assenza di elevazioni a potenza dei parametri nella definizione di f) la regressione si definisce **lineare**
- Nella regressione x è detta variabile **indipendente** e y variabile **dipendente**.
- Si assume che la variabile **indipendente** sia **esatta** mentre la variabile **dipendente** sia affetta da **errore** (es imprecisione di misura)

Se la variabile indipendente è uno scalare x (i.e. una sola variabile indipendente), parliamo di **simple linear regression** (retta di regressione).

Dato un training set TS contenente n dati $(x_1, y_1) \dots (x_n, y_n)$ e la seguente dipendenza tra variabile indipendente e dipendente

$$y_i = \alpha + \beta \cdot x_i + \varepsilon_i$$

dove:

- ε_i è l'errore di misura (incognito) del punto x_i
- α, β sono parametri da determinare


Regressione lineare semplice

La soluzione ai **minimi quadrati** (**Least Square**) del problema consiste nel determinare l'equazione della retta

$$f(x) = y = \alpha + \beta \cdot x$$

che minimizza la somma dei quadrati dei residui

$$\alpha^*, \beta^* = \operatorname{argmin}_{\alpha, \beta} \sum_{i=1 \dots n} (f(x) - y_i)^2 = \sum_{i=1 \dots n} \varepsilon_i^2$$



Il precedente problema di minimizzazione può essere facilmente risolto uguagliando a zero le derivate parziali della funzione obiettivo rispetto ai parametri α, β tenendo le cosiddette equazioni normali.

Risolvendo il sistema (due equazioni in due incognite) si ottiene:

$$\beta^* = \frac{\sum_{i=1\dots n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1\dots n}(x_i - \bar{x})^2}$$


$$\alpha^* = \bar{y} - \beta^* \bar{x}$$

dove $\bar{x}$ e $\bar{y}$ sono la media degli X_i e y_i rispettivamente.

Necessari almeno due punti x_i altrimenti il denominatore si annulla.

Regressione lineare semplice


Predizione Altezza da Peso



Peso	Altezza
72	173
54	159
65	172
58	170
62	165
72	176
60	173
64	179
55	166
46	158
52	158
47	160
55	167
54	166
55	164
49	157
51	165
51	162

Regressione lineare multipla

Se la variabile indipendente è un vettore $\mathbf{x}$ (i.e. più variabili indipendenti), parliamo di **multiple linear regression** (esempio iperpiano di regressione).



Regressione lineare multipla

Generalizziamo a iperpiani ($\mathbf{x} \in \mathbb{R}^d$).

Per semplicità di trattazione sia X la matrice rettangolare ($n \times (d + 1)$) ottenuta inserendo sulle righe gli n punti del TS, e avendo cura di inserire a destra una colonna con tutti valori 1

$$\mathbf{X} = \begin{bmatrix} x_{11} & \cdots & x_{1d} & 1 \\ x_{21} & \cdots & x_{2d} & 1 \\ \vdots & \ddots & \vdots & \vdots \\ x_{n1} & \cdots & x_{nd} & 1 \end{bmatrix}$$

e siano

$$\begin{array}{c} \text{uno scalare per} \\ \text{ogni pattern} \end{array} \rightarrow \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \text{e} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_{d+1} \end{bmatrix} \leftarrow \begin{array}{c} \text{termine noto} \end{array}$$

i vettori costruiti a partire dai valori della variabile indipendente (uno per ogni pattern) e dai $d + 1$ parametri da determinare.

Regressione lineare multipla

Le relazioni tra variabili indipendenti e dipendente possono essere scritte attraverso le equazioni

$$y_i = \sum_{j=1 \dots d+1} x_{ij} \cdot \beta_j \quad \text{per } i = 1 \dots n$$

.....



indici i, j riferiti alla matrice $\mathbf{X}$

o in forma matriciale come


$$\mathbf{y} = \mathbf{X}\beta$$

per $n > (d + 1)$, $\mathbf{X}$ è rettangolare, quindi ho un sistema di equazioni sovradeterminato.

In formato matriciale la funzione obiettivo da minimizzare Least Square può essere scritta come

$$\|\mathbf{y} - \mathbf{X}\beta\|^2$$

Regressione vs fitting geometrico



La regressione lineare least square minimizza le distanze **verticali** dall'iperpiano e non le distanze **euclidee** (cosa semplicemente ottenibile attraverso PCA). Ciò è conseguenza del fatto che le variabili indipendente e dipendente non hanno ruolo simmetrico (la variabile indipendente si considera esatta, mentre quella dipendente affetta da errore). Nota: scambiando le due variabili il risultato cambia. Nel caso di **nuvole di punti geometrici** le coordinate hanno lo stesso ruolo e PCA fitting è preferibile.

RMSE (Root Mean Square Error) è un indicatore di accuratezza di predizione. esso è la radice quadrata del criterio **MSE (Mean Square Error)** $= \frac{1}{N} \sum_{i=1 \dots N} (\hat{y}_i - y_i)^2$ implicito nell'ottimizzazione least square del modello lineare, dove y_i è il valore osservato e $\hat{y}_i$ è il valore predetto. Quindi $\hat{y}_i - y_i$ è l'errore (lo scostamento tra la curva fittata e i valori di input) punto per punto.

Altri modi di valutare l'accuratezza di predizione (non direttamente utilizzabili come loss per modello lineare) sono:

- **MAE** (Mean Absolute Error) = $\frac{1}{N} \sum_{i=1 \dots N} |\hat{y}_i - y_i|$
 - è più robusta di MSE rispetto a outliers (dati non affidabili con ampi scostamenti)
 - mantiene l'unità di misura (es scostamento in metri)
- **MAPE** (Mean Absolute Percentage Error) = $\frac{1}{N} \sum_{i=1 \dots N} \left| \frac{\hat{y}_i - y_i}{y_i} \right|$. E' una variante del MAE dove la penalizzazione dipende dallo scostamento percentuale rispetto alla grandezza dei dati.
- **R^2** (coefficiente di determinazione) = $1 - \frac{\sum_{i=1 \dots N} (y_i - \hat{y}_i)^2}{\sum_{i=1 \dots N} (y_i - \bar{y})^2}$. Indicatore statistico (con valori tra 0 e 1) che indica quanto il modello lineare fitta i dati (ovvero spiega la varianza della variabile dipendente). **Non valido per modelli non lineari.**


Con un semplice accorgimento è possibile continuare ad utilizzare la regressione lineare per approssimare i dati con **curve** e superfici. Nella teoria introdotta infatti l'importante è che la funzione di regressione sia lineare rispetto ai parametri e non rispetto alla variabile indipendente, i cui elementi possono comparire elevati a potenza, combinati tra loro, come argomento di funzioni trascendenti, ecc.

Accuratezza di predizione

Esempio, per $d = 1$ e modello **quadratico** $y = \beta_1 x^2 + \beta_2 x + \beta_3$ scriviamo X come

$$X = \begin{bmatrix} x_1^2 & x_1 & 1 \\ x_2^2 & x_2 & 1 \\ \vdots & \vdots & \vdots \\ x_n^2 & x_n & 1 \end{bmatrix}$$

ottenendo ($d = 2$ a destra)



Nel caso di dipendenza non lineare del modello dai parametri non esiste soluzione least square in forma-chiusa.

Esempio dalla biologia (enzyme-mediated reaction)

$$y = \frac{\beta_1 \cdot x}{\beta_2 + x}$$

Se la dipendenza è nota (come nell'esempio sopra), per la risoluzione si possono applicare tecniche iterative di **ottimizzazione numerica**:

- È possibile utilizzare il classico algoritmo di **Gradient Descent** (metodo del primo ordine che esegue passi in direzione contraria al gradiente)
- L'algoritmo più noto e utilizzato è quello di **Gauss-Newton** (metodo del secondo ordine che richiede stima Hessiana)

Regressione non lineare - dipendenza sconosciuta

Quando la dipendenza tra la variabile indipendente e dipendente non è nota (potrebbe essere lineare o non lineare) il problema può essere approcciato provando e validando sia il modello lineare (baseline) sia modelli non lineari via via più complessi.

Per alcune tecniche di classificazione studiate esiste una variante efficace per problemi di regressione. Casi notevoli (disponibili in scikit learn) sono

- **Random Forest Regressor**
- **Support Vector Regressor** (SVR). L'idea è di invertire la funzione obiettivo invece di richiedere che nella fascia del margine non ricadano sample, vogliamo che in essa ricada il maggior numero di sample del training set
- **Gradient Boosting Regressor**
- anche le **Reti Neurali** addestrate con classico error backpropagation consentono di risolvere efficacemente problemi di regressione

I vantaggi di un modello non lineare sono

- Maggiore **flessibilità** (più gradi di libertà del modello)
- Controllo della **complessità della soluzione** (gradi di libertà del modello, regolarizzazione, ecc)
- Possibilità di utilizzare funzioni loss alternative rispetto a MSE (che è implicita nella risoluzione least square) quali MAE, MAPE, ecc

Regressione ai quantili

Il modello lineare risolto ai minimi quadrati è uno stimatore della media condizionata. Significa che la retta di regressione è determinata per approssimare la media dei dati, e quindi l'entità degli **errori di previsione positivi e negativi** è la stessa.

Nel caso in cui si voglia dare un **peso diverso ai positivi e negativi** (es le conseguenze di una sottostima potrebbero essere più gravi di quelle di una sovrastima) si introduce la **regressione ai quantili** (o **percentili**).

- Con percentile **50%** si passa da media a mediana (la metà dei punti nel training set sono sopra la retta di regressione individuata e la metà sono sotto)
- percentile p la retta è individuata in modo da avere il $p\%$ di punti sotto e $1 - (p)\%$ sopra

Nella formulazione si utilizza una loss MAE con penalità diversa per predizioni in eccesso e difetto.

Per problemi di regressione di **piccole-medie dimensioni**

- Il modello **lineare** (rispetto ai parametri) risolto tramite least square (con fattorizzazione SVD) è l'approccio più semplice che costituisce una sorta di **baseline**
- Un modello **non lineare rispetto alla variabile indipendente** (ma lineare rispetto ai parametri) può essere un'ottima seconda scelta perché coniuga semplicità e flessibilità
- Quando sono necessari modelli più potenti, **Random Forest Regressor** rappresenta una valida alternativa
- Se la dipendenza tra variabile dipendente e indipendente è **nota** (ma **non lineare** rispetto ai parametri) l'ottimizzazione numerica con **Gauss-Newton** è la prima scelta

Per problemi di regressione di **grandi dimensioni** (lineari e non) l'approccio iterativo **Gradient Descent** utilizzato in combinazione con **Reti Neurali** è spesso preferibile per motivi di trattabilità numerica e complessità computazionale.

Nell'ambito del **deep learning**, reti neurali addestrate con gradient descent sono state utilizzate con successo per risolvere problemi di regressione di **enormi dimensioni** come la stima della posizione di un oggetto in un'immagine a partire da milioni di esempi (vedi **Faster R-CNN**)

- la variabile indipendente è un'immagine (pixel)
- La variabile dipendente la bounding box dell'oggetto (trattasi in questo caso di un vettore, quindi multivariate multiple regression)