

PARTE 4: AGENTE, ARBITRATO E RAGIONAMENTO

1. Il Ruolo di Qwen-VL-72B come Agente Senior

Nel progetto non ci limitiamo a usare modelli di computer vision come YOLO, infatti il cuore del sistema è il MedicalAgent che utilizza il Large Language Model Multimodale di Qwen-VL-72B che agisce da Arbitro Clinico.

Qwen riceve tre flussi di dati fusi insieme:

1. Visione Locale (Crops): YOLO identifica dei "bounding box" (aree sospette).

Queste aree vengono ritagliate ed inviate all'LLM ad alta risoluzione.

2. Conoscenza Esterna (RAG): Attraverso `RagTool`, interroghiamo il database vettoriale di ChromaDB

le quali informazioni vengono poi iniettate nel prompt per guidare l'LLM.

3. Contesto Globale (Swin-B): L'LLM riceve anche l'esito del classificatore globale. Se Swin-B dice che

l'immagine è negativa, ma YOLO trova un box, l'LLM viene allertato con una nota di cautela per evitare falsi positivi.

2. Implementazione Tecnica e Ottimizzazione

-Encoding e Latenza: Inviaamo le immagini codificate in Base64 dopo un ridimensionamento a 1024px.

Questo garantisce il miglior compromesso tra dettaglio diagnostico e velocità di risposta del server HPC.

-Integrazione Metadati: Se l'utente specifica la proiezione (AP/PA anteroposteriore, posteroanteriore), questa informazione entra nel prompt tecnico,

permettendo all'LLM di verificare se l'anatomia visibile (es. posizione delle scapole o clavicole) corrisponde alla tecnica dichiarata.

POSSIBILI DOMANDE DEL PROFESSORE

1. D: Perché usare un LLM invece di addestrare meglio YOLO?

R: YOLO è eccezionale nel trovare oggetti, ma manca di "senso clinico". L'LLM può capire che un'opacità in una certa zona è semplicemente la sovrapposizione di un osso e può spiegare il perché in linguaggio naturale, rendendo l'IA "Explainable" (XAI).

2. D: Come gestite il rischio di allucinazioni dell'LLM?

R: Usiamo il RAG. L'LLM non risponde basandosi solo sulla sua memoria latente, ma deve confrontare l'immagine con i protocolli medici reali estratti in tempo reale dal database. Inoltre, la temperatura del modello è impostata a 0.1 per favorire risposte deterministiche e precise.

3. D: Cos'è quel "Multimodal Arbitration" di cui parli?

R: È il processo in cui l'LLM riceve opinioni contrastanti e deve decidere chi ha ragione analizzando il contesto anatomico dell'area ritagliata.

PARTE 5: TRASPARENZA, ARCHITETTURA E REPORTING

1. L'Interfaccia Streamlit e lo "Streaming del Pensiero"

Abbiamo progettato l'interfaccia per essere dinamica. Infatti, invece di mostrare una barra di caricamento generica, l'utente vede il processo di ragionamento in tempo reale.

Ogni step (Analisi Tecnica, Analisi Area 1, Area 2, ecc.) appare non appena l'LLM finisce di elaborare, creando trasparenza operativa.

2. Toolstack

Backend/UI: Python 3.12, Streamlit per la presenza di componenti riutilizzabili

Visione: YOLO v10, YOLO v11, Swin Transformer-B

Multimodal LLM: Qwen-VL-72B che comunica con un Endpoint dell'HPC

Vector DB/RAG: ChromaDB, FastEmbed con il modello Multilingual-E5-Large che garantisce una vasta conoscenza

Deployment: Docker che ci permette di avere un ambiente riproducibile, NVIDIA Container Toolkit

per sfruttare l'accelerazione GPU per i modelli YOLO e Swin locali
Utilities: OpenCV per il preprocessing, FPDF per la generazione del report PDF, Pandas/Altair per la generazione dei grafici

POSSIBILI DOMANDE DEL PROFESSORE

1. D: Perché avete scelto Docker invece di un'installazione standard?

R: Nel settore medico, la riproducibilità è fondamentale. Docker garantisce che l'ambiente (versioni di Python, driver CUDA, librerie OpenCV) sia identico ovunque, eliminando il problema "sul mio PC funziona".

2. D: Come gestite la privacy in questo sistema?

R: Il sistema è progettato per funzionare in locale o in server privati. Il calcolo dell'hash MD5 non contiene dati sensibili del paziente, ma solo l'impronta digitale dell'immagine per l'indicizzazione.

3. D: Cosa aggiunge il report PDF rispetto alla visualizzazione web?

R: Il PDF è un documento immutabile che può essere allegato alla cartella clinica del paziente. Il nostro generatore (``pdf_generator.py``) pulisce il markdown e impagina i risultati in modo professionale, separando la sintesi diagnostica dal dettaglio tecnico.

PARTE 6: RISULTATI E VISIONE FUTURA

1. Dashboard di Performance

Abbiamo integrato una dashboard di performance basata su Pandas e Altair, che interroga i dati archiviati per monitorare metriche chiave come la confidenza media dei modelli e la distribuzione dei casi positivi e negativi. Questo strumento offre una panoramica epidemiologica chiara e costante sull'andamento delle analisi effettuate nel tempo.

2. Verso il Futuro: DICOM e Diagnosi 360°

Attualmente il sistema accetta comuni file immagine (PNG/JPG). La prossima evoluzione prevede:

- Integrazione DICOM nativa: Per leggere i metadati originali delle macchine radiografiche (dose di radiazioni, specifiche del sensore).
- Espansione della Knowledge Base: Caricando tramite ChromaDB nuovi PDF allargando quindi la knowledgebase su più punti di vista.
- Segmentazione polmonare: Tramite un algoritmo di segmentazione polmonare, ritaglio i polmoni per poi inviarli al LLM.
- Cascade R-CNN: Per migliorare la precisione del rilevamento di noduli polmonari.

POSSIBILI DOMANDE DEL PROFESSORE

1. D: Come misureresti il successo clinico di XRayAnalyzer?

R: Oltre alla precisione tecnica, il vero successo è quanto il sistema aiuti il medico a lavorare più velocemente e a non farsi sfuggire casi poco evidenti o "nascosti" che un occhio stanco potrebbe ignorare.

2. D: È facile scalare il database di conoscenza (RAG)?

R: Sì, grazie a ChromaDB. Basta aggiungere nuovi file PDF nella cartella di knowledge base e rieseguire l'embedding. Non è necessario ri-addestrare i modelli neurali (Swin o YOLO), rendendo il sistema estremamente flessibile.

3. D: Qual è il limite attuale del progetto?

R: Il limite principale è la dipendenza dalla connettività per l'LLM. Tuttavia, l'architettura è modulare e permette di sostituire l'endpoint remoto con un modello locale più piccolo per ambienti totalmente offline.