

Presentazione – Dissecting Racial Bias in an Algorithm Used to Manage the Health of Populations

Obermeyer e altri, *Science*, 2019

Introduzione: perché questo studio è importante

In questa presentazione analizzerò lo studio di Obermeyer e altri, pubblicato su *Science* nel 2019. Si tratta di un lavoro che ha avuto un impatto profondo nel dibattito sull'intelligenza artificiale applicata alla sanità, poiché affronta il tema dell'equità algoritmica in un contesto di scala nazionale.

Negli ultimi anni, gli algoritmi predittivi sono entrati stabilmente nei sistemi sanitari non solo per compiti diagnostici, ma anche per supportare decisioni organizzative critiche, come l'allocazione di cure aggiuntive a pazienti con bisogni complessi. Lo studio parte da un quesito fondamentale: un algoritmo ampiamente utilizzato nel sistema statunitense che influisce sulle cure di milioni di persone, è realmente neutrale rispetto alla razza o produce una discriminazione sistematica?

L'aspetto più significativo è che l'algoritmo non utilizza la variabile "razza" tra i suoi input. Eppure, i ricercatori hanno scoperto un forte bias razziale: a parità di punteggio di rischio, i pazienti Neri risultano significativamente più malati dei pazienti Bianchi. Questo è un punto centrale della mia analisi: l'algoritmo è tecnicamente "**race-blind**", ma lo studio dimostra chiaramente come l'omissione di un dato sensibile non garantisca affatto la neutralità dei risultati. L'obiettivo della presentazione sarà quindi sviscerare i meccanismi economici e metodologici che hanno generato questa disparità.

Il contesto: algoritmi nella gestione della salute

Passando all'analisi del contesto operativo, è opportuno sottolineare come i sistemi sanitari statunitensi si affidino sistematicamente a strumenti di predizione commerciale per identificare i pazienti con necessità cliniche complesse. Questi soggetti vengono indirizzati verso programmi di "high-risk care management", i quali mirano a migliorare i risultati clinici e la soddisfazione del paziente attraverso un coordinamento intensivo dell'assistenza, il supporto di personale infermieristico dedicato e l'accesso a risorse ambulatoriali supplementari.

Data l'onerosità di tali interventi, la selezione dei beneficiari rappresenta un problema critico di allocazione di risorse scarse. In questo scenario, l'algoritmo assegna a ogni paziente un punteggio di rischio (risk score) basato sui dati dell'anno precedente. Nella pratica osservata, i pazienti che superano il 97° percentile vengono solitamente inseriti in modo automatico, mentre quelli sopra il 55° percentile sono segnalati al medico curante per una valutazione discrezionale.

Secondo le stime del settore, questa tipologia di algoritmi viene applicata a circa 200 milioni di persone ogni anno negli Stati Uniti. Risulta quindi evidente che non si tratti di un caso marginale, ma di una metodologia strutturale della sanità contemporanea che incide profondamente sulla distribuzione delle cure.

Cosa predice realmente l'algoritmo?

Formalmente, l'algoritmo è progettato per predire il "rischio sanitario futuro" al fine di indirizzare i pazienti verso interventi preventivi. Tuttavia, emerge qui il primo nodo critico della ricerca: lo strumento non predice direttamente lo stato di salute o l'insorgenza di malattie, bensì i **costi sanitari totali** dell'anno successivo.

Questa scelta metodologica si basa su un presupposto fondamentale dell'industria assicurativa: i costi medici futuri rappresentano un efficace "proxy" (o variabile sostitutiva) delle necessità cliniche. L'ipotesi implicita è che i pazienti che genereranno una spesa maggiore siano anche quelli con il carico di malattia più elevato e che, di conseguenza, trarrebbero il massimo beneficio dai programmi di gestione.

Sebbene questa correlazione sembri intuitivamente corretta, dato che pazienti più malati tendono a consumare più risorse, lo studio dimostra che questa equivalenza è profondamente problematica e rappresenta la fonte primaria del bias razziale rilevato.

I dati utilizzati

Per quanto riguarda la metodologia e i dati utilizzati, lo studio si avvale della collaborazione con un importante ospedale accademico, prendendo in esame i dati relativi a pazienti inseriti in contratti basati sul rischio nel periodo compreso tra il 2013 e il 2015. La base dati è particolarmente robusta e comprende 6.079 pazienti neri e 43.539 pazienti bianchi, tutti regolarmente coperti da assicurazione sanitaria (commerciale o Medicare).

Per ogni soggetto, i ricercatori hanno potuto incrociare diverse fonti informative di grande dettaglio:

- I **punteggi di rischio** assegnati annualmente dall'algoritmo.
- I **dati clinici** estratti dalle cartelle cliniche elettroniche.
- Il **numero di patologie croniche attive**, utilizzato come misura complessiva dello stato di salute.
- I **costi sanitari reali** e i dati sull'utilizzo dei servizi (come ospedalizzazioni e visite d'emergenza) derivanti dai registri assicurativi.

Questa integrazione di dati ha consentito un confronto rigoroso tra tre dimensioni fondamentali: l'output previsionale dell'algoritmo, l'effettivo stato di salute biologica del paziente e la spesa sanitaria realmente generata.

Risultato principale

Il cuore dell'analisi evidenzia un risultato tanto lineare quanto critico: a parità di punteggio di rischio assegnato dall'algoritmo, i pazienti Neri presentano un quadro clinico significativamente più compromesso rispetto ai pazienti Bianchi.

Analizzando i dati nel dettaglio, emergono discrepanze sostanziali:

- **Malattie croniche:** Prendendo come riferimento la soglia del 97° percentile di rischio, i pazienti Neri hanno in media il **26,3% di malattie croniche in più** rispetto ai Bianchi.
- **Gravità biologica:** La disparità non riguarda solo il numero di diagnosi, ma la gravità oggettiva delle patologie misurata tramite biomarcatori.
- **Diabete e Ipertensione:** I pazienti Neri mostrano livelli significativamente più elevati di emoglobina glicata e una pressione sistolica più alta.
- **Funzione renale e Anemia:** Si riscontrano inoltre indicatori peggiori relativi alla creatinina (segno di insufficienza renale) e livelli più bassi di ematocrito, indicativi di una maggiore incidenza di anemia.

In sintesi, emerge che, se si considera la salute reale e biologica come parametro di riferimento, i pazienti Neri sono affetti da patologie più gravi e meno controllate rispetto ai pazienti Bianchi che hanno ricevuto lo stesso identico punteggio di rischio.

Conseguenze pratiche

In termini di impatto sulle politiche sanitarie, è necessario evidenziare come questo bias non rimanga confinato alla teoria, ma determini una disparità sistematica nell'accesso a programmi di cura intensiva.

L'effetto delle distorsioni algoritmiche si traduce in dati di partecipazione molto chiari:

- **Composizione attuale:** Tra i pazienti identificati automaticamente per il programma di gestione del rischio, la quota di pazienti Neri è solo del **17,7%**.
- **Scenario controfattuale:** Attraverso una simulazione che elimina il divario di salute condizionato al rischio, i ricercatori hanno dimostrato che la percentuale di pazienti Neri nel gruppo ad alta priorità dovrebbe salire al **46,5%**.
- **Sottorappresentazione:** Questo scarto indica che oltre la metà dei pazienti Neri con reali necessità sanitarie complesse non viene identificata come prioritaria dall'attuale sistema di punteggio.

Risulta dunque evidente che il bias algoritmico agisce come una barriera invisibile all'accesso alle cure: pur avendo bisogno di interventi di coordinamento clinico, molti pazienti Neri vengono esclusi perché lo score non riflette accuratamente il loro stato di salute biologica.

Il ruolo dei medici

In merito all'interazione tra l'intelligenza artificiale e il giudizio clinico, lo studio evidenzia come l'intervento umano non sia sufficiente a correggere le distorsioni del sistema.

L'algoritmo agisce come uno strumento di screening che segnala i pazienti ai medici, i quali possono poi decidere se procedere o meno con l'inserimento nel programma.

Analizzando i dati sulle iscrizioni effettive, emergono i seguenti punti:

- La quota di pazienti Neri effettivamente inseriti nel programma è pari al **19,2%**.
- Questo valore rappresenta solo un lieve incremento rispetto al **17,7%** che risulterebbe da una selezione puramente algoritmica basata sui costi.
- Tale correzione appare marginale se confrontata con il **46,5%** di pazienti Neri che dovrebbero essere inclusi se l'inserimento si basasse sull'effettivo bisogno di salute.

Questi risultati suggeriscono che l'essere umano, pur avendo accesso a informazioni contestuali e cartelle cliniche, non riesce a ribaltare l'ingiustizia strutturale dell'algoritmo.

Una volta che l'output algoritmico definisce il perimetro della decisione, il giudizio del medico tende a rimanere ancorato a quel suggerimento distorto, rendendo difficile la piena correzione del bias.

Il meccanismo del bias

Entrando nell'analisi tecnica del meccanismo di bias, è necessario distinguere tra l'accuratezza statistica del modello e la sua equità sostanziale. Un aspetto paradossale rilevato dallo studio è che l'algoritmo risulta **ben calibrato sui costi**.

I dati dimostrano infatti che:

- A parità di punteggio di rischio, i pazienti Bianchi e Neri generano costi sanitari quasi identici nell'anno successivo.
- Ad esempio, nel primo decile di rischio, i costi realizzati sono di circa \$5.147 per i pazienti Neri e \$4.995 per i Bianchi.
- Di conseguenza, se valutato esclusivamente rispetto all'obiettivo di prevedere la spesa sanitaria, l'algoritmo non presenta bias e appare tecnicamente preciso.

Il problema fondamentale emerge nel momento in cui si mette in relazione il costo con l'effettivo stato di salute. I ricercatori hanno osservato una discrepanza sistematica:

- A parità di numero di malattie croniche, i pazienti Neri generano costi significativamente inferiori rispetto ai Bianchi.
- Nello specifico, mantenendo costante il carico di patologie, per un paziente Nero si spendono in media **1.801 dollari in meno** all'anno.
- Questo implica un'equazione distorta: **stesso livello di gravità clinica → minore spesa sanitaria erogata**.

Poiché l'algoritmo utilizza la spesa come *proxy* della salute, interpreta erroneamente questa minore spesa come un minore bisogno clinico. Di conseguenza, un paziente Nero deve essere molto più malato di un paziente Bianco per generare lo stesso livello di costi e, quindi, per ottenere lo stesso punteggio di rischio.

Perché i pazienti neri generano meno costi?

Lo studio identifica due canali principali attraverso i quali le disuguaglianze strutturali influenzano i dati utilizzati dall'algoritmo.

Il primo canale riguarda i **fattori socioeconomici**. Nonostante la popolazione studiata sia interamente assicurata, permangono barriere sostanziali che limitano l'utilizzo dei servizi sanitari da parte dei pazienti Neri:

- Una minore disponibilità di trasporti o una collocazione geografica sfavorevole.
- Richieste contrastanti derivanti da impegni lavorativi o dalla cura dei figli.
- Una minore continuità nelle cure e una diversa consapevolezza delle ragioni per cui richiedere assistenza.

Il secondo canale è legato a **dinamiche di discriminazione** e al rapporto con il sistema sanitario:

- Una ridotta fiducia nel sistema, spesso riconducibile a esperienze storiche avverse.
- Bias impliciti dei medici e differenze nella percezione dei pazienti Neri in termini di affiliazione o tolleranza al dolore.
- Una dimostrata maggiore adesione alle cure preventive quando il medico appartiene alla stessa etnia del paziente, evidenziando barriere relazionali nel sistema standard.

Tutto ciò determina una situazione strutturale in cui i pazienti Neri ricevono meno cure e, di conseguenza, generano costi inferiori.

Un dettaglio tecnico fondamentale osservato dai ricercatori riguarda la **natura della spesa**. I pazienti Neri generano costi di natura diversa rispetto ai Bianchi:

- Registrano meno spese per interventi chirurgici e per visite specialistiche.
- Al contrario, presentano costi più elevati legati a visite d'emergenza e trattamenti di dialisi.

L'algoritmo, tuttavia, aggrega tutte queste voci in un unico indicatore di costo totale. Non distinguendo tra queste dinamiche, il modello interpreta la minore spesa complessiva come un segnale di salute migliore, ignorando che essa riflette in realtà un minor accesso a determinati livelli di cura.

Il problema della “label”

In questa fase dell'analisi, ci si sofferma sul contributo teorico più rilevante dello studio: la questione della "**problem formulation**". Il nocciolo della questione non risiede nella sofisticazione del modello statistico, ma nella scelta della variabile target, ovvero la *label* che decidiamo di predire.

Per dimostrare questo punto, i ricercatori hanno condotto una serie di esperimenti sviluppando nuovi algoritmi predittivi addestrati su obiettivi differenti:

- **Costi totali:** per replicare la logica del modello originale nel proprio dataset.
- **Costi evitabili:** legati a pronto soccorso e ospedalizzazioni.
- **Salute misurata:** intesa come il numero di patologie croniche attive.

I risultati mostrano che, mentre tutti i modelli sono statisticamente efficaci nel predire i rispettivi obiettivi, la composizione demografica del gruppo ad alto rischio cambia drasticamente. La frazione di pazienti Neri identificati sale dal 14,1% del modello basato sui costi al **26,7%** del modello basato sulla salute reale. Questo conferma che la scelta della *label* è il determinante principale del bias algoritmico.

Un elemento di grande valore accademico di questo lavoro è la collaborazione post-studio con il produttore dell'algoritmo. L'azienda ha replicato l'analisi su un dataset nazionale di **3,7 milioni di pazienti**, confermando integralmente le scoperte dei ricercatori.

Insieme hanno testato una soluzione concreta, mantenendo invariata l'infrastruttura del modello ma sostituendo la *label* del costo con un indice combinato che include misure di salute multidimensionali. Questo intervento ha permesso di **ridurre il bias dell'84%**. Questo risultato dimostra che il bias non è una caratteristica inevitabile dell'intelligenza artificiale, ma la conseguenza di un errore di progettazione. È un problema correggibile in quanto non richiede nuove tecniche statistiche, ma una scelta più oculata delle variabili target (le *label*) e una comprensione profonda del contesto clinico e sociale in cui l'algoritmo opera.

Implicazioni più ampie

È fondamentale sottolineare come questo meccanismo non sia limitato al solo settore sanitario. Lo studio evidenzia che la scelta di "proxy" apparentemente neutri, ma influenzati da disuguaglianze strutturali, è un problema trasversale a molti ambiti della scienza dei dati. Possiamo riscontrare analogie dirette in diversi settori critici:

- **Settore creditizio:** gli algoritmi predicono la solvibilità basandosi sul reddito, incorporando così le disparità esistenti nell'occupazione e nei salari.
- **Giustizia penale:** i software predicono il rischio di recidiva basandosi sui dati di arresto, i quali riflettono anche una maggiore sorveglianza di determinati gruppi.
- **Risorse umane:** gli algoritmi di assunzione predicono le performance basandosi su decisioni di impiego o valutazioni dei supervisor, che sono già influenzate da bias di genere e razza.
- **Commercio al dettaglio:** persino i sistemi di pricing possono penalizzare le famiglie più povere, che si ritrovano a pagare prezzi più alti come conseguenza di modelli nazionali.

In sintesi, quando la variabile target riflette disuguaglianze strutturali, l'algoritmo non fa altro che apprenderle e amplificarle.

Discussione critica

L'importanza di questo studio risiede nel dimostrare tre punti fondamentali per la comprensione dei sistemi complessi:

1. **Accuratezza vs Equità**: un algoritmo può essere tecnicamente accurato e tuttavia essere profondamente ingiusto sotto il profilo della salute.
2. **L'insufficienza della "Race-Blindness"**: l'assenza della variabile "razza" non garantisce la neutralità, poiché l'informazione può filtrare attraverso variabili correlate.
3. **Il bias nei dati**: la discriminazione emerge dalla struttura sociale incorporata nei dati storici usati per l'addestramento.

Tuttavia, è opportuno discutere anche alcuni **limiti del lavoro**:

- L'analisi si basa su un singolo sistema sanitario accademico.
- Pur evidenziando il bias, lo studio non può risolvere completamente il problema delle cause profonde della disuguaglianza nell'accesso alle cure.
- Rimane aperta la tensione tra l'efficienza economica (ridurre i costi) e l'equità clinica (curare chi è più malato).

Conclusione

In sintesi, il lavoro di Obermeyer dimostra che l'equità algoritmica non è solo una sfida tecnica, ma soprattutto concettuale e politica.

Questo caso studio ci insegna che, nell'analisi di sistemi complessi, non è più sufficiente chiedersi se un modello sia statisticamente accurato. La domanda centrale deve invece essere: **'Cosa stiamo effettivamente chiedendo al modello di imparare?'**.

Se la variabile target scelta, in questo caso il costo, è il prodotto di un'ingiustizia sociale preesistente, l'algoritmo non farà altro che automatizzare e scalare quella stessa ingiustizia su milioni di persone. Questo studio ci obbliga, quindi, a ripensare criticamente la scelta dei 'proxy' e il ruolo dell'intelligenza artificiale nei sistemi sociali, ricordandoci che il bias non è una fatalità tecnologica, ma un errore di progettazione che abbiamo il dovere di correggere.