

FONDAMENTI DELL'INTELLIGENZA ARTIFICIALE

PROGRAMMA E PROGETTI D'ESAME

Corso di Laurea Magistrale in Scienze Informatiche
Dipartimento di Scienze Matematiche, Fisiche e Informatiche (SMFI)
Università degli Studi di Parma

*

Programma d'Esame

Funzioni in più variabili

- Spazi metrici, metrica euclidea su $\mathbb{R}$, definizione di intorno sferico
- $\mathbb{R}^N$ come spazio vettoriale, base canonica di $\mathbb{R}^N$
- Norma euclidea su $\mathbb{R}^N$, prodotto scalare su $\mathbb{R}^N$, definizione di palla e di aperto di $\mathbb{R}^N$
- Definizione di funzione in più variabili $f : \mathbb{R}^N \rightarrow \mathbb{R}^M$
- Esempio: coordinate sferiche con codice
- Definizione di continuità per $f : \mathbb{R}^N \rightarrow \mathbb{R}$, continuità separata
- Derivabilità in più variabili: direzioni, derivata direzionale e parziale, gradiente, differenziale
- Esempio: derivata di $\|\underline{x}\|$
- Derivate parziali del secondo ordine, derivate miste, Teorema di Schwartz
- Metodo iterativo di discesa del gradiente con esempio di codice

Reti Neurali Artificiali

- Percettrone e neurone artificiale, definizione di pesi, bias
- Single Layer Perceptron (SLP)
- Addestramento di una rete neurale: apprendimento supervisionato e non supervisionato, dataset di training e di test
- Definizione di funzione di costo, loss L_1 (geometria del taxi) e loss L_2 (MSE)
- Algoritmo di discesa del gradiente su SLP
- Derivata della funzione composta in più variabili (chain rule)
- Calcolo del gradiente della funzione di costo MSE
- Funzioni di attivazione: Heaviside, sigmoide (logistica), ReLU, softplus, tanh
- Multi Layer Perceptron (MLP)
- Algoritmo di discesa del gradiente su MLP
- Calcolo del gradiente della funzione di costo MSE per MLP con un solo layer nascosto
- Algoritmo di backpropagation
- Algoritmo SGD (discesa del gradiente stocastica)

*Docente: Eleonora Iotti
e-mail: eleonora.iotti@unipr.it.

- Implementazione di MLP che classifica MNIST
- Teorema di approssimazione universale e relative considerazioni

Visione Artificiale

- Definizione di immagine, spazio colorimetrico
- Processo di digitalizzazione immagini attraverso campionamento e quantizzazione, definizione di risoluzione e codifiche colori
- Definizione di multi-linearità, tensori
- Visione di basso livello: operatori puntuali, locali e globali su immagine luminanza
- Istogramma dei livelli di grigio per operatori puntuali di inversione, compressione logaritmica, compressione potenza, espansione di contrasto
- Operatori locali, maschere e effetti di bordo
- Filtri di sharpening come operatori differenziali del I e II ordine
- Definizione di multi-indice e notazione
- Approssimazione di funzioni $f : \mathbb{R}^N \rightarrow \mathbb{R}$ con polinomi di Taylor, Teorema di Taylor
- Polinomi di Taylor per ottenere filtri di sharpening: filtro di Sobel, filtro Laplaciano
- Filtri di smoothing lineari: filtro di media, filtro gaussiano

Integrazione in più variabili e operazione di convoluzione

- Definizione di insieme compatto, supporto compatto, scatola chiusa, funzione semplice elementare
- Integrale su funzioni semplici elementari per definire l'integrale di $f : \mathbb{R}^N \rightarrow \mathbb{R}$ limitata e a supporto compatto
- Proprietà dell'integrale in più variabili
- Regola del cambio di variabile per integrali in $\mathbb{R}^N$
- Operazione di convoluzione e cross-correlazione nel continuo in una variabile
- Proprietà della convoluzione in una variabile: commutativa, linearità, tempo-invarianza
- Convoluzione nel continuo in due variabili
- Proprietà della convoluzione in due variabili: commutativa, linearità, indipendenza dalla posizione

Deep Learning

- Vanishing gradient problem: MLP con $L > 1$, esempio di percorso di backpropagation
- Convolutional Neural Networks (CNN) per gestire dati a griglia, ad esempio immagini, ragionamento a volumi o tensori
- Minimo esempio di strati usati in una CNN: layer convoluzionale, funzione di attivazione ReLU, layer di pooling, dropout
- Backpropagation sulla k -esima slice di un layer convolutivo
- Backpropagation sulla k -esima slice di un layer di pooling, problema della differenziabilità della funzione max
- Recurrent Neural Networks (RNN) per gestire dati sequenziali
- Variabili latenti e stima della verosimiglianza (likelihood)
- Cenni al Natural Language Processing (NLP) e ai Language Models (LM)
- Funzione di costo cross-entropy e attivazione softmax
- Reti generative differenziabili
- Metodo di inversione per la generazione di campioni da una distribuzione di probabilità
- Generative Adversarial Networks (GAN) come modelli generativi

Esempi di Progetti d'Esame

Reti Neurali Artificiali

1. Studiare la famiglia di algoritmi di ottimizzazione Adam. Implementare l'algoritmo di discesa del gradiente Adam e confrontare le prestazioni di quest'ultimo con SGD, su un MLP a uno strato nascosto e a più strati nascosti.
2. Studiare e confrontare tra loro le funzioni di attivazione ReLU, Leaky ReLU, GELU. Implementare un MLP a uno strato nascosto e a più strati nascosti, confrontando le prestazioni di queste funzioni di attivazione su un dataset di classificazione (ad esempio MNIST o FashionMNIST).
3. Studiare il dropout come tecnica di regolarizzazione per le reti neurali. Implementare un MLP a uno strato nascosto e a più strati nascosti, confrontando le prestazioni con e senza dropout su un dataset di classificazione (ad esempio MNIST o FashionMNIST).

Visione Artificiale

1. Studiare l'operazione di Cross Correlation normalizzata per trovare un pattern dentro a un'immagine (Template Matching) o di più occorrenze di tale pattern. Discutere il funzionamento del Template Matching quando il pattern da ricercare è ruotato, scalato, o parzialmente nascosto. Studiare un algoritmo di Non-Maximum Suppression per eliminare risultati ridondanti.
2. Studiare il problema dell'Edge Detection, individuando una pipeline adeguata che faccia uso di filtri e tecniche di visione artificiale classica. In particolare, implementare una versione del Canny Edge Detector.
3. Studiare l'uso di polinomi di Taylor per approssimare il flusso ottico (Optical Flow) in un video. Scegliere un metodo differenziale per stimare il flusso ottico e studiarne l'algoritmo (Kanade-Lucas-Tomasi o Gunnar-Farneback).
4. Studiare il problema di Background Subtraction (o Foreground detection), individuando una pipeline adeguata che faccia uso di tecniche di visione artificiale classica. Implementare in particolare il metodo MOG (Mixture of Gaussians) per estrarre informazioni da dati video.

Deep Learning

1. Studiare la rete Vision Transformer (ViT), descrivendola in termini di architettura. Analizzarne le prestazioni, confrontandone i risultati sul dataset ImageNet rispetto a una rete neurale convolutiva classica.
2. Studiare l'algoritmo di meta-learning Reptile e il setting few-shot. Implementare una CNN che classifichi il dataset Omniglot con Reptile. Confrontare le prestazioni di tale algoritmo rispetto a una CNN addestrata con SGD classico.
3. Studiare il task della Sentiment Analysis sul dataset IMDB Reviews. Individuare una pipeline adeguata per ottenere buone prestazioni su tale dataset, utilizzando approcci neurali (ad esempio RNN o LSTM).
4. Studiare le reti Transformer, descrivendole in termini di architettura. Confrontarne le prestazioni analizzando i risultati ottenuti con tali reti su un caso di studio, rispetto a un approccio classico.
5. Studiare il modello generativo dei Variational Auto-Encoders (VAE) e il modello generativo delle reti avversarie (GAN), confrontandoli tra loro.

6. Studiare il modello generativo dei Diffusion Models, confrontandolo con i modelli VAE e GAN.
7. Studiare il task della Semantic Segmentation su immagini del dataset COCO. Individuare una pipeline adeguata per ottenere buone prestazioni su tale dataset, utilizzando approcci neurali (ad esempio U-Net o Mask R-CNN).
8. Studiare il task della Object Detection su immagini del dataset COCO. Individuare una pipeline adeguata per ottenere buone prestazioni su tale dataset, utilizzando approcci neurali (ad esempio YOLO o Faster R-CNN).