

ESEMPI DI RISPOSTE ESAME

NB: Questi esempi non vanno presi alla lettera, ma dovrebbero darvi una idea del livello di dettaglio richiesto (quindi se alcune cose le scrivete diversamente ma sono CORRETTE, la risposta va bene lo stesso).

In riferimento al file domande.docx:

1) Per SPAZIO METRICO si intende la coppia (X, d) dove X è un INSIEME e d una DISTANZA, ovvero:

- $\forall x, y \in X, d(x, y) \geq 0$ POSITIVITA'
- $\forall x, y \in X, d(x, y) = d(y, x)$ SIMMETRIA
- $\forall x, y, z \in X, d(x, y) + d(y, z) \geq d(x, z)$ DIS. TRIANGOL.

La metrica EUCLIDEA è def. su $\mathbb{R}$ da:

$$d(x, y) = \sqrt{(x-y)^2} = |x-y|$$

2) Sia $f: \mathbb{R}^N \rightarrow \mathbb{R}$, si dice CONTINUA se

$$\forall \underline{x} \in \mathbb{R}^N \quad \forall \varepsilon > 0 \quad \exists \delta > 0 : \forall y \in \mathbb{R}^N,$$

$$\| \underline{x} - y \| \leq \delta \Rightarrow |f(\underline{x}) - f(y)| < \varepsilon$$

Questa definizione implica la continuità

in ogni direzione. Se $N=2$, ovvero se il dominio è in $\mathbb{R}^2$, si può parlare di CONTINUITÀ SEPARATA in x e in y .

Cio' significa che la definizione vale solo nella direzione individuata dalla VARIABILE x , ovvero $e_1 = (1, 0)$, oppure dalla y , ovvero $e_2 = (0, 1)$, rispettivamente.

3) Sia $f: \mathbb{R}^N \rightarrow \mathbb{R}$, data una direzione $\underline{v}$ si definisce DERIVATA DIREZIONALE, SE ESISTE, il limite del rapporto incrementale in quella direzione, ovvero:

$$\lim_{t \rightarrow 0} \frac{f(\underline{x}_0 + \underline{v}t) - f(\underline{x}_0)}{t}$$

Se $\underline{v}$ è una direzione delle basi canoniche, allora tale limite, se esiste, si dice DERIVATA PARZIALE.

Il gradiente è il vettore dato dalle derivate parziali in tutte le direzioni canoniche:


$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_N} \right)$$

4) Sia $f: \mathbb{R}^N \rightarrow \mathbb{R}$. Il metodo di DISCESA DEL GRADIENTE è un approccio iterativo per la ricerca di eventuali MINIMI della funzione f .

Sia $\underline{x}_0 \in \mathbb{R}^N$ nel dominio di f . Ad ogni passo, esso viene "spostato" nella DIREZIONE OPPOSTA rispetto a quella individuata dal gradiente ∇f , per un fattore moltiplicativo detto LEARNING RATE.

$$\begin{cases} \underline{x}_0 = \underline{a} \in \mathbb{R}^N & \text{arbitrario} \\ \underline{x}_t = \underline{x}_{t-1} - \eta \nabla f(\underline{x}_{t-1}) \end{cases}$$

5) IDEM come sopra + Non è garantita la CONVERGENZA, ad esempio, per $N=1$:




Il punto $\underline{x}_0$ è troppo vicino a un minimo LOCALE e si "incastra" senza raggiungere l'ottimo.

Il punto $\underline{x}_0$ è in una buona posizione ma il numero di iterazioni è insufficiente.

Altri casi: learning rate troppo basso $\rightarrow$ il metodo ci mette troppo tempo; oppure LR troppo alto $\rightarrow$ instabilità e oscillazioni; ecc...

6) SLP è un GRAFO ORIENTATO ACICLICO e BIPARTITO i cui vertici sono NEURONI ARTIFICIALI. Consiste di uno STRATO di INPUT e uno di OUTPUT.



Su ogni arco (i, j) è presente un PESO w_{ij} e su ogni neurone di out. è presente un BIAS b_j


Approssima una funzione $F: \mathbb{R}^N \rightarrow \mathbb{R}^M$ data da

$$F(\underline{x}) = \sigma(W^T \underline{x} + \underline{b})$$

SLP è un approssimatore LINEARE, non approssima tutte le fz CONTINUE.

7) ReLU:

$$\sigma(x) = \max(0, x) = \begin{cases} 0 & \text{se } x \leq 0 \\ x & \text{se } x > 0 \end{cases}$$




$$\sigma \in \mathcal{C}^0(\mathbb{R}), \quad \sigma' \nearrow$$

$$\sigma'(x) = \begin{cases} 0 & \text{se } x \leq 0 \\ 1 & \text{se } x > 0 \end{cases}$$

In genere la ReLU viene applicata nelle reti neurali moderne, in particolare dopo i layer convoluzionali nelle CNN.

SIGMOIDE: $\sigma \in C^\infty(\mathbb{R})$, $\sigma \uparrow$, $|\sigma| \leq 1$

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$




$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

Si usa negli strati lineari se si vuole un output tra 0 e 1, interpretabile come probabilità (es. di appartenere a una determinata classe)

Tanh: $\sigma \in C^\infty(\mathbb{R})$, $\sigma \uparrow$, $|\sigma| \leq 1$

$$\sigma(x) = \tanh(x)$$



Simile alla sigmoide come uso in layer lineari, ma spesso usata nelle reti Ricorrenti o LSTM.

8) L'algoritmo di BACKPROPAGATION è una tecnica usata nell'addestramento di RETI NEURALI per il CALCOLO del GRADIENTE della funzione di costo (o loss).

MLP con 1 strato nascosto:

$$F(\underline{x}) = \sigma(W_2^T \underbrace{\sigma(W_1^T \underline{x} + \underline{b}_1)}_{\delta_1} + \underline{b}_2) \\ = \sigma(\delta_2)$$

$$\text{loss: } \mathcal{L}(\theta) = \mathcal{L}(W_1, W_2, \underline{b}_1, \underline{b}_2)$$

Partendo dall'errore sull'ultimo strato:

$$\underline{\delta}^{(2)} = (\sigma(\delta_2) - y) \sigma'(\delta_2)$$

Si propaga all'INDIETRO nel primo:

$$\delta_j^{(1)} = \sum_k \delta_k^{(2)} w_{jk}^{(1)} \sigma'(\delta_1)$$

Questo si può spiegare a parole.

Da cui si ricave:

$$\frac{\partial \mathcal{L}}{\partial w^{(e)}} = \frac{1}{n} \sum_{k=1}^n \delta^{(e)} \cdot \sigma(\delta^{(e-1)})$$

$$\frac{\partial \mathcal{L}}{\partial b^{(e)}} = \frac{1}{n} \sum_{k=1}^n \delta^{(e)}$$

* somma sugli n elementi del DATASET.

9) La Loss è una funzione definita su un DATASET $D = \{(\underline{x}, y) : \underline{x} \in \mathbb{R}^N, y \in \mathbb{R}^M\}$

$\mathcal{L} : D \rightarrow \mathbb{R}$ che misura l'errore tra i dati attesi e la previsione del modello.

MSE:

$$\mathcal{L}_2(D) = \frac{1}{2n} \sum_{i=1}^n \| \underset{\text{dal DATASET}}{y_i} - \underset{\text{MODELLO}}{F_g(\underline{x}_i)} \|^2$$

dove $|D| = n$.

E ora si può vedere in funzione dei PARAMETRI del modello:

$$\mathcal{L}(D) = \mathcal{L}(\theta)$$

e addestrare il modello diventa così un problema di MINIMIZZAZIONE della LOSS al variare dei PARAMETRI θ .

