



**Finanziato
dall'Unione europea**
NextGenerationEU



**Ministero
dell'Università
e della Ricerca**



Italiadomani
PIANO NAZIONALE
DI RIPRESA E RESILIENZA



**NATIONAL
BIODIVERSITY
FUTURE CENTER**

Metodi di Intelligenza Artificiale per la Caratterizzazione delle Molecole Inquinanti e l'Analisi delle loro Implicazioni sulla Salute Umana

Parma, 14 Novembre 2025

Eva Viesi, PhD




**UNIVERSITÀ
di VERONA**

Dipartimento
di **INFORMATICA**

Cos'è la chemoinformatica?

- ❖ La **chemoinformatica** è una disciplina che utilizza **strumenti informatici** e **algoritmi** per recuperare, rappresentare e analizzare **informazioni chimiche**, con l'obiettivo di predire **proprietà fisico-chimiche**, **attività biologiche** e **tossicologiche** e di supportare la **scoperta** e la **progettazione** di farmaci.
- ❖ Step principali:
 1. Consultazione di **banche dati chimiche**
 2. Rappresentazione **digitale** delle **strutture molecolari**
 3. Calcolo di **descrittori molecolari** e **fingerprint**
 4. Ricerca di **molecole simili** e **clustering**
 5. Predizione di **proprietà** e **attività biologica**



Database e identificatori chimici

- ❖ Le molecole di interesse possono essere annotate utilizzando diverse fonti online...



Ampia raccolta di informazioni chimiche



Risorsa di molecole bioattive curata manualmente



Dizionario di piccoli composti chimici

- ❖ ...che forniscono utili **identificatori chimici**:

- **Chemical Name:**


Trichloroethylene

- **InChI:**

InChI=1S/C2HCl3/c3-1-2(4)5/h1H

- **InChIKey:**

XSTXAVWGXDQKEL-UHFFFAOYSA-N



- **Canonical SMILES:**

C(=C(Cl)Cl)Cl

- **Molecular Formula:**

C2HCl3

- **CAS Registry Number:**

79-01-6



Rappresentazione della struttura molecolare

- ❖ Si tratta di un **problema di codifica**: la struttura di una molecola può essere rappresentata in modi diversi, ma serve un **formato** che il computer possa interpretare.
- ❖ Le strutture molecolari sono raccolte nei **formati di dati chimici** più riconosciuti:
 - Il formato **SDF** (Structure Data File), un file in ASCII che memorizza informazioni sulle **posizioni** degli **atomi** e sui loro **legami**.
 - Il formato **SMILES** (Simplified Molecular-Input Line-Entry System), una stringa ASCII che rappresenta la **connettività** degli **atomi** all'interno di una molecola.

6575	Header block																Atom block
-OEChem-05142505282D																	
Counts line block																	
6	5	0	0	0	0	0	0	0999	V2000								
2.0000	0.7500	0.0000	Cl	0	0	0	0	0	0	0	0	0	0	0	0	0	
2.8660	-0.7500	0.0000	Cl	0	0	0	0	0	0	0	0	0	0	0	0	0	
4.5981	0.2500	0.0000	Cl	0	0	0	0	0	0	0	0	0	0	0	0	0	
2.8660	0.2500	0.0000	C	0	0	0	0	0	0	0	0	0	0	0	0	0	
3.7321	0.7500	0.0000	C	0	0	0	0	0	0	0	0	0	0	0	0	0	
3.7321	1.3700	0.0000	H	0	0	0	0	0	0	0	0	0	0	0	0	0	
Bond block																	
1	4	1	0	0	0	0											
2	4	1	0	0	0	0											
3	5	1	0	0	0	0											
4	5	2	0	0	0	0											
5	6	1	0	0	0	0											
M END																	
> <PUBCHEM_IUPAC_NAME> 1,1,2-trichloroethene																	
> <PUBCHEM_IUPAC_INCHIKEY> XSTXAVWGXDQKEL-UHFFFAOYSA-N																	
> <PUBCHEM_MOLECULAR_FORMULA> C2HCl3																	
> <PUBCHEM_SMILES> C(=C(Cl)Cl)Cl																	
\$\$\$\$																End of file	

.sdf

“The molecular descriptor is the final result of a logic and mathematical procedure which transforms chemical information encoded within a symbolic representation of a molecule into a useful number or the result of some standardized experiment” (Todeschini & Consonni, 2000, Handbook of Molecular Descriptors).




CanonicalSMILES	nAtom	nBond	APol
<chem>CCC(C)C1=CC=CC=C1</chem>	12	15	26.935102
<chem>CCC(C)CC1CCCCC1</chem>	15	18	0.4897200399
<chem>CC(C)CC1=CC=CC=C1</chem>	17	22	26.935102
<chem>CC(Cl)(Cl)Cl</chem>	7	12	25.601516
<chem>C(C(Cl)Cl)(Cl)Cl</chem>	11	9	14.936344
<chem>C(C(Cl)Cl)Cl</chem>	8	12	16.615379
<chem>CC1CCCCC1(C)C</chem>	16	20	15.703586
<chem>C=C(Cl)Cl</chem>	13	18	7.081586


Fingerprint molecolari

- ❖ Una **fingerprint** molecolare è un **vettore** binario o numerico che codifica la **presenza**, l'**assenza** o il **numero di occorrenze** di **frammenti strutturali**, **gruppi funzionali** o **sequenze di legami** di lunghezza fissa.

Structure-based fingerprint



Path-based fingerprint



(Huang *et al.*, 2018, *Molecules*)

- ❖ La meccanica quantistica descrive lo **stato elettronico** di atomi e molecole, modellando il **comportamento degli elettroni** attraverso l'**equazione di Schrödinger**.

Time-independent Schrödinger equation:

$$\hat{H}\Psi = E\Psi$$


Ψ is the **wave function** describing the quantum state of a particle;

E is the **total energy**;

$\hat{H}$ is the Hamiltonian operator, which includes **kinetic** and **potential energy** (Griffiths & Schroeter, 2018, Introduction to Quantum Mechanics).

- ❖ $|\Psi|^2$ rappresenta la **densità elettronica** $\rho(r)$, che descrive la **probabilità di trovare un elettrone** nello **spazio** attorno a un punto r .

- ❖ Le proprietà quantistiche descrivono la **reattività** e la **stabilità** molecolare su scala atomica e subatomica.





(Gotsu *et al.*, 2018, *Molecules*)

Confronto tra molecole: similarità molecolare

❖ Descrittori molecolari

Un insieme di proprietà o di fingerprint binarie.



❖ Coefficiente di similarità/dissimilarità

Similarità del coseno, distanza euclidea o di Manhattan, coefficiente di Tanimoto.

- **Similarità del coseno** tra descrittori corrispondenti [0,1]:

$$Sim(\vec{A}, \vec{B}) = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$


- **Coefficiente di Tanimoto** tra fingerprint binarie [0,1]:

$$Sim(\vec{A}, \vec{B}) = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$



Quante sottostrutture hanno in comune A e B?

❖ Ricerca di sottostrutture

Query




Hits




<https://www.rdkit.org/>

❖ Clustering

K-means Clustering




Hierarchical Clustering Dendrogram



Applicazioni: predizione di attività da saggi biologici

- ❖ Un saggio biologico (**bioassay**) è un metodo *in vitro* (o *in vivo*) utilizzato per testare e determinare l'**attività biologica** di una **sostanza** o **molecola** su un **target biologico** come un **organismo**, un **tessuto**, una **cellula** o una **proteina**.
- ❖ I modelli QSAR (Quantitative Structure-Activity Relationship) relazionano **descrittori molecolari** con **attività biologiche e tossicologiche**.




IC_{50} : concentrazione di una sostanza necessaria per inibire del 50% una specifica attività biologica o biochimica.

K_i : concentrazione di un inibitore necessaria per occupare il 50% dei siti di legame di un'enzima o recettore.

Caso studio

Inquinamento atmosferico e salute


- ❖ L'**Organizzazione Mondiale della Sanità (OMS)** stima che **oltre il 90%** della popolazione mondiale respiri aria contenente alti livelli di **sostanze inquinanti**, causando circa **7 milioni di morti all'anno** (OMS, 2018).
- ❖ L'**esposizione ad alte concentrazioni** di inquinanti è associata a **effetti dannosi** sui nostri organi vitali, ossia **polmoni, cervello e cuore**.
- ❖ Gli inquinanti ambientali **aumentano i fattori di rischio per disturbi neurodegenerativi** come la demenza e il morbo di Alzheimer (Costa *et al.*, 2017).




Dalle molecole inquinanti agli effetti sulla salute umana

❖ Approcci di studio degli inquinanti

- Studi epidemiologici
- Studi di inalazione *in vivo*
- Studi *in vitro*
- **Studi *in silico***




→
molecolari
&
cellulari


❖ Impatto sui sistemi biologici

▪ Sistema nervoso




- ↓ funzioni cognitive
- ↑ rischio di neurodegenerazione

▪ Apparato respiratorio



- ↑ malattie respiratorie
- ↑ infiammazione

▪ Apparato cardiovascolare




- ↑ stress ossidativo
- ↑ ipertensione

Cosa sono gli inquinanti atmosferici?

❖ L'inquinamento atmosferico è una miscela di sostanze dannose che include:

- **Gas** – monossido di carbonio (CO), anidride solforosa (SO₂), ozono (O₃), ossidi di azoto (NO_x)
- **Composti organici** – idrocarburi policiclici aromatici (IPA), composti organici volatili (COV)
- **Metalli** – piombo (Pb), mercurio (Hg), cadmio (Cd)
- **Particolato** – PM₁₀, PM_{2.5}

—provenienti sia da **fonti antropiche** sia **naturali** (NIEHS, 2022).



APDB: a database on air pollutant characterization and similarity prediction




JOURNAL ARTICLE

APDB: a database on air pollutant characterization and similarity prediction

Eva Viesi ✉, Davide Stefano Sardina, Ugo Perricone, Rosalba Giugno

<https://doi.org/10.1093/database/baad046>

<http://apdb.di.univr.it>




The screenshot shows the APDB website interface. At the top is a red navigation bar with links: Home, Statistics, Documentation, and Downloads/Contacts. Below the navigation bar, the title "APDB: Database of Air Pollutants" is centered. Underneath the title is a "Browse" section with four interactive cards. Each card contains an icon, a label, and a "Run" button. The cards are: 1. "molecular annotations" with a ball-and-stick molecular model icon. 2. "targets & bioassays" with a protein structure icon. 3. "molecular descriptors" with an atomic model icon. 4. "molecular similarities" with a heatmap icon.

Dati EPA (Environmental Protection Agency)

- SPECIATE 5.1 database
- 6 "Criteria Air Pollutants"
- Hazardous Air Pollutants

Maestro GUI




Jaguar software

QM properties

- Polarizability
- Dipole moments (x,y,z)
- HOMO & LUMO energies
- Frequencies

Similarity search


Query



Hit




<https://www.rdkit.org/>



Applications

Clustering



K-means clusters



Dati PubChem

- Molecular annotations
- Targets & Biossays


PaDEL-Descriptor software

Fingerprints (FPs)		Molecular descriptors	
EState FP	79-bit array	ALOGP	3
MACCS FP	166-bit array	APol	1
PubChem FP	881-bit array	Aromatic atoms count	1
Klekota-Roth FP	4860-bit array	Aromatic bonds count	1
2D atom pairs FP	780-bit array	Autocorrelation	346

Target e saggi biologici di PubChem

Target information

CYP2C19



UniProtKB
P33261

Target GeneID
1557

PDB Resolution
2.87


Download
[PDB](#)

Associated molecules

CID	Chemical Name	Molecular Formula	Canonical SMILES
5954	Benz(a)anthracene	C18H12	<chem>C1=CC=C2C(=C1)C=CC3=CC4=CC=CC=C4C32</chem>
9128	Benzo[e]pyrene	C20H12	<chem>C1=CC=C2C(=C1)C3=CC=CC4=C3C5=CC(=CC=C5)C=C4</chem>

PubChem Benz(a)anthracene (Compound)

PubChem BioAssays




Cytochrome P450 Family 2 Subfamily C Member 19 (CYP2C19) small molecule antagonists: luciferase reporter qHTS assay

Activity: [Active](#) Activity Type: Potency Activity Value: 50.2499 μ M

BioAssay AID: [1671197](#)

Substance SID: [144210817](#) Compound CID: [5954](#)




Cytochrome P450 Family 2 Subfamily C Member 9 (CYP2C9) small molecule antagonists: luciferase reporter qHTS assay

Activity: [Active](#) Activity Type: Potency Activity Value: 25.1846 μ M

BioAssay AID: [1671198](#)

Substance SID: [144210817](#) Compound CID: [5954](#)




Cytochrome P450 Family 2 Subfamily C Member 9 (CYP2C9) small molecule antagonists: luciferase reporter qHTS assay

Activity: [Active](#) Activity Type: Potency Activity Value: 25.1846 μ M

BioAssay AID: [1671198](#)

Substance SID: [144210817](#) Compound CID: [5954](#)



Cytochrome P450 Family 2 Subfamily D Member 6 (CYP2D6) small molecule antagonists: luciferase reporter qHTS assay

Activity: [Active](#) Activity Type: Potency Activity Value: 35.7194 μ M


BioAssay AID: [1671196](#)

Substance SID: [144209258](#) Compound CID: [5954](#)

- ❖ **371 proteine target** annotate utilizzando il pacchetto R AnnotationDbi.
- ❖ Sono stati selezionati solo **geni umani**.


- ❖ I bioassays sono accessibili tramite il **servizio PUG-REST** di PubChem interrogando un composto tramite il suo **CID** (Compound Identifier).

Software Jaguar: calcolo di proprietà quantomeccaniche



- ❖ **Input:** 1830 stringhe **SMILES** (esempio: C1=CC(=C(C=C1C2=CC(=C(C=C2)N)Cl)Cl)N)
- ❖ **Output:** strutture 3D ottimizzate (formato SDF).

Maestro GUI



Bochevarov et al., 2013, *Int. J. Quantum Chem.*

- **Polarizzabilità:** capacità di una molecola di reagire a un campo elettrico e acquisire un momento di dipolo elettrico.
- **Momenti dipolari (x, y, z):** distribuzione e separazione delle cariche all'interno di una molecola.
- **Energie HOMO e LUMO:** energie dell'orbitale molecolare occupato più alto e dell'orbitale non occupato più basso, che indicano la reattività molecolare (nucleofila o elettrofila).
- **Frequenze:** gli spettri vibrazionali forniscono informazioni sulla struttura molecolare e sulla composizione chimica.
- **Proprietà termochimiche:** capacità termica, entropia, entalpia, energia interna, energia di Gibbs.

.sdf

Software PaDEL-Descriptor: calcolo di descrittori molecolari

❖ **Input:** strutture 3D ottimizzate (.sdf).

❖ **Output:**

- **1875 descrittori** (1D, 2D, 3D).
- **12 tipi di fingerprint molecolari basati su sottostrutture e sequenze di legami** (ad es., CDK FP, E-state FP, MACCS keys, Pubchem FP, 2D atom pairs).

❖ **Altri software:**


- Chemistry Development Kit (CDK)
- RDKit
- Mordred
- PyDPI
- Rcp
- Dragon

(Yap, 2011)

Descriptor class		#		
Acidic group count	1	Largest chain	1	3D
ALOGP	3	Largest Pi system	1	
APol	1	Longest aliphatic chain	1	
Aromatic atoms count	1	Mannhold LogP	1	
Aromatic bonds count	1	McGowan volume	1	
Atom count	14	Molecular distance edge	19	
Autocorrelation	346	Molecular linear free energy relation	6	
Barysz matrix	91	Path counts	22	
Basic group count	1	Petitjean number	1	
BCUT	6	Ring count	68	
Bond count	10	Rotatable bonds count	4	
BPol	1	Rule of five	1	
Burden modified eigenvalues	96	Topological	3	
Carbon types	9	Topological charge	21	
Chi chain	10	Topological distance matrix	11	
Chi cluster	8	Topological polar surface area	1	
Chi path cluster	6	Van der Waals volume	1	
Chi path	32	Vertex adjacency information	1	
Constitutional	12	Walk counts	20	
Crippen logP and MR	2	Weight	2	
Detour matrix	11	Weighted path	5	
Eccentric connectivity index	1	Wiener numbers	2	3D
Atom type electrotopological state	489	XLogP	1	
Extended topochemical atom	43	Zagreb index	1	
FMFDescriptor	1	3D autocorrelation	80	
Fragment complexity	1	Charged partial surface area	29	
Hbond acceptor count	4	Gravitational index	9	
Hbond donor count	2	Length over breadth	2	
Hybridization ratio	1	Moment of inertia	7	
Information content	42	Petitjean shape index	3	
Kappa shape indices	3	RDF	210	
		WHIM	91	

APDB embedding e similarità












- ❖ A partire da **fingerprint** e **descrittori molecolari**, sono stati identificati quattro "**spazi chimici**" per il **confronto di similarità** tra molecole: fingerprint bits, fingerprint counts, molecular descriptors, quantum properties.
- ❖ Pipeline di analisi:




- Dati discreti/categorici: **TF-IDF, LSI**.
- Dati continui: **imputazione, scaling, PCA**.
- Algoritmo node2vec (Grover & Leskovec, 2016): le **similarità statisticamente significative** tra archi guidano le **probabilità di attraversamento** del grafo per apprendere gli **embedding** dei nodi.

Osservazioni interessanti

- ❖ Query diverse rivelano **aspetti analoghi e complementari** tra molecole simili.
- ❖ Fingerprint bits e counts:
 - gli **isomeri strutturali** del composto nitroaromatico 1-methyl-4-nitronaphthalene (CID 70155) evidenziano **pattern strutturali e caratteristiche simili**.
 - il tetracloruro di carbonio (CID 5943) e il fosgene (CID 6371) contengono lo stesso **atomo di carbonio centrale** legato a diversi **atomi di cloro**.
- ❖ Molecular e quantum properties:
 - solfuro di carbonile (CID 10039) condivide il **gruppo carbonilico** con il fosgene (CID 6371), suggerendo una **reattività** e una **composizione chimica** simili.

Origin	Similar	Fingerprints Bits	Fingerprints Counts	Molecular Descriptors	Quantum Properties
CID: 6371 	CID: 10039 				
	CID: 5943 				
SMILES: C(=O)(Cl)Cl		Fingerprints Bits	Fingerprints Counts	Molecular Descriptors	Quantum Properties
CID: 14781 	CID: 25477 				
	CID: 9989226 				
SMILES: [OH-].[O-]P(=O)([O-])[O-].[O-]P(=O)([O-])[O-].[O-]P(=O)([O-])[O-].[O-].[Ca+2].[Ca+2].[Ca+2].[Ca+2].[Ca+2]		Fingerprints Bits	Fingerprints Counts	Molecular Descriptors	Quantum Properties
CID: 32881 	CID: 8087 				
	CID: 15287 				
SMILES: CC(CO)OCC(C)O		Fingerprints Bits	Fingerprints Counts	Molecular Descriptors	Quantum Properties
CID: 70155 	CID: 93496 				
	CID: 86258 				
SMILES: CC1=CC=C(C(C2=CC=CC=C2)[N+](=O)[O-])C1					



Home Statistics Documentation Downloads/Contacts

1,1-dichloroethene

Chemical Name
1,1-dichloroethene

PubChem CID
6366

Molecular Formula
C2H2Cl2

InChIKey
LGXVIGDEPROXKC-UHFFFAOYSA-N

Molecule Type
organic

Canonical SMILES
C=C(Cl)Cl

Targets
NR1I2, CYP2C19

Download SDF

Similarity threshold (0.75-0.99): 0,95 Run

Similarity:
~ 0.95 ~ 0.85 ~ 0.75 ● not sign.

63 records found.


MOST SIMILAR	Fingerprints Bits	Fingerprints Counts	Molecular Descriptors	Quantum Properties
6365 1,1-dichloroethane CC(Cl)Cl	●	●	●	●

❖ APDB è un database relazionale **PostgreSQL** con un'interfaccia web basata su **Flask**.

❖ Un pannello mostra le **molecole simili** a una molecola query.


La similarità oltre la chimica

- ❖ Gli embedding basati su descrittori e fingerprint molecolari riflettono solo **proprietà chimiche**, senza includere **dati di bioattività**.
- ❖ Il **Chemical Checker** (CC): estende la **similarità chimica** a tutti i **livelli biologici** (target, network, cellule, clinica) per identificare **meccanismi d'azione** (MoA) e **profili di tossicità** simili nel processo di scoperta di nuovi farmaci (Duran-Frigola *et al.*, 2020, *Nat. Biotechnol.*)
- ❖ I nuovi embedding, chiamati **bioactivity signatures**, permettono di catturare caratteristiche e **tratti biologici** rilevanti per il calcolo della **similarità tra molecole**.




Chemical Checker (CC)

- ❖ Circa **1 milione di molecole** organizzate in **5 livelli** di complessità crescente, ciascuno suddiviso in **5 spazi**.
- ❖ *Principio di similarità*: dalla **chimica** alla **biologia** (ad es., esperimenti di binding, espressione genica, effetti terapeutici e collaterali).




- ❖ *Signaturizer*: modello utilizzato per **predire** una **bioactivity signature** per qualsiasi molecola (Bertoni *et al.*, 2021, *Nat. Commun.*).



Morgan Fingerprint (2,048-bit, raggio 2)

Rappresentazione **binaria** della struttura 2D di una molecola dove ciascun bit indica la presenza di una **sottostruttura molecolare** a un determinato **raggio circolare**.




PubChem Bioassays (da ChEMBL)

Composti attivi (hit) ottenuti da **saggi di screening** ad alto rendimento (HTS) contro **proteine target** (principalmente saggi di conferma con concentrazioni inferiori a 10 μ m o "attivi").


PubChem

ChEMBL



L1000 Connectivity Map


Profili di espressione genica di cellule in coltura trattate con piccole molecole.



Subramanian *et al.*, 2017, *Cell*


SIDER

Effetti collaterali di farmaci espressi in termini di Unified Medical Language System (UMLS).




CC bioactivity signatures di tipo 1 e 2

- ❖ La **conoscenza sperimentale** della bioattività copre solo una **piccola frazione** dei composti noti (A-E).
- ❖ Per integrare le informazioni sperimentali mancanti, il modello *signaturizer* deriva le **signatures di bioattività** per qualsiasi molecola.
- ❖ Gli spazi di bioattività sono **correlati** e consentono di **trasferire le similarità** presenti in un dataset (interazioni con target) ad altri dataset (effetti collaterali).
 1. i dati grezzi vengono filtrati e pre-elaborati per generare *signatures di tipo 0*, in seguito ridotti di dimensionalità tramite PCA o LSI per produrre *signatures di tipo 1*;
 2. le rappresentazioni a dimensionalità ridotta vengono utilizzate per costruire **network di similarità**, dalle quali si ottengono le *signatures di tipo 2* tramite un **algoritmo di embedding**;



3. gli **embedding calcolati** vengono dati in input ad una Siamese Neural Network (SNN) per derivare le *signatures di tipo 3*, che **spiegano le similarità inizialmente osservate** nelle *signatures di tipo 1*.

- **Input:** una **matrice di covariate** (signatures S_1 - S_{25}) di dimensione $(n, 128*m)$, n molecole, m dataset.
- **Output:** un vettore di 128D, ottimizzato per catturare il **profilo di similarità** di ciascuna molecola in ogni S_i .



4. Una Deep Neural Network (DNN), chiamata *chemistry-to-signature **signaturizer***, viene infine addestrata a prevedere le *signatures di tipo 3* a partire dalle *signatures di tipo 0*, rappresentate da **Morgan fingerprints (A1)**, generando così *signatures di tipo 4*.

Confronto tra le signatures di APDB e CC


- ❖ Sono state derivate *ex novo* le **signatures di bioattività (0–4)** per i quattro **spazi chimici** di APDB: **F1** (fingerprint bits), **F2** (fingerprint counts), **M1** (molecular descriptors), **Q1** (quantum properties), e confrontate con quelle presenti nel CC.

natureprotocols


Integration of diverse bioactivity data into the Chemical Checker compound universe

[Arnau Comajuncosa-Creus](#), [Martino Bertoni](#), [Miquel Duran-Frigola](#),
[Adrià Fernández-Torras](#), [Oriol Guitart-Pla](#), [Nils Kurzawa](#), [Martina Locatelli](#),
[Yasmin Martins](#), [Elena Pareja-Lorente](#), [Gema Rojas-Granado](#),
[Nicolas Soler](#), [Eva Viesi](#) & [Patrick Aloy](#) 

<https://doi.org/10.1038/s41596-025-01167-3>



Modello chemogenomico




Metodi ligand-based e structure-based


❖ Limitazioni principali:

- richiedono un **elenco esaustivo** e ben annotato di **composti bioattivi** per lo **screening virtuale**;
- dipendono da **strutture 3D risolte**, ancora **non disponibili** per molte proteine target.

Somiglianza tra sottostrutture



Docking molecolare




Metodi feature-based methods: selezione dei campioni negativi

❖ Limitazioni:

- **Classi sbilanciate** dovute al numero limitato di interazioni validate tramite saggi biologici.
- I campioni negativi esistenti possono includere **interazioni positive non osservate**.
- Il **campionamento casuale** può comportare la selezione di interazioni negative **molto simili** a quelle positive.

❖ Soluzione:

- Selezione di campioni negativi **robusti e affidabili** usando metodi basati sulla **similarità** o sulle **features** (Liu *et al.*, 2015, *Bioinformatics*, Zheng *et al.*, 2019, *BMC Bioinformatics*).



APBIO: bioactive profiling of air pollutants through inferred bioactivity signatures and prediction of novel target interactions

 **BMC** Part of Springer Nature


Journal of Cheminformatics

APBIO: bioactive profiling of air pollutants through inferred bioactivity signatures and prediction of novel target interactions

Eva Viesi , Ugo Perricone, Patrick Aloy & Rosalba Giugno

<https://doi.org/10.1186/s13321-025-00961-1>


<https://ap-bio.streamlit.app>



Bioactivity signatures delle molecole inquinanti

- ❖ Un modello **signaturizer** integra la conoscenza disponibile sulla bioattività per **catturare i tratti biologici** delle piccole molecole (ad es., meccanismo d'azione) in un'unica rappresentazione vettoriale (128D).

APDB signaturizers



Viesi et al., 2023, Database

Chemical Checker signaturizers

Chemistry
A1 (2D FPs), A2 (3D FPs), A3 (scaffolds), A4 (struc. keys), A5 (physicochem.)
Targets
B1 (MoA), B2 (metab. genes), B3 (crystals), B4 (binding), B5 (HTS bioass.)
Networks
C1 (mol. roles), C2 (mol. pathw.), C3 (sig. pathw.), C4 (BP), C5 (interactome)
Cells
D1 (transc.), D2 (cancer cells), D3 (chem. gen.), D4 (morph.), D5 (cell bioass.)
Clinics
E1 (therap. areas), E2 (indications), E3 (side eff.), E4 (dis. & tox.), E5 (DDIs)

Duran-Frigola et al., 2020, Nat. Biotechnol., Bertoni et al., 2021, Nat. Commun.

Descrittori di sequenza del target

- ❖ Le **sequenze proteiche** (AA) vengono recuperate in **formato FASTA** tramite le API REST di UniProt.
- ❖ I **descrittori del target** (1623D) sono calcolati utilizzando il pacchetto Python iFeature.

Descriptor	#components	Type
Amino acid composition	20	Sequence composition
Dipeptide composition	400	Sequence composition
Normalized Moreau – Broto autocorrelation	240	Correlation of physicochemical properties
Moran autocorrelation	240	Correlation of physicochemical properties
Geary autocorrelation	240	Square correlation of physicochemical properties
Descriptors of composition, transition and distribution (C/T/D)	273	Distribution and variation of physicochemical properties
Sequence-Order-Coupling Number	160	Combination of sequence composition and correlation of physicochemical properties
Quasi-Sequence-Order	50	Combination of sequence composition and correlation of physicochemical properties

Chen *et al.*, 2018, *Bionformatics*, Ong *et al.*, 2007, *BMC Bioinformatics*

Selezione dei target per validazione

■ B4: Binding

Term	Description
Class:1054	Cytochrome P450 family 1 (1A/1A2)
Class:1055	Cytochrome P450 family 2 (2A/2A5/2A6)
P00915	Carbonic anhydrase 1
P22748	Carbonic anhydrase 4
P35218	Carbonic anhydrase 5A
P23280	Carbonic anhydrase 6
P35869	Aryl hydrocarbon receptor (AhR)
P21397	Amine oxidase A (MAO-A)


■ B2: Metabolic genes

Term	Description
Class:704	SLC16 family of monocarboxylate transporters
O15427	Monocarboxylate transporter 4 (MCT 4)
O94956	Solute carrier organic anion transporter family member 2B1 (OATP-B)
P53985	Monocarboxylate transporter 1 (MCT 1)

- ❖ L'esposizione all'inquinamento atmosferico può **alterare l'espressione** e la **funzione** dei **trasportatori SLC**, contribuendo potenzialmente alla **neurodegenerazione** (Puris *et al.*, 2022, *Environ. Toxicol. Pharmacol.*).

- ❖ Il **particolato atmosferico** (PM) può **influenzare l'attività** degli **enzimi CYP450**, responsabili del metabolismo degli xenobiotici, provocando **risposte immunitarie alterate** e **stress ossidativo** (Vogel *et al.*, 2020, *Redox Biol.*).
- ❖ I **metalloenzimi** (CA) sono **sensibili agli inquinanti** (ad es., metalli pesanti), evidenziando il loro potenziale come biomarcatori per il **biomonitoraggio ambientale**. (Lionetto *et al.*, 2012, *Int. J. Environ. Res. Public Health*).

Generazione dei dataset di interazioni




3534 saggi di conferma e profili tossicologici attivi

PubChem



Strategia di selezione dei campioni negativi

❖ OCSVM: One-Class Support Vector Machine




Schölkopf *et al.*, 2001, *Neural Comput.*

❖ Distribuzione delle classi:



- Pos:Neg = 1:10;
- Numero di interazioni positive = 2609;
- Numero di interazioni negative = 26090.

1. Apprendere i **pattern intrinseci** nei dati **positivi** per discriminare **outlier** o **anomalie**.
2. Selezionare i campioni **negativi** tra quelli **più distanti dall'iperpiano** (Zheng *et al.*, 2019, *BMC Bioinformatics*).









`sklearn.svm.OneClassSVM.decision_function`

OCSVM (AP1) vs. random (AP2) sampling



Nested CV model performance



Validazione esterna: nuove interazioni predette






❖ Dataset esterni:



- 34 interazioni da **PubChem BioAssay (PB)**
- 23 interazioni da **geni metabolici (SLC) e dati di binding (B2B4)**

Comparative Toxicogenomics Database (CTD):

- 1059 interazioni con **enzimi CYP450 (CYP)**
- 152 interazioni con **anidrasi carbonica (CA)**




❖ Performance **robuste e stabili.**



Conclusioni


❖ Chemoinformatica e applicazioni:

- **Rappresentazione digitale** delle strutture molecolari.
- **Calcolo di descrittori e proprietà** per valutare similarità e attività.
- **Screening virtuale di composti** per selezionare potenziali candidati farmaceutici.
- **Identificazione di interazioni** con target biologici.



❖ Caso studio: inquinamento atmosferico e salute

- **Calcolo di descrittori molecolari, fingerprint e proprietà quantistiche** per analisi di similarità.
- **Derivazione di descrittori di bioattività** per catturare tratti biologici ed effetti cellulari e clinici.
- **Predizione di interazioni non note** tra inquinanti atmosferici e specifiche classi di proteine.




- ❖ Studio di altri tipi di molecole, come **prodotti naturali** o **metaboliti vegetali**, per identificare **proprietà** e **attività** in grado di mitigare gli effetti tossicologici.



- ❖ Sperimentazione di **nuove rappresentazioni** di molecole e target basate su **Transformers** o **GNNs**.

- ❖ Predizione di nuove **interazioni** e **prioritizzazione** dei target tramite **approcci network-based** o di **deep learning**.



- ❖ **Integrazione** di studi terapeutici e tossicologici con **dati multi-omici** per chiarire i meccanismi molecolari e cellulari a livello **tissutale** e di **singola cellula** e identificare **potenziali biomarcatori** di **malattie complesse**.



Finanziato
dall'Unione europea
NextGenerationEU



Ministero
dell'Università
e della Ricerca



Italiadomani
PIANO NAZIONALE
DI RIPRESA E RESILIENZA




NATIONAL
BIODIVERSITY
FUTURE CENTER



INSTITUTE
FOR RESEARCH
IN BIOMEDICINE



Grazie per la vostra attenzione!



website: <https://infomics.github.io/InfOmics/>

