

Modelli computazionali e di machine learning per l'analisi di dati di Trascrittomica Spaziale

Simone Avesani, Ph.D.
simone.avesani@univr.it

14-11-2025



UNIVERSITÀ
di **VERONA**

Dipartimento
di **INFORMATICA**



Il DNA: contenitore dell'informazione biologica

- DNA (acido desossiribonucleico) contiene le **istruzioni per la vita**.
- Struttura a **doppia elica** antiparallela che conferisce **stabilità** alla molecola.
- Composto da quattro **nucleotidi**: Adenina, Timina, Citosina, Guanina.
- Contiene l'informazione genetica, tramanda i dati genetici tra generazioni ed è il punto di partenza per la sintesi proteica.
- La sequenza nucleotidica del DNA codifica **geni** e **regioni regolatorie** che orchestrano la complessa rete dei processi cellulari.
- Il DNA è organizzato in cromosomi.




Image from Labster Theory pages.

Il Gene: l'unità fondamentale dell'informazione genetica

- Segmento di DNA che contiene le istruzioni per produrre proteine o RNA funzionali.
- Nel DNA umano ci sono circa 20.000 geni che contengono informazioni necessaria alle cellule per creare proteine specifiche.
- Composto da diversi elementi strutturali (esoni, introni, promotori etc.) e da altri elementi di controllo.
- Possono avere una dimensione molto differente, da centinaia a milioni di nucleotidi.
- Sono presenti su tutti e 23 i cromosomi.






Image from Genomics Education Programme.

RNA: il messaggero delle cellule

RNA
(Ribonucleic acid)



DNA
(Deoxyribonucleic acid)




Image from Genomics Education Programme .

- RNA (acido ribonucleico) svolge una funzione di messaggero a partire dall'informazione contenuta nel DNA.
- Struttura a **singola elica** che conferisce che rende la molecola più **instabile** e facile da degradare.
- Composto da quattro **nucleotidi**: Adenina, Uracile, Citosina, Guanina.
- Contiene l'informazione essenziale per la sintesi proteica.
- Esistono varie tipologie di RNA:
 - **tRNA**: RNA di trasferimento.
 - **mRNA**: RNA messaggero.
 - **rRNA**: RNA ribosomiale

La proteina: unità funzionale delle cellule

- Molecole fondamentali per la **struttura**, **funzione** e **regolazione** di tutti i processi cellulari.
- Composte da catene di amminoacidi.
- Struttura complessa organizzata in 4 livelli:
 - **Primaria**: sequenza amminoacidica.
 - **Secondaria**: α -eliche e β -foglietti.
 - **Terziaria**: ripiegamento tridimensionale.
 - **Quaternaria**: unione di più subunità.
- La proteina rappresenta l'esecutore principale delle istruzioni genetiche.






Image from Wikipedia.


Dal DNA alla proteina



Dal DNA alla proteina




La Cellula








La teoria cellulare


1. Tutti gli organismi viventi sono composti da una o più cellule.
2. La cellula è l'unità alla base della struttura e dell'organizzazione dell'organismo.
3. Le cellule nascono da cellule pre-esistenti.



Le cellule sono classificate in base a funzione, posizione e struttura




Skin Cells	Immune Cells	Brain Cells	Muscle Cells
 Fibroblasts	 Megakaryocytes	 Neurons	 Smooth Muscle
 Adipocytes	 Dendritic Cells	 Ependymal Cells	 Skeletal Muscle
 Epithelial Cells	 T Cells	 Astrocytes	 Cardiac Muscle




**Tutte le cellule sono uguali
ma**

non sono uguali

Dal DNA alla proteina




Espressione genica



Espressione genica

- L'insieme dei geni espressi da una cellula costituisce il suo profilo di espressione.
- Il profilo di espressione di una cellula è l'insieme di **features** che la caratterizzano.



Tumor Immunology

©CellCartoons




Image from CellCartoons.

Tessuti come sistemi biologici complessi






Image from Vizgen.

Tessuti come sistemi biologici complessi






Trascrittomica Spaziale (ST)


Human Breast Cancer



- La Trascrittomica Spaziale è una nuova tecnologia che ci permette di studiare il profilo di espressione genica cellulare nel contesto di un tessuto organizzato spazialmente.
- Per ogni cellula o spot possiamo estrarre due informazioni:
 - Il suo **profilo di espressione**.
 - La sua **posizione** in un sistema di coordinate X e Y.




10x Visium



- Il tessuto viene posizionato su un vetrino quadrato e composto da migliaia di fori.
- Il tessuto viene denaturato e le **cellule** cadono nei vari fori.
- In ogni foro **l'RNA** delle cellule viene **estratto** e legato ad una **etichetta** specifica.
- I vari frammenti di RNA vengono raggruppati tutti insieme e poi passati al **sequenziatore** per la lettura.

10x Visium




- Il tessuto viene posizionato su un vetrino quadrato e composto da migliaia di fori.
- Il tessuto viene denaturato e le **cellule** cadono nei vari fori.
- In ogni foro **l'RNA** delle cellule viene **estratto** e legato ad una **etichetta** specifica.
- I vari frammenti di RNA vengono raggruppati tutti insieme e poi passati al **sequenziatore** per la lettura.




Dati 10x Visium

Immagine Tessuto




Dati 10x Visium

Immagine Tessuto




Profilo di espressione cellulare




Dati 10x Visium

Immagine Tessuto



Profilo di espressione cellulare



Coordinate cellule


x	y

Problema biologico


Abbiamo un dataset collezionato da un tessuto tumorale e, a partire dai dati, vogliamo rispondere ad alcune domande biologiche:

1. Dove sono localizzate le cellule tumorali all'interno del tessuto?
2. Cosa differenzia, a livello di profilo di espressione, le cellule tumorali dalle altre cellule presenti?
3. Con quali cellule stanno comunicando le cellule tumorali?
4. A quali cellule sono vicine le cellule tumorali?

Immagine Tessuto



Domande?



Analisi computazionale di dati ST





Image from Kleino et al. 2022.

Analisi computazionale di dati ST




Ci sono cellule sequenziate male?
Quali sono i **geni** più **importanti**?

Quali sono i **tipi cellulari** presenti nel dataset? Dove sono **localizzati**?

Come **comunicano** le cellule tra loro?

Come le cellule si stanno **differenziando e evolvendo**?

Identificare geni importanti




- La matrice dei profili di espressione genica è molto sparsa.
- I molti valori a 0 sono dovuti ai limiti della tecnologia nella cattura dell'RNA.
- Tale sparsità rende la matrice molto rumorosa.
- E' necessario ridurre il rumore e identificare i geni o feature più importanti.
- Identificare i geni importanti ci permette di ridurre il rumore e studiare in dettaglio le differenze tra le cellule.

High Variable Genes (HVG)


- Nei dati ST la **varianza** non è una buona misura per determinare la variabilità dei geni.
- Geni con un'espressione media molto alta avranno valori di varianza molto diversi dai geni con espressione media molto bassa.
- Per dati ST si utilizza la dispersione (varianza / media).
- In particolare tale dispersione viene normalizzata per gruppi di geni con media simile.
 1. Geni divisi in gruppi rispetto alla loro media
 2. Calcolo della dispersione di ogni gene
 3. La dispersione di ogni gene viene normalizzata rispetto alla dispersione media del gruppo di appartenenza.

$$\text{normalized dispersion} = \frac{\text{raw dispersion} - \mu_{\text{bin}}}{\sigma_{\text{bin}}}$$

- Quanto un gene varia di più rispetto a geni con media simile.



Spatial Variable Genes (SVG)




- HVG ci permettono di identificare geni che hanno profili differenti tra cellule o gruppi di cellule.
- Tuttavia, falliscono nel catturare il contesto spaziale e non riescono quindi a modellare la variabilità nello spazio.
- Esistono vari approcci basati su: correlazione (SpatialDE, SPARK), Gaussian diffusion (Sepal), Graph Convolutional networks (SpaGCN).


Indice di Moran

- L'indice di Moran è un indice di autocorrelazione spaziale e ha valori compresi tra -1 e 1.
- Se i valori simili dei parametri sono localizzati spazialmente è presente una autocorrelazione spaziale **positiva**.
- Una prossimità spaziale di valori dissimili, cioè non stabili nello spazio, indica una autocorrelazione spaziale **negativa**.


$$I = \frac{N}{W} \cdot \frac{\sum_{i=1}^N \sum_{j=1}^N w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_{i=1}^N (x_i - \bar{x})^2}$$



Moran's Index
0.97








Moran's Index
-0.02



Moran's Index
-1.00

Image from Böck et al. 2017

SVG guidano l'identificazione di domini spaziali



Analisi computazionale di dati ST




Image from Kleino et al. 2022.

Ci sono cellule sequenziate male?
Quali sono i **geni** più **importanti**?


Quali sono i **tipi cellulari** presenti nel dataset? Dove sono **localizzati**?

Come **comunicano** le cellule tra loro?

Come le cellule si stanno **differenziando e evolvendo**?

Clustering

- Clustering ci permette di raggruppare insieme oggetti simili.
- Clustering è un task complesso più nell'interpretazione del risultato che nella struttura dell'algoritmo.
- Fare clustering in Spatial Transcriptomics significa raggruppare insieme cellule o spot simili.
- In ST non è chiaro quanto la trascrittomico, combinata con l'informazione spaziale migliori il risultato.



Stardust


- *Stardust* è un metodo di clustering che raggruppa i dati di spatial transcriptomics combinando le **distanze spaziali** e le **distanze di espressione**.
- Sono state sviluppate due diverse configurazioni del metodo:
 - Stardust
 - Stardust*



GigaScience, 2022, 11, 1–11
DOI: 10.1093/gigascience/giac075
TECH NOTE

Stardust: improving spatial transcriptomics data analysis through space-aware modularity optimization-based clustering


Simone Avesani^{1,†}, Eva Viesi^{1,†}, Luca Alessandri², Giovanni Motterle¹, Vincenzo Bonnici⁴, Marco Beccuti³, Raffaele Calogero² and Rosalba Giugno^{1,*}



Stardust

Distanza spaziale (**S**)

Distanza espressione (**T**)



Distanza combinata (**ST**)

- **Stardust**: pesatura **lineare** dello spazio.

$$ST = S' * spaceWeight + T$$


- *spaceWeight* definito dall'utente tra $[0,1]$ rappresenta il peso dato alla distanza spaziale;
- S' è la versione scalata della matrice S .
- **Stardust***: pesatura **non-lineare** dello spazio.

$$ST = S' * T' + T$$


- T' è la matrice T normalizzata in $[0,1]$.
- Il peso della distanza spaziale cambia dinamicamente secondo T' .

Stardust





- **Stardust** incrementa la stabilità dell'algoritmo considerando lo spazio.



- **Stardust** e **Stardust*** sono più stabili rispetto allo stato dell'arte.



- **Stardust** e **Stardust*** preservano la struttura spaziale e la coerenza biologica del tessuto.



Modelli basati su grafi e reti neurali

- I grafi sono una struttura dati estremamente utile per l'integrazione di dati eterogenei.
- Con un grafo possiamo modellare la similarità tra oggetti ma anche la loro prossimità spaziale.
- Negli anni molti modelli di clustering per dati ST sono stati sviluppati a partire da grafi e modelli di deep learning.
- Due esempi sono:
 - **GraphST**
 - **GIST**




Image from *Hu et al., Nature Methods, 2021*

GraphST

- GraphST è un metodo per ST basato su Graph Neural Networks (GNN).
- L'architettura di GraphST permette di risolvere diversi problemi nell'analisi di dati ST:
 - Clustering
 - Correzione del batch effect
 - Deconvoluzione
- Per migliorare le performance, il tool è stato basato sul contrastive learning.




Image from Long et al., Nature Communications, 2023


GraphST Clustering

Image from Long et al., Nature Communications, 2023

1. Viene generato un **grafo di vicinanza (G)** dove ogni spot è connesso ai suoi 3 spot più vicini spazialmente e viene creato anche un **grafo di vicinanza corrotto (G')**.
2. Un encoder GNN è utilizzato per creare una rappresentazione degli spot (Z), successivamente un decoder ricostruisce i profili di espressione (H).

$$\mathcal{L}_{recon} = \sum_{i=1}^{N_{spot}} \|x_i - h_i\|_F^2,$$

3. Il contrastive learning è applicato per rendere il modello più discriminativo. L'idea è massimizzare l'informazione condivisa da coppie positive di rappresentazione dello spot e del contesto (z, g) e minimizzare l'informazione condivisa da coppie negative (z', g).



4. Una loss complessiva viene calcolata considerando lo step di ricostruzione e lo step di contrastive learning.

$$\mathcal{L} = \lambda_1 \mathcal{L}_{recon} + \lambda_2 (\mathcal{L}_{SCL} + \mathcal{L}_{SCL_corrupt})$$

GraphST Clustering

- GraphST ottiene uno score di accuratezza migliore rispetto agli altri tool allo stato dell'arte.
- Riesce ad identificare molto bene domini spaziali stratificati.





Image from Long et al., Nature Communications, 2023

GIST (Graph Information for Spatial Transcriptomics)

- GIST è un modello per clustering di dati ST basato su GNN che integra informazione spaziale e trascrittomica per costruire una rappresentazione a grafo di un tessuto o slice.
- Come GraphST, utilizza il contrastive learning per migliorare la capacità di discriminare del modello.



Leveraging Graph Information for Spatially Informed Patient Data Analysis with GIST

1st Gospel Ozioma Nnadi
Department of Computer Science,
University of Verona,
Verona, Italy.
0009-0004-4651-9876

2nd Vincenzo Bonnici
Department of Mathematical, Physical and Computer Sciences,
University of Parma,
Parma, Italy.
0000-0002-1637-7545


3rd Simone Avesani
Department of Computer Science,
University of Verona,
Verona, Italy.
0000-0003-3200-2521

4th Eva Viesi
Department of Computer Science,
University of Verona,
Verona, Italy.
0000-0002-6137-2479

5th Rosalba Giugno
Department of Computer Science,
University of Verona,
Verona, Italy.
0000-0001-9843-7638

GIST (Graph Information for Spatial Transcriptomics)

Human Breast Cancer
Ground truth Annotation




ARI: 0.60
AMI: 0.68
Hom: 0.68
SSS: 0.06
Avg_penalty: 0.20
SS: 0.15




GIST

ARI: 0.51
AMI: 0.67
Hom: 0.69
SSS: -0.01
Avg_penalty: 0.27
SS: 0.14




DeepST

ARI: 0.53
AMI: 0.66
Hom: 0.67
SSS: -0.02
Avg_penalty: 0.2
SS: 0.09




GraphST

DLPFC 151510
Ground truth Annotation




ARI: 0.54
AMI: 0.63
Hom: 0.66
SSS: -0.07
Avg_penalty: 0.22
SS: 0.09




GIST

ARI: 0.45
AMI: 0.59
Hom: 0.63
SSS: -0.09
Avg_penalty: 0.26
SS: 0.08




DeepST

ARI: 0.46
AMI: 0.63
Hom: 0.66
SSS: -0.12
Avg_penalty: 0.15
SS: 0.02




GraphST

ARI: 0.43
AMI: 0.61
Hom: 0.64
SSS: -0.1
Avg_penalty: 0.41
SS: 0.12




STAGATE

ARI: 0.57
AMI: 0.65
Hom: 0.66
SSS: 0.04
Avg_penalty: 0.43
SS: 0.2




SpaGCN

ARI: 0.44
AMI: 0.59
Hom: 0.60
SSS: -0.23
Avg_penalty: 0.36
SS: -0.05




conST

ARI: 0.38
AMI: 0.65
Hom: 0.66
SSS: -0.02
Avg_penalty: 0.12
SS: 0.05




SEDR

ARI: 0.51
AMI: 0.63
Hom: 0.65
SSS: -0.11
Avg_penalty: 0.21
SS: 0.07




STAGATE

ARI: 0.46
AMI: 0.59
Hom: 0.62
SSS: -0.15
Avg_penalty: 0.46
SS: 0.10




SpaGCN

ARI: 0.31
AMI: 0.44
Hom: 0.46
SSS: -0.28
Avg_penalty: 0.59
SS: 0.01



conST

ARI: 0.46
AMI: 0.63
Hom: 0.63
SSS: -0.13
Avg_penalty: 0.19
SS: 0.04



SEDR

Trascrittomica Spaziale prospettive future

- Nuove tecnologie per il sequenziamento di dati ST sono state messe sul mercato: Visium HD, Xenium etc.
- Queste nuove tecnologie permettono di ottenere dataset ad una risoluzione molto più elevata, addirittura sub-cellulare.
- Con Visium HD si è passati da un pannello di 50.000 spot ad un pannello di 10.5 milioni di spot.
- Le nuove tecnologie di sequenziamento stanno fissando un nuovo limite per l'analisi computazionale.




Image from Faria de Oliveira et al., Nature Genetics, 2025

Trascrittomica Spaziale prospettive future




Image from 10x Genomics

Trascrittomica Spaziale prospettive future






Image from Gong et al., Nature Communications, 2025



UNIVERSITÀ
di **VERONA**

Dipartimento
di **INFORMATICA**

|nf  mics

HEAL  **ITALIA**