TRATTAMENTO di DATI SPERIMENTALI ... ovvero...

Come STIMARE i PARAMETRI di una DISTRIBUZIONE

Nella pratica capita spesso di avere a che fare con FENOMENI di cui ABBIAMO RAGIONE di CREDERE siano DISTRIBUITI in ACCORDO a una DISTRIBUZIONE di PROBABILITA',
Il punto è che spesso questa ci è IGNOTA...
Nota che potremmo CONOSCERE davvero POCO, nemmeno avere una idea chiara di quale tipo di distribuzione sia quella che descrive i dati, Viceversa, potremmo conoscerne la NATURA, ma non i PARAMETRI, ad es: il FENOMENO (abbiamo ragione di credere...) è POISSONIANO, ma ... quale POISSONIANA? ovvero, di che parametro?

In generale si pone il problema di DETERMINARE i PARAMETRI FONDAMENTALI.
A tutti gli effetti pratici, il problema principale è determinare

- QUAL E' IL VALOR MEDIO (o SPERANZA MATEMATICA)?
  primo momento della distribuzione

ed insieme determinare

- QUAL E' LA VARIANZA (ovvero il secondo momento centrato)?

Notare che determinare questi parametri ci consente spesso di CAPIRE QUALE SIA LA DISTRIBUZIONE che SOGGIACE AI DATI. Ad esempio, se abbiamo ragione di credere che il processo sia POISSONIANO, dovremo attenderci che VALOR MEDIO e VARIANZA siano uguali!

In generale, la ricostruzione sarebbe ideale se potessimo DETERMINARE TUTTI I MOMENTI, le RELAZIONI fra i quali ci direbbero MOLTO (idealmente TUTTO, ricostruendo TUTTI i MOMENTI) della DISTRIBUZIONE incognita.

Nella pratica dobbiamo spesso accontentarci di poco... o comunque spesso di non molto...

In generale il PROBLEMA è riconducibile a questo:

ABBIAMO a DISPOSIZIONE un CAMPIONE di VALORI OSSERVATI

$$X_1 \dots X_n$$

e vogliamo determinare STIME dei parametri della distribuzione.

Se il parametro da stimare è a la nostra STIMA sarà una FUNZIONE degli $X_1, \dots, X_n$ che denotiamo $\tilde{a}(X_1, \dots, X_n)$

con la richiesta che

① La STIMA $\tilde{a}$ sia CORRETTA

Questo vuol dire che per $n \to \infty$ essa CONVERGE in PROBABILITA' ad a

ovvero per $n \to \infty$, dati ε e δ QUALSIASI $P(|\tilde{a} - a| < \varepsilon) > 1 - \delta$
(la probabilità di andare comunque vicino al valore corretto è maggiore di qualsiasi numero fissato minore di 1... si noterà, al solito, che la convergenza in probabilità è debole... si noti ad esempio che dobbiamo dare ε e δ...)

② La STIMA $\tilde{a}$ sia NON DISTORTA

Questo vuol dire che $M[\tilde{a}] = a$ ovvero che ad ogni n fissato in MEDIA determiniamo la QUANTITA' GIUSTA

③ Idealmente vorremo anche una STIMA $\tilde{a}$ EFFICIENTE ovvero $D[\tilde{a}] =$ minima

ovvero non solo in MEDIA otteniamo a n fissato il risultato corretto, ma anche le fluttuazioni sono contenute e "un determinato risultato può sbagliare di poco"...

Sottolineiamo la DIFFERENZA fra STIMA CORRETTA e NON-VIZIATA (in inglese UNBIASED)

di cui vedremo a breve un esempio...

Per il VALOR MEDIO $M[X] = m_x$ assumiamo come STIMA la MEDIA ARITMETICA $\tilde{m} = \frac{1}{n}\sum_i X_i = \overline{X}$

- La CORRETTEZZA discende immediatamente dalla LEGGE dei GRANDI NUMERI (via disuguaglianza di Cebyscev, come mostrato...)
- Quanto al carattere NON-VIZIATO, è una conseguenza immediata della proprietà (ugualmente mostrata) che il VALOR MEDIO di una SOMMA è la SOMMA dei VALORI MEDI

$$M[\tilde{m} = \overline{X}] = M\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n} M\left[\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n} M[X_i] = \frac{1}{n}\sum_{i=1}^{n} m_x = \frac{1}{n} n m_x = m_x$$

NB Tutto questo è naturale ... La legge dei grandi numeri dice appunto che i valori medi vengono ricostruiti dalle medie aritmetiche sulle osservazioni dei fenomeni...

Per la VARIANZA $D[X] = M[(X - M[X])^2] = M[X^2] - (M[X])^2 = D_x$ assumiamo come STIMA $\tilde{D} = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \tilde{m})^2$

dove $\tilde{m} = \overline{X} = \frac{1}{n}\sum_i X_i$, come visto sopra...

Attenzione! Notare che NON prendiamo per STIMA della VARIANZA

$$D^* = \frac{1}{n}\sum_{i=1}^{n}(X_i - \tilde{m})^2$$

ENTRAMBE SONO CORRETTE (ancora una volta per la legge dei GRANDI NUMERI)

... e d'altronde $\frac{1}{n} \sim \frac{1}{n-1}$ per $n \to \infty$...

D^* è PERÒ <u>DISTORTA</u> in quanto

$$M[D^*] = M\left[\frac{1}{n}\sum_{i=1}^{n}(X_i-\hat{m})^2\right] = M\left[\frac{1}{n}\sum_{i=1}^{n}(X_i^2+\hat{m}^2-2X_i\hat{m})\right]$$

$$= M\left[\frac{1}{n}\sum_i X_i^2\right] + \underbrace{M\left[\frac{1}{n}\sum_{i=1}^{n}\hat{m}^2\right] - 2\hat{m}\,M\left[\frac{1}{n}\sum_{i=1}^{n}X_i\right]}_{\hat{m}^2-2\hat{m}^2}$$

ovvero

$$= M\left[\frac{1}{n}\sum_i X_i^2\right] - M\left[\frac{1}{n^2}\left(\sum_i X_i\right)^2\right] = M\left[\frac{1}{n}\sum_i X_i^2 - \frac{1}{n^2}\left(\sum_i X_i\right)^2\right]$$

$$M[D^*] = \frac{1}{n}\sum_i \underbrace{M[X_i^2]}_{a} - \frac{1}{n^2}M\Big[\underbrace{\sum_i X_i^2}_{b} + \sum_{i\neq j}X_iX_j\Big] = \underbrace{M[X^2]}_{a} - \frac{1}{n}M[X^2] - \frac{1}{n^2}\sum_{i\neq j}M[X_i]M[X_j]$$

dove la doppia somma è stata spezzata nel CONTRIBUTO con $i=j$ (n termini)
e in QUELLO con $i\neq j$ (i rimanenti (n^2-n)...)

Ora $M[X_iX_j]$ è il VALOR MEDIO di un PRODOTTO di variabili INDIPENDENTI,
e per questo vale il PRODOTTO dei VALORI MEDI, con $M[X_i]=M[X_j] = M[X]$

... e dunque...

il numero di contributi in $\sum_{i\neq j}$ ... è (n^2-n) ...

$$M[D^*] = M[X^2] - \frac{1}{n}M[X^2] - \frac{(n^2-n)}{n^2}(M[X])^2 \qquad \left(\text{dove } \sum_{i\neq j}M[X_i]M[X_j] = (n^2-n)(M[X])^2\right)$$

$$= \frac{n-1}{n}\left(M[X^2]-(M[X])^2\right) = \frac{n-1}{n}D_x$$

il che dimostra che D^* è <u>DISTORTA</u> mentre ci insegna anche che

$$M[\tilde{D}] = M\left[\frac{n}{n-1}D^*\right] = \frac{n}{n-1}M[D^*] = \frac{n}{n-1}\frac{n-1}{n}D_x = D_x$$ come vogliamo...!

Ripetiamo la <u>MORALE</u> • Per <u>$n\to\infty$</u> <u>SIA $\tilde{D}$ SIA D^* RICOSTRUISCONO IL RISULTATO CORRETTO</u>
(ovvero sono CORRETTE)

• mentre a <u>n FINITO</u> $\tilde{D}$ <u>in MEDIA</u> ci ritorna il RISULTATO CORRETTO
mentre D^* <u>in MEDIA</u> SBAGLIA (sottostima...)

E' da notare come la LEGGE dei GRANDI NUMERI ci aveva insegnato anche che

LA VARIANZA della MEDIA ARITMETICA $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$

VALE $D[\overline{X}] = \frac{D_x}{n}$

ovvero è uguale alla VARIANZA del FENOMENO DIVISA per n

Questo vuol dire che SAPPIAMO assegnare una VARIANZA alla NOSTRA STIMA

$D[\hat{m}] = \frac{D_x}{n}$ che però sarebbe "poco utile" se non sapessimo stimare D_x, ... cosa appena imparata

Alla fine, siamo dunque anche in grado di ASSEGNARE una VARIANZA alla STIMA $\tilde{m}$

pari a $\left\{ \frac{\tilde{D}}{n} \right\}$

NB Vedremo che il TEOREMA LIMITE CENTRALE ci farà dire di più in proposito...